

Numerische Optimierung und modellprädiktive Regelung

Prof. Dr.-Ing. Knut Graichen

Sommersemester 2026

Lehrstuhl für Regelungstechnik

Technische Fakultät

Friedrich-Alexander-Universität Erlangen-Nürnberg

“Cum enim mundi universi fabrica sit perfectissima atque a Creatore sapientissimo absoluta, nihil omnino in mundo contingit, in quo non maximi minimive ratio quaequam eluceat; quamobrem dubium prorsus est nullum, quin omnes mundi effectus ex causis finalibus ope methodi maximorum et minimorum aequè feliciter determinari queant, atque ex ipsis causis efficientibus.”

“Da nämlich der Bau der gesamten Welt höchst vollkommen und vom weisesten Schöpfer vollendet wurde, geschieht überhaupt nichts in der Welt, bei dem nicht das Verhältnis eines Maximums oder Minimums hervorleuchtet; deshalb gibt es durchaus keinen Zweifel, dass alle Wirkungen der Welt, die auf Finalursachen beruhen, mit Hilfe der Methode der Maxima und Minima gleich erfolgreich bestimmt werden können wie aus den bewirkten Ursachen selbst.”

Leonhard Euler, *Variationsrechnung*, 1744.

Inhaltsverzeichnis

1	Einleitung	1
1.1	Statische Optimierungsprobleme	1
1.1.1	Mathematische Formulierung	1
1.1.2	Beispiele	2
1.2	Dynamische Optimierungsprobleme	5
1.2.1	Mathematische Formulierung	6
1.2.2	Beispiele	6
1.3	Literatur	10
2	Grundlagen der Optimierung	11
2.1	Lokale/globale Minima und zulässige Menge	11
2.2	Gradient und Hesse-Matrix	13
2.3	Konvexität	14
2.3.1	Konvexe Mengen	15
2.3.2	Konvexe Funktionen	15
2.3.3	Konvexe Optimierungsprobleme	18
2.4	Literatur	19
3	Statische Optimierung ohne Beschränkungen	21
3.1	Notwendige Optimalitätsbedingungen	21
3.2	Hinreichende Optimalitätsbedingungen	22
3.3	Numerische Lösung mit Liniensuchverfahren	24
3.3.1	Bestimmung der Schrittweite	25
3.3.2	Gradientenverfahren	29
3.3.3	Konjugierte-Gradienten-Verfahren	31
3.3.4	Newton-Verfahren	32
3.3.5	Quasi-Newton-Verfahren	33
3.4	Weitere numerische Verfahren	35
3.4.1	Methode der Vertrauensbereiche	35
3.4.2	Direkte Suchverfahren	36
3.5	Beispiel: Rosenbrock's "Bananenfunktion"	38
3.6	Literatur	43

4	Statische Optimierung mit Beschränkungen	45
4.1	Einführende Beispiele	45
4.1.1	Eine Gleichungsbeschränkung	45
4.1.2	Eine Ungleichungsbeschränkung	46
4.1.3	Zwei Ungleichungsbeschränkungen	49
4.2	Optimalitätsbedingungen	50
4.2.1	Beschränkungsqualifikation	50
4.2.2	Optimalitätsbedingungen 1. Ordnung	51
4.2.3	Optimalitätsbedingungen 2. Ordnung	53
4.2.4	Interpretation der Lagrange-Multiplikatoren	54
4.3	Lineare Optimierung	56
4.3.1	Standardform-Darstellung	56
4.3.2	Optimalitätsbedingungen	57
4.3.3	Simplex-Algorithmus	57
4.3.4	Interior-Point-Verfahren	62
4.3.5	Beispiel: Transportnetz	65
4.4	Quadratische Optimierung	67
4.4.1	Optimalitätsbedingungen	67
4.4.2	Gleichungsbeschränkte quadratische Probleme	68
4.4.3	Aktive-Restriktionen-Verfahren	69
4.4.4	Weitere numerische Verfahren	72
4.5	Nichtlineare Optimierung	73
4.5.1	Sequentielle quadratische Programmierung	73
4.5.2	Weitere numerische Verfahren	78
4.6	Lagrange-Dualität	80
4.6.1	Duale Formulierung	80
4.6.2	Erweiterte Lagrange-Methode	86
4.6.3	Handhabung von Ungleichungsbeschränkungen	89
4.6.4	Anmerkungen	90
4.7	Software-Übersicht	91
4.8	Literatur	92
5	Dynamische Optimierung	95
5.1	Allgemeine Aufgabenstellung	95
5.2	Variationsrechnung	97
5.2.1	Grundlagen	97
5.2.2	Euler-Lagrange-Gleichung	101
5.2.3	Beispiel: Galileos hängende Kette	102
5.3	Unbeschränkte Optimalsteuerungsprobleme	104
5.3.1	Anwendung der Variationsrechnung	104
5.3.2	Optimalitätsbedingungen	107

5.3.3	Beispiel zur Betrachtung einer freien Endzeit	109
5.3.4	Allgemeine Vorgehensweise und singularer Fall	112
5.3.5	Interpretation der adjungierten Variablen	114
5.3.6	Erweiterung auf allgemeine Randbedingungen	116
5.4	Optimierung linearer Systeme mit quadratischem Kostenfunktional	117
5.4.1	Riccati-Differenzialgleichung	117
5.4.2	Beispiel: 2FHG-Regelung zum Aufschwingen des Einfachpendels	118
5.4.3	Algebraische Riccati-Gleichung (Sonderfall $t_f \rightarrow \infty$)	123
5.5	Optimalsteuerungsprobleme mit Eingangsbeschränkungen	124
5.5.1	Pontryagin's Maximumprinzip	124
5.5.2	Allgemeine Vorgehensweise	127
5.5.3	Minimierung der Hamilton-Funktion	127
5.5.4	Beispiel: Doppelintegrator	130
5.5.5	Zustandsabhängige Eingangsbeschränkungen	133
5.6	Numerische Lösung der Optimalitätsbedingungen (indirekte Methoden)	134
5.6.1	Diskretisierungsverfahren	134
5.6.2	Schießverfahren	136
5.6.3	Berücksichtigung allgemeiner Endbedingungen und freier Endzeit	137
5.6.4	Gradientenverfahren	138
5.7	Reduktion auf statische Optimierungsprobleme (direkte Methoden)	140
5.7.1	Teildiskretisierung	141
5.7.2	Volldiskretisierung	142
5.8	Software-Übersicht	143
5.9	Literatur	144
6	Modellprädiktive Regelung (MPC)	145
6.1	Grundprinzip der modellprädiktiven Regelung	145
6.1.1	Dynamische Optimierung auf bewegtem Horizont	145
6.1.2	Zeitkontinuierliche vs. zeitdiskrete MPC-Darstellung	147
6.2	MPC-Formulierungen	148
6.2.1	Unendlicher Horizont	148
6.2.2	Endlicher Horizont und Endbeschränkungen	150
6.2.3	Endlicher Horizont und Endregion	151
6.2.4	Endlicher Horizont und Endkostengewichtung	153
6.2.5	Hinreichend langer Horizont	156
6.3	Echtzeitfähige Implementierung	160
6.3.1	Suboptimale Lösungsstrategie	160
6.3.2	Stabilität und inkrementelle Verbesserung	161
6.3.3	Anwendungsbeispiel	163
6.4	Software-Übersicht	167
6.5	Literatur	167

1 Einleitung

Unter dem Begriff der Optimierung wird im Allgemeinen das Suchen einer (in einem gewissen Sinne) optimalen Lösung zu einem Problem verstanden. Das Feld der Optimierung ist in vielen Feldern von Industrie und Wirtschaft vertreten. Einige Beispiele sind

- Wirtschaft und Finanzen: z.B. Portfolio-Optimierung oder Unternehmensentwicklung (Maximierung des Gewinns durch optimale Verteilung von Investitionen, Ausgaben, Anlagen, etc.).
- Prozess- und Produktoptimierung: z.B. Ablaufplanung von Prozessen, Minimierung von Herstellungskosten, energieeffizienter Betrieb.
- Regelungstechnik allgemein: z.B. Berechnung optimaler Bahnen in der Robotik, Entwurf optimaler Steuerungen und Regelungen, Parameterschätzung, optimale Reglerauslegung.

Die mathematische Formulierung dieser Probleme führt auf ein Optimierungsproblem. Generell wird dabei zwischen *statischen* und *dynamischen Optimierungsproblemen* unterschieden, deren Unterschied im Folgenden erläutert werden soll.

- *Statisches Optimierungsproblem*: Minimierung einer Funktion mit Optimierungsvariablen, die Elemente des Euklidischen Raumes sind.
- *Dynamisches Optimierungsproblem*: Minimierung eines Funktionals, bei dem die Optimierungsvariablen Elemente des Hilbert-Raumes sind (z.B. Zeitfunktionen).

In diesem Kapitel soll zunächst an einigen Beispielen ein Eindruck sowie der prinzipielle Unterschied zwischen der statischen und dynamischen Optimierung vermittelt werden.

1.1 Statische Optimierungsprobleme

Unter einem *statischen Optimierungsproblem* wird das Minimieren einer Funktion $f(\mathbf{x})$ unter Berücksichtigung gewisser Nebenbedingungen verstanden, bei dem die Optimierungsvariablen Elemente $\mathbf{x}$ des Euklidischen Raumes $\mathbb{R}^n$ sind.

1.1.1 Mathematische Formulierung

Die Standardformulierung eines statischen Optimierungsproblems wird wie folgt angegeben:

$$\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) \quad \text{Kostenfunktion} \quad (1.1)$$

$$\text{u.B.v. } g_i(\mathbf{x}) = 0, \quad i = 1, \dots, p \quad \text{Gleichungsbeschränkungen} \quad (1.2)$$

$$h_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, q \quad \text{Ungleichungsbeschränkungen} \quad (1.3)$$

Ist ein Optimierungsproblem ohne die Ungleichungs- und Gleichungsbeschränkungen (1.3), (1.2) gegeben, spricht man von einem *unbeschränkten Optimierungsproblem*. Im allgemeinen Fall, d.h. unter Berücksichtigung der Nebenbedingungen (1.2)-(1.3), handelt es sich um ein *beschränktes Optimierungsproblem*.

Im Laufe der Jahrzehnte hat sich die Formulierung als Minimierungsproblem (1.1) standardisiert. Analog dazu kann ein Maximierungsproblem ebenfalls in der Notation (1.1) geschrieben werden:

$$\max_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) = \min_{\mathbf{x} \in \mathbb{R}^n} -f(\mathbf{x}).$$

Neben der Bezeichnung statische Optimierung werden auch die Begriffe *Mathematische Programmierung* oder *Endlich-Dimensionale Optimierung* verwendet.

Die Bezeichnung "Programmierung" ist historisch begründet. Die ersten Anwendungen der Optimierung waren militärischer Natur, bei denen es um Aktionspläne ging:

"It is a word used by the military for a plan, a schedule, or in general for a program of actions. This is exactly what it means for computers: a program of actions for the computer to execute."

George Danzig

Begründer der Linearen Programmierung

Unterschieden werden bei statischen Optimierungsproblemen häufig folgende Klassen:

- *Lineare Programmierung*: Die Kostenfunktion und Beschränkungen sind linear.
- *Quadratische Programmierung*: Die Kostenfunktion ist quadratisch, während die Beschränkungen linear sind.
- *Nichtlineare Programmierung*: Die Kostenfunktion oder mindestens eine Beschränkung ist nichtlinear.
- *Integer-Programmierung*: Alle Variablen sind diskret.
- *Mixed-Integer-Programmierung*: Kontinuierliche und diskrete Variablen treten auf.

1.1.2 Beispiele

Insbesondere die *lineare Programmierung* wird häufig bei wirtschaftlichen Fragestellungen, wie Produktions-, Planungs- oder Investitionsproblemen, eingesetzt. Das folgende Beispiel ist ein stark vereinfachtes Beispiel einer Portfolio-Optimierung.

Beispiel 1.1 (Portfolio-Optimierung) Ein Anleger möchte 10.000 Euro gewinnbringend investieren und hat die Auswahl zwischen drei Aktienfonds mit unterschiedlicher Gewinnerwartungen und Risikoeinstufung:

Fonds	erwarteter Gewinn/Jahr	Risikoeinstufung
Fonds A	10%	4
Fonds B	7%	2
Fonds C	4%	1

Der Anleger möchte nach einem Jahr mindestens 600 Euro Gewinn erzielen. Andererseits möchte er sein Geld eher konservativ anlegen, d.h. er möchte mindestens 4.000 Euro in Fonds C investieren und das Risiko minimieren. Wie muss der Anleger die 10.000 Euro verteilen, damit diese Kriterien erfüllt werden?

Zunächst werden die Optimierungsvariablen x_1, x_2, x_3 eingeführt, die den prozentualen Anteil der investierten 10.000 Euro an den jeweiligen Fonds A, B, C kennzeichnen. Dabei kann x_3 durch die Beziehung

$$x_3 = 1 - x_1 - x_2$$

ersetzt werden. Der geforderte Mindestgewinn von 600 Euro lässt sich als die Beschränkung

$$10.000[0.1x_1 + 0.07x_2 + 0.04(1 - x_1 - x_2)] \geq 600 \Rightarrow 6x_1 + 3x_2 \geq 2 \quad (1.4)$$

ausdrücken. Die Mindestanlage von 4.000 Euro in Fonds C führt zu

$$10.000(1 - x_1 - x_2) \geq 4.000 \Rightarrow x_1 + x_2 \leq 0.6 \quad (1.5)$$

Des Weiteren muss $x_1, x_2, x_3 \geq 0$ gelten. Das Ziel ist die Minimierung des Anlagerisikos, was sich durch die Funktion

$$f(\mathbf{x}) = 4x_1 + 2x_2 + (1 - x_1 - x_2) = 1 + 3x_1 + x_2 \quad (1.6)$$

ausdrücken lässt. Somit kann das statische Optimierungsproblem in der Form

$$\min_{\mathbf{x} \in \mathbb{R}^2} f(\mathbf{x}) = 1 + 3x_1 + x_2 \quad (1.7a)$$

$$\text{u.B.v. } 6x_1 + 3x_2 \geq 2 \quad (1.7b)$$

$$x_1 + x_2 \leq 0.6 \quad (1.7c)$$

$$x_1 + x_2 \leq 1 \quad (1.7d)$$

$$x_1, x_2 \geq 0 \quad (1.7e)$$

geschrieben werden. Abbildung 1.1 stellt die einzelnen Beschränkungen sowie den zulässigen Bereich grafisch dar. Aus dem Verlauf der Höhenlinien $f(\mathbf{x}) = \text{konst.}$ der Kostenfunktion (1.7a) ist direkt ersichtlich, dass der Punkt $\mathbf{x}^*$ des zulässigen Bereiches mit dem niedrigsten Wert von $f(\mathbf{x})$ an der Ecke $\mathbf{x}^*$ liegt. Somit ergibt sich für die optimale Verteilung der 10.000 Euro auf die einzelnen Fonds

$$x_1^* = \frac{1}{15}, \quad x_2^* = \frac{8}{15}, \quad x_3^* = \frac{6}{15}. \quad (1.8)$$

Das folgende (akademische) Beispiel der quadratischen Programmierung soll den Einfluss von Beschränkungen auf eine optimale Lösung verdeutlichen.

Beispiel 1.2 Betrachtet wird das (zunächst) unbeschränkte Problem

$$\min_{\mathbf{x} \in \mathbb{R}^2} f(\mathbf{x}) = (x_1 - 2)^2 + (x_2 - 1)^2. \quad (1.9)$$

Die Höhenlinien $f(\mathbf{x}) = \text{konst.}$ der Funktion $f(\mathbf{x})$ sind in Abbildung 1.2 in Abhängigkeit der beiden Optimierungsvariablen $\mathbf{x} = [x_1, x_2]^T$ dargestellt. Es ist direkt ersichtlich, dass das Minimum $f(\mathbf{x}^*) = 0$ an der Stelle $\mathbf{x}^* = [2, 1]^T$ auftritt.




Abbildung 1.1: Veranschaulichung der Portfolio-Optimierung in Beispiel 1.1.

Um den Einfluss verschiedener Beschränkungen zu untersuchen, wird zunächst eine zusätzliche Gleichungsbeschränkung der Form (1.2) betrachtet:

$$g(\mathbf{x}) = x_2 - 2x_1 = 0. \quad (1.10)$$

Die Gleichungsbeschränkung entspricht einer algebraischen Zwangsbedingung, wodurch lediglich noch eine Optimierungsvariable frei wählbar ist. Geometrisch interpretiert bedeutet dies, dass eine mögliche Lösung auf der Geraden liegen muss, die durch (1.10) definiert wird, siehe Abbildung 1.3. Die optimale Lösung liegt dabei auf dem Berührungspunkt der Geraden $g(\mathbf{x}) = 0$ mit der Höhenlinie $f(\mathbf{x}) = 1.8$.

Anstelle der Gleichungsbeschränkung (1.10) wird nun die Ungleichungsbeschränkung

$$h_1(\mathbf{x}) = x_1 + x_2 - 2 \leq 0 \quad (1.11)$$

betrachtet, wodurch sich die Menge der zulässigen Punkte $\mathbf{x} = [x_1, x_2]^T$ auf die Region unterhalb der Geraden $h_1(\mathbf{x}) = 0$ beschränkt (Abbildung 1.4). Das Optimum $f(\mathbf{x}^*) = 0.5$ an der Stelle $\mathbf{x}^* = [1.5, 0.5]^T$ befindet sich an der Grenze des zulässigen Bereiches und liegt, wie im vorherigen Szenario, auf einer Höhenlinie, die die Gerade $h_1(\mathbf{x}) = 0$ tangential berührt.

Zusätzlich zur ersten Ungleichungsbeschränkung (1.11) soll eine weitere Ungleichung der Form

$$h_2(\mathbf{x}) = x_1^2 - x_2 \leq 0, \quad (1.12)$$

betrachtet werden, durch die sich die Menge der zulässigen Punkte weiter verkleinert (Abbildung 1.5). Der optimale Punkt $\mathbf{x} = [1, 1]^T$ mit dem Minimum $f(\mathbf{x}^*) = 1$ liegt nun im Schnittpunkt der Kurven $h_1(\mathbf{x}) = 0$ und $h_2(\mathbf{x}) = 0$, d.h. beide Beschränkungen (1.11) und (1.12) sind aktiv.

Das obige Beispiel 1.2 verdeutlicht den Einfluss von Gleichungs- und Ungleichungsbeschränkungen auf die Lösung (und Lösbarkeit) des Optimierungsproblems (1.1)-(1.3). Für eine systematische Untersuchung von statischen OP sowie Verfahren zur numerischen Lösung von statischen OP sei auf die hinteren Kapitel verwiesen.




Abbildung 1.2: Geometrische Darstellung des unbeschränkten OP (1.9).




Abbildung 1.3: Geometrische Darstellung des beschränkten OP (1.9), (1.10).




Abbildung 1.4: Geometrische Darstellung des beschränkten OP (1.9), (1.11).




Abbildung 1.5: Geometrische Darstellung des beschränkten OP (1.9), (1.11), (1.12).

1.2 Dynamische Optimierungsprobleme

Bei den Problemstellungen der statischen Optimierung im vorherigen Abschnitt 1.1 stellen die Optimierungsvariablen $\mathbf{x}$ Elemente aus dem Euklidischen Raum $\mathbb{R}^n$ dar. Bei der dynamischen Optimierung handelt es sich darum, Funktionen einer unabhängigen Variablen zu bestimmen. Da es sich bei der unabhängigen Variablen meistens um die Zeit t handelt, wird in diesem Zusammenhang von *dynamischer Optimierung* gesprochen.

1.2.1 Mathematische Formulierung

Die generelle Struktur eines dynamischen Optimierungsproblems lautet

$$\min_{\mathbf{u}(\cdot)} \quad J(\mathbf{u}) = V(\mathbf{x}(t_f), t_f) + \int_{t_0}^{t_f} l(\mathbf{x}(t), \mathbf{u}(t), t) dt \quad \text{Kostenfunktional} \quad (1.13a)$$

$$\text{u.B.v.} \quad \dot{\mathbf{x}} = \mathbf{f}(\mathbf{x}, \mathbf{u}, t), \quad \mathbf{x}(t_0) = \mathbf{x}_0 \quad \text{Systemdynamik \& AB} \quad (1.13b)$$

$$\mathbf{g}(\mathbf{x}(t_f), t_f) = \mathbf{0} \quad \text{Endbedingungen (EB)} \quad (1.13c)$$

$$h_i(\mathbf{x}, \mathbf{u}) \leq 0, \quad i = 1, \dots, q \quad \text{Ungleichungsbeschr.} \quad (1.13d)$$

Dabei stellt $\mathbf{u} \in \mathbb{R}^m$ die Eingangsgröße des nichtlinearen Systems (1.13b) mit dem Zustand $\mathbf{x} \in \mathbb{R}^n$ dar. Zusätzlich zu den Anfangsbedingungen in (1.13b) sind häufig Endbedingungen der Form (1.13c) gegeben, um z.B. einen gewünschten Zustand $\mathbf{x}_f$ zur Endzeit t_f zu erreichen (also $\mathbf{g}(\mathbf{x}(t_f), t_f) = \mathbf{x}(t_f) - \mathbf{x}_f$). Ein häufiges Problem in der Praxis ist das Auftreten von Ungleichungsbeschränkungen (1.13d), die z.B. die Begrenzung einer Stellgröße oder Sicherheitsschranken eines Zustandes darstellen können.

Die Problemstellung der dynamischen Optimierung besteht nun darin, eine Eingangstrajektorie $\mathbf{u}(t)$, $t \in [t_0, t_f]$ derart zu finden, dass die Zustandstrajektorie $\mathbf{x}(t)$, $t \in [t_0, t_f]$ des dynamischen Systems (1.13b), die Endbedingungen (1.13c) und Beschränkungen (1.13d) erfüllt und gleichzeitig das Kostenfunktional (1.13a) minimiert wird. Abhängig davon, ob t_f vorgegeben oder unbekannt ist, spricht man von einer *festen* oder *freien Endzeit* t_f .

Neben der Bezeichnung dynamische Optimierung werden auch die Begriffe *Unendlich-Dimensionale Optimierung*, *Optimalsteuerung* oder *Dynamische Programmierung* verwendet. Im Folgenden sind einige Beispiele angegeben, um die Problem- und Aufgabenstellung der dynamischen Optimierung zu erläutern.

1.2.2 Beispiele

Beispiel 1.3 (Inverses Pendel) Ein klassisches Problem in der Regelungstechnik ist das inverse Pendel, das an einem Wagen drehbar befestigt ist. Als Beispielproblem soll das seitliche Versetzen des Pendels betrachtet werden:

$$\min_{\mathbf{u}(\cdot)} \quad J(u) = \int_0^{t_f} 1 + c u^2 dt, \quad (1.14a)$$

$$\text{u.B.v.} \quad \begin{bmatrix} 1 & \varepsilon \cos \theta \\ \cos \theta & 1 \end{bmatrix} \begin{bmatrix} \ddot{x} \\ \ddot{\theta} \end{bmatrix} = \begin{bmatrix} \varepsilon \dot{\theta}^2 \sin \theta + u \\ -\sin \theta \end{bmatrix}, \quad \varepsilon = m/(M + m) \quad (1.14b)$$

$$\mathbf{x}(0) = [0, 0, 0, 0]^T, \quad \mathbf{x}(t_f) = [1, 0, 0, 0]^T, \quad (1.14c)$$

$$-1 \leq u \leq 1. \quad (1.14d)$$

Die vereinfachten Bewegungsgleichungen (1.14b) für die Zustände $\mathbf{x} = [x, \dot{x}, \theta, \dot{\theta}]^T$ sind normiert. Der Eingang u stellt die am Wagen angreifende (normierte) Kraft dar und ist durch (1.14d) beschränkt. Abbildung 1.6 zeigt exemplarisch das seitliche Versetzen des Pendels, um die Bewegung zu verdeutlichen.




Abbildung 1.6: Momentaufnahmen für das Versetzen des inversen Pendels.

Das Kostenfunktional (1.14a) und somit der Charakter des Optimierungsproblems hängt von dem Parameter c ab. Für $c = 0$ ergibt sich die Aufgabe, die Endzeit t_f zu minimieren:

$$J(u) = \int_0^{t_f} 1 \, dt = t_f. \quad (1.15)$$

Für $c > 0$ wird der Eingang u im Kostenfunktional und somit der Aspekt der Energieoptimalität mit berücksichtigt.

Abbildung 1.7 zeigt die optimalen Trajektorien für die Werte $c = 0$, $c = 0.25$ und $c = 1$. Für $c = 0$ weist der Eingang u ein Bang-bang-Verhalten auf, während für $c > 0$ die Steueramplituden kleiner werden und die Versatzzeit t_f zunimmt.




Abbildung 1.7: Optimale Trajektorien für das Versetzen des inversen Pendels.

Das inverse Pendel ist ein gutes Beispiel um zu verdeutlichen, dass nicht zu jedem Optimierungsproblem eine Lösung existiert, insbesondere wenn die Endzeit t_f nicht festgelegt ist. Wie in Abbildung 1.7 dargestellt ist, vergrößert sich die Endzeit t_f bei zunehmender Gewichtung von u^2 im Vergleich zum zeitoptimalen Anteil in dem Kostenfunktional (1.14a). Wenn reine Energieoptimalität gefordert würde, d.h.

$$J(u) = \int_0^{t_f} u^2 dt, \quad (1.16)$$

hätte das Optimierungsproblem keine Lösung, da das Versetzen des Pendels dann unendlich langsam mit $t_f \rightarrow \infty$ ablaufen würde.

Beispiel 1.4 (Goddard-Rakete [2, 1]) Ein klassisches Optimierungsproblem aus der Raumfahrt ist die Maximierung der Flughöhe einer Rakete unter dem Einfluss von Luftreibung und Erdbeschleunigung. Dieses Problem wurde von dem amerikanischen Raketenpionier Robert H. Goddard im Jahr 1919 aufgestellt und kann wie folgt (normiert) geschrieben werden:

$$\min_{u(\cdot)} -h(t_f) \quad (1.17)$$

$$\text{u.B.v.} \quad \dot{h} = v, \quad \dot{v} = \frac{u - D(h, v)}{m} - \frac{1}{h^2}, \quad \dot{m} = -\frac{u}{c}, \quad (1.18)$$

$$h(0) = 1, \quad v(0) = 0, \quad m(0) = 1, \quad m(t_f) = 0.6, \quad (1.19)$$

$$0 \leq u \leq 3.5. \quad (1.20)$$

Die Zustandsgrößen sind die Flughöhe h , die Geschwindigkeit v und die Masse m der Rakete. Die Luftreibung $D(h, v)$ hängt über die Funktion

$$D(h, v) = D_0 v^2 \exp[\beta(1 - h)] \quad (1.21)$$

von den Zuständen h und v ab. Die Randbedingungen in (1.19) umfassen die normierten Anfangsbedingungen sowie die Endbedingung für $m(t_f)$, die dem Leergewicht der Rakete ohne Treibstoff entspricht. Der Eingang des Systems ist der Schub u , der innerhalb der Beschränkungen (1.20) liegen muss.

Abbildung 1.8 stellt die optimalen Trajektorien für die Goddard-Rakete im Vergleich zum Flug mit maximalen Schub dar.¹ Bei den optimalen Trajektorien ist der Schub $u(t)$ am Anfang ebenfalls maximal, weist dann aber einen parabelförmigen Verlauf auf, bevor der Treibstoff verbraucht ist. Dieses Verhalten wird durch den Luftwiderstand $D(h, v)$ hervorgerufen, der mit zunehmender Höhe abnimmt. Es ist somit "optimaler", im Falle eines hohen Luftwiderstandes anfänglich nicht mit vollem Schub zu fliegen. Verglichen mit dem Flug mit maximalem Schub bis der Treibstoff verbraucht ist ergibt sich eine um ca. 2,7% verbesserte Flughöhe, vgl. Abbildung 1.8.

Beispiel 1.5 (Ökonomisches Modell [4, 3]) Ein weiterer Anwendungszweig der dynamischen Optimierung sind wirtschaftliche Prozesse. Das folgende Beispiel beschreibt das Verhalten eines typischen Konsumenten, der Konsum, Freizeit und Bildung über die Lebensdauer

¹ Die verwendeten Parameterwerte sind $c = 0.5$, $D_0 = 310$, $\beta = 500$.




Abbildung 1.8: Optimale Trajektorien für die Goddard-Rakete in Beispiel 1.4.

maximieren will. Der Bildungsgrad B und das Kapital K eines durchschnittlichen Konsumenten lassen sich durch folgendes Modell beschreiben:

$$\dot{B} = \overbrace{B^\epsilon u_2 u_3}^{\text{Weiterbildung}} - \overbrace{\delta B}^{\text{Vergessen}}, \quad B(0) = B_0 \quad (1.22)$$

$$\dot{K} = \underbrace{iK}_{\text{Verzinsung}} + \underbrace{B u_2 g(u_3)}_{\text{Einkommen}} - \underbrace{u_1}_{\text{Konsum}}, \quad K(0) = K_0 \quad (1.23)$$

Die Eingangsgrößen sind der Konsum u_1 , der Anteil der Arbeitszeit an der Gesamtzeit u_2 sowie der Anteil der Fortbildungszeit an der Arbeitszeit u_3 . Die Eingänge unterliegen den Beschränkungen

$$u_1 > 0, \quad 0 \leq u_2 \leq 1, \quad 0 \leq u_3 < 1. \quad (1.24)$$

Das Optimierungsziel des Konsumenten ist die Maximierung von Konsum, Freizeit und Bildung über die Lebensdauer von $t_f = 75$ Jahren, was in dem folgenden (zu minimierenden) Kostenfunktional ausgedrückt ist:

$$J(\mathbf{u}) = -K^\kappa(t_f) - \int_{t_0}^{t_f} U(t, u_1, u_2, B) e^{-\rho t} dt. \quad (1.25)$$

Der Integralanteil

$$U(t, u_1, u_2, B) = \alpha_0 u_1^\alpha + \beta_0 (1 - u_2)^\beta + \gamma_0 t B^\gamma \quad (1.26)$$

gewichtet dabei den Konsum u_1 , die Freizeit $1 - u_2$ und den Bildungsgrad B , während der Endwert $-K^\kappa(t_f)$ in (1.25) zusätzlich das Vererbungskapital berücksichtigt.

Die optimalen Zeitverläufe des Bildungsgrades $B(t)$ und des Kapitals $K(t)$ sind in Abbildung 1.9 dargestellt.² Die ersten 17 Jahren stellen die Lernphase dar (d.h. $u_3 = 1$). Daraufhin




Abbildung 1.9: Optimale Trajektorien für das Konsumentenverhalten in Beispiel 1.5.

folgt eine lange Arbeitsphase von 34 Jahren mit einem hohen Maß an Weiterbildung, bevor in den nächsten 10 Jahren (52.-61. Lebensjahr) eine reine Arbeitsphase mit zusätzlich reduzierter Arbeitszeit u_2 stattfindet. Ab dem 62. Lebensjahr setzt der Ruhestand ein. Der Bildungsgrad B ist besonders hoch im Alter von 30-60 Jahren. Das Kapital K ist negativ während der ersten Lebenshälfte, was der Aufnahme eines Kredites entspricht. Im Laufe des Lebens wird dies aber durch das steigende Einkommen kompensiert.

1.3 Literatur

- [1] A.E. Bryson. *Dynamic Optimization*. Menlo Park, CA: Addison-Wesley, 1999.
- [2] R.H. Goddard. "A method for reaching extreme altitudes". In: *Smithsonian Miscellaneous Collections* 71 (1919).
- [3] H.J. Oberle und R. Rosendahl. "Numerical computation of a singular-state subarc in an economic optimal control model". In: *Optimal Control Applications and Methods* 27 (2006), S. 211–235.
- [4] K. Pohmer. *Mikroökonomische Theorie der personellen Einkommens- und Vermögensverteilung*. Studies in Contemporary Economics. Bd. 16. Springer, 1985.

² Die verwendeten Parameterwerte sind $\alpha = -1$, $\alpha_0 = -1$, $\beta = -0.5$, $\beta_0 = -1$, $\gamma = 0.2$, $\gamma_0 = 5$, $\kappa = 0.2$, $\rho = 0.01$, $\varepsilon = 0.35$, $\delta = 0.01$, $i = 0.04$, $H_0 = 1$, $K_0 = 30$. Die Funktion $g(u_3)$ in (1.23) ist durch die Parabel $g(u_3) = 1 - (1 - a)u_3 - au_3^2$ gegeben.

2 Grundlagen der Optimierung

In diesem Kapitel werden zunächst einige Begriffe und Eigenschaften statischer Optimierungsprobleme

$$\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) \quad (2.1)$$

$$\text{u.B.v. } g_i(\mathbf{x}) = 0, \quad i = 1, \dots, p \quad (2.2)$$

$$h_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, q \quad (2.3)$$

betrachtet, auf die in den folgenden Kapiteln Bezug genommen wird.

2.1 Lokale/globale Minima und zulässige Menge

Definition 2.1 (Globale und lokale Minima) Die Funktion $f(\mathbf{x})$ mit $f : \mathcal{X} \rightarrow \mathbb{R}$ und $\mathcal{X} \subseteq \mathbb{R}^n$ besitzt an der Stelle $\mathbf{x}^* \in \mathcal{X}$

- a) ein lokales Minimum, falls $f(\mathbf{x}^*) \leq f(\mathbf{x})$ für alle $\mathbf{x}$ in einer hinreichend kleinen Umgebung von $\mathbf{x}^*$,
- b) ein striktes lokales Minimum, falls $f(\mathbf{x}^*) < f(\mathbf{x})$ für alle $\mathbf{x}$ in einer hinreichend kleinen Umgebung von $\mathbf{x}^*$,
- c) ein globales (absolutes) Minimum, falls $f(\mathbf{x}^*) \leq f(\mathbf{x})$ für alle $\mathbf{x} \in \mathcal{X}$,
- c) ein eindeutiges globales Minimum, falls $f(\mathbf{x}^*) < f(\mathbf{x})$ für alle $\mathbf{x} \in \mathcal{X}$.

Aus der Definition ergibt sich, dass ein globales Minimum stets auch ein lokales Minimum ist. Die unterschiedlichen Arten von Minima sind in Abbildung 2.1 skizziert.

Definition 2.2 (Zulässige Menge) Die zulässige Menge $\mathcal{X}_{ad}$ (Englisch: admissible set) des Optimierungsproblems (2.1)-(2.3) ist

$$\mathcal{X}_{ad} = \left\{ \mathbf{x} \in \mathbb{R}^n : \begin{array}{l} g_i(\mathbf{x}) = 0, \quad i = 1, \dots, p \\ h_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, q \end{array} \right\}. \quad (2.4)$$

Alle Punkte $\mathbf{x} \in \mathcal{X}_{ad}$ werden als *zulässige Punkte* bezeichnet und erfüllen die Nebenbedingungen $g_i(\mathbf{x}) = 0$ und $h_i(\mathbf{x}) \leq 0$. Somit lässt sich das statische OP (2.1)-(2.3) auch in der äquivalenten Form

$$\min_{\mathbf{x} \in \mathcal{X}_{ad}} f(\mathbf{x}) \quad (2.5)$$

angeben. Im Falle von unbeschränkten Problemen gilt $\mathcal{X}_{ad} = \mathbb{R}^n$.




Abbildung 2.1: Verschiedene Minima einer Funktion $f(x)$ mit $x \in \mathbb{R}$.

Beispiel 2.1 Im eingangs erwähnten Beispiel 1.2 mit den beiden Ungleichungsbeschränkungen (1.11) und (1.12) ist der zulässige Bereich durch

$$\mathcal{X}_{ad} = \{ \mathbf{x} \in \mathbb{R}^n : h_1(\mathbf{x}) = x_1 + x_2 - 2 \leq 0, \quad h_2(\mathbf{x}) = x_1^2 - x_2 \leq 0 \}$$

definiert. Dies entspricht der zwischen der Geraden $h_1(\mathbf{x}) = 0$ und der Parabel $h_2(\mathbf{x}) = 0$ eingeschlossenen Fläche, siehe Abbildung 1.5.

Es ist direkt ersichtlich, dass $\mathcal{X}_{ad}$ nicht die leere Menge sein darf, da das Optimierungsproblem (2.5) ansonsten keine Lösung besitzt. Eine weitere notwendige Bedingung für $\mathcal{X}_{ad}$ kann aus den Gleichungsbedingungen (2.2) abgeleitet werden, da sich durch die algebraischen Restriktionen $g_i(\mathbf{x}) = 0$ die Anzahl der freien Optimierungsvariablen $\mathbf{x} \in \mathbb{R}^n$ reduziert. Somit darf die Anzahl p der (unabhängigen) Gleichungsbedingungen (2.2) nicht größer als die Anzahl der Optimierungsvariablen $\mathbf{x} \in \mathbb{R}^n$ sein, da die zulässige Menge $\mathcal{X}_{ad}$ ansonsten leer wäre.

Satz 2.1 (Weierstrass) Sei $f : \mathcal{X}_{ad} \rightarrow \mathbb{R}$ stetig und $\mathcal{X}_{ad}$ eine kompakte nichtleere Menge. Dann besitzt das Problem

$$\min_{\mathbf{x} \in \mathcal{X}_{ad}} f(\mathbf{x}) \quad (2.6)$$

an mindestens einem Punkt $\mathbf{x}^* \in \mathcal{X}_{ad}$ ein Minimum.

Beispiel 2.2 Betrachtet wird das beschränkte Optimierungsproblem aus Beispiel 1.2 bzw. Abbildung 1.5:

$$\min_{\mathbf{x} \in \mathbb{R}^2} (x_1 - 2)^2 + (x_2 - 1)^2 \quad (2.7)$$

$$\text{u.B.v. } x_1 + x_2 - 2 \leq 0 \quad (2.8)$$

$$x_1^2 - x_2 \leq 0 \quad (2.9)$$

Die Kostenfunktion ist stetig und die zulässige Menge $\mathcal{X}_{ad}$ ist nicht-leer und kompakt. Somit folgt aus Satz 2.1 die Existenz einer Lösung $\mathbf{x}^*$.

Der Satz von Weierstrass gilt nicht für Probleme, die auf einer offenen, nicht kompakten Menge definiert sind (z.B. $\mathcal{X}_{ad} = \mathbb{R}^n$). Ein Beispiel ist

$$\min_{x \in (0, \infty)} \frac{1}{x}. \quad (2.10)$$




Abbildung 2.2: Maximale Abstiegsrichtung $-\nabla f(\mathbf{x})$ für eine Funktion $f(\mathbf{x})$ mit $\mathbf{x} \in \mathbb{R}^2$.

Obwohl $f(x) = 1/x$ auf dem offenen Intervall $x \in (0, \infty)$ stetig ist, existiert kein Minimum. Allerdings kann die Existenz einer Lösung eines unbeschränkten Optimierungsproblems garantiert werden, wenn die Funktion $f(\mathbf{x})$ die Bedingung $\lim_{\|\mathbf{x}\| \rightarrow \infty} f(\mathbf{x}) = \infty$ erfüllt.

2.2 Gradient und Hesse-Matrix

Die Berechnung von Ableitungen erster und zweiter Ordnung einer Kostenfunktion $f(\mathbf{x})$ ist von fundamentaler Bedeutung in der Optimierung. Da im Falle von unstetigen Funktionen oder unstetigen Ableitungen häufig Probleme auftreten (sowohl numerischer als auch theoretischer Natur), wird oft angenommen, dass alle Funktionen eines Optimierungsproblems stetig und hinreichend oft differenzierbar sind.

Definition 2.3 (Gradient) Sei $f : \mathcal{X} \rightarrow \mathbb{R}$ stetig differenzierbar. Dann bezeichnet

$$\nabla f(\mathbf{x}) = \left(\frac{\partial f}{\partial \mathbf{x}} \right)^T = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{bmatrix} \quad (2.11)$$

den Gradienten (also die 1. partielle Ableitung) von $f(\mathbf{x})$ an der Stelle $\mathbf{x} = [x_1, \dots, x_n]^T$.

Der negative Gradient ist von besonderer Bedeutung zur Lösung eines Optimierungsproblems, da er die sogenannte *maximale Abstiegsrichtung* einer Kostenfunktion $f(\mathbf{x})$ an der Stelle $\mathbf{x}$ angibt, siehe Abbildung 2.2. Diese Eigenschaft wird im nächsten Kapitel näher untersucht.

Definition 2.4 (Hesse-Matrix) Sei $f : \mathcal{X} \rightarrow \mathbb{R}$ zweimal stetig differenzierbar. Dann bezeichnet

$$\nabla^2 f(\mathbf{x}) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \vdots & & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix} \quad (2.12)$$

die Hesse-Matrix (also die 2. partielle Ableitung) von $f(\mathbf{x})$ an der Stelle $\mathbf{x} = [x_1, \dots, x_n]^T$.

Im Falle von ein-dimensionalen Funktionen $f(x)$ wird die ∇ -Notation normalerweise durch $f'(x)$ und $f''(x)$ ersetzt. Nach dem Satz von Schwarz folgt aus der Stetigkeit der 2. partiellen Ableitungen Kommutativität, d.h.

$$\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i}.$$

Somit ist die Hesse-Matrix symmetrisch ($\nabla^2 f(\mathbf{x}) = \nabla^2 f(\mathbf{x})^\top$) und hat stets reelle Eigenwerte. In der Optimierung ist oft von Bedeutung, ob Hesse-Matrizen positiv (semi-)definit sind. Diese Eigenschaft kann wie folgt untersucht werden:

Satz 2.2 (Definitheit) Die Definitheit einer symmetrischen Matrix $\mathbf{A} \in \mathbb{R}^{n \times n}$ lässt sich durch folgende Bedingungen charakterisieren:

Matrix $\mathbf{A}$ ist	(1): für alle $\mathbf{p} \in \mathbb{R}^n$ mit $\mathbf{p} \neq \mathbf{0}$ gilt	(2): alle n Eigen- werte λ_i sind	(3): für alle n Haupt- unterdet. D_i gilt
positiv semi-definit:	$\mathbf{p}^\top \mathbf{A} \mathbf{p} \geq 0$	reell und ≥ 0	
positiv definit:	$\mathbf{p}^\top \mathbf{A} \mathbf{p} > 0$	reell und > 0	$D_i > 0$
negativ semi-definit:	$\mathbf{p}^\top \mathbf{A} \mathbf{p} \leq 0$	reell und ≤ 0	
negativ definit:	$\mathbf{p}^\top \mathbf{A} \mathbf{p} < 0$	reell und < 0	$(-1)^{i+1} D_i < 0$

Die Eigenwerte λ_i , $i = 1, \dots, n$ der Matrix $\mathbf{A}$ sind die Lösungen der Gleichung

$$\det(\lambda \mathbf{I} - \mathbf{A}) = 0,$$

wobei $\mathbf{I}$ die Einheitsmatrix der Dimension n darstellt. Die Hauptunterdeterminanten D_i sind die Determinanten der linken oberen Untermatrizen von $\mathbf{A}$:

$$D_1 = |a_{11}|, \quad D_2 = \begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix} \quad \dots \quad D_n = \begin{vmatrix} a_{11} & \dots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \dots & a_{nn} \end{vmatrix},$$

wobei die Elemente a_{ij} die Elemente der Matrix $\mathbf{A}$ darstellen. Um die Definitheit einer symmetrischen Matrix $\mathbf{A}$ zu bestimmen, reicht es eine der drei Bedingungen (1)-(3) auszuwerten, da jede für sich notwendig und hinreichend ist. Das Kriterium (3) wird auch *Sylvester-Kriterium* genannt, das allerdings nur für (positiv oder negativ) definite Matrizen gilt. Zur Anwendung der drei Kriterien zur Bestimmung der Definitheit einer Matrix sei auf Aufgabe 2.1 verwiesen.

2.3 Konvexität

Die Eigenschaft der Konvexität ist von fundamentaler Bedeutung in der Optimierung und führt im Allgemeinen zu einer einfacheren numerischen Lösung des Optimierungsproblems. Zudem ist Konvexität notwendig, um eine Aussage über eine eindeutige Lösung eines Optimierungsproblems treffen zu können. Der Begriff *konvex* kann sowohl auf Mengen als auch auf Funktionen und Optimierungsprobleme angewendet werden.

2.3.1 Konvexe Mengen

Definition 2.5 (Konvexe Menge) Eine Menge $\mathcal{X} \subseteq \mathbb{R}^n$ ist konvex, falls die folgende Bedingung für beliebige Punkte $\mathbf{x}, \mathbf{y} \in \mathcal{X}$ erfüllt ist:

$$\mathbf{z} = k \mathbf{x} + (1 - k) \mathbf{y} \in \mathcal{X} \quad \text{für alle } k \in [0, 1]. \quad (2.13)$$

Eine geometrische Interpretation dieser Definition ist, dass eine Menge $\mathcal{X} \subseteq \mathbb{R}^n$ genau dann konvex ist, falls die Verbindungslinie zwischen zwei beliebigen Punkten $\mathbf{x}, \mathbf{y} \in \mathcal{X}$ komplett in $\mathcal{X}$ enthalten ist. Abbildung 2.3 zeigt einige Beispiele konvexer und nicht-konvexer Mengen.

Eine bekannte Eigenschaft konvexer Mengen ist, dass ihre Schnittmenge ebenfalls eine konvexe Menge darstellt. Diese Eigenschaft ist von Bedeutung zur Charakterisierung der Konvexität der zulässigen Menge $\mathcal{X}_{ad}$ von Optimierungsproblemen (siehe Satz 2.4).




Abbildung 2.3: Beispiele von konvexen Mengen.

2.3.2 Konvexe Funktionen

Definition 2.6 (Konvexe und konkave Funktionen) Sei $\mathcal{X} \subseteq \mathbb{R}^n$ eine konvexe Menge. Eine Funktion $f : \mathcal{X} \rightarrow \mathbb{R}$ ist konvex auf $\mathcal{X}$, falls die folgende Bedingung für beliebige Punkte $\mathbf{x}, \mathbf{y} \in \mathcal{X}$, $\mathbf{x} \neq \mathbf{y}$ und $\mathbf{z} = k \mathbf{x} + (1 - k) \mathbf{y}$ erfüllt ist:

$$f(\mathbf{z}) \leq k f(\mathbf{x}) + (1 - k) f(\mathbf{y}) \quad \forall k \in [0, 1]. \quad (2.14)$$

Die Funktion f ist strikt konvex, falls

$$f(\mathbf{z}) < k f(\mathbf{x}) + (1 - k) f(\mathbf{y}) \quad \forall k \in (0, 1). \quad (2.15)$$

Die Funktion ist f (strikt) konkav, falls $-f$ (strikt) konvex ist.

Die Definition 2.6 kann wie folgt geometrisch interpretiert werden: eine Funktion f ist konvex (konkav), falls alle Funktionswerte $f(\mathbf{z})$ mit $\mathbf{z} = k \mathbf{x} + (1 - k) \mathbf{y}$ unterhalb (oberhalb) der Verbindungslinie zwischen $f(\mathbf{x})$ und $f(\mathbf{y})$ liegen. Abbildung 2.4 zeigt einige Beispiele konvexer und konkaver Funktionen. Es ist direkt ersichtlich, dass lineare Funktionen sowohl konkav als auch konvex sind.




Abbildung 2.4: Beispiele von konvexen und konkaven Funktionen.

Konvexe Funktionen besitzen einige interessante Eigenschaften:

a) Die Summenfunktion

$$f(\mathbf{x}) = \sum_{i=1}^k a_i f_i(\mathbf{x}) \quad (2.16)$$

von konvexen Funktionen $f_i(\mathbf{x})$, $i = 1, \dots, k$ mit den Koeffizienten $a_i \geq 0$, $i = 1, \dots, k$ ist konvex.

b) Ist die Funktion $f(\mathbf{x})$ konvex, so ist die Menge

$$\mathcal{S} = \{\mathbf{x} \in \mathbb{R}^n : f(\mathbf{x}) \leq k\} \quad (2.17)$$

mit $k > 0$ stets konvex, siehe Abbildung 2.5.

c) Eine stetig differenzierbare Funktion $f(\mathbf{x})$ ist konvex auf $\mathcal{X}$, wenn für alle $\mathbf{x}, \mathbf{y} \in \mathcal{X}$ die Ungleichung

$$f(\mathbf{y}) \geq f(\mathbf{x}) + (\mathbf{y} - \mathbf{x})^\top \nabla f(\mathbf{x}) \quad (2.18)$$

erfüllt ist. Dies kann als eine Alternative zu Definition 2.6 angesehen werden und ist in Abbildung 2.6 veranschaulicht. Die geometrische Interpretation der Ungleichung (2.18) ist, dass an jedem Punkt $\mathbf{x}$ einer konvexen Funktion $f(\mathbf{x})$ eine sogenannte *stützende Hyperebene* (skalärer Fall: *Stütztangente*) existieren muss, oberhalb der $f(\mathbf{x})$ verläuft.




Abbildung 2.5: Konvexe Menge $\mathcal{S}$, die durch den Schnitt einer konvexen Funktion $f(\mathbf{x})$ mit der Ebene $f(\mathbf{x}) = \text{konst.}$ entsteht.




Abbildung 2.6: Stütztangente einer konvexen Funktion $f(\mathbf{x})$.

Beispiel 2.3 Gegeben ist die Funktion

$$\min_{\mathbf{x} \in \mathbb{R}^2} f(\mathbf{x}) = -\frac{100}{(x_1 - 1)^2 + (x_2 - 1)^2 + 1} - \frac{200}{(x_1 + 1)^2 + (x_2 + 2)^2 + 1}. \quad (2.19)$$

die in Abbildung 2.7 dargestellt ist. Es ist leicht zu sehen, dass die Funktion (2.19) auf $\mathbb{R}^2$ nicht konvex ist. Dies ist auch anhand der Höhenlinien in Abbildung 2.7 ersichtlich, die die Schnittmengen (2.17) definieren: es ist offensichtlich, dass Schnittmengen existieren, die nicht konvex sind.




Abbildung 2.7: Profil und Höhenlinien der Funktion (2.19).

Der folgende Satz charakterisiert die Konvexität einer Funktion anhand der Definitheit ihrer Hesse-Matrix (siehe auch Satz 2.2):

Satz 2.3 Sei $\mathcal{X} \subseteq \mathbb{R}^n$ konvex und $f : \mathcal{X} \rightarrow \mathbb{R}$ zweimal stetig differenzierbar. Dann gilt:

- a) f ist konvex, falls $\nabla^2 f(\mathbf{x})$ für alle $\mathbf{x} \in \mathcal{X}$ positiv semi-definit ist,
- b) f ist strikt konvex, falls $\nabla^2 f(\mathbf{x})$ für alle $\mathbf{x} \in \mathcal{X}$ positiv definit ist,
- c) f ist konkav, falls $\nabla^2 f(\mathbf{x})$ für alle $\mathbf{x} \in \mathcal{X}$ negativ semi-definit ist,
- d) f ist strikt konkav, falls $\nabla^2 f(\mathbf{x})$ für alle $\mathbf{x} \in \mathcal{X}$ negativ definit ist.

An dieser Stelle sei allerdings angemerkt, dass die strikte Konvexität einer Funktion $f(\mathbf{x})$ nicht die Positiv-Definitheit der Hesse-Matrix gewährleistet. Ein Beispiel ist die strikt konvexe Funktion $f(x) = x^4$ mit der zweiten Ableitung $f''(0) = 0$ am Punkt $x = 0$.

Aufgabe 2.1 Untersuchen Sie, ob die folgenden Funktionen auf Ihrem Definitionsbereich konvex sind, indem Sie die Definitheit der Hesse-Matrix $\nabla^2 f(\mathbf{x})$ mittels der Kriterien (1)-(3) in Satz 2.2 überprüfen:

$$f(\mathbf{x}) = x_1^4 + x_1^2 - 2x_1x_2 + x_2^2, \quad \mathbf{x} \in \mathbb{R}^2 \quad (2.20)$$

$$f(\mathbf{x}) = x_2 + \frac{1}{x_1x_2}, \quad x_{1,2} > 0. \quad (2.21)$$

Aufgabe 2.2 Untersuchen Sie, ob die folgenden Funktionen auf Ihrem Definitionsbereich konvex bzw. konkav sind und stellen Sie die Funktionen grafisch (z.B. unter MATLAB) dar:

$$f(x) = e^x - 1, \quad x \in \mathbb{R} \quad (2.22)$$

$$f(\mathbf{x}) = x_1^\alpha x_2^{1-\alpha}, \quad x_1, x_2 > 0, \quad \alpha \in [0, 1]. \quad (2.23)$$

2.3.3 Konvexe Optimierungsprobleme

Der Begriff der Konvexität von Mengen und Funktionen lässt sich ebenfalls auf Optimierungsprobleme erweitern:

Definition 2.7 Das statische Optimierungsproblem

$$\min_{\mathbf{x} \in \mathcal{X}_{ad}} f(\mathbf{x})$$

ist (strikt) konvex, falls die zulässige Menge $\mathcal{X}_{ad}$ konvex und die Kostenfunktion f (strikt) konvex auf $\mathcal{X}_{ad}$ ist.

Die Konvexität einer zulässigen Menge $\mathcal{X}_{ad}$ kann wie folgt untersucht werden:

Satz 2.4 Falls die Funktionen $g_i : \mathbb{R}^n \rightarrow \mathbb{R}$, $i = 1, \dots, p$ linear und die Funktionen $h_i : \mathbb{R}^n \rightarrow \mathbb{R}$, $i = 1, \dots, q$ konvex sind, dann ist die zulässige Menge $\mathcal{X}_{ad}$ in (2.4) konvex.

Dieser Satz ergibt sich aus der bereits erwähnten Eigenschaft, dass der Schnitt zweier konvexer Mengen wiederum eine konvexe Menge ergibt. Für lineare (und somit konvexe) Gleichungsbedingungen $g_i(\mathbf{x}) = 0$ und konvexe Ungleichungsnebenbedingungen $h_i(\mathbf{x}) \leq 0$ sind die zugehörigen Untermengen stets konvex (siehe auch Punkt b) auf Seite 16 und Abbildung 2.5). Somit ist die gesamte Schnittmenge, also die zulässige Menge $\mathcal{X}_{ad}$, ebenfalls konvex.

Mit den vorherigen Ergebnissen können nun hinreichende Bedingungen für die Konvexität von statischen Optimierungsproblemen angegeben werden:

Satz 2.5 Das statische Optimierungsproblem

$$\begin{aligned} \min_{\mathbf{x} \in \mathbb{R}^n} \quad & f(\mathbf{x}) \\ \text{u.B.v.} \quad & g_i(\mathbf{x}) = 0, \quad i = 1, \dots, p \\ & h_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, q \end{aligned}$$

ist (strikt) konvex, falls

- a) die Funktionen $g_i : \mathbb{R}^n \rightarrow \mathbb{R}$, $i = 1, \dots, p$ linear sind,
- b) die Funktionen $h_i : \mathbb{R}^n \rightarrow \mathbb{R}$, $i = 1, \dots, q$ konvex sind,
- c) die Kostenfunktion f (strikt) konvex auf $\mathcal{X}_{ad} \subseteq \mathbb{R}^n$ ist.

Einige wichtige Eigenschaften konvexer Optimierungsprobleme sind:

- a) Jedes lokale Minimum ist ein globales Minimum.
- b) Falls ein striktes lokales Minimum existiert, dann ist dieses eindeutig und global.
- c) Ein strikt konvexes Optimierungsproblem kann nicht mehr als eine Lösung besitzen: falls ein lokales Minimum existiert, ist dieses das eindeutige globale Minimum.

Es sei an dieser Stelle angemerkt, dass strikte Konvexität eines Optimierungsproblems nicht die Existenz einer Lösung impliziert. Als Beispiel dient wieder das Problem (2.10)

$$\min_{x \in (0, \infty)} \frac{1}{x}. \quad (2.24)$$

Die erste und zweite Ableitung der Funktion $f(x) = \frac{1}{x}$ lauten $f'(x) = -\frac{1}{x^2}$ und $f''(x) = \frac{2}{x^3} > 0$. Somit ist $f''(x) > 0$ für alle $x \in \mathcal{X} = (0, \infty)$ und das Optimierungsproblem (2.24) ist strikt konvex. Allerdings ist direkt ersichtlich, dass kein Minimum existiert.¹

Aus den oben angegebenen Eigenschaften konvexer Optimierungsprobleme ist ersichtlich, dass Konvexität die Analyse von Optimierungsproblemen erheblich vereinfacht. Die meisten theoretischen Untersuchungen von Optimierungsproblemen und Konvergenzeigenschaften numerischer Verfahren basieren auf dieser Annahme. Da die meisten numerischen Verfahren zu einem lokalen Minimum konvergieren, impliziert dies im Falle von (strikter) Konvexität automatisch eine (eindeutige) globale Lösung.

Beispiel 2.4 Betrachtet wird das Problem aus Beispiel 2.2. Die Kostenfunktion (2.7) und die Beschränkungen (2.8), (2.9) sind konvex. Somit ist das Optimierungsproblem (2.7)-(2.9) konvex und die lokale Lösung $\mathbf{x}^* = [1, 1]^T$ (siehe Abbildung 1.5) ist die globale Lösung.

2.4 Literatur

- [1] S. Boyd und L. Vandenberghe. *Convex Optimization*. http://www.stanford.edu/~boyd/cvxbook/bv_cvxbook.pdf. Cambridge: Cambridge University Press, 2004.
- [2] J. Nocedal und S.J. Wright. *Numerical Optimization*. New York: Springer, 2006.
- [3] M. Papageorgiou, M. Leibold und M. Buss. *Optimierung*. Berlin: Springer, 2012.

¹ Es sei an dieser Stelle auch daran erinnert, dass der Satz 2.1 von Weierstrass nur dann die Existenz einer Lösung garantiert, wenn die zulässige Menge $\mathcal{X}$ (bzw. $\mathcal{X}_{ad}$) kompakt ist.

3 Statische Optimierung ohne Beschränkungen

In diesem Kapitel werden unbeschränkte statische Optimierungsprobleme der Form

$$\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) \quad (3.1)$$

betrachtet sowie notwendige und hinreichende Optimalitätsbedingungen hergeleitet. Im Anschluss werden einige bekannte numerische Verfahren vorgestellt, um einen Eindruck zu vermitteln, wie unbeschränkte Optimierungsprobleme numerisch gelöst werden können.

3.1 Notwendige Optimalitätsbedingungen

Die Optimalitätsbedingungen für unbeschränkte Probleme (3.1) dienen einerseits zum Auffinden von (lokalen) Extremwerten $\mathbf{x}^*$ als auch zum Überprüfen, ob es sich tatsächlich um ein Minimum handelt, dass also

$$f(\mathbf{x}) \geq f(\mathbf{x}^*) \quad (3.2)$$

für alle $\mathbf{x}$ in einer hinreichend kleinen Umgebung von $\mathbf{x}^*$ (siehe Definition 2.1) gilt.

Unter der Annahme, dass $f(\mathbf{x})$ mindestens zweimal stetig differenzierbar ist, lässt sich $f(\mathbf{x})$ an der Stelle $\mathbf{x}^*$ in eine Taylorreihe entwickeln:

$$f(\mathbf{x}^* + \delta\mathbf{x}) = f(\mathbf{x}^*) + \nabla f(\mathbf{x}^*)^\top \delta\mathbf{x} + \frac{1}{2} \delta\mathbf{x}^\top \nabla^2 f(\mathbf{x}^*) \delta\mathbf{x} + \mathcal{O}(\|\delta\mathbf{x}\|^3). \quad (3.3)$$

Falls der Punkt $\mathbf{x}^*$ ein lokales Minimum darstellt, muss (3.2) mit $\mathbf{x} = \mathbf{x}^* + \delta\mathbf{x}$ für alle hinreichend kleinen $\delta\mathbf{x}$ erfüllt sein. Einsetzen von (3.3) in (3.2) führt auf die Ungleichung

$$\nabla f(\mathbf{x}^*)^\top \delta\mathbf{x} + \frac{1}{2} \delta\mathbf{x}^\top \nabla^2 f(\mathbf{x}^*) \delta\mathbf{x} + \mathcal{O}(\|\delta\mathbf{x}\|^3) \geq 0. \quad (3.4)$$

Für hinreichend kleine $\delta\mathbf{x}$ ist der erste Term $\nabla f(\mathbf{x}^*)^\top \delta\mathbf{x}$ dominant und bestimmt das Vorzeichen der gesamten linken Seite in (3.4). Es muss also $\nabla f(\mathbf{x}^*)^\top \delta\mathbf{x} \geq 0$ erfüllt sein. Da $\mathbf{x}^*$ nur ein lokales Minimum ist, wenn die Ungleichung (3.4) für alle (hinreichend kleinen) $\delta\mathbf{x}$ erfüllt ist, ergibt sich direkt, dass

$$\nabla f(\mathbf{x}^*) = \mathbf{0} \quad (3.5)$$

gelten muss. Allerdings sagt diese Bedingung 1. Ordnung lediglich aus, dass $\mathbf{x}^*$ ein Extrempunkt von f ist, da $\nabla f(\mathbf{x}^*) = \mathbf{0}$ auch von Maxima oder Sattelpunkten erfüllt wird, wie in Abbildung 3.1 dargestellt ist. In der Optimierung spricht man in diesem Zusammenhang oft von einem *stationären Punkt*.




Abbildung 3.1: Beispiele von stationären Punkten im ein- und zwei-dimensionalen Fall.

Eine strengere Bedingung 2. Ordnung für ein lokales Minimum $\mathbf{x}^*$ ergibt sich aus (3.4):

$$\delta \mathbf{x}^T \nabla^2 f(\mathbf{x}^*) \delta \mathbf{x} \geq 0. \quad (3.6)$$

Da diese Bedingung für alle hinreichend kleinen $\delta \mathbf{x}$ in einer Umgebung von $\mathbf{x}^*$ gelten soll, muss die Hesse-Matrix $\nabla^2 f(\mathbf{x}^*)$ folglich positiv semi-definit sein, wie sich aus Satz 2.2 leicht ablesen lässt. Die notwendigen Bedingungen für ein lokales Minimum sind im folgenden Satz zusammengefasst:

Satz 3.1 (Notwendige Optimalitätsbedingungen) Sei $f : \mathbb{R}^n \rightarrow \mathbb{R}$ eine zweimal stetig differenzierbare Funktion und $\mathbf{x}^*$ ein lokales Minimum von f . Dann gelten die folgenden Optimalitätsbedingungen 1. und 2. Ordnung:

$$\nabla f(\mathbf{x}^*) = \mathbf{0} \quad (3.7)$$

$$\nabla^2 f(\mathbf{x}^*) \geq \mathbf{0} \quad (\text{positiv semi-definit}). \quad (3.8)$$

Allerdings stellen diese Optimalitätsbedingungen keine hinreichenden Bedingungen dar und sind somit nicht umkehrbar. Ein Beispiel ist die Funktion $f(x) = x^3$, die an der Stelle $\mathbf{x}^* = 0$ einen Extrempunkt besitzt, wie man anhand der ersten Ableitung $f'(x) = 3x^2$ leicht erkennen kann. Obwohl die zweite Ableitung $f''(\mathbf{x}^*) = 6x^* = 0$ positiv semi-definit ist, ist $\mathbf{x}^* = 0$ kein Minimum, sondern ein Sattelpunkt (siehe Abbildung 3.1).

3.2 Hinreichende Optimalitätsbedingungen

Eine hinreichende Bedingung, die die Existenz eines lokalen Minimums $\mathbf{x}^*$ garantiert, kann aus der Ungleichung (3.4) abgelesen werden. Falls $\nabla f(\mathbf{x}^*) = \mathbf{0}$ gilt und der quadratische Term in (3.4) strikt positiv ist, d.h.

$$\delta \mathbf{x}^T \nabla^2 f(\mathbf{x}^*) \delta \mathbf{x} > 0, \quad (3.9)$$

dann ist garantiert, dass für alle hinreichend kleinen $\delta \mathbf{x}$ die Ungleichung (3.4) strikt erfüllt ist und somit $\mathbf{x}^*$ ein lokales Minimum darstellt. Man spricht in diesem Fall von *hinreichenden Optimalitätsbedingungen*, die im folgenden Satz zusammengefasst sind:

Satz 3.2 (Hinreichende Optimalitätsbedingungen) Sei $f : \mathbb{R}^n \rightarrow \mathbb{R}$ eine zweimal stetig differenzierbare Funktion und $\mathbf{x}^* \in \mathcal{X}$. Falls $f(\mathbf{x}^*)$ die Bedingungen

$$\nabla f(\mathbf{x}^*) = \mathbf{0} \quad (3.10)$$

$$\nabla^2 f(\mathbf{x}^*) > \mathbf{0} \quad (\text{positiv definit}) \quad (3.11)$$

erfüllt, dann ist $\mathbf{x}^*$ ein striktes lokales Minimum von f .

An dieser Stelle sei angemerkt, dass ein striktes Minimum $\mathbf{x}^*$ nicht automatisch die Positiv-Definitheit der Hesse-Matrix $\nabla^2 f(\mathbf{x}^*)$ impliziert. Ein Beispiel ist die Funktion $f(x) = x^4$, die offensichtlich ein striktes Minimum an der Stelle $x^* = 0$ besitzt. Allerdings verschwindet die zweite Ableitung $f''(x) = 12x^2$ an der Stelle $x^* = 0$ und ist somit nicht positiv definit.

Die Optimalitätsbedingungen erster Ordnung, $\nabla f(\mathbf{x}^*) = \mathbf{0}$, stellen ein nichtlineares Gleichungssystem der Ordnung n dar, das gelöst werden kann, um einen stationären Punkt $\mathbf{x}^*$ zu bestimmen. Die Positiv-Definitheit der Hesse-Matrix $\nabla^2 f(\mathbf{x}^*)$ kann dann mit Hilfe der Methoden in Satz 2.2 untersucht werden, um zu überprüfen, ob $\mathbf{x}^*$ ein striktes Minimum ist.

Beispiel 3.1 Für das Optimierungsproblem

$$\min_{\mathbf{x} \in \mathbb{R}^2} x_1^2 + ax_2^2 - x_1x_2, \quad (3.12)$$

sollen die stationären Werte $\mathbf{x}^*$ in Abhängigkeit des Parameters a charakterisiert werden. Der Gradient und die Hesse-Matrix von $f(\mathbf{x})$ ergeben sich zu

$$\nabla f(\mathbf{x}) = \begin{bmatrix} 2x_1 - x_2 \\ 2ax_2 - x_1 \end{bmatrix}, \quad \nabla^2 f(\mathbf{x}) = \begin{bmatrix} 2 & -1 \\ -1 & 2a \end{bmatrix}. \quad (3.13)$$

Aus $\nabla f(\mathbf{x}^*) = \mathbf{0}$ folgt $\mathbf{x}^* = [0, 0]^T$ als einziger stationärer Punkt für $a \neq 1/4$. Die Definitheit der Hesse-Matrix $\nabla^2 f(\mathbf{x})$ an der Stelle $\mathbf{x}^*$ lässt sich mit Hilfe der Hauptunterdeterminanten (Sylvesterkriterium, siehe (3) in Satz 2.2) untersuchen:

$$D_1 = 2, \quad D_2 = 4a - 1. \quad (3.14)$$

Somit ist $\nabla^2 f(\mathbf{x}^*)$ positiv definit für $a > 1/4$ und $\mathbf{x}^* = [0, 0]^T$ stellt ein striktes Minimum dar. Für $a < 1/4$ ist $D_1 > 0$ und $D_2 < 0$ und $\nabla^2 f(\mathbf{x})$ somit indefinit. In diesem Fall ist $\mathbf{x}^* = [0, 0]^T$ ein Sattelpunkt, wie er in Abbildung 3.1b) für $a = -1$ dargestellt ist.

Falls die Kostenfunktion $f(\mathbf{x})$ konvex (bzw. strikt konvex) ist, lassen sich stärkere Aussagen treffen als in den Sätzen 3.1 und 3.2:

Satz 3.3 (Hinreichende Optimalitätsbedingungen für konvexe Funktionen)

Sei $f : \mathbb{R}^n \rightarrow \mathbb{R}$ eine stetig differenzierbare und (strikt) konvexe Funktion. Falls $\nabla f(\mathbf{x}^*) = \mathbf{0}$, dann ist $\mathbf{x}^*$ ein (eindeutiges) globales Minimum der Funktion f .

3.3 Numerische Lösung mit Liniensuchverfahren

Da die Stationaritätsbedingung $\nabla f(\mathbf{x}^*) = \mathbf{0}$ nur in seltenen Fällen analytisch ausgewertet werden kann, ist man im Allgemeinen auf numerische Verfahren angewiesen, um einen stationären Punkt $\mathbf{x}^*$ zu finden. Eines der bekanntesten numerischen Verfahren ist die *Liniensuche* (Englisch: *line search*). Ausgehend von einer suboptimalen Startlösung $\mathbf{x}^0$ mit $f(\mathbf{x}^0) > f(\mathbf{x}^*)$ versuchen Liniensuchverfahren sich iterativ einem Minimum $\mathbf{x}^*$ anzunähern. Dabei wird in jedem Schritt k gefordert, dass

$$f(\mathbf{x}^{k+1}) < f(\mathbf{x}^k) \quad \forall k \in \mathbb{N}_0^+ \quad (3.15)$$

erfüllt ist, um im Grenzfall $k \rightarrow \infty$ gegen ein Minimum zu konvergieren:

$$\lim_{k \rightarrow \infty} \mathbf{x}^k = \mathbf{x}^*. \quad (3.16)$$

Liniensuchverfahren verfolgen dabei prinzipiell die Strategie, zunächst eine *Suchrichtung* (oder *Abstiegsrichtung*) $\mathbf{s}^k$ zu bestimmen, entlang der die Ungleichung (3.15) erfüllt ist.

Um dies zu verdeutlichen, wird die Kostenfunktion $f(\mathbf{x})$ an der Stelle $\mathbf{x}^k$ in eine Taylorreihe entwickelt:

$$f(\mathbf{x}^k + \mathbf{s}) = f(\mathbf{x}^k) + \nabla f(\mathbf{x}^k)^T \mathbf{s} + \mathcal{O}(\|\mathbf{s}\|^2). \quad (3.17)$$

Für hinreichend kleine $\mathbf{s}$ kann der Restterm $\mathcal{O}(\|\mathbf{s}\|^2)$ vernachlässigt werden und man erkennt sofort, dass an dem Punkt $\mathbf{x}^k$ eine geeignete Suchrichtung $\mathbf{s}^k$ die *Abstiegsbedingung*

$$\nabla f(\mathbf{x}^k)^T \mathbf{s}^k < 0 \quad (3.18)$$

erfüllen muss, damit $f(\mathbf{x}^k + \mathbf{s}^k) < f(\mathbf{x}^k)$ gilt. Verschiedene Methoden existieren zur Bestimmung der Suchrichtung $\mathbf{s}^k$. Die gebräuchlichsten Verfahren sind in den Abschnitten 3.3.2 bis 3.3.5 vorgestellt.

Zusätzlich muss eine geeignete *Schrittweite* α^k bestimmt werden, um festzulegen, wie weit in Suchrichtung $\mathbf{s}^k$ bis zum nächsten Punkt

$$\mathbf{x}^{k+1} = \mathbf{x}^k + \alpha^k \mathbf{s}^k \quad (3.19)$$

vorangeschritten werden soll. Die optimale Schrittweite α^k stellt die Lösung des unterlagerten (skalaren) Optimierungsproblems

$$\alpha^k = \arg \min_{\alpha > 0} \phi(\alpha) \quad \text{mit} \quad \phi(\alpha) = f(\mathbf{x}^k + \alpha \mathbf{s}^k) \quad (3.20)$$

dar, was dem maximal möglichen Abstieg entlang der Suchrichtung $\mathbf{s}^k$ entspricht. Abbildung 3.2 veranschaulicht das Prinzip der Liniensuche für eine (nicht konvexe) Kostenfunktion $f(\mathbf{x})$ mit $\mathbf{x} \in \mathbb{R}^2$ und einer gegebenen Suchrichtung $\mathbf{s}^k$.

Im Allgemeinen wird (3.20) nicht exakt gelöst, sondern anhand geeigneter Methoden approximiert (siehe Abschnitt 3.3.1). Das gewählte α^k definiert dann die Schrittweite in der k -ten Iteration und bestimmt den nächsten Punkt (3.19). Der grundsätzliche Algorithmus von Liniensuchverfahren ist in Tabelle 3.1 dargestellt.




Abbildung 3.2: Veranschaulichung des Liniensuchproblems (3.20).

Initialization: $\mathbf{x}^0$ (Startwert)
 $k \leftarrow 0$ (Iterationsindex)
 $\varepsilon_x, \varepsilon_f$ (Abbruchkriterien)

repeat

Wahl der Suchrichtung $\mathbf{s}^k$
 Wahl der Schrittweite α^k
 $\mathbf{x}^{k+1} \leftarrow \mathbf{x}^k + \alpha^k \mathbf{s}^k$
 $k \leftarrow k + 1$

until $\|\mathbf{x}^k - \mathbf{x}^{k-1}\| \leq \varepsilon_x$ **or** $\|f(\mathbf{x}^k) - f(\mathbf{x}^{k-1})\| \leq \varepsilon_f$

Tabelle 3.1: Allgemeine Struktur von Liniensuchverfahren.

3.3.1 Bestimmung der Schrittweite

Die Berechnung einer geeigneten Schrittweite α^k stellt einen Kompromiss zwischen Rechenzeit und Genauigkeit dar. Die optimale Lösung bestünde darin, das skalare Optimierungsproblem (3.20) exakt oder zumindest hinreichend genau zu lösen, was jedoch in der Praxis zu viele Auswertungen der Kostenfunktion f und eventuell des Gradienten ∇f benötigen würde.

Die meisten numerischen Verfahren verwenden deshalb eine suboptimale Liniensuche, um eine Schrittweite α^k zu bestimmen, die zu einer adäquaten Reduktion der Kostenfunktion f im nächsten Schritt $\mathbf{x}^{k+1}$ führt. Im Folgenden wird dabei auf folgende Aspekte eingegangen:

- Abstiegs- und Krümmungsbedingungen
- Backtracking-Verfahren
- Intervallschachtelungsverfahren.




Abbildung 3.3: Veranschaulichung der Abstiegsbedingung (3.21).

Abstiegs- und Krümmungsbedingungen (Wolfe-Bedingungen)

Ein erstes Kriterium für einen hinreichenden Abstieg in der Kostenfunktion f ist die Ungleichung

$$\underbrace{f(\mathbf{x}^k + \alpha^k \mathbf{s}^k)}_{= \phi(\alpha^k)} \leq \underbrace{f(\mathbf{x}^k)}_{= \phi(0)} + c_1 \alpha^k \underbrace{\nabla f(\mathbf{x}^k)^T \mathbf{s}^k}_{= \phi'(0)} \quad (3.21)$$

in Abhängigkeit einer Konstanten $c_1 \in (0, 1)$. Gelegentlich wird die Abstiegsbedingung auch *Armijo-Bedingung* genannt. Anschaulich interpretiert bedeutet die Ungleichung (3.21), dass der Abstieg in f proportional zur Schrittweite α^k und der Richtungsableitung $\phi'(0) = \nabla f(\mathbf{x}^k)^T \mathbf{s}^k$ sein sollte.

Abbildung 3.3 illustriert diesen Zusammenhang. Die rechte Seite der Ungleichung (3.21) stellt eine Gerade mit der negativen Steigung $c_1 \phi'(0)$ dar, aber aufgrund der Konstanten $c_1 \in (0, 1)$ liegt die Gerade für hinreichend kleine Werte von α^k über dem Funktionswert $\phi(\alpha^k)$. Die Abstiegsbedingung (3.21) verlangt folglich, dass Werte von α^k nur zulässig sind, wenn ihr Funktionswert $\phi(\alpha^k)$ unterhalb dieser Geraden liegt. In der Praxis wird c_1 häufig sehr klein gewählt (z.B. 10^{-4}), damit die Abstiegsbedingung nicht zu restriktiv ist.

Die Abstiegsbedingung (3.21) alleine ist oft nicht genug, um einen nennenswerten Abstieg in der Kostenfunktion f zu gewährleisten, da sie für hinreichend kleine Schrittweiten α^k stets erfüllt ist (siehe Abbildung 3.3). Unnötig kleine Werte von α^k können durch ein zweites zusätzliches Kriterium, die sogenannte *Krümmungsbedingung*, vermieden werden¹

$$\underbrace{|\nabla f(\mathbf{x}^k + \alpha^k \mathbf{s}^k)^T \mathbf{s}^k|}_{= \phi'(\alpha^k)} \leq c_2 \underbrace{|\nabla f(\mathbf{x}^k)^T \mathbf{s}^k|}_{= \phi'(0)}. \quad (3.22)$$

Die Konstante $c_2 \in (c_1, 1)$ wird dabei in Abhängigkeit der ersten Konstante c_1 aus (3.21) gewählt. Da die linke Seite der Krümmungsbedingung den Gradienten $\phi'(\alpha^k)$ darstellt, bedeutet das Kriterium also, dass der Betrag der Steigung $\phi'(\alpha^k)$ an der Stelle α^k kleiner oder gleich dem c_2 -fachen Betrag der Anfangssteigung $\phi'(0)$ sein muss, siehe Abbildung 3.4. Zusammen mit der Abstiegsbedingung (3.21) ergibt sich somit eine Menge an zulässigen Schrittweiten α^k .

¹ Genau genommen handelt es sich um eine *strenge* Krümmungsbedingung, da eine schwächere Bedingung der Form (3.22) auch ohne Betragsfunktionen angegeben werden kann.




Abbildung 3.4: Veranschaulichung der Wolfe-Bedingungen.

Die Formulierung der Krümmungsbedingung macht durchaus Sinn, da im Falle einer stark negativen Steigung $\phi'(\alpha^k)$ davon auszugehen ist, dass ϕ (und damit f) weiter reduziert werden kann, wenn man sich weiter entlang der α^k -Achse bewegt. Andererseits wird durch die Betragsbedingung vermieden, dass die Steigung $\phi'(\alpha^k)$ zu groß wird und man somit zu weit von einem lokalen Minimum von ϕ entfernt ist.

Die Abstiegs- und Krümmungsbedingungen (3.21)-(3.22) werden auch *Wolfe-Bedingungen* genannt und können in den meisten Liniensuchverfahren eingesetzt werden. Typischerweise wird c_2 zu 0.9 gewählt, wenn die Suchrichtung $\mathbf{s}^k$ durch ein Newton- oder Quasi-Newton-Verfahren bestimmt wird, bzw. zu 0.1 im Falle von Konjugierten-Gradienten-Verfahren (siehe die folgenden Abschnitte).

Es lässt sich zeigen, dass für stetig differenzierbare und von unten beschränkte Funktionen f stets ein Intervall existiert, in dem die Wolfe-Bedingungen erfüllt sind.

Backtracking-Verfahren

Wie bereits erwähnt wurde, ist die Abstiegsbedingung (3.21) allein nicht ausreichend, um einen hinreichend schnellen Abstieg in der Kostenfunktion f zu gewährleisten. Wenn allerdings die Kandidaten für die Schrittweite α^k geeignet gewählt werden, kann die Krümmungsbedingung (3.22) vernachlässigt werden und die Liniensuche anhand der Abstiegsbedingung (3.21) abgebrochen werden. Ein geeignetes Verfahren ist das *Backtracking*-Verfahren, das (in der einfachsten Form) durch den Algorithmus in Tabelle 3.2 beschrieben wird.

Das Vorgehen kann anhand von Abbildung 3.3 erklärt werden. Wenn der Startwert $\bar{\alpha}$ weit auf der rechten Seite liegt, wird α solange um den Faktor ρ reduziert, bis $\phi(\alpha) = f(\mathbf{x}^k + \alpha \mathbf{s}^k)$ unterhalb einer der Geraden (mit $c = 0.1$ oder 0.25) liegt. Die sukzessive Reduktion um einen Faktor ρ stellt sicher, dass α^k klein genug ist, um die Abstiegsbedingung (3.21) zu erfüllen. Andererseits wird durch die sukzessive Reduktion um den Faktor ρ sichergestellt, dass α^k *nicht zu klein* wird, was zu einer Stagnation des Verfahrens führen könnte.

Das Backtracking-Verfahren wird häufig in Zusammenhang mit Newton-Verfahren eingesetzt und die Startschrittweite zu $\bar{\alpha} = 1$ gewählt. Für Quasi-Newton- oder Konjugierte-Gradienten-Verfahren (Abschnitte 3.3.3 und 3.3.5) ist dieses Verfahren allerdings weniger gut geeignet.

Initialization: $\alpha \leftarrow \bar{\alpha} > 0$ (Startwert)
 $\rho \in (0, 1)$ (Backtracking-Parameter)
 c (Abstiegsbedingung)

repeat
 $\alpha \leftarrow \rho \alpha$

until $f(\mathbf{x}^k + \alpha \mathbf{s}^k) \leq f(\mathbf{x}^k) + c \alpha \nabla f(\mathbf{x}^k)^\top \mathbf{s}^k$

$\alpha^k \leftarrow \alpha$ (Schrittweite)

Tabelle 3.2: Backtracking-Verfahren.

Intervallschachtelungsverfahren (“Goldener Schnitt”)

Ein alternatives Verfahren zur Bestimmung der Schrittweite α^k ist das *Intervallschachtelungsverfahren*, das eine konvergierende Folge von Intervallschachtelungen erzeugt, um das Minimum von $\phi(\alpha)$ einzugrenzen.

Zunächst muss ein Intervall $[\alpha_l, \alpha_r]$ gefunden werden, in dem die Funktion $\phi(\alpha^k)$ ein Minimum aufweist, siehe Abbildung 3.5. Dies kann z.B. dadurch erreicht werden, dass mit einem hinreichend kleinen α_l gestartet wird und α_r (ausgehend von α_l) sukzessive vergrößert wird, bis der Funktionswert $\phi(\alpha_r)$ anfängt zuzunehmen.

Anschließend werden zwei innere Werte $\alpha_l < \hat{\alpha}_l < \hat{\alpha}_r < \alpha_r$ durch die linearen Beziehungen

$$\hat{\alpha}_l = \alpha_l + (1 - a)(\alpha_r - \alpha_l), \quad \hat{\alpha}_r = \alpha_l + a(\alpha_r - \alpha_l) \quad (3.23)$$

mit dem Parameter $a \in (\frac{1}{2}, 1)$ bestimmt und die Funktionswerte $\phi(\hat{\alpha}_l)$ und $\phi(\hat{\alpha}_r)$ berechnet. Falls $\phi(\hat{\alpha}_l) < \phi(\hat{\alpha}_r)$ gilt, so liegt das Minimum offenbar im Intervall $[\alpha_l, \hat{\alpha}_r]$ und der äußere rechte Punkt α_r wird verworfen (siehe “1. Schritt” in Abbildung 3.5). Falls andererseits $\phi(\hat{\alpha}_l) > \phi(\hat{\alpha}_r)$ gilt, so muss das Minimum im Intervall $[\hat{\alpha}_l, \alpha_r]$ liegen und der linke äußere Punkt α_l wird verworfen. Im nächsten Iterationsschritt wird somit das verkürzte Intervall $[\alpha_l, \hat{\alpha}_r]$ bzw. $[\hat{\alpha}_l, \alpha_r]$ betrachtet und die Intervallschachtelung erneut angewendet.




Abbildung 3.5: Veranschaulichung der Intervallhalbierungsmethode.

```

Initialization:   $\alpha_l, \alpha_r$  (Startintervall mit innerem Minimum)
                    $a = 0.618$  (Goldener Schnitt-Parameter)
                    $\varepsilon_\alpha > 0$  (Abbruchskriterien)
                    $\hat{\alpha}_l \leftarrow \alpha_l + (1 - a)(\alpha_r - \alpha_l)$  (innere Punkte)
                    $\hat{\alpha}_r \leftarrow \alpha_l + a(\alpha_r - \alpha_l)$ 

repeat
  if  $\phi(\hat{\alpha}_l) < \phi(\hat{\alpha}_r)$  do
     $\alpha_r \leftarrow \hat{\alpha}_r$ 
     $\hat{\alpha}_r \leftarrow \hat{\alpha}_l$ 
     $\hat{\alpha}_l \leftarrow \alpha_l + (1 - a)(\alpha_r - \alpha_l)$ 
  else (d.h.  $\phi(\hat{\alpha}_l) \geq \phi(\hat{\alpha}_r)$ )
     $\alpha_l \leftarrow \hat{\alpha}_l$ 
     $\hat{\alpha}_l \leftarrow \hat{\alpha}_r$ 
     $\hat{\alpha}_r \leftarrow \alpha_l + a(\alpha_r - \alpha_l)$ 
  end
until  $|\alpha_r - \alpha_l| \leq \varepsilon_\alpha$ 

```

Tabelle 3.3: Intervallschachtelungsverfahren ("Goldener Schnitt").

Wenn der Parameter a zu

$$a = \frac{\sqrt{5} - 1}{2} \approx 0.618 \quad (3.24)$$

gewählt wird, ist lediglich eine weitere Funktionsauswertung notwendig, um einen neuen inneren Punkt zu bestimmen (siehe "2. Schritt", $\hat{\alpha}_r^2 = \hat{\alpha}_l^1$, in Abbildung 3.5). Aus diesem Grund wird diese Wahl von a als der *Goldene Schnitt* bezeichnet. Pro Schritt wird das ursprüngliche Intervall somit um ca. 38% reduziert. Tabelle 3.3 fasst den Algorithmus zusammen.

Abschließend kann α^k entweder aus der Mittelung $\alpha^k = (\alpha_l + \alpha_r)/2$ oder aus einer quadratischen Interpolation zwischen den kleinsten drei der vier Funktionswerte ϕ von $(\alpha_l, \hat{\alpha}_l, \hat{\alpha}_r, \alpha_r)$ gewonnen werden.

Das Intervallschachtelungsverfahren ist ein einfaches und robustes Verfahren, das allerdings meistens mehr Iterationen benötigt als andere Verfahren, um eine geeignete Schrittweite α^k zu bestimmen.

3.3.2 Gradientenverfahren

Zusätzlich zur Schrittweite α^k ist die Bestimmung der Suchrichtung $\mathbf{s}^k$ von elementarer Bedeutung, um den nächsten Iterationspunkt

$$\mathbf{x}^{k+1} = \mathbf{x}^k + \alpha^k \mathbf{s}^k \quad (3.25)$$

mit einem möglichst großen Abstieg in der Kostenfunktion f zu bestimmen. Dabei existieren unterschiedliche Verfahren zur Bestimmung der Suchrichtung $\mathbf{s}^k$, die sich hinsichtlich Genauigkeit, Konvergenzgeschwindigkeit und Rechenaufwand unterscheiden.

Die einfachste Methode, um eine Suchrichtung zu bestimmen, besteht darin, den negativen




Abbildung 3.6: Gut und schlecht konditioniertes Problem (links/rechts) für das Gradientenverfahren.

Gradienten an der Stelle $\mathbf{x}^k$ zu verwenden,

$$\mathbf{s}^k = -\nabla f(\mathbf{x}^k), \quad (3.26)$$

weshalb dieses Verfahren auch *Gradientenverfahren* genannt wird. Es ist leicht zu verifizieren, dass die Ungleichung (3.18) für nicht-stationäre Punkte ($\nabla f(\mathbf{x}^k) \neq \mathbf{0}$) erfüllt ist:

$$-\nabla f(\mathbf{x}^k)^T \nabla f(\mathbf{x}^k) = -\|\nabla f(\mathbf{x}^k)\|^2 < 0. \quad (3.27)$$

Da der negative Gradient die Ungleichung (3.18) minimiert, spricht man von der Richtung des *steilsten Abstiegs* (Englisch: *steepest descent*). Der Gradient steht dabei orthogonal zu der Höhenlinie $f(\mathbf{x}^k) = \text{konst.}$, die durch den Punkt $\mathbf{x}^k$ verläuft, siehe Abbildung 3.6.

Wenn ein Problem gut konditioniert ist (z.B. $f(\mathbf{x}) = x_1^2 + x_2^2$), zeigt der negative Gradient in die Richtung des Minimums $\mathbf{x}^*$, siehe Abbildung 3.6. In diesem Fall konvergiert das Gradientenverfahren schnell zur optimalen Lösung. Wenn andererseits das Problem schlecht konditioniert ist und der negative Gradient nicht in die Nähe des Minimums $\mathbf{x}^*$ weist, konvergiert das Gradientenverfahren sehr langsam, wie in Abbildung 3.6 (rechts) dargestellt ist. Dies wird auch aus dem folgenden Satz deutlich:

Satz 3.4 (Konvergenzrate des Gradientenverfahrens)

Für quadratische Funktionen $f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^T \mathbf{Q} \mathbf{x} + \mathbf{b}^T \mathbf{x} + c$ mit positiv definiter Matrix $\mathbf{Q}$ konvergiert das Gradientenverfahren bei exakter Lösung des Liniensuchproblems (3.20) gemäß

$$f(\mathbf{x}^{k+1}) - f(\mathbf{x}^*) \leq \left(\frac{\kappa - 1}{\kappa + 1} \right)^2 [f(\mathbf{x}^k) - f(\mathbf{x}^*)], \quad \kappa = \frac{\lambda_{\max}}{\lambda_{\min}}, \quad (3.28)$$

wobei $\lambda_{\min}$ und $\lambda_{\max}$ der kleinste und größte Eigenwert von $\mathbf{Q}$ sind.

Die Zahl κ stellt die spektrale Konditionszahl der Matrix $\mathbf{Q}$ dar und beeinflusst direkt die Konvergenzgeschwindigkeit, wie in der folgenden Aufgabe untersucht werden soll.

Aufgabe 3.1 Untersuchen Sie die Konvergenzrate (3.28) des Gradientenverfahrens für das quadratische Problem

$$\min_{\mathbf{x} \in \mathbb{R}^2} f(\mathbf{x}) = \frac{1}{2} \left(\frac{x_1 - x_1^*}{a} \right)^2 + \frac{1}{2} (x_2 - x_2^*)^2 \quad (3.29)$$

mit den Werten $a = 1$ und $a = 5$ (siehe Abbildung 3.6).

Die Vor- und Nachteile des Gradientenverfahrens sind im Folgenden zusammengefasst:

- + größerer Konvergenzbereich als beim Newton-Verfahren ($\nabla^2 f(\mathbf{x}^k) > \mathbf{0}$ nicht verlangt)
- + einfaches Verfahren
- langsame Konvergenz bei schlecht konditionierten/schlecht skalierten Problemen
- begrenzte Genauigkeit (Verfahren erster Ordnung)

3.3.3 Konjugierte-Gradienten-Verfahren

Das *Konjugierte-Gradienten-Verfahren* ist eine bedeutende Alternative zum herkömmlichen Gradientenverfahren, da der Rechenaufwand nicht viel höher ist, die Effizienz und Konvergenzeigenschaften aber deutlich besser sind als beim Gradientenverfahren.

Das Konjugierte-Gradienten-Verfahren nützt Informationen des vorherigen Schrittes aus, um die Suchrichtung $\mathbf{s}^k$ zu bestimmen:

$$\mathbf{s}^0 = -\nabla f(\mathbf{x}^0) \quad (3.30a)$$

$$\mathbf{s}^k = -\nabla f(\mathbf{x}^k) + \beta^k \mathbf{s}^{k-1}. \quad (3.30b)$$

Der Start des Verfahrens erfolgt mit dem steilsten Abstieg $-\nabla f(\mathbf{x}^0)$, während bei allen weiteren Schritten gemäß (3.30b) ein Korrekturterm in Abhängigkeit der vorherigen Suchrichtung $\mathbf{s}^{k-1}$ dazukommt. Der Faktor β^k wird durch die Beziehung

$$\beta^k = \frac{||\nabla f(\mathbf{x}^k)||^2}{||\nabla f(\mathbf{x}^{k-1})||^2} \quad (3.31)$$

aktualisiert, die von *Fletcher* und *Reeves* vorgeschlagen wurde. Weitere Formeln sind in den am Ende des Kapitels aufgelisteten Lehrbüchern angegeben.

Konjugierte-Gradienten-Verfahren verzichten prinzipiell auf aufwendige Matrixoperationen und sind somit gut auf große Probleme anwendbar, bei denen auf Speichereffizienz geachtet werden muss. Des Weiteren kann gezeigt werden, dass bei quadratischen Problemen der Form

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{Q} \mathbf{x} + \mathbf{b}^T \mathbf{x} + c, \quad \mathbf{x} \in \mathbb{R}^n$$

mit positiv definiter Hesse-Matrix $\mathbf{Q}$ und exakter Lösung des Liniensuchproblems (3.20) das Konjugierte-Gradienten-Verfahren nach höchstens n Iterationen konvergiert.

Aufgabe 3.2 Verifizieren Sie, dass das Konjugierte-Gradienten-Verfahren bei exakter Liniensuche tatsächlich eine Abstiegsrichtung $\mathbf{s}^k$ liefert, die die Ungleichung (3.18) erfüllt.

3.3.4 Newton-Verfahren

Ein Sonderfall des Liniensuchverfahrens liegt vor, wenn die Suchrichtung $\mathbf{s}^k$ so gewählt wird, dass die Iterationsvorschrift $\mathbf{x}^{k+1} = \mathbf{x}^k + \alpha^k \mathbf{s}^k$ dem Newton-Verfahren entspricht. In diesem Fall spricht man von der *Newton-Richtung* $\mathbf{s}^k$.

Zunächst wird die Kostenfunktion $f(\mathbf{x}) = f(\mathbf{x}^k + \mathbf{s})$ an der Stelle $\mathbf{x}^k$ durch ein quadratisches Modell

$$m^k(\mathbf{s}) = f(\mathbf{x}^k) + \nabla f(\mathbf{x}^k)^\top \mathbf{s} + \frac{1}{2} \mathbf{s}^\top \nabla^2 f(\mathbf{x}^k) \mathbf{s} \quad (3.32)$$

approximiert, für das das Minimum $\mathbf{s}$ gesucht wird. Durch Ableitung von (3.32) nach $\mathbf{s}^k$ ergibt sich

$$\nabla f(\mathbf{x}^k) + \nabla^2 f(\mathbf{x}^k) \mathbf{s} = \mathbf{0}. \quad (3.33)$$

Unter der Annahme, dass $\nabla^2 f(\mathbf{x}^k)$ positiv definit ist, lautet die Newton-Richtung $\mathbf{s}^k = \mathbf{s}$ an der Stelle $\mathbf{x}^k$ somit

$$\mathbf{s}^k = -[\nabla^2 f(\mathbf{x}^k)]^{-1} \nabla f(\mathbf{x}^k). \quad (3.34)$$

Des Weiteren ist leicht zu überprüfen, dass die Ungleichung (3.18)

$$\nabla f(\mathbf{x}^k)^\top \mathbf{s}^k = -\nabla f(\mathbf{x}^k)^\top [\nabla^2 f(\mathbf{x}^k)]^{-1} \nabla f(\mathbf{x}^k) < 0. \quad (3.35)$$

stets erfüllt ist, da für positiv definite $\nabla^2 f(\mathbf{x}^k)$ die Inverse ebenfalls positiv definit ist.

Mit Hilfe der Newton-Richtung (3.34) ergibt sich der neue Iterationspunkt $\mathbf{x}^{k+1} = \mathbf{x}^k + \mathbf{s}^k$, was einer "natürlichen" Schrittweite $\alpha^k = 1$ für die Iterationsvorschrift (3.25) des Liniensuchverfahrens entspricht. Die meisten Varianten des Newton-Verfahrens verwenden deshalb standardmäßig eine Schrittlänge von $\alpha^k = 1$, die lediglich reduziert wird, wenn der Abstieg in der Kostenfunktion $f(\mathbf{x}^{k+1})$ unterhalb einer Schranke liegt.

Das Newton-Verfahren ist ein Verfahren zweiter Ordnung, da die Approximation (3.32) die Fehlerordnung $\mathcal{O}(\|\mathbf{s}\|^3)$ besitzt. Es ist zuverlässig und auch für hoch-dimensionale Systeme gut geeignet, wenn die quadratische Approximation der Funktion f an der Stelle $\mathbf{x}^k$ hinreichend genau ist. Abbildung 3.7 illustriert die quadratische Approximationsgüte des Newton-Verfahrens im Vergleich zur steilsten Abstiegsrichtung $-\nabla f$ des Gradientenverfahrens.

Aufgabe 3.3 Zeigen Sie, dass das Newton-Verfahren für quadratische Probleme

$$\min_{\mathbf{x} \in \mathbb{R}^n} \frac{1}{2} \mathbf{x}^\top \mathbf{Q} \mathbf{x} + \mathbf{b}^\top \mathbf{x} + c \quad (\mathbf{Q} \text{ positiv definit}) \quad (3.36)$$

unabhängig vom Startpunkt $\mathbf{x}^0$ innerhalb von einem Iterationsschritt konvergiert.




Abbildung 3.7: Veranschaulichung der Newton-Richtung $\mathbf{s}^k$.

Die Vor- und Nachteile des Newton-Verfahrens sind im Folgenden zusammengefasst:

- + quadratische Konvergenz in der Nähe von $\mathbf{x}^*$ (innerhalb weniger Iterationen)
- + hohe Genauigkeit (Verfahren zweiter Ordnung)
- nur lokale Konvergenz ($\nabla^2 f(\mathbf{x}) > \mathbf{0}$ im Allg. nicht für alle $\mathbf{x}$ gewährleistet)
- aufwendige Berechnung der Hesse-Matrix $\nabla^2 f$, insbesondere bei großen Problemen

Um globale Konvergenz des Newton-Verfahrens zu erreichen, gibt es verschiedene Ansätze, die die Positiv-Definitheit der Hesse-Matrix gewährleisten (z.B. durch Modifikationen), auf die an dieser Stelle aber nicht näher eingegangen wird.

Die aufwendige Berechnung der Hesse-Matrix $\nabla^2 f$ kann durch Approximationen (z.B. finite Differenzen) oder Quasi-Newton-Verfahren vermieden werden, wie im nächsten Abschnitt beschrieben wird.

3.3.5 Quasi-Newton-Verfahren

Quasi-Newton-Verfahren stellen eine attraktive Alternative zum reinen Newton-Verfahren dar, da sie die aufwendige Berechnung der Hesse-Matrix $\nabla^2 f$ und ihrer Inversen vermeiden. Statt dessen wird die Hesse-Matrix approximiert und während der einzelnen Iterationen aktualisiert. Dazu werden Informationen über die Gradienten an den einzelnen Iterationspunkten ausgenutzt, die Informationen über die zweite Ableitung entlang der Suchrichtung liefern.

Um dieses Vorgehen zu illustrieren, wird der Gradient ∇f an der Stelle $\mathbf{x}^k$ durch ein lineares Modell approximiert:

$$\nabla f(\mathbf{x}^k + \mathbf{s}) \approx \nabla f(\mathbf{x}^k) + \nabla^2 f(\mathbf{x}^k) \mathbf{s}. \quad (3.37)$$

Für hinreichend kleine $\mathbf{s} = \mathbf{x}^{k-1} - \mathbf{x}^k$ ergibt sich somit eine Approximationsgleichung für den Gradienten am vorherigen Iterationspunkt $\mathbf{x}^{k-1}$:

$$\nabla f(\mathbf{x}^{k-1}) \approx \nabla f(\mathbf{x}^k) + \nabla^2 f(\mathbf{x}^k)(\mathbf{x}^{k-1} - \mathbf{x}^k). \quad (3.38)$$

Aus diesem Zusammenhang wird ersichtlich, dass die Hesse-Matrix an dem Punkt $\mathbf{x}^k$ durch eine Matrix $\mathbf{H}^k \approx \nabla^2 f(\mathbf{x}^k)$ angenähert werden kann, die die folgende sogenannte *Sekantengleichung* erfüllen muss:

$$\mathbf{H}^k(\mathbf{x}^k - \mathbf{x}^{k-1}) = \nabla f(\mathbf{x}^k) - \nabla f(\mathbf{x}^{k-1}). \quad (3.39)$$

Da es sich hierbei um ein unterbestimmtes Problem handelt ($\mathbf{H}^k$ hat n^2 Elemente, aber (3.39) nur n Gleichungen), werden typischerweise weitere Bedingungen an $\mathbf{H}^k$ gestellt, z.B. Symmetrie und minimale Differenz zwischen $\mathbf{H}^k$ und $\mathbf{H}^{k-1}$. Diese zusätzlichen Bedingungen lassen sich zusammen mit (3.39) in einem Optimierungsproblem für $\mathbf{H}^k$ formulieren, das analytisch gelöst werden kann.

Eine der bekanntesten Formeln zur Aktualisierung von $\mathbf{H}^k$ ist die sogenannte *BFGS-Formel* (nach *Broyden, Fletcher, Goldfarb, Shanno*)

$$\mathbf{H}^k = \mathbf{H}^{k-1} - \frac{\mathbf{H}^{k-1} \mathbf{d}^k (\mathbf{d}^k)^\top \mathbf{H}^{k-1}}{(\mathbf{d}^k)^\top \mathbf{H}^{k-1} \mathbf{d}^k} + \frac{\mathbf{y}^k (\mathbf{y}^k)^\top}{(\mathbf{d}^k)^\top \mathbf{y}^k} \quad (3.40)$$

mit den Abkürzungen

$$\mathbf{d}^k = \mathbf{x}^k - \mathbf{x}^{k-1}, \quad \mathbf{y}^k = \nabla f(\mathbf{x}^k) - \nabla f(\mathbf{x}^{k-1}). \quad (3.41)$$

Die Initialisierung des Quasi-Newton-Verfahrens an der Stelle $\mathbf{x}^0$ erfolgt über eine positiv definite Schätzung $\mathbf{H}^0 \approx \nabla^2 f(\mathbf{x}^0)$ oder im einfachsten Fall mit Hilfe der Einheitsmatrix $\mathbf{H}^0 = \mathbf{I}$.

Da ein Newton-Verfahren die inverse Hesse-Matrix benötigt, um die Suchrichtung $\mathbf{s}^k$ zu berechnen, siehe (3.34), ist es oft sinnvoller, anstelle von $\mathbf{H}^k$ eine Approximation der inversen Hesse-Matrix $\mathbf{B}^k = (\mathbf{H}^k)^{-1}$ zu bestimmen. Die zu der BFGS-Formel (3.40) äquivalente Formel lautet

$$\mathbf{B}^k = [\mathbf{I} - \rho^k \mathbf{d}^k (\mathbf{y}^k)^\top] \mathbf{B}^{k-1} [\mathbf{I} - \rho^k \mathbf{y}^k (\mathbf{d}^k)^\top] + \rho^k \mathbf{d}^k (\mathbf{d}^k)^\top, \quad \rho^k = \frac{1}{(\mathbf{y}^k)^\top \mathbf{d}^k}. \quad (3.42)$$

Somit ergibt sich analog zur Newton-Richtung (3.34) die Suchrichtung

$$\mathbf{s}^k = -\mathbf{B}^k \nabla f(\mathbf{x}^k). \quad (3.43)$$

Quasi-Newton-Verfahren zeichnen sich durch eine schnelle Konvergenz aus, erreichen aber in der Regel nicht die Konvergenzgeschwindigkeit des reinen Newton-Verfahrens. Dafür sind die Vektor-Matrizen-Multiplikationen zur Berechnung von $\mathbf{H}^k$ bzw. $\mathbf{B}^k$ deutlich schneller auszuführen als die Berechnung der Hesse-Matrix $\nabla^2 f$ und ihrer Inversen in (3.34).

Ein weiterer Vorteil gegenüber dem Newton-Verfahren ist, dass Singularitätsprobleme theoretisch nicht auftreten können, da zumindest bei exakter Lösung des Liniensuchproblems (3.20) die Positiv-Definitheit von $\mathbf{H}^k$ bzw. $\mathbf{B}^k$ gewährleistet ist.

Ähnlich wie bei den Konjugierten-Gradienten-Verfahren kann gezeigt werden, dass Quasi-Newton-Verfahren bei quadratischen Problemen

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{Q} \mathbf{x} + \mathbf{b}^\top \mathbf{x} + c, \quad \mathbf{x} \in \mathbb{R}^n$$

mit positiv definiter Hesse-Matrix $\mathbf{Q}$ und exakter Lösung des Liniensuchproblems (3.20) nach höchstens n Iterationen konvergieren.

3.4 Weitere numerische Verfahren

In Folgenden werden weitere Verfahren zur numerischen Lösung von unbeschränkten Optimierungsproblemen vorgestellt. Die *Methode der Vertrauensbereiche* besitzt Ähnlichkeit zu den Liniensuchverfahren im vorherigen Abschnitt, während *direkte Suchverfahren* ohne die Auswertung von Gradienten auskommen.

3.4.1 Methode der Vertrauensbereiche

Anders als die Liniensuchverfahren in Abschnitt 3.3 konstruiert die *Methode der Vertrauensbereiche* (Englisch: *trust region method*) ein lokales vereinfachtes Modell $m^k(\mathbf{s}) \approx f(\mathbf{x}^k)$ der Kostenfunktion $f(\mathbf{x}^k)$ an der Stelle $\mathbf{x}^k$, das anstelle des ursprünglichen Optimierungsproblems (3.1) gelöst wird:

$$\min_{\|\mathbf{s}\| \leq \Delta^k} m^k(\mathbf{s}) \quad \text{mit} \quad m^k(\mathbf{s}) \approx f(\mathbf{x}^k) \quad \text{für} \quad \|\mathbf{s}\| \leq \Delta^k. \quad (3.44)$$

Da das Modell $m^k(\mathbf{s})$ in der Regel nur lokal (für hinreichend kleine $\mathbf{s}$) genau ist, wird die Suche nach dem Minimum von $m^k(\mathbf{s})$ auf einen *Vertrauensbereich* $\|\mathbf{s}\| \leq \Delta^k$ beschränkt.

Das Näherungsmodell m^k wird im Allgemeinen durch eine quadratische Funktion der Form

$$m^k(\mathbf{s}) = \frac{1}{2} \mathbf{s}^\top \mathbf{H}^k \mathbf{s} + \nabla f(\mathbf{x}^k)^\top \mathbf{s} + f(\mathbf{x}^k) \quad (3.45)$$

angesetzt, wobei die Matrix $\mathbf{H}^k$ entweder durch die Hesse-Matrix $\nabla^2 f(\mathbf{x}^k)$ oder eine Approximation davon gegeben ist. Die Lösung $\mathbf{s}^k$ des neuen Optimierungsproblems (3.44) führt zu einem "Kandidaten" für den nächsten Punkt $\mathbf{x}^{k+1} = \mathbf{x}^k + \mathbf{s}^k$. Falls der entsprechende Funktionswert $f(\mathbf{x}^{k+1})$ nicht zu einer hinreichenden Reduktion des vorherigen Kostenfunktionswertes $f(\mathbf{x}^k)$ führt, wird der Vertrauensbereich Δ^k verkleinert und (3.45) erneut gelöst.

Während jeder dieser Iterationen mit abnehmendem Vertrauensbereich Δ^k wird der Abstand zwischen $\mathbf{x}^k$ und dem neuen Kandidaten $\mathbf{x}^{k+1}$ kleiner werden und $\mathbf{s}^k$ in der Regel in eine andere Richtung weisen. Somit unterscheidet sich die Methode der Vertrauensbereiche von den bisherigen Liniensuchverfahren in der Art und Weise, wie die Richtung und Schrittweite zum nächsten Iterationspunkt gewählt wird:

- Liniensuchverfahren fixieren die Suchrichtung $\mathbf{s}^k$ und bestimmen dann eine geeignete Schrittweite α^k .
- In der Methode der Vertrauensbereiche wird zunächst ein maximaler Vertrauensbereich Δ^k gewählt und dann *simultan* die geeignete Richtung und Abstand (also $\mathbf{s}^k$) zum nächsten Iterationspunkt $\mathbf{x}^{k+1}$ bestimmt. Gegebenenfalls wird der Vertrauensbereich verkleinert und die Suche wiederholt.

Der Vertrauensbereich Δ^k wird in jedem Iterationsschritt in Abhängigkeit der Übereinstimmung des Modells m^k und der Kostenfunktion f angepasst. Dazu wird das Verhältnis

$$\rho^k(\mathbf{s}^k) = \frac{f(\mathbf{x}^k) - f(\mathbf{x}^k + \mathbf{s}^k)}{m^k(\mathbf{0}) - m^k(\mathbf{s}^k)} \quad (3.46)$$

eingeführt, das ein Maß für die *Modellgüte* darstellt. Der Zählerterm bezeichnet den tatsächlichen Abstieg in der Kostenfunktion, während der Nennerterm den prädizierten Abstieg wiedergibt. Für $\rho^k \approx 1$ besteht eine gute Übereinstimmung zwischen Modell und Realität in dem momentanen Iterationsschritt, so dass der Vertrauensbereich Δ^k im nächsten Schritt vergrößert werden kann. Falls stattdessen $\rho^k \ll 1$ gilt, sollte Δ^k im nächsten Schritt reduziert werden. Der grundlegende Algorithmus für die Methode der Vertrauensbereiche ist in Tabelle 3.4 angegeben.

Initialization:	$\bar{\Delta}, \Delta^0 \in (0, \bar{\Delta})$	(Vertrauensbereich: Grenz- & Startwert)
	$\eta \in [0, \frac{1}{4})$	(Parameter)
	$k \leftarrow 0$	(Iterationsindex)
	$\varepsilon_x, \varepsilon_{\nabla f}$	(Abbruchkriterien)
repeat		
	$m^k(s) \leftarrow (3.45)$	(Modell)
	$s^k \leftarrow \arg \min \{m^k(s) : \ s\ \leq \Delta^k\}$	(evtl. approximativ gelöst)
	$\rho^k \leftarrow (3.46)$	(Modellgüte)
	if $\rho^k < \frac{1}{4}$ do	
	$\Delta^{k+1} \leftarrow \frac{1}{4}\Delta^k$	(Reduktion)
	else if $\rho^k > \frac{3}{4}$ and $\ s^k\ = \Delta^k$ do	
	$\Delta^{k+1} \leftarrow \min\{2\Delta^k, \bar{\Delta}\}$	(Vergrößerung)
	else	
	$\Delta^{k+1} \leftarrow \Delta^k$	
	end if	
	if $\rho^k > \eta$ do	
	$x^{k+1} \leftarrow x^k + s^k$	(nächster Schritt)
	$H^{k+1} \leftarrow H^k + \dots$	(Aktualisierung der Hesse-Matrix)
	else	
	$x^{k+1} \leftarrow x^k$	(Schritt mit $\Delta^{k+1} < \Delta^k$ wiederholen)
	end if	
	$k \leftarrow k + 1$	
until	$\ \nabla f(x^k)\ \leq \varepsilon_{\nabla f}$	(oder anderes Abbruchkriterium)

Tabelle 3.4: Methode der Vertrauensbereiche.

3.4.2 Direkte Suchverfahren

Die vorhergegangenen sogenannten *ableitungsbehafteten* Lösungsverfahren verwenden Informationen der Gradienten ∇f (und der Hesse-Matrix $\nabla^2 f$ falls verfügbar), um mittels einer Iterationsvorschrift einen neuen Punkt zu bestimmen, der einen hinreichenden Abstieg in der Kostenfunktion ermöglicht.

Allerdings sind in manchen praktischen Fällen die partiellen Ableitungen nicht verfügbar bzw. können nicht approximiert oder mit vertretbarem Aufwand berechnet werden, da das betrachtete Problem zu komplex bzw. nicht stetig differenzierbar ist. Abhilfe verschaffen in diesem Fall sogenannte *direkte* oder *ableitungsfreie Suchverfahren*, die mit Hilfe von Stichproben eine Reihe von Funktionswerten berechnen, um daraus einen neuen Iterationspunkt zu bestimmen.

Eines der bekanntesten und gleichzeitig einfachsten Verfahren in der nichtlinearen Optimierung ist das *Simplex-Verfahren* nach *Nelder* und *Mead*.² Der Algorithmus basiert auf einem *Simplex* im n -dimensionalen Parameterraum, das aus $n + 1$ Punkten $\mathbf{x}^i$, $i = 1, \dots, n + 1$ aufgespannt wird.³ Für $n = 1$ ist dies eine Gerade, für $n = 2$ ein Dreieck, usw.

Für die $n + 1$ Punkte $\mathbf{x}^i$ des Simplex werden die Funktionswerte $f(\mathbf{x}^i)$ berechnet und der Größe nach umsortiert, so dass sich die aufsteigende Folge

$$f(\mathbf{x}^1) \leq f(\mathbf{x}^2) \leq \dots \leq f(\mathbf{x}^{n+1}) \quad (3.47)$$

ergibt. Der Algorithmus ersetzt dann den "schlechtesten" Punkt $\mathbf{x}^{n+1}$ durch einen neuen Punkt nach der Geradengleichung

$$g(a) = \bar{\mathbf{x}} + a(\bar{\mathbf{x}} - \mathbf{x}^{n+1}), \quad \bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}^i. \quad (3.48)$$

in Abhängigkeit eines Parameters a . Der Punkt $\bar{\mathbf{x}}$ stellt den Mittelpunkt (bzw. Schwerpunkt) des restlichen Simplex dar. Das Simplex-Verfahren verwendet verschiedene Abbildungen mittels der Geradengleichung (3.48), um ein geeignetes neues Simplex zu finden: *Reflexion*, *Expansion*, *innere/äußere Kontraktion* und *Schrumpfung*.

- a) **Reflexion** (siehe Abbildung 3.8a):
Bestimme den Reflexionspunkt $\mathbf{x}_r = g(1)$ und $f_r = f(\mathbf{x}_r)$.
Falls $f(\mathbf{x}^1) \leq f_r < f(\mathbf{x}^n)$, setze $\mathbf{x}^{n+1} = \mathbf{x}_r$.
- b) **Expansion** (siehe Abbildung 3.8b):
Falls $f_r < f(\mathbf{x}^1)$, berechne $\mathbf{x}_e = g(2)$ und $f_e = f(\mathbf{x}_e)$.
Falls $f_e < f_r$, setze $\mathbf{x}^{n+1} = \mathbf{x}_e$. Andernfalls setze $\mathbf{x}^{n+1} = \mathbf{x}_r$.
- c) **äußere Kontraktion** (siehe Abbildung 3.8c):
Falls $f(\mathbf{x}^n) \leq f_r < f(\mathbf{x}^{n+1})$, berechne $\mathbf{x}_c = g(1/2)$ und $f_c = f(\mathbf{x}_c)$.
Falls $f_c \leq f_r$, setze $\mathbf{x}^{n+1} = \mathbf{x}_c$. Andernfalls gehe zu Schritt e).
- d) **innere Kontraktion** (siehe Abbildung 3.8d):
Falls $f_r \geq f(\mathbf{x}^{n+1})$, berechne $\mathbf{x}_c = g(-1/2)$ und $f_c = f(\mathbf{x}_c)$.
Falls $f_c < f(\mathbf{x}^{n+1})$, setze $\mathbf{x}^{n+1} = \mathbf{x}_c$. Andernfalls gehe zu Schritt e).
- e) **Schrumpfung** (siehe Abbildung 3.8e):
Komprimiere den Simplex um den "besten" Punkt $\mathbf{x}^1$:
 $\mathbf{x}^i = \frac{1}{2}(\mathbf{x}^1 + \mathbf{x}^i)$, $i = 2, \dots, n + 1$.

Der Algorithmus und die einzelnen Simplexoperationen sind in Tabelle 3.5 und in Abbildung 3.8 dargestellt. Das Simplex-Verfahren wird iterativ fortgesetzt, bis ein Konvergenzkriterium erfüllt ist. Der Simplex wandert dabei in Richtung des Optimums und zieht sich zusammen. Allerdings ist die Konvergenz nicht garantiert und es kann vorkommen, dass das Simplex-Verfahren zu einem nicht-optimalen Punkt konvergiert.⁴ In der Praxis führt das Simplex-Verfahren aber häufig zu guten Ergebnissen, wenn auch nur mit mäßig schneller Konvergenz. Aufgrund der Robustheit und des einfachen Algorithmus ist es ein gebräuchliches Optimierungsverfahren.

² Das Simplex-Verfahren nach Nelder und Mead unterscheidet sich grundsätzlich vom Simplex-Algorithmus in der Linearen Programmierung, der von G. Danzig eingeführt wurde!

³ Der bisher verwendete Iterationsindex k wird der Einfachheit halber vernachlässigt.

⁴ Es kann versucht werden, den Algorithmus mit einem neuen Simplex an der letzten Stelle neu zu starten.

Initialization: $\mathbf{x}^i, \dots, \mathbf{x}^{n+1}$ (Startsimplex)
 $\varepsilon_x, \varepsilon_f > 0$ (Abbruchkriterium)

repeat

Sortierung (3.47)
 $\bar{\mathbf{x}} \leftarrow (3.48)$ (Mittelpunkt)
 Austausch von $\mathbf{x}^{n+1}$ (Reflexion/Expansion/Kontraktion)
 bzw. von $\mathbf{x}^i, i = 2, \dots, n + 1$ (Schrumpfung)

until $\max_{2 \leq i \leq n+1} \|\mathbf{x}^i - \mathbf{x}^1\| \leq \varepsilon_x$ **or** $f(\mathbf{x}^{n+1}) - f(\mathbf{x}^1) \leq \varepsilon_f$

Tabelle 3.5: Simplex-Verfahren nach Nelder und Mead.




Abbildung 3.8: Operationen des Simplex-Verfahrens nach Nelder und Mead.

3.5 Beispiel: Rosenbrock's "Bananenfunktion"

Ein bekanntes Beispiel in der Optimierung ist das *Rosenbrock*-Problem

$$\min_{\mathbf{x} \in \mathbb{R}^2} f(\mathbf{x}) \quad \text{mit} \quad f(\mathbf{x}) = 100(x_2 - x_1^2)^2 + (x_1 - 1)^2. \quad (3.49)$$

Abbildung 3.9 zeigt das Profil und die Höhenlinien der Funktion, die auch als *Bananenfunktion* bezeichnet wird. Das Rosenbrock-Problem soll als Beispiel verwendet werden, um die Konvergenzeigenschaften der behandelten Verfahren numerisch mit Hilfe von MATLAB zu untersuchen.




Abbildung 3.9: Profil und Höhenlinien von Rosenbrock's Bananenfunktion.

Aufgabe 3.4 Verifizieren Sie, dass der Punkt $\mathbf{x}^* = [1, 1]^T$ ein eindeutiges Minimum darstellt. Sind die Funktion $f(\mathbf{x})$ und das Optimierungsproblem (3.49) konvex?

Zur Lösung von unbeschränkten Optimierungsproblemen stellt die *Optimization Toolbox* von MATLAB die folgenden Funktionen zur Verfügung

- `fminunc`: Liniensuche: Gradientenverfahren, Quasi-Newton-Verfahren
Methode der Vertrauensbereiche: Newton-Verfahren
- `fminsearch`: Simplex-Verfahren nach Nelder und Mead.

Eine Alternative ist die frei zugängliche MATLAB-Funktion `minFunc` [5], die eine große Auswahl an Liniensuchverfahren bietet. Tabelle 3.6 zeigt einige Vergleichsdaten für die numerische Lösung des Rosenbrock-Problems (ausgehend vom Startwert $\mathbf{x}^0 = [-1, -1]^T$), die mit Hilfe von `fminunc`, `fminsearch` und `minFunc` berechnet wurden.

Abbildung 3.10 stellt zusätzlich die Iterationsverläufe für die Verfahren dar, die unter `fminunc` und `fminsearch` implementiert sind. Der Vollständigkeit halber ist in Abbildung 3.12 am Ende des Kapitels der MATLAB-Code für das Rosenbrock-Problem (3.49) angegeben, um zu verdeutlichen, wie die einzelnen Optimierungsverfahren mit `fminunc` und `fminsearch` angesprochen werden können.

Beim Gradientenverfahren fällt die langsame Konvergenz auf, da auch nach dem Erreichen der maximalen Anzahl an Funktionsauswertungen (200) das Minimum noch nicht erreicht ist. In Abbildung 3.11 ist der Iterationsverlauf des Gradientenverfahrens noch einmal detailliert über die Höhenlinien der Rosenbrock-Funktion (3.49) dargestellt. Erkennbar ist, dass sich das Gradientenverfahren an der maximalen Abstiegsrichtung orientiert, die senkrecht zu der jeweiligen Höhenlinie verläuft. In Richtung des Minimums werden die Iterationsschritte immer kleiner. Die niedrige Konvergenzgeschwindigkeit wurde bereits in Abbildung 3.6 veranschaulicht und soll in der folgenden Aufgabe näher untersucht werden:

Aufgabe 3.5 Berechnen Sie für das Minimum $\mathbf{x}^* = [1, 1]^T$ des Rosenbrock-Problems (3.49) die Konvergenzrate des Gradientenverfahrens gemäß Satz 3.4.

Verfahren	Iter.	$f(\mathbf{x}^*)$	$\nabla f(\mathbf{x}^*)$	Funktionsaufrufe:		
				$f(\mathbf{x})$	$\nabla f(\mathbf{x})$	$\nabla^2 f(\mathbf{x})$
LS: Gradientenverfahren	57	0.1232	1.1978	200	200	-
LS: Konj.-Grad.-Verf.	31	$4.1 \cdot 10^{-17}$	$6.9 \cdot 10^{-9}$	91	90	-
LS: Newton-Verfahren	21	$3.5 \cdot 10^{-17}$	$3.5 \cdot 10^{-8}$	29	28	24
LS: Quasi-Newton (BFGS)	23	$5.4 \cdot 10^{-12}$	$9.2 \cdot 10^{-6}$	29	29	-
VB: Newton-Verfahren	25	$2.2 \cdot 10^{-18}$	$2.1 \cdot 10^{-8}$	26	26	26
Simplex-Verf. (Nelder-Mead)	67	$5.3 \cdot 10^{-10}$	-	125	-	-

Tabelle 3.6: Vergleich der numerischen Verfahren für das Rosenbrock-Problem (LS=Liniensuche, VB=Methode der Vertrauensbereiche).




Abbildung 3.10: Rosenbrock's Bananenfunktion: Vergleich der numerischen Verfahren mit `fminunc` und `fminsearch`.

Das Konvergenzverhalten des Quasi-Newton-Verfahrens in Abbildung 3.10 ist wesentlich besser als beim Gradientenverfahren. Das Newton-Verfahren (Methode der Vertrauensbereiche) in Abbildung 3.10 startet zunächst in die "falsche" Richtung, was durch die quadratische Approximation (3.45) am Startpunkt $\mathbf{x}^0 = [-1, 1]^T$ zu erklären ist, dessen Minimum in der Nähe von $\mathbf{x} \approx [-1, 1]^T$ liegt. Allerdings sind die einzelnen Schritte entlang des Tales der Rosenbrock-Funktion deutlich größer, da das Newton-Verfahren die Hesse-Matrix explizit verwendet und




Abbildung 3.11: Darstellung der Iterationen des Gradientenverfahrens.

nicht auf eine Approximation angewiesen ist wie im Fall des Quasi-Newton-Verfahrens.

Zusätzlich sind in Tabelle 3.6 und Abbildung 3.10 die Ergebnisse für das Simplex-Verfahren von Nelder-Mead angegeben, die mit der MATLAB-Funktion `fminsearch` erzielt wurden. Allerdings bietet die Grafikausgabe unter `fminsearch` nicht die Möglichkeit, die einzelnen Simplexe darzustellen. In der nächsten Aufgabe soll das Simplex-Verfahren deshalb näher untersucht werden, um einen Eindruck von den Simplex-Operationen und der Robustheit des Verfahrens zu erhalten.

Aufgabe 3.6 Schreiben Sie eine MATLAB-Funktion, die das Rosenbrock-Problem (3.49) mit Hilfe des Simplex-Verfahrens nach Nelder-Mead numerisch löst (siehe Abschnitt 3.4.2). Konstruieren Sie den ersten Simplex mit den Eckpunkten

$$\mathbf{x}^{0,1} = \begin{bmatrix} -1 \\ -1 \end{bmatrix}, \quad \mathbf{x}^{0,2} = \mathbf{x}^{0,1} + s \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{x}^{0,3} = \mathbf{x}^{0,1} + s \begin{bmatrix} 0 \\ 1 \end{bmatrix} \quad (3.50)$$

in Abhängigkeit der Seitenlänge $s = 1$. Verwenden Sie für die Abbruchbedingung in Tabelle 3.5 die Schranke $\varepsilon = 10^{-9}$ und vergleichen Sie Ihre Ergebnisse mit den `fminsearch`-Ergebnissen in Tabelle 3.6. Stellen Sie die Simplexe aus den einzelnen Iterationen grafisch dar. Untersuchen Sie die Robustheit und das Konvergenzverhalten des Simplex-Verfahrens für verschiedene Seitenlängen s des Startsimplex und unterschiedliche Startpunkte $\mathbf{x}^{0,1}$.

Aufgabe 3.7 (optional) Schreiben Sie eine MATLAB-Funktion, die das Rosenbrock-Problem (3.49) mit Hilfe des Newton-Verfahrens (Liniensuche) löst, siehe Abschnitt 3.3.4. Verwenden Sie zur Bestimmung der Schrittweite α^k das Backtracking-Verfahren mit dem Startwert $\alpha = 1$ und der Armijo-Bedingung (3.21) als Abbruchkriterium für die Schrittweitenbestimmung. Vergleichen Sie die Konvergenzergebnisse mit den Werten in Tabelle 3.6. Stellen Sie die einzelnen Iterationen grafisch dar und variieren Sie die Startpunkte $\mathbf{x}^0$.

```

function Xopt = rosenbrock_problem(Xinit,methodQ)
% -----
% Xinit:    initial point
% methodQ:  1 - line search: gradient method
%           2 - line search: quasi-Newton
%           3 - trust region method (Newton)
%           4 - Nelder-Mead simplex method
global old
old = [Xinit; rosenbrock(Xinit)];

% options for optimization
opt1 = optimoptions('fminunc','Display','iter','PlotFcns',@plot_iterates);
opt2 = optimset('Display','iter','PlotFcns',@plot_iterates);

switch methodQ
case 1,      % line search: gradient method
    opt1 = optimoptions(opt1,'HessUpdate','steepdesc','GradObj','on');
case 2,      % line search: quasi-Newton
    opt1 = optimoptions(opt1,'Algorithm','quasi-newton','GradObj','on');
case 3,      % trust region method (Newton)
    opt1 = optimoptions(opt1,'Algorithm','trust-region','Hessian','on','GradObj','on');
end

if methodQ<4,    Xopt = fminunc(@rosenbrock,Xinit,opt1);      % numeric solution with
else            Xopt = fminsearch(@rosenbrock,Xinit,opt2);    % fminunc or fminsearch
end

function [f, grad, H] = rosenbrock(x)
% -----
grad = {}; H = {};
f = 100*(x(2)-x(1)^2)^2 + (x(1)-1)^2;      % Rosenbrock function
if nargin>1,                               % if gradient is requested
    grad = [ -400*(x(2)-x(1)^2)*x(1)+2*(x(1)-1);
             200*(x(2)-x(1)^2) ];
end
if nargin>2,                               % if Hessian is requested
    H = [ -400*(x(2)-3*x(1)^2)+2,    -400*x(1);
          -400*x(1),                200 ];
end

function stop = plot_iterates(x,info,state)
% -----
global old
f = rosenbrock(x);
switch state
case 'init',                               % graphical output:
    plot_surface(x,f);                     % initialization
case 'iter',                               % iterations
    plot3([old(1),x(1)],[old(2),x(2)],[old(3),f],'b-o','LineWidth',1);
case 'done',                               % after last iterations
    plot3(x(1),x(2),f,'go','LineWidth',5);
end
stop = false;                             % no stopping criterion
old = [x,f];

function plot_surface(x,f)
% -----
[X1,X2] = meshgrid(-1.5:0.15:1.5);
F = 100*(X2-X1.^2).^2 + (X1-1).^2;          % 3D profile of
                                           % Rosenbrock function
h = surf(X1,X2,F,'EdgeColor',0.6*[1,1,1],'FaceColor','none');
hold on; axis tight;
plot3(x(1),x(2),f,'ko','LineWidth',5);    % initial point
plot3(1,1,0,'ro','LineWidth',5);          % optimal solution
xlabel('x_1'); ylabel('x_2'); zlabel('f')
set(gcf,'ToolBar','figure');              % figure settings
set(gca,'Xdir','reverse','Ydir','reverse');

```

Abbildung 3.12: MATLAB-Code für das Rosenbrock-Problem (fminunc, fminsearch).

3.6 Literatur

- [1] S. Boyd und L. Vandenberghe. *Convex Optimization*. http://www.stanford.edu/~boyd/cvxbook/bv_cvxbook.pdf. Cambridge: Cambridge University Press, 2004.
- [2] C.T. Kelley. *Iterative Methods for Optimization*. Society for Industrial und Applied Mathematics (SIAM), 1999.
- [3] J. Nocedal und S.J. Wright. *Numerical Optimization*. New York: Springer, 2006.
- [4] M. Papageorgiou, M. Leibold und M. Buss. *Optimierung*. Berlin: Springer, 2012.
- [5] Mark Schmidt. *minFunc (MATLAB-Funktion zur Lösung unbeschränkter Optimierungsprobleme)*. University of British Columbia, Vancouver, Kanada. Available at <https://www.cs.ubc.ca/~schmidtm/Software/minFunc.html>.

4 Statische Optimierung mit Beschränkungen

In diesem Kapitel werden beschränkte Optimierungsprobleme

$$\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) \quad (4.1a)$$

$$\text{u.B.v. } g_i(\mathbf{x}) = 0, \quad i = 1, \dots, p \quad (4.1b)$$

$$h_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, q \quad (4.1c)$$

mit den Gleichungs- und Ungleichungsbeschränkungen (4.1b), (4.1c) betrachtet. Die notwendigen und hinreichenden Optimalitätsbedingungen des unbeschränkten Falls (Kapitel 3) müssen dafür entsprechend erweitert werden.

4.1 Einführende Beispiele

Zur Veranschaulichung wird Beispiel 1.2 aus Kapitel 1 verwendet und die einzelnen Beschränkungen (1.10)-(1.12) sukzessive betrachtet, um die Erweiterungen gegenüber dem unbeschränkten Fall sowie die Unterschiede zwischen Gleichungs- und Ungleichungsbeschränkungen herzuleiten.

4.1.1 Eine Gleichungsbeschränkung

Beispiel 4.1 Betrachtet wird das Optimierungsproblem (1.9) mit der Gleichungsbeschränkung (1.10):

$$\min_{\mathbf{x} \in \mathbb{R}^2} f(\mathbf{x}) = (x_1 - 2)^2 + (x_2 - 1)^2 \quad (4.2a)$$

$$\text{u.B.v. } g(\mathbf{x}) = x_2 - 2x_1 = 0. \quad (4.2b)$$

Abbildung 4.1 stellt die Gerade $g(\mathbf{x}) = 0$ und Höhenlinien von $f(\mathbf{x})$ dar. Da optimale Punkte $\mathbf{x}^*$ auf der Geraden $g(\mathbf{x}) = 0$ liegen müssen, existieren z.B. für die Höhenlinie $f(\mathbf{x}) = 4$ zwei Schnittpunkte. Es ist direkt ersichtlich, dass für Höhenlinien mit $f(\mathbf{x}) < 4$ die Schnittpunkte dichter zusammenwandern und schließlich zum Minimum

$$\mathbf{x}^* = [0.8, 1.6]^T, \quad f(\mathbf{x}^*) = 1.8 \quad (4.3)$$

führen. Eine wichtige Rolle spielen dabei die Gradienten der Funktionen $f(\mathbf{x})$ und $g(\mathbf{x})$

$$\nabla f(\mathbf{x}) = \begin{bmatrix} 2(x_1 - 2) \\ 2(x_2 - 1) \end{bmatrix}, \quad \nabla g(\mathbf{x}) = \begin{bmatrix} -2 \\ 1 \end{bmatrix}. \quad (4.4)$$




Abbildung 4.1: Veranschaulichung einer Gleichungsbeschränkung (Beispiel 4.1).

Bei allen nicht-optimalen Punkten auf der Geraden $g(\mathbf{x}) = 0$ sind ∇f und ∇g nicht kollinear, d.h. es existiert eine Komponente von $-\nabla f$ (maximale Abstiegsrichtung) in Richtung der Geraden $g(\mathbf{x}) = 0$, die zu einer Abnahme der Kostenfunktion f unter Einhaltung der Gleichungsbeschränkung $g(\mathbf{x}) = 0$ führt. Am optimalen Punkt $\mathbf{x}^*$ sind dagegen die Gradientenvektoren

$$\nabla f(\mathbf{x}^*) = \begin{bmatrix} -2.4 \\ 1.2 \end{bmatrix}, \quad \nabla g(\mathbf{x}^*) = \begin{bmatrix} -2 \\ 1 \end{bmatrix} \quad (4.5)$$

kollinear, d.h., es gilt $\nabla f(\mathbf{x}^*) \parallel \nabla g(\mathbf{x}^*)$ bzw.

$$0 = \nabla f(\mathbf{x}^*) + \lambda^* \nabla g(\mathbf{x}^*) \quad \text{mit} \quad \lambda^* = -1.2. \quad (4.6)$$

Das Ergebnis des Beispiels kann mit Hilfe der *Lagrange-Funktion*

$$L(\mathbf{x}, \lambda) = f(\mathbf{x}) + \lambda g(\mathbf{x}) \quad (4.7)$$

verallgemeinert werden. Dabei wird die Gleichungsbeschränkung mit Hilfe eines *Lagrange-Multiplikators* λ zu der Kostenfunktion $f(\mathbf{x})$ addiert. Die Kollinearität der Gradienten ∇f und ∇g an einem optimalen Punkt $\mathbf{x}^*$ ergibt sich dann aus der *Stationaritätsbedingung*

$$\nabla_{\mathbf{x}} L(\mathbf{x}^*, \lambda^*) = \nabla f(\mathbf{x}^*) + \lambda^* \nabla g(\mathbf{x}^*) = 0. \quad (4.8)$$

Zusammen mit der Gleichungsbeschränkung $g(\mathbf{x}^*) = 0$ erhält man ein Gleichungssystem der Ordnung $n + 1$ für die $n + 1$ Unbekannten $\mathbf{x}^* \in \mathbb{R}^n$ und $\lambda^* \in \mathbb{R}$. Allerdings sei angemerkt, dass es sich bei (4.8) lediglich um eine *notwendige* und keine *hinreichende* Bedingung für Optimalität handelt.

4.1.2 Eine Ungleichungsbeschränkung

Beispiel 4.2 Anstelle der Gleichungsbeschränkung (1.10) wird nun die Ungleichungsbeschränkung (1.11) betrachtet

$$\min_{\mathbf{x} \in \mathbb{R}^2} \quad f(\mathbf{x}) = (x_1 - 2)^2 + (x_2 - 1)^2 \quad (4.9a)$$

$$\text{u.B.v.} \quad h(\mathbf{x}) = x_1 + x_2 - 2 \leq 0. \quad (4.9b)$$




Abbildung 4.2: Veranschaulichung einer Ungleichungsbeschränkung (Beispiel 4.2).

Abbildung 4.2 zeigt den optimalen Punkt $\mathbf{x}^* = [1.5, 0.5]^T$, der auf dem Rand der zulässigen Menge

$$\mathcal{X}_{ad} = \{\mathbf{x} \in \mathbb{R}^2 : h(\mathbf{x}) \leq 0\}$$

liegt. Die Beschränkung (4.9b) ist somit aktiv, d.h. $h(\mathbf{x}^*) = 0$ und die Gradienten $\nabla f(\mathbf{x}^*) = [-1, -1]^T$ und $\nabla h(\mathbf{x}^*) = [1, 1]^T$ sind kollinear am optimalen Punkt $\mathbf{x}^*$.

Für alle anderen Punkte, bei denen die Beschränkung (4.9b) aktiv ist, existiert eine Komponente der maximalen Abstiegsrichtung $-\nabla f$ in Richtung von $h(\mathbf{x}) = 0$, die zu einer Abnahme der Kostenfunktion f unter Einhaltung der aktiven Ungleichungsbeschränkung (4.9b) führt, siehe Abbildung 4.2.

Eine wichtige Eigenschaft an dieser Stelle ist, dass der negative Gradient $-\nabla h$ einer aktiven Ungleichungsbeschränkung $h(\mathbf{x}) = 0$ in die Richtung der zulässigen Menge $\mathcal{X}_{ad}$ weist.

Allgemein kann eine Ungleichungsbeschränkung $h(\mathbf{x}) \leq 0$ wie im vorherigen Fall durch die Lagrange-Funktion

$$L(\mathbf{x}, \mu) = f(\mathbf{x}) + \mu h(\mathbf{x}) \quad (4.10)$$

berücksichtigt werden, wobei an dieser Stelle unterschieden werden muss, ob im optimalen Punkt $\mathbf{x}^*$ die Beschränkung $h(\mathbf{x}) \leq 0$ aktiv ist oder nicht. Falls $h(\mathbf{x}^*) < 0$ gilt, muss $\mathbf{x}^*$ dem unbeschränkten Minimum entsprechen, es muss also gelten

$$\nabla_{\mathbf{x}} L(\mathbf{x}^*, \mu^*) = \nabla f(\mathbf{x}^*) = 0 \quad \text{mit} \quad \mu^* = 0. \quad (4.11)$$

Im Falle einer aktiven Beschränkung kann $h(\mathbf{x}) = 0$ als Gleichungsbeschränkung betrachtet werden, d.h. die Gradienten ∇f und ∇h müssen im optimalen Punkt $\mathbf{x}^*$ kollinear sein. Dies kann mit Hilfe der Lagrange-Funktion (4.10) durch

$$\nabla_{\mathbf{x}} L(\mathbf{x}^*, \mu^*) = \nabla f(\mathbf{x}^*) + \mu^* \nabla h(\mathbf{x}^*) = 0 \quad (4.12)$$

ausgedrückt werden. Allerdings spielt an dieser Stelle das Vorzeichen des Lagrange-Multiplikators μ^* eine wichtige Rolle. Um dies zu untersuchen, wird die Funktion $h(\mathbf{x})$ in eine Taylorreihe 1. Ordnung entwickelt:

$$h(\mathbf{x} + \mathbf{s}) = h(\mathbf{x}) + \nabla h(\mathbf{x})^T \mathbf{s} + \mathcal{O}(\|\mathbf{s}\|^2).$$




Abbildung 4.3: Geometrische Interpretation der Bedingungen (4.13) und (4.14) für eine aktive Ungleichungsbeschränkung im $\mathbb{R}^2$.

Im Falle einer aktiven Beschränkung $h(\mathbf{x}) = 0$ muss eine (hinreichend kleine) zulässige Richtung $\mathbf{s}$ die Ungleichung $h(\mathbf{x} + \mathbf{s}) \leq 0$ erfüllen, d.h.

$$\nabla h(\mathbf{x})^T \mathbf{s} \leq 0. \quad (4.13)$$

Analog dazu wird die Kostenfunktion $f(\mathbf{x})$ in eine Taylorreihe entwickelt

$$f(\mathbf{x} + \mathbf{s}) = f(\mathbf{x}) + \nabla f(\mathbf{x})^T \mathbf{s} + \mathcal{O}(\|\mathbf{s}\|^2).$$

Wenn der Punkt $\mathbf{x}$ kein Minimum $\mathbf{x}^*$ darstellt, muss es eine Abstiegsrichtung $\mathbf{s}$ mit $f(\mathbf{x} + \mathbf{s}) < f(\mathbf{x})$ geben, d.h.

$$\nabla f(\mathbf{x})^T \mathbf{s} < 0 \quad (4.14)$$

gelten und gleichzeitig (4.13) erfüllt sein. Im Umkehrschluss bedeutet dies: falls $\mathbf{x}^*$ ein Minimum am Rand $h(\mathbf{x}^*) = 0$ darstellt, so darf es keine Richtung $\mathbf{s}$ geben, die *beide* Bedingungen (4.13), (4.14) erfüllt. Dieser Umstand ist in Abbildung 4.3 für einen nicht-optimalen Punkt $\mathbf{x}$ veranschaulicht.

Aus Abbildung 4.3 ist ersichtlich, dass es nur dann keine zulässige Richtung $\mathbf{s}$ gibt, die beide Ungleichungen (4.13), (4.14) erfüllt, wenn $-\nabla f$ und ∇h in die gleiche Richtung weisen, d.h.

$$-\nabla f(\mathbf{x}^*) = \mu^* \nabla h(\mathbf{x}^*) \quad \text{mit} \quad \mu^* \geq 0. \quad (4.15)$$

Mit anderen Worten: falls (4.15) gilt, existiert keine zulässige Richtung $\mathbf{s}$, die zu einer Verringerung der Kostenfunktion $f(\mathbf{x}^* + \mathbf{s})$ führt, ohne die aktive Beschränkung $h(\mathbf{x}^*) = 0$ zu verletzen.

Das Vorzeichen von μ^* ist wichtig in diesem Zusammenhang und kann anhand von Abbildung 4.3 erklärt werden. Falls $\mu^* < 0$ wäre, würden ∇f und ∇h in die gleiche Richtung weisen, und eine ganze Halbebene an zulässigen Richtungen $\mathbf{s}$ würde entstehen, die zu einer Abnahme von f führen würde, während die Beschränkung $h(\mathbf{x}) \leq 0$ eingehalten wäre.

Die Bedingungen für ein Minimum an der Stelle $\mathbf{x}^*$ lassen sich wie folgt zusammenfassen:

$$\exists \mu^* \geq 0 : \quad \nabla_{\mathbf{x}} L(\mathbf{x}^*, \mu^*) = 0, \quad \mu^* h(\mathbf{x}^*) = 0 \quad (4.16)$$

Die Gleichung $\mu^* h(\mathbf{x}^*) = 0$ drückt in einer kompakten Schreibweise die Bedingung $\mu^* = 0$ im Falle einer inaktiven Beschränkung $h(\mathbf{x}^*) < 0$ aus und wird als *Komplementaritätsbedingung* bezeichnet.




Abbildung 4.4: Geometrische Interpretation der Bedingungen (4.18) und (4.19) für zwei aktive Ungleichungsbeschränkungen im $\mathbb{R}^2$.

4.1.3 Zwei Ungleichungsbeschränkungen

Im Folgenden sollen zwei Ungleichungsbeschränkungen betrachtet werden:

$$\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) \quad (4.17a)$$

$$\text{u.B.v. } h_1(\mathbf{x}) \leq 0 \quad (4.17b)$$

$$h_2(\mathbf{x}) \leq 0. \quad (4.17c)$$

Analog zum vorhergehenden Fall mit einer Beschränkung muss an Punkten $\mathbf{x}$ an denen beide Beschränkungen aktiv sind, d.h. $h_1(\mathbf{x}) = 0$ und $h_2(\mathbf{x}) = 0$ gilt, eine zulässige Richtung $\mathbf{s}$ die Bedingung (4.13)

$$\nabla h_1(\mathbf{x})^T \mathbf{s} \leq 0, \quad \nabla h_2(\mathbf{x})^T \mathbf{s} \leq 0 \quad (4.18)$$

erfüllen. Die Bedingungen (4.18) lassen sich für $\mathbf{x} \in \mathbb{R}^2$ anschaulich erklären, da in diesem Fall zulässige Richtungen $\mathbf{s}$ in dem Kegel liegen müssen, der durch die Tangenten an die Kurven $h_1(\mathbf{x}) = 0$ und $h_2(\mathbf{x}) = 0$ aufgespannt wird, siehe Abbildung 4.4.

Falls der Punkt $\mathbf{x}$ kein Minimum darstellt, muss es Richtungen $\mathbf{s}$ geben, die die Abstiegsbedingung (4.14)

$$\nabla f(\mathbf{x})^T \mathbf{s} < 0 \quad (4.19)$$

erfüllen. Im Umkehrschluss darf an einem Minimum $\mathbf{x}^*$ keine Richtung $\mathbf{s}$ existieren, die gleichzeitig (4.18) und (4.19) erfüllt. Dies ist genau dann der Fall, wenn der negative Gradient $-\nabla f(\mathbf{x}^*)$ in den Kegel weist, der durch die Gradienten $\nabla h_1(\mathbf{x}^*)$ und $\nabla h_2(\mathbf{x}^*)$ aufgespannt wird. Abbildung 4.4c) veranschaulicht diesen Zusammenhang für $\mathbf{x} \in \mathbb{R}^2$.

Somit muss der negative Gradient $-\nabla f(\mathbf{x}^*)$ an einem Minimum $\mathbf{x}^*$ mit zwei aktiven Ungleichungsbeschränkungen eine *positive* Linearkombination der Gradienten der Beschränkungsfunktionen sein:

$$\exists \mu_1^*, \mu_2^* \geq 0 : \quad -\nabla f(\mathbf{x}^*) = \mu_1^* \nabla h_1(\mathbf{x}^*) + \mu_2^* \nabla h_2(\mathbf{x}^*). \quad (4.20)$$

Analog zu den vorherigen Abschnitten können die notwendigen Bedingungen für ein lokales Minimum $\mathbf{x}^*$ wieder mit der Lagrange-Funktion

$$L(\mathbf{x}, \boldsymbol{\mu}) = f(\mathbf{x}) + \mu_1 h_1(\mathbf{x}) + \mu_2 h_2(\mathbf{x}), \quad \boldsymbol{\mu} = [\mu_1, \mu_2]^T \quad (4.21)$$

angegeben werden:

$$\exists \mu_1^*, \mu_2^* \geq 0 : \quad \nabla_x L(\mathbf{x}^*, \boldsymbol{\mu}^*) = 0, \quad \mu_1^* h_1(\mathbf{x}^*) = 0, \quad \mu_2^* h_2(\mathbf{x}^*) = 0. \quad (4.22)$$

Die beiden Komplementaritätsbedingungen in (4.22) sind erfüllt, falls entweder die entsprechende Beschränkung $h_i(\mathbf{x}^*) \leq 0$ aktiv oder der Lagrange-Multiplikator $\mu_i^* = 0$ ist.

Aufgabe 4.1 Als Erweiterung von Beispiel 4.2 wird die zweite Ungleichungsbeschränkung (1.12) betrachtet

$$\min_{\mathbf{x} \in \mathbb{R}^2} \quad f(\mathbf{x}) = (x_1 - 2)^2 + (x_2 - 1)^2 \quad (4.23a)$$

$$\text{u.B.v.} \quad h_1(\mathbf{x}) = x_1 + x_2 - 2 \leq 0 \quad (4.23b)$$

$$h_2(\mathbf{x}) = x_1^2 - x_2 \leq 0. \quad (4.23c)$$

Berechnen Sie für den optimalen Punkt $\mathbf{x}^* = [1, 1]^T$ die Lagrange-Multiplikatoren μ_1^* , μ_2^* und überprüfen Sie die Vorzeichenbedingung (4.20) grafisch.

4.2 Optimalitätsbedingungen

Die Ergebnisse aus dem vorherigen Abschnitt lassen sich auf den allgemeinen Fall

$$\min_{\mathbf{x} \in \mathbb{R}^n} \quad f(\mathbf{x}) \quad (4.24a)$$

$$\text{u.B.v.} \quad g_i(\mathbf{x}) = 0, \quad i = 1, \dots, p \quad (4.24b)$$

$$h_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, q \quad (4.24c)$$

mit p Gleichungs- und q Ungleichungsbeschränkungen übertragen.

4.2.1 Beschränkungsqualifikation

Aus dem betrachteten Beispiel mit der Gleichungsbeschränkung $g(\mathbf{x}) = 0$ (Abschnitt 4.1.1) ist ersichtlich, dass die $n + 1$ Gleichungen

$$g(\mathbf{x}) = 0, \quad \nabla_x L(\mathbf{x}, \lambda) = \nabla f(\mathbf{x}) + \lambda \nabla g(\mathbf{x}) = 0$$

zusammen betrachtet werden müssen, um den Punkt $\mathbf{x} \in \mathbb{R}^n$ und $\lambda \in \mathbb{R}$ bestimmen zu können. Das Gleiche gilt auch im Falle einer aktiven Ungleichungsbeschränkung $h(\mathbf{x}) = 0$, um $\mathbf{x} \in \mathbb{R}^n$ und $\mu \in \mathbb{R}$ aus den Gleichungen

$$h(\mathbf{x}) = 0, \quad \nabla_x L(\mathbf{x}, \mu) = \nabla f(\mathbf{x}) + \mu \nabla h(\mathbf{x}) = 0$$

zu erhalten. Für das allgemeine Optimierungsproblem (4.24) mit p Gleichungs- und q Ungleichungsbeschränkungen muss deshalb eine zusätzliche Annahme für aktive Beschränkungen getroffen werden. Dafür wird die folgende Definition verwendet:

Definition 4.1 (Menge aktiver Ungleichungsbeschränkungen) Die Menge aktiver Ungleichungsbeschränkungen des Optimierungsproblems (4.24) an einem Punkt $\mathbf{x}$ ist definiert durch

$$\mathcal{A}(\mathbf{x}) = \{i \in \{1, \dots, q\} \mid h_i(\mathbf{x}) = 0\}. \quad (4.25)$$

Die sogenannte *Beschränkungsqualifikation* (Englisch: *constraint qualification*) fordert, dass die Gradienten der aktiven Ungleichungsbeschränkungen und der Gleichungsbeschränkungen linear unabhängig sind

$$\text{Rang} \begin{bmatrix} \nabla \mathbf{g}(\mathbf{x}) \\ \nabla \mathbf{h}_{\mathcal{A}(\mathbf{x})}(\mathbf{x}) \end{bmatrix} = p + |\mathcal{A}(\mathbf{x})|. \quad (4.26)$$

Die vektorielle Gradientennotation $\nabla \mathbf{g}(\mathbf{x})$ bedeutet $\nabla \mathbf{g}(\mathbf{x}) = [\nabla g_1(\mathbf{x}), \dots, \nabla g_p(\mathbf{x})]^\top$. Analog dazu ist der zweite Term $\nabla \mathbf{h}_{\mathcal{A}(\mathbf{x})}(\mathbf{x})$ zu verstehen, wobei die Vektorfunktion $\mathbf{h}_{\mathcal{A}(\mathbf{x})}$ die im Punkt $\mathbf{x}$ aktiven Ungleichungsbeschränkungen darstellt:

$$\mathbf{h}_{\mathcal{A}(\mathbf{x})}(\mathbf{x}) = [h_i(\mathbf{x})]_{i \in \mathcal{A}(\mathbf{x})} \quad (4.27)$$

Die Rangbedingung (4.26) besagt, dass maximal $n - p$ Ungleichungsbeschränkungen am gleichen Punkt $\mathbf{x}$ aktiv sein dürfen. Wäre dies nicht der Fall, würde das Gleichungssystem bestehend aus $\mathbf{g}(\mathbf{x}) = 0$ und $\mathbf{h}_{\mathcal{A}(\mathbf{x})}(\mathbf{x}) = 0$ mehr als n Gleichungen umfassen und wäre somit überbestimmt.

Die Beschränkungsqualifikation (4.26) betrifft die lineare Unabhängigkeit der aktiven Beschränkungen und ist die gebräuchlichste Bedingung dieser Art in der Optimierung. Allerdings sei angemerkt, dass (4.26) nicht notwendig, sondern nur *hinreichend* ist und in manchen Fällen zu konservativ sein kann. Weitere Beschränkungsqualifikationen können in der Literatur gefunden werden.

4.2.2 Optimalitätsbedingungen 1. Ordnung

Definition 4.2 (Lagrange-Funktion) Die Lagrange-Funktion für das Optimierungsproblem (4.24) ist

$$L(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\mu}) = f(\mathbf{x}) + \sum_{i=1}^p \lambda_i g_i(\mathbf{x}) + \sum_{i=1}^q \mu_i h_i(\mathbf{x}) \quad (4.28)$$

mit den Lagrange-Multiplikatoren $\boldsymbol{\lambda} = [\lambda_1, \dots, \lambda_p]^\top$ und $\boldsymbol{\mu} = [\mu_1, \dots, \mu_q]^\top$.

Mit Hilfe der Lagrange-Funktion $L(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\mu})$ können die notwendigen Optimalitätsbedingungen erster Ordnung für das Optimierungsproblem (4.24) angegeben werden:

Satz 4.1 (Notwendige Optimalitätsbedingungen 1. Ordnung) Sei $\mathbf{x}^*$ ein lokales Minimum des Optimierungsproblems (4.24) und sei die Beschränkungsqualifikation (4.26) am Punkt $\mathbf{x}^*$ erfüllt. Falls die Funktionen f , g_i und h_i stetig differenzierbar sind, existieren

Lagrange-Multiplikatoren $\boldsymbol{\lambda}^* = [\lambda_1^*, \dots, \lambda_p^*]^T$ und $\boldsymbol{\mu}^* = [\mu_1^*, \dots, \mu_q^*]^T$, die die folgenden Bedingungen erfüllen:

$$\nabla_{\mathbf{x}} L(\mathbf{x}^*, \boldsymbol{\lambda}^*, \boldsymbol{\mu}^*) = \mathbf{0} \quad (4.29a)$$

$$g_i(\mathbf{x}^*) = 0, \quad i = 1, \dots, p \quad (4.29b)$$

$$h_i(\mathbf{x}^*) \leq 0, \quad i = 1, \dots, q \quad (4.29c)$$

$$\mu_i^* \geq 0, \quad i = 1, \dots, q \quad (4.29d)$$

$$\mu_i^* h_i(\mathbf{x}^*) = 0, \quad i = 1, \dots, q. \quad (4.29e)$$

Die Bedingungen (4.29) werden als *Karush-Kuhn-Tucker-Bedingungen* bzw. KKT-Bedingungen bezeichnet. Die *Komplementaritätsbedingung* impliziert, dass die i -te Ungleichungsbeschränkung entweder aktiv ist, d.h. $h_i(\mathbf{x}^*) = 0$ oder $\mu_i^* = 0$ gilt. Die Optimalitätsbedingungen in Satz 4.1 sind nur gültig, wenn die Beschränkungsqualifikation (4.26) am Minimum $\mathbf{x}^*$ erfüllt ist. Andernfalls kann es sein, dass die KKT-Bedingungen (4.29) nicht anwendbar sind, wie im nächsten Beispiel gezeigt wird.

Beispiel 4.3 Betrachtet wird das Problem

$$\min_{\mathbf{x} \in \mathbb{R}^2} \quad -x_1 \quad (4.30a)$$

$$\text{u.B.v.} \quad h_1(\mathbf{x}) = x_1^3 - x_2 \leq 0 \quad (4.30b)$$

$$h_2(\mathbf{x}) = x_1^3 + x_2 \leq 0. \quad (4.30c)$$

Abbildung 4.5 zeigt die zulässige Menge $\mathcal{X}_{ad}$ und den optimalen Punkt $\mathbf{x}^* = [0, 0]^T$, an dem beide Beschränkungen aktiv sind. Die Gradienten der Kostenfunktion f und der Beschränkungsfunktionen an diesem Punkt $\mathbf{x}^*$ lauten

$$\nabla f(\mathbf{x}^*) = \begin{bmatrix} -1 \\ 0 \end{bmatrix}, \quad \nabla h_1(\mathbf{x}^*) = \begin{bmatrix} 0 \\ -1 \end{bmatrix}, \quad \nabla h_2(\mathbf{x}^*) = \begin{bmatrix} 0 \\ 1 \end{bmatrix}. \quad (4.31)$$

womit sich die KKT-Bedingung (4.29a)

$$\nabla_{\mathbf{x}} L(\mathbf{x}^*, \boldsymbol{\mu}^*) = \begin{bmatrix} -1 \\ 0 \end{bmatrix} + \mu_1^* \begin{bmatrix} 0 \\ -1 \end{bmatrix} + \mu_2^* \begin{bmatrix} 0 \\ 1 \end{bmatrix} = \mathbf{0} \quad (4.32)$$

ergibt. Allerdings besitzt diese Gleichung keine Lösung, da die Beschränkungsqualifikation (4.26) am optimalen Punkt $\mathbf{x}^*$ verletzt ist.

Aufgabe 4.2 Gegeben sei das Optimierungsproblem

$$\min_{\mathbf{x} \in \mathbb{R}^n} \quad f(\mathbf{x}) = (x_1 - 2)^2 + \left(\frac{x_2 - 2}{3} \right)^2 \quad (4.33a)$$

$$\text{u.B.v.} \quad h_1(\mathbf{x}) = 2x_1 + x_2 - 2 \leq 0 \quad (4.33b)$$

$$h_2(\mathbf{x}) = x_1 - x_2 - 1 \leq 0. \quad (4.33c)$$

Bestimmen Sie die optimale Lösung $\mathbf{x}^*$, indem Sie die KKT-Bedingungen (4.29) für die unterschiedlichen Fälle an aktiven/inaktiven Beschränkungen untersuchen und in Abbildung 4.6 eintragen.




Abbildung 4.5: Veranschaulichung von Problem (4.30) in Beispiel 4.3.




Abbildung 4.6: Höhenlinien und zulässige Menge in Aufgabe 4.2.

Aufgabe 4.3 Folgendes Optimierungsproblem ist in Abhängigkeit des Parameters s gegeben:

$$\min_{\mathbf{x} \in \mathbb{R}^n} \left(x_1 - \frac{3}{2} \right)^2 + (x_2 - s)^4 \quad \text{u.B.v.} \quad \begin{bmatrix} 1 - x_1 - x_2 \\ 1 - x_1 + x_2 \\ 1 + x_1 - x_2 \\ 1 + x_1 + x_2 \end{bmatrix} \geq \mathbf{0}. \quad (4.34a)$$

Für welche Werte von s erfüllt der Punkt $\mathbf{x}^* = [1, 0]^T$ die KKT-Bedingungen (4.29)?

4.2.3 Optimalitätsbedingungen 2. Ordnung

Satz 4.2 (Notwendige Optimalitätsbedingungen 2. Ordnung) Sei $\mathbf{x}^*$ ein lokales Minimum des Optimierungsproblems (4.24) und sei die Beschränkungsqualifikation (4.26) am Punkt $\mathbf{x}^*$ erfüllt, so dass die KKT-Bedingungen (4.29) mit zugehörigen Lagrange-Multiplikatoren $\boldsymbol{\lambda}^*, \boldsymbol{\mu}^*$ gelten. Falls f , g_i und h_i zweimal stetig differenzierbar sind, dann gilt zusätzlich

$$\mathbf{s}^T \nabla_{\mathbf{x}\mathbf{x}}^2 L(\mathbf{x}^*, \boldsymbol{\lambda}^*, \boldsymbol{\mu}^*) \mathbf{s} \geq 0 \quad \forall \mathbf{s} \in \mathcal{C}(\mathbf{x}^*, \boldsymbol{\mu}^*) \quad (4.35)$$

mit

$$\begin{aligned} \mathcal{C}(\mathbf{x}^*, \boldsymbol{\mu}^*) = \{ \mathbf{s} \in \mathbb{R}^n : & \nabla g_i(\mathbf{x}^*)^T \mathbf{s} = 0, \quad i = 1, \dots, p \\ & \nabla h_i(\mathbf{x}^*)^T \mathbf{s} = 0, \quad i \in \mathcal{A}(\mathbf{x}^*), \mu_i^* > 0 \\ & \nabla h_i(\mathbf{x}^*)^T \mathbf{s} \leq 0, \quad i \in \mathcal{A}(\mathbf{x}^*), \mu_i^* = 0 \}. \end{aligned} \quad (4.36)$$

Die Bedingung (4.35) hat Ähnlichkeit mit dem unbeschränkten Fall (Satz 3.1), bei dem die Hesse-Matrix $\nabla^2 f(\mathbf{x}^*)$ am Punkt $\mathbf{x}^*$ positiv semi-definit sein musste, d.h. $\mathbf{s}^T \nabla^2 f(\mathbf{x}^*) \mathbf{s} \geq 0$ für alle $\mathbf{s} \in \mathbb{R}^n$. Im hier betrachteten beschränkten Fall beinhaltet die Menge $\mathcal{C}(\mathbf{x}^*, \boldsymbol{\mu}^*)$ nur

zulässige Richtungen $\mathbf{s}$, für die die Beschränkungen (4.24b), (4.24c) eingehalten werden. Dabei werden nur Richtungen $\mathbf{s}$ betrachtet, bei denen aus den Informationen der ersten Ableitungen nicht hervorgeht, ob sie zu einer Abnahme oder Zunahme der Kostenfunktion $f(\mathbf{x}^* + \mathbf{s})$ führen.¹

Satz 4.3 (Hinreichende Optimalitätsbedingungen) Sei $\mathbf{x}^*$ ein zulässiger Punkt des Optimierungsproblems (4.24) mit zugehörigen Lagrange-Multiplikatoren $\boldsymbol{\lambda}^*, \boldsymbol{\mu}^*$, so dass die KKT-Bedingungen (4.29) erfüllt sind. Falls f , g_i und h_i zweimal stetig differenzierbar sind und

$$\mathbf{s}^T \nabla_{\mathbf{x}\mathbf{x}}^2 L(\mathbf{x}^*, \boldsymbol{\lambda}^*, \boldsymbol{\mu}^*) \mathbf{s} > 0 \quad \forall \mathbf{s} \in \mathcal{C}(\mathbf{x}^*, \boldsymbol{\mu}^*), \mathbf{s} \neq \mathbf{0} \quad (4.37)$$

mit $\mathcal{C}(\mathbf{x}^*, \boldsymbol{\mu}^*)$ in (4.36) gilt, dann ist $\mathbf{x}^*$ ein striktes lokales Minimum.

Falls die Hesse-Matrix $\nabla_{\mathbf{x}\mathbf{x}}^2 L$ positiv definit ist, d.h.

$$\mathbf{s}^T \nabla_{\mathbf{x}\mathbf{x}}^2 L(\mathbf{x}^*, \boldsymbol{\lambda}^*, \boldsymbol{\mu}^*) \mathbf{s} > 0 \quad \forall \mathbf{s} \in \mathbb{R}^n, \mathbf{s} \neq \mathbf{0} \quad (4.38)$$

gilt, dann ist die hinreichende Bedingung (4.37) stets erfüllt. Dies ist vor allem bei quadratischen Problemen mit positiv definiter Hesse-Matrix $\nabla^2 f(\mathbf{x})$ der Kostenfunktion der Fall.

Im Allgemeinen kann bei konvexen Problemen auf die Auswertung der Optimalitätsbedingungen 2. Ordnung verzichtet werden, da in diesem Fall die Erfüllung der KKT-Bedingungen (4.29) notwendig und hinreichend ist, wie im folgenden Satz gezeigt wird:

Satz 4.4 (Hinreichende Optimalitätsbedingungen für konvexe Probleme) Seien $f : \mathbb{R}^n \rightarrow \mathbb{R}$ und $h_i : \mathbb{R}^n \rightarrow \mathbb{R}$ konvexe und stetig differenzierbare Funktionen und sei $g_i : \mathbb{R}^n \rightarrow \mathbb{R}$ stetig differenzierbar und linear. Falls ein Punkt $\mathbf{x}^*$ mit zugehörigen Lagrange-Multiplikatoren $\boldsymbol{\lambda}^*, \boldsymbol{\mu}^*$ die KKT-Bedingungen (4.29) erfüllt, dann ist $\mathbf{x}^*$ ein globales Minimum des Optimierungsproblems (4.24).

Aufgabe 4.4 (Fortsetzung von Aufgabe 4.2) Überprüfen Sie die hinreichenden Optimalitätsbedingungen nach Satz 4.3 und Satz 4.4 für das Problem (4.33) aus Aufgabe 4.2.

4.2.4 Interpretation der Lagrange-Multiplikatoren

Die Bedeutung der Lagrange-Multiplikatoren ist durch die einführenden Beispiele in Abschnitt 4.1 illustriert worden. Neben der mathematischen Formulierung existiert auch eine anschauliche Interpretation, die im Folgenden für den Fall einer Gleichungsbeschränkung

$$\begin{aligned} \min_{\mathbf{x} \in \mathbb{R}^n} \quad & f(\mathbf{x}) \\ \text{u.B.v.} \quad & g(\mathbf{x}) = 0 \end{aligned}$$

untersucht werden soll. Für eine optimale Lösung $\mathbf{x}^*$ dieses Problems muss gelten

$$\nabla_{\mathbf{x}} L(\mathbf{x}^*, \boldsymbol{\lambda}^*) = \nabla f(\mathbf{x}^*) + \boldsymbol{\lambda}^* \nabla g(\mathbf{x}^*) = \mathbf{0}. \quad (4.39)$$

¹ Für aktive Ungleichungsbeschränkungen mit $\mu_i^* > 0$ führen alle zulässigen Richtungen mit $\nabla h_i(\mathbf{x}^*)^T \mathbf{s} < 0$ zu einer Zunahme der Kostenfunktion $f(\mathbf{x}^* + \mathbf{s})$, siehe Abschnitt 4.2.4.

Um die Beziehung zwischen den Lagrange-Multiplikatoren und der optimalen Lösung $\mathbf{x}^*$ zu untersuchen, wird eine kleine Modifikation der Beschränkungen

$$g(\mathbf{x}) = \varepsilon \quad \Rightarrow \quad \bar{g}(\mathbf{x}(\varepsilon), \varepsilon) = g(\mathbf{x}(\varepsilon)) - \varepsilon = 0 \quad (4.40)$$

betrachtet. Die Variablen $\mathbf{x}(\varepsilon)$ hängen nun von ε ab, wobei sich für $\varepsilon = 0$ die ursprüngliche Lösung $\mathbf{x}^* = \mathbf{x}(0)$ des obigen Problems ergibt. Da $\bar{g}(\mathbf{x}(\varepsilon), \varepsilon) = 0$ für alle ε gelten muss, folgt

$$\frac{\partial \bar{g}}{\partial \varepsilon} + \nabla_{\mathbf{x}} \bar{g}(\mathbf{x}(\varepsilon), \varepsilon)^T \frac{d\mathbf{x}}{d\varepsilon} = 0 \quad \Rightarrow \quad \nabla_{\mathbf{x}} \bar{g}(\mathbf{x}(\varepsilon), \varepsilon)^T \frac{d\mathbf{x}}{d\varepsilon} = 1 \quad (4.41)$$

mit $\partial \bar{g} / \partial \varepsilon = -1$. Von besonderem Interesse ist die Auswirkung von ε auf den minimalen Kostenwert $f(\mathbf{x}^*)$. Dies kann mit Hilfe der Bezeichnung $\bar{f}(\varepsilon) = f(\mathbf{x}(\varepsilon))$ wie folgt ausgedrückt werden:

$$\left. \frac{d\bar{f}}{d\varepsilon} \right|_{\varepsilon=0} = \nabla f(\mathbf{x}^*)^T \left. \frac{d\mathbf{x}}{d\varepsilon} \right|_{\varepsilon=0} \stackrel{(4.39)}{=} -\lambda^* \nabla g(\mathbf{x}^*)^T \left. \frac{d\mathbf{x}}{d\varepsilon} \right|_{\varepsilon=0} \stackrel{(4.41)}{\Rightarrow} \boxed{\left. \frac{d\bar{f}}{d\varepsilon} \right|_{\varepsilon=0} = -\lambda^*}. \quad (4.42)$$

Der Lagrange-Multiplikator λ^* ist also ein *direktes Maß der Veränderung (Sensitivität)* der Kostenfunktion am Optimum bezogen auf eine Veränderung der Gleichungsbeschränkung $g(\mathbf{x}^*) = 0$. Analog gilt für eine aktive Ungleichungsbeschränkung

$$h(\mathbf{x}) \leq \varepsilon \quad \Rightarrow \quad \boxed{\left. \frac{d\bar{f}}{d\varepsilon} \right|_{\varepsilon=0} = -\mu^*}, \quad (4.43)$$

wobei μ^* den entsprechenden (optimalen) Lagrange-Multiplikator für den optimalen Punkt $\mathbf{x}^*$ mit $h(\mathbf{x}^*) = 0$ darstellt. Die Interpretation ist dabei die gleiche wie im Fall der Gleichungsbeschränkung: der Lagrange-Multiplikator μ^* einer aktiven Ungleichungsbeschränkung $h(\mathbf{x}) \leq 0$ am Optimum $\mathbf{x}^*$ spiegelt die Sensitivität der Kostenfunktion $f(\mathbf{x}^*)$ bzgl. dieser Beschränkung wider.

Mit anderen Worten: ein großer Wert von λ^* oder μ^* weist darauf hin, dass die "Lockerung" einer sehr restriktiven Beschränkung zu einer deutlichen Reduktion der Kostenfunktion f führen kann.

Die Untersuchungen sind direkt auf den allgemeinen Fall (4.24) mit p Gleichungs- und q Ungleichungsbeschränkungen erweiterbar. Die Gleichung (4.43) verdeutlicht auch die Vorzeichenbedingung (4.29d) der KKT-Bedingungen. Falls $\mu^* < 0$ wäre, würde dies bedeuten, dass

$$\left. \frac{d\bar{f}}{d\varepsilon} \right|_{\varepsilon=0} > 0$$

wäre und somit eine Reduktion der Kostenfunktion $f(\mathbf{x}^*)$ durch Verlassen der aktiven Ungleichungsbeschränkung (für $\varepsilon < 0$) möglich wäre. Da in diesem Fall $\mathbf{x}^*$ nicht die optimale Lösung wäre, muss folglich $\mu^* \geq 0$ gelten.

Aufgabe 4.5 (Fortsetzung von Aufgabe 4.2) Interpretieren Sie den Einfluß der Lagrange-Multiplikatoren grafisch für das Problem (4.33) aus Aufgabe 4.2.

4.3 Lineare Optimierung

Die lineare Optimierung (auch *lineare Programmierung* genannt) ist ein Sonderfall der nicht-linearen Optimierung, bei der die Kostenfunktion und die Beschränkungen linear sind. Dieser Spezialfall stellt die für praktische Anwendungen am weitesten verbreitete Optimierungsaufgabe dar. Ihre vielfältige Anwendung z.B. bei wirtschaftlichen Fragestellungen oder Produktions- und Transportproblemen (siehe Abschnitt 4.3.5) verdankt die lineare Programmierung sowohl ihrer Einfachheit als auch dem Vorhandensein zuverlässiger numerischer Lösungsverfahren.

4.3.1 Standardform-Darstellung

Die Standardform eines linearen Optimierungsproblems

$$\min_{\mathbf{x} \in \mathbb{R}^n} \quad \mathbf{c}^T \mathbf{x} \quad (4.44a)$$

$$\text{u.B.v.} \quad \mathbf{Ax} = \mathbf{b}, \quad \mathbf{A} \in \mathbb{R}^{p \times n}, \quad \mathbf{b} \in \mathbb{R}^p \quad (4.44b)$$

$$\mathbf{x} \geq \mathbf{0} \quad (4.44c)$$

stellt die Basis für die meisten numerischen Verfahren der linearen Optimierung dar. Jedes lineare Optimierungsproblem lässt sich anhand von einfachen Methoden in diese Standardform bringen. Ist z.B. das Problem

$$\min_{\mathbf{x} \in \mathbb{R}^n} \quad \mathbf{c}^T \mathbf{x} \quad (4.45a)$$

$$\text{u.B.v.} \quad \mathbf{Ax} \leq \mathbf{b}, \quad \mathbf{A} \in \mathbb{R}^{q \times n}, \quad \mathbf{b} \in \mathbb{R}^q \quad (4.45b)$$

gegeben, so können die Ungleichungsbeschränkungen (4.45b) mit Hilfe von *Schlupfvariablen* $\mathbf{z}$ in Gleichungsbeschränkungen und zusätzliche Ungleichungen transformiert werden

$$\mathbf{Ax} \leq \mathbf{b} \Rightarrow \mathbf{Ax} + \mathbf{z} = \mathbf{b}, \quad \mathbf{z} \geq \mathbf{0}. \quad (4.46)$$

Da die Variablen $\mathbf{x}$ bisher nicht notwendigerweise die Ungleichung (4.44c) erfüllen, wird $\mathbf{x}$ in nicht-negative und nicht-positive Anteile aufgespalten:

$$\mathbf{x} = \mathbf{x}^+ - \mathbf{x}^-, \quad \mathbf{x}^-, \mathbf{x}^+ \geq \mathbf{0}. \quad (4.47)$$

Somit kann das Problem (4.45) in die Standardform (4.44)

$$\min_{\bar{\mathbf{x}} \in \mathbb{R}^{2n+q}} \quad [\mathbf{c}^T, -\mathbf{c}^T, \mathbf{0}^T] \bar{\mathbf{x}} \quad (4.48a)$$

$$\text{u.B.v.} \quad [\mathbf{A}, -\mathbf{A}, \mathbf{I}] \bar{\mathbf{x}} = \mathbf{b}, \quad \bar{\mathbf{x}} = \begin{bmatrix} \mathbf{x}^+ \\ \mathbf{x}^- \\ \mathbf{z} \end{bmatrix} \quad (4.48b)$$

$$\bar{\mathbf{x}} \geq \mathbf{0} \quad (4.48c)$$

mit dem erweiterten Variablenvektor $\bar{\mathbf{x}}$ transformiert werden. Im Weiteren wird angenommen, dass das Optimierungsproblem bereits in der Standardform (4.44) vorliegt.

Aufgabe 4.6 Transformieren Sie das folgende lineare Problem in die Standardform (4.44):

$$\min_{\mathbf{x} \in \mathbb{R}^3} \quad -x_1 + 2x_2 + x_3 \quad (4.49a)$$

$$\text{u.B.v.} \quad x_1 + x_3 = 1 \quad (4.49b)$$

$$-x_1 + x_2 + x_3 \leq 1 \quad (4.49c)$$

$$x_2, x_3 \geq 0 \quad (4.49d)$$

4.3.2 Optimalitätsbedingungen

Mit der Lagrange-Funktion

$$L(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\mu}) = \mathbf{c}^T \mathbf{x} + \boldsymbol{\lambda}^T (\mathbf{A}\mathbf{x} - \mathbf{b}) + \boldsymbol{\mu}^T (-\mathbf{x})$$

$$\nabla_{\mathbf{x}} L(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\mu}) = \mathbf{c} + \mathbf{A}^T \boldsymbol{\lambda} - \boldsymbol{\mu}$$

und $\boldsymbol{\lambda} = [\lambda_1, \dots, \lambda_p]^T$, $\boldsymbol{\mu} = [\mu_1, \dots, \mu_n]^T$ ergeben sich die Optimalitätsbedingungen für das lineare Problem (4.44) als Sonderfall der KKT-Bedingungen (4.29):

$$\mathbf{c} + \mathbf{A}^T \boldsymbol{\lambda}^* - \boldsymbol{\mu}^* = \mathbf{0} \quad (4.50a)$$

$$\mathbf{A}\mathbf{x}^* - \mathbf{b} = \mathbf{0} \quad (4.50b)$$

$$\mathbf{x}^* \geq \mathbf{0} \quad (4.50c)$$

$$\mu_i^* \geq 0, \quad i = 1, \dots, n \quad (4.50d)$$

$$\mu_i^* (-x_i^*) = \mu_i^* x_i^* = 0, \quad i = 1, \dots, n. \quad (4.50e)$$

Da das lineare Problem (4.44) konvex ist (siehe Satz 2.5 und 4.4), stellt eine Lösung der Optimalitätsbedingungen (4.50) ein globales Minimum dar. Somit ist auch die Auswertung der Optimalitätsbedingungen 2. Ordnung nicht notwendig. Diese liefern ohnehin keine zusätzlichen Informationen, da die Hesse-Matrix $\nabla_{\mathbf{x}\mathbf{x}} L = \mathbf{0}$ ist.

4.3.3 Simplex-Algorithmus

Der *Simplex-Algorithmus* wurde 1948 von *George B. Danzig* entwickelt und markierte (zusammen mit dem Aufkommen digitaler Computer) den Startpunkt der modernen numerischen Optimierung. Der Simplex-Algorithmus nützt die geometrischen Eigenschaften von linearen Optimierungsproblemen aus, dass die zulässige Menge

$$\mathcal{X}_{ad} = \{\mathbf{x} \in \mathbb{R}^n : \mathbf{A}\mathbf{x} = \mathbf{b}, \mathbf{x} \geq \mathbf{0}\} \quad (4.51)$$

stets einen konvexen *Polyeder* mit endlich vielen Eckpunkten bildet (Abbildung 4.7). Die optimale Lösung $\mathbf{x}^*$ liegt (falls sie existiert) immer auf dem Rand von $\mathcal{X}_{ad}$. Falls die Lösung $\mathbf{x}^*$ eindeutig ist, liegt sie auf einer Ecke des Polyeders. Das Simplex-Verfahren nutzt diese Eigenschaft aus, indem es von einer beliebigen Ecke des zulässigen Polyeders entlang seiner Kanten zur optimalen Lösung $\mathbf{x}^*$ läuft, siehe Abbildung 4.7.

Definition 4.3 (Notationen des Simplex-Algorithmus)

Basis und Basismatrix: Sei $\mathcal{B}$ eine Untermenge von $\{1, \dots, n\}$ mit p Elementen. Falls die $p \times p$ -Matrix $\mathbf{B} = [\mathbf{A}_i]_{i \in \mathcal{B}}$ regulär ist, dann ist $\mathcal{B}$ eine Basis und $\mathbf{B}$ die Basismatrix.²

Basisvariablen: $\mathbf{x}_B = [x_i]_{i \in \mathcal{B}} = \mathbf{B}^{-1} \mathbf{b}$

Nichtbasisvariablen: $\mathbf{x}_N = [x_i]_{i \in \mathcal{N}} = \mathbf{0}$ mit $\mathcal{N} = \{1, \dots, n\} \setminus \mathcal{B}$

Zulässige Basislösung: $\mathbf{x}$ mit $\mathbf{x}_B = \mathbf{B}^{-1} \mathbf{b} \geq \mathbf{0}$ und $\mathbf{x}_N = \mathbf{0}$.

Nichtdegenerierte

zulässige Basislösung: $\mathbf{x}$ mit $\mathbf{x}_B = \mathbf{B}^{-1} \mathbf{b} > \mathbf{0}$ und $\mathbf{x}_N = \mathbf{0}$.




Abbildung 4.7: Veranschaulichung des Simplex-Algorithmus.

Da die Gleichungsbeschränkungen (4.44b) mit $p < n$ ein unterbestimmtes Gleichungssystem darstellen, können p Elemente $\mathbf{x}_B$ berechnet werden (die Basisvariablen), während $n - p$ Elemente $\mathbf{x}_N = \mathbf{0}$ (die Nichtbasisvariablen) zu Null gesetzt werden.

Unter der Annahme, dass die $(p \times n)$ -Matrix $\mathbf{A}$ zeilenregulär ist, ist es stets möglich, eine Basis $\mathcal{B}$ zu bestimmen, so dass die zugehörige Basismatrix $\mathbf{B} = [\mathbf{A}_i]_{i \in \mathcal{B}}$ regulär ist. Somit können die Gleichungsbeschränkungen (4.44b) in $\mathbf{x}_B$ und $\mathbf{x}_N$ aufgespalten werden

$$\mathbf{b} = \mathbf{B}\mathbf{x}_B + \mathbf{N}\mathbf{x}_N, \quad \mathbf{N} = [\mathbf{A}_i]_{i \in \mathcal{N}}, \quad (4.52)$$

um $\mathbf{x}_B$ mit Hilfe der regulären Basismatrix $\mathbf{B}$ zu berechnen:

$$\mathbf{x}_B = \mathbf{B}^{-1}(\mathbf{b} - \mathbf{N}\mathbf{x}_N) = \mathbf{B}^{-1}\mathbf{b} \quad \text{mit} \quad \mathbf{x}_N = \mathbf{0}. \quad (4.53)$$

Falls $\mathbf{x}_B \geq \mathbf{0}$ gilt, so stellen die Basisvariablen $\mathbf{x}_B$ und $\mathbf{x}_N = \mathbf{0}$ eine (zulässige) Basislösung dar. Die Initialisierungsphase des Simplex-Verfahrens besteht darin, eine Basislösung mit $\mathbf{x}_B \geq \mathbf{0}$ zu finden, was am Ende des Abschnitts erklärt wird. Ist dieser Startpunkt $\mathbf{x}$ einmal bestimmt, liefern die nachfolgenden Iterationen des Simplex-Verfahrens stets zulässige Basislösungen.

Beispiel 4.4 Betrachtet wird das Beispiel

$$\min_{\mathbf{x} \in \mathbb{R}^4} \mathbf{c}^T \mathbf{x}, \quad \mathbf{c}^T = [1, 2, 3, 4] \quad (4.54a)$$

$$\text{u.B.v. } \mathbf{A}\mathbf{x} = \mathbf{b}, \quad \mathbf{A} = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & 0 & 1 & -3 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \quad (4.54b)$$

$$\mathbf{x} \geq \mathbf{0} \quad (4.54c)$$

In der folgenden Tabelle werden einige mögliche Basen $\mathcal{B}$ betrachtet. Im letzten Fall ergibt sich keine zulässige Basislösung. Keine Basis für das betrachtete Beispiel wäre $\{1, 3\}$, da in diesem Fall $\mathbf{B}$ singulär wäre.

² Der Vektor $\mathbf{A}_i$ bezeichnet die i -te Spalte der Matrix $\mathbf{A}$.

Basis $\mathcal{B}$	Basismatrix $\mathbf{B}$	$\mathbf{x}_B = \mathbf{B}^{-1}\mathbf{b}$	$\mathbf{x}_N = \mathbf{0}$	zul. Basislösung?
$\mathcal{B} = \{1, 2\}$	$\mathbf{B} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix}$	$x_1 = 0.5$ $x_2 = 0.5$	$x_3 = 0$ $x_4 = 0$	ja
$\mathcal{B} = \{1, 4\}$	$\mathbf{B} = \begin{bmatrix} 1 & 1 \\ 1 & -3 \end{bmatrix}$	$x_1 = 0.875$ $x_4 = 0.125$	$x_2 = 0$ $x_3 = 0$	ja
$\mathcal{B} = \{2, 4\}$	$\mathbf{B} = \begin{bmatrix} 1 & 1 \\ 0 & -3 \end{bmatrix}$	$x_2 = 7/6$ $x_4 = -1/6$	$x_1 = 0$ $x_3 = 0$	nein

Das prinzipielle Vorgehen des Simplex-Algorithmus besteht im iterativen Überprüfen der Optimalitätsbedingungen (4.50) und dem Bestimmen einer neuen zulässigen Basislösung $\mathbf{x}^+$ mit $f(\mathbf{x}^+) < f(\mathbf{x})$.

Schritt 1: Überprüfung der Optimalitätsbedingungen (4.50)

Eine zulässige Basislösung (4.53), d.h. $\mathbf{x}_B \geq \mathbf{0}$ und $\mathbf{x}_N = \mathbf{0}$, erfüllt bereits die KKT-Bedingungen (4.50b) und (4.50c). Als nächstes wird die Stationaritätsbedingung (4.50a) betrachtet und bezüglich der Basis $\mathcal{B}$ und $\mathcal{N}$ aufgespalten:

$$\begin{bmatrix} \mathbf{c}_B \\ \mathbf{c}_N \end{bmatrix} + \begin{bmatrix} \mathbf{B}^T \\ \mathbf{N}^T \end{bmatrix} \boldsymbol{\lambda} = \begin{bmatrix} \boldsymbol{\mu}_B \\ \boldsymbol{\mu}_N \end{bmatrix}. \quad (4.55)$$

Um die Komplementaritätsbedingung (4.50e) zu erfüllen, wird $\boldsymbol{\mu}_B = \mathbf{0}$ gesetzt. Für $\boldsymbol{\mu}_N$ ist (4.50e) bereits erfüllt, da $\mathbf{x}_N = \mathbf{0}$ gilt. Die in (4.55) verbleibenden Vektoren $\boldsymbol{\lambda}$ und $\boldsymbol{\mu}_N$ berechnen sich zu

$$\boldsymbol{\lambda} = -(\mathbf{B}^T)^{-1} \mathbf{c}_B, \quad \boldsymbol{\mu}_N = \mathbf{c}_N + \mathbf{N}^T \boldsymbol{\lambda}. \quad (4.56)$$

Die letzte verbleibende KKT-Bedingung ist $\boldsymbol{\mu}_N \geq \mathbf{0}$. Wenn diese Bedingung durch die Gleichungen (4.56) erfüllt ist, ist die Basislösung $(\mathbf{x}_B, \mathbf{x}_N)$ die optimale Lösung $\mathbf{x}^*$ und der Algorithmus terminiert.

Schritt 2: Wahl einer neuen Basisvariablen

Falls ein oder mehrere $\mu_i, i \in \mathcal{N}$ negativ sein sollten, so stellt $\mathbf{x}$ nicht die optimale Lösung dar. In diesem Fall konstruiert das Simplex-Verfahren eine neue zulässige Basislösung $(\mathbf{x}_B^+, \mathbf{x}_N^+)$ durch Vertauschen zweier Elemente aus $\mathbf{x}_B$ und $\mathbf{x}_N$ mit den Indices $r \in \mathcal{B}$ und $s \in \mathcal{N}$. Dazu wird $x_r^+ = 0$ gesetzt und $x_s^+ \geq 0$ zugelassen, d.h.

$$\mathbf{x}_B^+ = [\dots, x_r^+ = 0, \dots]^T, \quad \mathbf{x}_N^+ = [\dots, x_s^+ \geq 0, \dots]^T. \quad (4.57)$$

Zunächst muss ein Element x_s mit $s \in \mathcal{N}$ und $\mu_s < 0$ ausgewählt werden, das ausgetauscht werden soll. Naheliegender ist das Element mit dem "negativsten" μ_i zu nehmen, also das Element aus $\mathbf{x}_N$, dass die Optimalitätsbedingung $\boldsymbol{\mu}_N \geq \mathbf{0}$ am stärksten verletzt:

$$\mu_s = \min_{i \in \mathcal{N} | \mu_i < 0} \mu_i \quad \text{mit zugehörigem Index } s \in \mathcal{N} \quad (4.58)$$

Schritt 3: Wahl einer neuen Nichtbasisvariablen

Im vorherigen Schritt wurde das Element $s \in \mathcal{N}$ ausgewählt, das gegen ein Element $r \in \mathcal{B}$ ausgetauscht werden soll. Um den Index r der neuen Nichtbasisvariablen x_r^+ aus den bisherigen Basisvariablen $\mathbf{x}_B^+$ auszuwählen, muss der Wert von x_s^+ geeignet bestimmt werden. Einen Hinweis darauf liefert die Gleichungsbeschränkung (4.52), die für $\mathbf{x}_B^+$ und $\mathbf{x}_N^+$ erfüllt sein muss. Mit (4.53) ergibt sich für die neuen Basisvariablen

$$\begin{aligned} \mathbf{x}_B^+ &= \mathbf{B}^{-1}(\mathbf{b} - \mathbf{N}\mathbf{x}_N^+) \\ &= \mathbf{x}_B - \mathbf{B}^{-1}\mathbf{A}_s x_s^+ \quad \text{mit} \quad \mathbf{x}_B = \mathbf{B}^{-1}\mathbf{b} \\ &= \mathbf{x}_B - \mathbf{d} x_s^+ \quad \mathbf{d} = \mathbf{B}^{-1}\mathbf{A}_s, \end{aligned} \quad (4.59)$$

wobei $\mathbf{A}_s$ die s -te Spalte der Matrix $\mathbf{A}$ bezeichnet. Der Vektor $\mathbf{d}$ stellt die Veränderungsrichtung der bisherigen Basisvariablen $\mathbf{x}_B$ bei einer Vergrößerung von x_s^+ dar.

Gilt insbesondere $d_i > 0$ für ein Element von $\mathbf{d}$, so führt eine Vergrößerung von x_s^+ zu einer Verkleinerung des entsprechenden Elements $x_{B,i}^+$ von $\mathbf{x}_B^+$. Somit darf x_s^+ nur soweit vergrößert werden, bis ein Element von $\mathbf{x}_B^+$ an die Grenze der Beschränkung $\mathbf{x}_B^+ \geq \mathbf{0}$ gelangt. Gemäß (4.59) wird aber eine Basisvariable $x_{B,i}^+$ zu Null, wenn $x_s^+ = x_{B,i}^+/d_i$ gilt. Somit kann x_s^+ mittels

$$x_s^+ = \min_{i|d_i>0} \frac{x_{B,i}^+}{d_i} \quad \text{mit zugehörigem Index } r \in \mathcal{B} \quad (4.60)$$

bestimmt werden. Der Index r kennzeichnet die Basisvariable x_r^+ , die als Erstes die Grenze der Beschränkung $\mathbf{x}_B^+ \geq \mathbf{0}$ erreicht. Mit x_s^+ ergibt sich aus (4.59) der neue Basispunkt $\mathbf{x}_B^+$ in (4.57), wobei die Position von $x_r^+ = 0$ im Vektor $\mathbf{x}_B^+$ genau der Index i ist, der das Minimierungsproblem (4.60) löst.

Falls $\mathbf{d} \leq \mathbf{0}$ gilt, kann x_s^+ beliebig groß gewählt werden, ohne dass die Beschränkung $\mathbf{x}_B^+ \geq \mathbf{0}$ verletzt wird. In diesem Fall ist der zulässige Bereich $\mathcal{X}_{ad}$ des Problems unbeschränkt und es existiert keine Lösung im Endlichen.

Da der neue zulässige Punkt (4.57) nun festgelegt ist, werden für die nächste Simplex-Iteration die Basis $\mathcal{B}$ entsprechend aktualisiert und die Indices $r \in \mathcal{B}$ und $s \in \mathcal{N}$ vertauscht. Tabelle 4.1 fasst die Operationen eines Simplex-Schrittes zusammen.

Geometrisch interpretiert bedeutet die Vergrößerung der Nichtbasisvariablen x_s^+ eine geradlinige Bewegung entlang einer Randkante des zulässigen Bereiches $\mathcal{X}_{ad}$ bis zum nächsten Randpunkt, siehe Abbildung 4.7. Dieser neue Punkt kann wieder auf Optimalität überprüft werden, bevor gegebenenfalls wieder eine neue Iteration gestartet wird. Im nichtdegenerierten Fall (siehe Definition 4.3) kann gezeigt werden, dass jeder Schritt des Simplex-Algorithmus zu einer Reduktion der Kostenfunktion führt und der Algorithmus in einer endlichen Anzahl von Schritten zum optimalen Punkt $\mathbf{x}^*$ konvergiert. Eine Ausnahme ist der oben bereits erwähnte Fall, dass der Vektor $\mathbf{d}$ keine positiven Elemente besitzt.

Ein rechentechnischer Nachteil des Simplex-Verfahrens besteht darin, dass die Anzahl der Iterationen im "worst case" gleich der Anzahl der Randpunkte des zulässigen Bereiches ist, die wiederum exponentiell mit der Variablendimension $\mathbf{x} \in \mathbb{R}^n$ anwächst. Allerdings zeigt sich in den meisten praktischen Anwendungen, dass das Simplex-Verfahren wesentlich schneller konvergiert als die "worst case"-Abschätzung.

und $s \in \mathcal{N}$ vertauscht, womit sich die neue zulässige Lösung

$$\begin{aligned} \mathcal{B} &= \{1, 4\}, \quad \mathbf{B} = \begin{bmatrix} 1 & 1 \\ 1 & -3 \end{bmatrix}, \quad \mathbf{x}_B = \begin{bmatrix} 0.875 \\ 0.125 \end{bmatrix}, \quad \mathbf{c}_B = \begin{bmatrix} 1 \\ 4 \end{bmatrix} \\ \mathcal{N} &= \{3, 2\}, \quad \mathbf{N} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix}, \quad \mathbf{x}_N = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad \mathbf{c}_N = \begin{bmatrix} 3 \\ 2 \end{bmatrix} \end{aligned}$$

ergibt. Optional können die Einträge in $\mathbf{N}$, $\mathbf{x}_B$ und $\mathbf{c}_N$ vertauscht werden, um die Indices in $\mathcal{N}$ aufsteigend zu ordnen. Die Überprüfung der KKT-Bedingungen mittels (4.56) für den neuen Punkt ergibt

$$\boldsymbol{\lambda} = -(\mathbf{B}^T)^{-1} \mathbf{c}_B = \begin{bmatrix} -1.75 \\ 0.75 \end{bmatrix}, \quad \boldsymbol{\mu}_N = \mathbf{c}_N + \mathbf{N}^T \boldsymbol{\lambda} = \begin{bmatrix} 2 \\ 0.25 \end{bmatrix} > \mathbf{0}.$$

Da beide Lagrange-Multiplikatoren $\boldsymbol{\mu}_N = [\mu_{N,1}, \mu_{N,2}]^T = [\mu_3, \mu_2]^T$ positiv sind, ist der Punkt $\mathbf{x}^* = [0.875, 0, 0, 0.125]^T$ die optimale Lösung.

Initialisierungsphase

Falls (anders als im vorherigen Beispiel) eine zulässige Startlösung für das Simplex-Verfahren nicht leicht gefunden werden kann, kann das ursprüngliche Problem (4.44) durch einen Trick umgeschrieben werden, indem zusätzliche Variablen $\mathbf{z}$ eingeführt werden:

$$\begin{aligned} \min_{(\mathbf{x}, \mathbf{z}) \in \mathbb{R}^{n+p}} \quad & \sum_{i=1}^p z_i \\ \text{u.B.v.} \quad & \mathbf{Ax} + \mathbf{Ez} = \mathbf{b} \quad \text{mit} \quad E_{ii} = \begin{cases} 1 & \text{falls } b_i \geq 0 \\ -1 & \text{falls } b_i < 0 \end{cases} \\ & \mathbf{x} \geq \mathbf{0}, \quad \mathbf{z} \geq \mathbf{0}. \end{aligned} \quad (4.61)$$

Die Matrix $\mathbf{E} = \text{diag}\{E_{ii}\} \in \mathbb{R}^{p \times p}$ wird in Abhängigkeit der Vorzeichen des Vektors $\mathbf{b}$ angesetzt. Eine zulässige Basislösung für dieses Problem ist offensichtlich

$$\mathbf{x} = \mathbf{0}, \quad z_i = |b_i|, \quad i = 1, \dots, p, \quad (4.62)$$

wodurch das modifizierte Problem (4.61) mit dem Simplex-Verfahren gelöst werden kann.

Findet man eine optimale Lösung mit $\mathbf{x}^*$ und $\mathbf{z}^* = \mathbf{0}$, so ist $\mathbf{x}^*$ eine zulässige Startlösung für das Originalproblem (4.44). Die Basis $\mathcal{B}^*$ und Basismatrix $\mathbf{B}^*$ der letzten Iteration kann für den ersten Simplex-Schritt des Originalproblems (4.44) verwendet werden. Falls andererseits nicht alle Elemente z_i^* des optimalen Vektors $\mathbf{z}^*$ identisch Null sind, so besitzt das Originalproblem (4.44) keine Lösung.

4.3.4 Interior-Point-Verfahren

Ein Nachteil des Simplex-Verfahrens ist, dass die maximale Anzahl an Rechenoperationen exponentiell mit der Problemgröße anwachsen kann, obwohl dies in der Praxis kaum der Fall ist. Eine Alternative sind *Interior-Point-Verfahren*, die maßgeblich auf *Karmarkar's Projektionsalgorithmus* aus dem Jahr 1984 basieren. Diese Verfahren zeichnen sich durch einen Rechenzeitaufwand aus, der maximal polynomial von der Systemordnung n abhängt.

Prinzip des Verfahrens

Im Prinzip wäre es möglich, die KKT-Bedingungen (4.50) mit Hilfe eines Newton-Verfahrens direkt zu lösen, um einen optimalen Punkt $\mathbf{x}^*$ zu bestimmen. Im Allgemeinen wird dieses Vorgehen aber eine sehr langsame Konvergenz besitzen, da die Schrittweite des Newton-Verfahrens so klein gewählt werden müsste, dass in jedem Iterationsschritt die Beschränkungen $x_i \geq 0$ und $\mu_i \geq 0$ eingehalten werden.

Die Grundidee der Interior-Point-Verfahren besteht darin, die Komplementaritätsbedingung (4.50e) durch einen Parameter $x_i \mu_i = \tau$ aufzuweichen. Vektoriell geschrieben ergibt sich somit das nichtlineare Gleichungssystem

$$\mathbf{F}(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\mu}) = \begin{bmatrix} \mathbf{c} + \mathbf{A}^T \boldsymbol{\lambda} - \boldsymbol{\mu} \\ \mathbf{A} \mathbf{x} - \mathbf{b} \\ \mathbf{X} \mathbf{M} \mathbf{e} \end{bmatrix} - \begin{bmatrix} \mathbf{0} \\ \mathbf{0} \\ \tau \mathbf{e} \end{bmatrix} = \mathbf{0}, \quad (\mathbf{x}, \boldsymbol{\mu}) \geq \mathbf{0} \quad (4.63)$$

mit den Matrizen $\mathbf{X} = \text{diag}(\mathbf{x})$, $\mathbf{M} = \text{diag}(\boldsymbol{\mu})$ und $\mathbf{e} = [1, \dots, 1]^T$. Es kann gezeigt werden, dass sich die optimale Lösung $(\mathbf{x}^*, \boldsymbol{\lambda}^*, \boldsymbol{\mu}^*)$ für $\tau \rightarrow 0$ ergibt:

$$\lim_{\tau \rightarrow 0} (\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\mu}) = (\mathbf{x}^*, \boldsymbol{\lambda}^*, \boldsymbol{\mu}^*). \quad (4.64)$$

In den meisten praktischen Algorithmen, die (4.63) iterativ lösen, wird τ mit Hilfe des sogenannten *Dualitätsmaßes*

$$\bar{\mu} = \frac{1}{n} \sum_{i=1}^n x_i \mu_i = \frac{1}{n} \mathbf{x}^T \boldsymbol{\mu} \quad (4.65)$$

in jedem Iterationsschritt k wie folgt angesetzt:

$$\tau^k = \sigma^k \bar{\mu}^k, \quad \sigma^k \in [0, 1]. \quad (4.66)$$

Der Parameter σ ist dabei der Reduktionsfaktor, um den das Dualitätsmaß $\bar{\mu}^k$ im jeweiligen Schritt k verkleinert werden soll.

Die Iterationsvorschrift zum Lösen des nichtlinearen Gleichungssystems (4.63), (4.66) lautet

$$\begin{bmatrix} \mathbf{x}^{k+1} \\ \boldsymbol{\lambda}^{k+1} \\ \boldsymbol{\mu}^{k+1} \end{bmatrix} = \begin{bmatrix} \mathbf{x}^k \\ \boldsymbol{\lambda}^k \\ \boldsymbol{\mu}^k \end{bmatrix} + \alpha^k \mathbf{s}^k \quad \text{mit} \quad \mathbf{s}^k = \begin{bmatrix} \Delta \mathbf{x}^k \\ \Delta \boldsymbol{\lambda}^k \\ \Delta \boldsymbol{\mu}^k \end{bmatrix}. \quad (4.67)$$

Die Suchrichtung $\mathbf{s}^k$ berechnet sich mit Hilfe des Newton-Verfahrens (siehe auch Abschnitt 3.3.4) aus dem Gleichungssystem³

$$\underbrace{\begin{bmatrix} \mathbf{0} & \mathbf{A}^T & -\mathbf{I} \\ \mathbf{A} & \mathbf{0} & \mathbf{0} \\ \mathbf{M}^k & \mathbf{0} & \mathbf{X}^k \end{bmatrix}}_{\nabla \mathbf{F}(\mathbf{x}^k, \boldsymbol{\lambda}^k, \boldsymbol{\mu}^k)} \underbrace{\begin{bmatrix} \Delta \mathbf{x}^k \\ \Delta \boldsymbol{\lambda}^k \\ \Delta \boldsymbol{\mu}^k \end{bmatrix}}_{-\mathbf{F}(\mathbf{x}^k, \boldsymbol{\lambda}^k, \boldsymbol{\mu}^k)} = \begin{bmatrix} -\mathbf{c} - \mathbf{A}^T \boldsymbol{\lambda}^k + \boldsymbol{\mu}^k \\ -\mathbf{A} \mathbf{x}^k + \mathbf{b} \\ -\mathbf{X}^k \mathbf{M}^k \mathbf{e} + \sigma^k \bar{\mu}^k \mathbf{e} \end{bmatrix}. \quad (4.68)$$

³ Gleichung (4.68) ergibt sich aus der Approximation von (4.63) mittels des linearen Modells $m_F^k(\mathbf{s}) = \mathbf{F}(\mathbf{x}^k, \boldsymbol{\lambda}^k, \boldsymbol{\mu}^k) + \nabla \mathbf{F}(\mathbf{x}^k, \boldsymbol{\lambda}^k, \boldsymbol{\mu}^k) \mathbf{s}$ und der Forderung $m_F^k(\mathbf{s}) = 0$. Die Bestimmung der Newton-Richtung $\mathbf{s}$ ist analog zum Vorgehen in Abschnitt 3.3.4. Dort wurde zunächst ein *quadratisches Modell* (3.32) aufgestellt. Die Bestimmung des Minimums gemäß $\nabla m^k(\mathbf{s}) = 0$ führte dabei ebenfalls zu einem linearen Modell in $\mathbf{s}$.

mit $\bar{\mu}^k$ aus (4.65). Darüberhinaus muss die Schrittweite α^k in (4.67) durch ein geeignetes Liniensuchverfahren so bestimmt werden, dass die strikten Beschränkungen

$$\mathbf{x}^k > \mathbf{0}, \quad \boldsymbol{\mu}^k > \mathbf{0} \quad (4.69)$$

in jedem Schritt k eingehalten werden. Aus diesem Zusammenhang entstammt auch der Name *Interior-Point-Verfahren*. Einen Einfluss auf die Schrittweite α^k übt auch der Reduktionsfaktor $\sigma^k \in [0, 1]$ aus. Für größere Werte von σ^k (gegen 1 gehend) ist es in der Regel möglich, einen größeren Schritt α^k in die durch (4.68) definierte Newton-Richtung $\mathbf{s}^k$ zu gehen, bevor die Beschränkungen $(\mathbf{x}^k, \boldsymbol{\mu}^k) > \mathbf{0}$ verletzt werden.

Es existieren mehrere unterschiedlich komplexe Verfahren zur Wahl von α^k und σ^k , auf die an dieser Stelle nicht näher eingegangen werden soll (z.B. Kurzschrift-, Langschrittverfahren, Prädiktor-Korrektorverfahren). Eine große Rolle spielt des Weiteren die Wahl der Startlösung $(\mathbf{x}^0, \boldsymbol{\lambda}^0, \boldsymbol{\mu}^0)$, die das Gleichungssystem (4.63) und die Beschränkungen $(\mathbf{x}^0, \boldsymbol{\mu}^0) > \mathbf{0}$ ausreichend genau erfüllen sollte.

Interior-Point-Verfahren sind auch für große Probleme gut einsetzbar. In diesem Fall gibt es effiziente Algorithmen, die die meistens dünn-besetzte Struktur des linearen Gleichungssystems (4.68) ausnutzen. Mehr Details zu diesen Punkten findet man z.B. in [17, 14].

Zusammenhang mit Barrieremethoden

Interior-Point-Verfahren sind eng verwandt mit Barrieremethoden, bei denen die Beschränkungen $\mathbf{x} \geq \mathbf{0}$ durch logarithmische Strafterme zur Kostenfunktion addiert werden:

$$\min_{\mathbf{x} \in \mathbb{R}^n} \quad \mathbf{c}^T \mathbf{x} - \tau \sum_{i=1}^n \log x_i, \quad \tau > 0 \quad (4.70a)$$

$$\text{u.B.v.} \quad \mathbf{Ax} = \mathbf{b}. \quad (4.70b)$$

Da die Kostenfunktion (4.70a) aufgrund der log-Terme gegen Unendlich geht, wenn eine Variable x_i zu Null wird, muss eine Lösung des Problems (4.70) die strikte Beschränkung $\mathbf{x} > \mathbf{0}$ erfüllen. Der Strafparameter τ beeinflusst die Form der Barrierenfunktionen, siehe Abbildung 4.8. Für $\tau \rightarrow 0$ nähern die log-Terme ein diskontinuierliches Verhalten an, während die Bestrafung für innere Punkte $\mathbf{x} > \mathbf{0}$ immer geringer wird.

Mit der Lagrange-Funktion

$$L(\mathbf{x}, \boldsymbol{\lambda}) = \mathbf{c}^T \mathbf{x} - \tau \sum_{i=1}^n \log x_i + \boldsymbol{\lambda}^T (\mathbf{Ax} - \mathbf{b})$$

lauten die KKT-Bedingungen (4.50a), (4.50b) für das Barriereproblem

$$\begin{aligned} c_i - \frac{\tau}{x_i} + \mathbf{A}_i^T \boldsymbol{\lambda} &= 0, \quad i = 1, \dots, n \\ \mathbf{Ax} &= \mathbf{b}, \end{aligned} \quad (4.71)$$

wobei $\mathbf{A}_i$ die i -te Spalte der Matrix $\mathbf{A}$ darstellt. Mit der Einführung der neuen Variablen $\mu_i = \tau/x_i$ ergibt sich das gleiche Gleichungssystem wie in (4.63):

$$\mathbf{F}(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\mu}) = \begin{bmatrix} \mathbf{c} + \mathbf{A}^T \boldsymbol{\lambda} - \boldsymbol{\mu} \\ \mathbf{Ax} - \mathbf{b} \\ \mathbf{X} \mathbf{M} \mathbf{e} \end{bmatrix} - \begin{bmatrix} \mathbf{0} \\ \mathbf{0} \\ \tau \mathbf{e} \end{bmatrix} = \mathbf{0}, \quad (\mathbf{x}, \boldsymbol{\mu}) \geq \mathbf{0}$$




Abbildung 4.8: Logarithmische Barrierefunktion für verschiedene Werte von τ .




Abbildung 4.9: Zentraler Pfad, der durch τ definiert wird.

Die Optimalitätsbedingungen für Interior-Point-Verfahren und logarithmische Barrieremethoden sind also (über die Einführung der neuen Variablen $\mu_i = \tau/x_i$) äquivalent.

Reine Barriereverfahren wie in (4.70) sind in der Regel numerisch sensibel, da die Terme in den KKT-Bedingung (4.71) sehr groß werden können, wenn man im Grenzfall $\tau \rightarrow 0$ nahe an die Beschränkungen $\mathbf{x} \geq \mathbf{0}$ gelangt. Die Formulierung der Interior-Point-Verfahren ist in der Regel vorzuziehen, da gezeigt werden kann, dass das Gleichungssystem (4.63) eine bessere Konditionierung aufweist als die Optimalitätsbedingungen (4.71) von Barriereverfahren.

Das Verhalten der logarithmischen Barrierefunktionen kann jedoch verwendet werden, um die Interior-Point-Verfahren zu veranschaulichen. Jeder Wert $\tau^k \geq 0$ definiert eine Lösung $(\mathbf{x}^k, \boldsymbol{\lambda}^k, \boldsymbol{\mu}^k)$. Die Menge aller Lösungen für verschiedene τ beschreibt den sogenannten *zentralen Pfad*, der für eine Sequenz $\{\tau^k\}$ mit $\tau^{k+1} < \tau^k$ im Grenzfall $\lim_{k \rightarrow \infty} \tau^k = 0$ zur optimalen Lösung $(\mathbf{x}^*, \boldsymbol{\lambda}^*, \boldsymbol{\mu}^*)$ des ursprünglichen Problems (4.44) führt, siehe Abbildung 4.9. Da τ dem Parameter (4.66) entspricht, weisen Interior-Point-Verfahren das gleiche Verhalten auf und nähern die optimale Lösung über den zentralen Pfad an.

4.3.5 Beispiel: Transportnetz

Das in zwei Raffinerien R_1 und R_2 hergestellte Benzin soll über das in der Abbildung 4.10 dargestellte Transportnetz bestehend aus vier Pipelines $l_1, \dots, l_4$ zu den Verbrauchszentren Z_1, Z_2 transportiert werden.⁴ Die Verbrauchszentren Z_1, Z_2 haben die konstanten Verbrauchsraten V_1, V_2 . Die Transportkosten innerhalb einer Leitung seien direkt proportional zu dem Durchfluss x_i der Leitung mit dem Proportionalitätsfaktor K_i .

Gesucht wird die optimale Verteilung der Durchflüsse x_i zur Minimierung der Transportkosten unter Gewährleistung der Verbrauchsraten V_1, V_2 und der Einhaltung der maximalen Durchflusskapazitäten C_i der Leitungen. Des Weiteren soll berücksichtigt werden, dass die Raffinerie R_1 eine maximale Produktionsrate P_1 besitzt.

⁴ Dies ist eine modifizierte Version des Raffinerien-Beispiels aus [15].




Abbildung 4.10: Transportnetz des Raffinerien-Beispiels.

Für die Parameter werden folgende Werte betrachtet:

$$\begin{array}{llll}
 K_1 = 40, & C_1 = 30, & V_1 = 50, & P_1 = 45 \\
 K_2 = 20, & C_2 = 20, & V_2 = 40 & \\
 K_3 = 10, & C_3 = 30 & & \\
 K_4 = 10, & C_4 = 60. & &
 \end{array}$$

Aufgabe 4.7 Formulieren Sie das Transportproblem als Optimierungsproblem. Reduzieren Sie das Problem anschließend auf ein zweidimensionales Optimierungsproblem durch Einsetzen der Gleichungsbeschränkungen.

Aufgabe 4.8 Stellen Sie den zulässigen Bereich und die Höhenlinien der Kostenfunktion grafisch dar und ermitteln Sie auf diese Weise die optimale Lösung.

Die Optimization Toolbox von MATLAB stellt die Funktion

$$\text{linprog}(f, A, b, Aeq, beq, LB, UB, X0, options)$$

zur Lösung von linearen Optimierungsproblemen der Form

$$\min_{x \in \mathbb{R}^n} f^T x \quad \text{u.B.v.} \quad A_{eq} x = b_{eq}, \quad Ax \leq b, \quad LB \leq x \leq UB$$

zur Verfügung. Das Simplex-Verfahren bzw. das Interior-Point-Verfahren können über die folgenden Optionen eingestellt werden:

Simplex-Verfahren: `opt = optimoptions('linprog','Algorithm','dual-simplex')`

Interior-Point-Verfahren: `opt = optimoptions('linprog','Algorithm','interior-point')`

Bei der Option 'dual-simplex' wendet MATLAB das Simplex-Verfahren auf das zu (4.44) *duale Problem* an, siehe Abschnitt 4.6 und Beispiel 4.8.

Aufgabe 4.9 Lösen Sie das Transportproblem unter MATLAB (siehe Abbildung 4.11) und vergleichen Sie das Simplex-Verfahren mit dem Interior-Point-Verfahren hinsichtlich Genauigkeit und Anzahl an Iterationen.

```

function transport_problem(methodQ)
% -----
% methodQ: 1 - Simplex method
%           2 - Interior point method

opt = optimoptions('linprog','Display','iter'); % options for output

switch methodQ
    case 1, % simplex method
        opt = optimoptions(opt,'Algorithm','dual-simplex');
    case 2, % interior point method
        opt = optimoptions(opt,'Algorithm','interior-point');
end

K = [40; 20; 10; 10]; % parameters for
C = [30; 20; 30; 60]; % transport problem
R = [50; 40];

xopt = [20;10;30;60]; % optimal point

c = K; % cost vector
Aeq = [1,0,1,0; 0,1,-1,1]; beq = R; % equality constraints
LB = [0;0;0;0]; UB = C; % constraints on x
A = [1,1,0,0]; b = 45; % general constraints Ax <= b

% call of linprog
% -----
[x,f] = linprog(c,A,b,Aeq,beq,LB,UB,opt);
fprintf('\nComputed solution: [%g, %g, %g, %g] with f(x) = %g',x,f);
fprintf('\nDistance to optimum: [%2.2g, %2.2g, %2.2g, %2.2g]\n',x-xopt);

```

Abbildung 4.11: MATLAB-Code für das Transportnetz-Problem (linprog).

4.4 Quadratische Optimierung

Ein weiterer Sonderfall in der statischen Optimierung ist die quadratische Optimierung (auch *quadratische Programmierung* genannt), zu der Optimierungsprobleme mit quadratischer Kostenfunktion und linearen Beschränkungen gehören:

$$\min_{\mathbf{x} \in \mathbb{R}^n} \quad \frac{1}{2} \mathbf{x}^T \mathbf{G} \mathbf{x} + \mathbf{c}^T \mathbf{x}, \quad \mathbf{G} \in \mathbb{R}^{n \times n} \quad (4.72a)$$

$$\text{u.B.v.} \quad \mathbf{A} \mathbf{x} = \mathbf{b}, \quad \mathbf{A} \in \mathbb{R}^{p \times n}, \quad \mathbf{b} \in \mathbb{R}^p \quad (4.72b)$$

$$\mathbf{C} \mathbf{x} \leq \mathbf{d}, \quad \mathbf{C} \in \mathbb{R}^{q \times n}, \quad \mathbf{d} \in \mathbb{R}^q. \quad (4.72c)$$

Die Gewichtungsmatrix $\mathbf{G} \in \mathbb{R}^{n \times n}$ sei symmetrisch und i.d.R. positiv definit. Ebenso wie die lineare Optimierung (Abschnitt 4.3) ist diese Problemklasse von besonderer Bedeutung. Ein Beispiel ist die Portfolio-Optimierung, bei der ein Optimum zwischen Ertragsmaximierung und Risikominimierung (Kovarianz) erzielt werden soll. Darüber hinaus basieren viele numerische Verfahren zur Lösung von allgemeinen nichtlinearen Optimierungsproblemen (Abschnitt 4.5) auf einer sequentiellen Lösung von quadratischen Problemen.

4.4.1 Optimalitätsbedingungen

Die allgemein nichtlinearen KKT-Bedingungen (4.29) vereinfachen sich strukturell für quadratische Probleme der Form (4.72). Mit Hilfe der Lagrange-Funktion

$$L(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\mu}) = \frac{1}{2} \mathbf{x}^T \mathbf{G} \mathbf{x} + \mathbf{c}^T \mathbf{x} + \boldsymbol{\lambda}^T (\mathbf{A} \mathbf{x} - \mathbf{b}) + \boldsymbol{\mu}^T (\mathbf{C} \mathbf{x} - \mathbf{d})$$

und den Lagrange-Multiplikatoren $\lambda \in \mathbb{R}^p$, $\mu \in \mathbb{R}^q$ lauten die KKT-Bedingungen für eine optimale Lösung

$$Gx^* + c + A^T \lambda^* + C^T \mu^* = 0 \quad (4.73a)$$

$$Ax^* - b = 0 \quad (4.73b)$$

$$Cx^* - d \leq 0 \quad (4.73c)$$

$$\mu_i^* \geq 0, \quad i = 1, \dots, n \quad (4.73d)$$

$$\mu_i^*(C_i^T x^* - d_i) = 0, \quad i = 1, \dots, n. \quad (4.73e)$$

Dabei stellt C_i^T die i -te Zeile der Beschränkungsmatrix C dar. Falls G positiv semi-definit ist, spricht man von einem *konvexen* quadratischen Problem. Im konvexen Fall ist eine Lösung x^* (falls sie existiert) immer eine globale Lösung des quadratischen Problems und die KKT-Bedingungen (4.29) sind notwendig und hinreichend für die Existenz von x^* . Nicht-konvexe quadratische Probleme sind im Allgemeinen schwieriger zu handhaben, da mehrere stationäre Punkte und Minima auftreten können.

4.4.2 Gleichungsbeschränkte quadratische Probleme

Von besonderem Interesse sind gleichungsbeschränkte quadratische Probleme

$$\min_{x \in \mathbb{R}^n} \quad \frac{1}{2} x^T G x + c^T x \quad (4.74a)$$

$$\text{u.B.v.} \quad Ax = b, \quad A \in \mathbb{R}^{p \times n}, \quad b \in \mathbb{R}^p, \quad (4.74b)$$

für die sich die KKT-Bedingungen (4.73) auf das lineare Gleichungssystem

$$\begin{bmatrix} G & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} x^* \\ \lambda^* \end{bmatrix} = \begin{bmatrix} -c \\ b \end{bmatrix} \quad (4.75)$$

reduzieren. Das Gleichungssystem (4.75) umfasst $n+p$ Gleichungen für die $n+p$ Unbekannten (x^*, λ^*) . Die Blockmatrix in (4.75) wird *Karush-Kuhn-Tucker-Matrix* (kurz: *KKT-Matrix*) genannt.

Es existieren unterschiedliche Verfahren zur Lösung von (4.75), die an dieser Stelle nur kurz skizziert werden sollen.⁵

- *Direkte Verfahren* lösen das Gleichungssystem (4.75) mit Hilfe von Faktorisierungen, z.B. das *Nullraum-Verfahren*. Diese Verfahren werden vorrangig bei Problemen kleiner und mittlerer Dimension eingesetzt, da die Berechnung der Faktorisierungen mit zunehmender Dimension recht aufwändig werden kann.
- *Iterative Verfahren* sind für große Problemdimensionen besonders gut geeignet. Beispiele dafür sind bestimmte Klassen von *Konjugierte-Gradienten-Verfahren*.

Gleichungsbeschränkte quadratische Probleme sind von großer Bedeutung in der Optimierung, da das zu lösende Gleichungssystem (4.75) linear ist und mittels der oben erwähnten Verfahren effizient gelöst werden kann.

Des Weiteren basieren ungleichungsbeschränkte quadratische Probleme sowie generell nichtlineare Probleme oft auf der (sequentiellen) Lösung von gleichungsbeschränkten Unterproblemen der Form (4.74).

⁵ Mehr Informationen findet man z.B. in [14].

4.4.3 Aktive-Restriktionen-Verfahren

Eine bekannte Methode zur Lösung von allgemeinen quadratischen Problemen (4.72) ist das *Aktive-Restriktionen-Verfahren*, das (ähnlich wie das Simplex-Verfahren in der Linearen Optimierung) aktive Beschränkungen in jeder Iteration identifiziert und ein gleichungsbeschränktes Problem der Form (4.74) mit einer kleineren Anzahl von freien Optimierungsvariablen löst.

Die Grundidee des Aktive-Restriktionen-Verfahrens besteht darin, in jeder Iteration k eine Anzahl von aktiven Ungleichungsbeschränkungen $\mathbf{C}\mathbf{x} \leq \mathbf{d}$ zu bestimmen, die als *Arbeitsmenge* $\mathcal{A}^k$ bezeichnet wird:

$$\mathbf{C}_i^T \mathbf{x}^k = d_i, \quad i \in \mathcal{A}^k.$$

Die Menge $\mathcal{A}^k$ berücksichtigt nicht notwendigerweise alle im Punkt $\mathbf{x}^k$ aktiven Beschränkungen, sondern wird im Laufe der Iterationen vervollständigt, bis der optimale Punkt $\mathbf{x}^*$ mit der Menge der aktiven Beschränkungen (siehe Definition 4.1)

$$\mathcal{A}(\mathbf{x}^*) = \{i \in \{1, \dots, q\} \mid \mathbf{C}_i^T \mathbf{x}^* = d_i\}$$

erreicht ist. Im Allgemeinen wird angenommen, dass in jedem Iterationspunkt $\mathbf{x}^k$ die Beschränkungsqualifikation (4.26) erfüllt ist, d.h.

$$\text{Rang} \begin{bmatrix} \mathbf{A} \\ [\mathbf{C}_i^T]_{i \in \mathcal{A}^k} \end{bmatrix} = p + |\mathcal{A}^k| \quad \forall k. \quad (4.76)$$

Des Weiteren wird angenommen, dass die Matrix $\mathbf{G}$ positiv definit ist.

Das Aktive-Restriktionen-Verfahren überprüft in jeder Iteration k , ob der Punkt $\mathbf{x}^k$ mit der Arbeitsmenge $\mathcal{A}^k$ die optimale Lösung des quadratischen Problems darstellt. Wenn dies nicht der Fall ist, wird ein Schritt $\mathbf{s}$ berechnet, indem ein gleichungsbeschränktes Problem gelöst wird, bei dem alle aktiven Ungleichungen entsprechend der Arbeitsmenge $\mathcal{A}^k$ als Gleichungsbeschränkungen betrachtet werden. Aus dem Originalproblem (4.72) ergibt sich somit durch Ersetzen von $\mathbf{x} = \mathbf{x}^k + \mathbf{s}$ und der momentanen Arbeitsmenge $\mathcal{A}^k$ das gleichungsbeschränkte quadratische Problem⁶

$$\min_{\mathbf{s} \in \mathbb{R}^n} \quad \frac{1}{2} \mathbf{s}^T \mathbf{G} \mathbf{s} + (\mathbf{G} \mathbf{x}^k + \mathbf{c})^T \mathbf{s} \quad (4.77a)$$

$$\text{u.B.v.} \quad \mathbf{A} \mathbf{s} = \mathbf{0}, \quad \mathbf{C}_i^T \mathbf{s} = 0, \quad i \in \mathcal{A}^k \quad (4.77b)$$

mit der Lösung $\mathbf{s}^k$. Eine wichtige Eigenschaft dieser Formulierung ist, dass jede aktive Beschränkung $i \in \mathcal{A}^k$ aktiv bleibt und nicht verletzt wird, da

$$\mathbf{C}_i^T (\mathbf{x}^k + \alpha \mathbf{s}^k) = \mathbf{C}_i^T \mathbf{x}^k = d_i, \quad \forall i \in \mathcal{A}^k \quad \forall \alpha \geq 0. \quad (4.78)$$

Somit sind alle aktiven Beschränkungen in $\mathcal{A}^k$, die in $\mathbf{x}^k$ aktiv sind, ebenfalls für $\mathbf{x}^k + \alpha \mathbf{s}^k$ für alle Schrittweiten α aktiv. Da angenommen wurde, dass $\mathbf{G}$ positiv definit ist, kann (4.77) mit einem der in Abschnitt 4.4.2 erwähnten Verfahren gelöst werden.

⁶ Beim Ersetzen von $\mathbf{x} = \mathbf{x}^k + \mathbf{s}$ in der Kostenfunktion (4.72a) entsteht ein zusätzlicher Term $\frac{1}{2}(\mathbf{x}^k)^T \mathbf{G} \mathbf{x}^k + \mathbf{c}^T \mathbf{x}^k$, der aber unabhängig von $\mathbf{s}$ ist und somit in der neuen Kostenfunktion (4.77a) vernachlässigt werden kann.

Falls für die Lösung $\mathbf{s}^k \neq \mathbf{0}$ gilt und $\mathbf{x}^k + \mathbf{s}^k$ ein zulässiger Punkt im Hinblick auf die Beschränkungen $\mathbf{C}(\mathbf{x}^k + \mathbf{s}^k) \leq \mathbf{d}$ ist, wird $\mathbf{x}^{k+1} = \mathbf{x}^k + \mathbf{s}^k$ als neuer Iterationspunkt verwendet. Wenn $\mathbf{x}^k + \mathbf{s}^k$ nicht zulässig ist, wird

$$\mathbf{x}^{k+1} = \mathbf{x}^k + \alpha^k \mathbf{s}^k \quad (4.79)$$

gesetzt, wobei die *Schrittweite* $\alpha^k < 1$ soweit verkleinert wird, bis alle Beschränkungen erfüllt sind. Um α^k geeignet zu bestimmen, müssen lediglich die Beschränkungen betrachtet werden, die nicht in $\mathcal{A}^k$ enthalten sind, da alle aktiven Beschränkungen $i \in \mathcal{A}^k$ für alle α^k erfüllt bleiben, siehe (4.78).

Von Interesse sind die Beschränkungen $i \notin \mathcal{A}^k$, für die $\mathbf{C}_i^T \mathbf{s}^k > 0$ gilt. In diesem Fall wird die ursprüngliche Beschränkung $\mathbf{C}_i^T (\mathbf{x}^k + \alpha^k \mathbf{s}^k) \leq d_i$ nur erfüllt sein, wenn

$$\alpha^k \leq \frac{d_i - \mathbf{C}_i^T \mathbf{x}^k}{\mathbf{C}_i^T \mathbf{s}^k} \quad (4.80)$$

gilt. Die größtmögliche Schrittweite α^k lässt sich wie folgt bestimmen:

$$\alpha^k = \min \left\{ 1, \min_{i \notin \mathcal{A}^k, \mathbf{C}_i^T \mathbf{s}^k > 0} \frac{d_i - \mathbf{C}_i^T \mathbf{x}^k}{\mathbf{C}_i^T \mathbf{s}^k} \right\}. \quad (4.81)$$

Falls $\alpha^k < 1$ aus (4.81) folgt und somit eine aktiv werdende Beschränkung außerhalb der Arbeitsmenge $\mathcal{A}^k$ die maximale Schrittweite $\alpha^k = 1$ verhindert, wird eine neue Arbeitsmenge $\mathcal{A}^{k+1}$ gebildet, indem der Index i der neuen aktiven Ungleichungsbeschränkung zu $\mathcal{A}^k$ hinzugefügt wird.

Dieses Verfahren wird iterativ wiederholt, d.h. aktive Beschränkungen sukzessive zur Arbeitsmenge $\mathcal{A}^k$ hinzugefügt, bis ein Punkt $\mathbf{x}^k$ die quadratische Kostenfunktion (4.77a) minimiert. In diesem Fall muss $\mathbf{s}^k = \mathbf{0}$ gelten. Damit die KKT-Bedingungen (4.73) an diesem Punkt $\mathbf{x}^k$ tatsächlich erfüllt sind, müssen alle Lagrange-Multiplikatoren μ_i^k , $i \in \mathcal{A}^k$, die den aktiven Beschränkungen in der Arbeitsmenge $\mathcal{A}^k$ entsprechen, nicht-negativ sein, d.h. $\mu_i^k \geq 0$, $i \in \mathcal{A}^k$. Ist dies der Fall, stellt $\mathbf{x}^k$ die optimale Lösung $\mathbf{x}^*$ dar. Da $\mathbf{G}$ positiv definit ist, ist $\mathbf{x}^* = \mathbf{x}^k$ auch die globale Lösung.

Falls andererseits mindestens einer der Lagrange-Multiplikatoren μ_i^k , $i \in \mathcal{A}^k$ negativ ist, bedeutet dies, dass die Kostenfunktion (4.72a) weiter reduziert werden kann, wenn eine der aktiven Beschränkungen in $\mathcal{A}^k$ fallen gelassen wird (siehe Abschnitt 4.1.2 und 4.1.3). Die Reduktion von $\mathcal{A}^k$ um ein Element $i \in \mathcal{A}^k$ mit $\mu_i^k < 0$ und die anschließende erneute Lösung des Problems (4.77) erzeugt eine zulässige neue Richtung $\mathbf{s}^{k+1}$.

Der Algorithmus des Aktive-Restriktionen-Verfahrens ist in Tabelle 4.2 zusammengefasst. Es kann gezeigt werden, dass das Aktive-Restriktionen-Verfahren für strikt konvexe quadratische Probleme in einer endlichen Anzahl von Iterationen konvergiert.

Beispiel 4.6 ([14]) Betrachtet wird das Beispiel

$$\begin{aligned} \min_{\mathbf{x} \in \mathbb{R}^2} \quad & (x_1 - 1)^2 + (x_2 - 2.5)^2 \\ \text{u.B.v.} \quad & 1) \quad -x_1 + 2x_2 - 2 \leq 0 \\ & 2) \quad x_1 + 2x_2 - 6 \leq 0 \\ & 3) \quad x_1 - 2x_2 - 2 \leq 0 \\ & 4) \quad x_1 \geq 0 \\ & 5) \quad x_2 \geq 0. \end{aligned}$$

Initialization:	$\mathbf{x}^0$ & $\mathcal{A}^0$	Startpunkt & Arbeitsmenge
for $k = 0, 1, 2, \dots$ do		
$\mathbf{s}^k$ & $\mu_i^k, i \in \mathcal{A}^k \leftarrow (4.77) \text{ \& } (4.73)$		gleichungsbeschr. quadr. Problem (4.77)
if $\mathbf{s}^k = \mathbf{0}$ then		Minimum gefunden ($\mathbf{s}^k = \mathbf{0}$)?
if $\mu_i^k \geq 0 \forall i \in \mathcal{A}^k$ then		
return $\mathbf{x}^* = \mathbf{x}^k$		optimale Lösung
else		
$i^k \leftarrow \arg \min_{\mathcal{A}^k} \mu_i^k$		
$\mathcal{A}^{k+1} \leftarrow \mathcal{A}^k \setminus \{i^k\}, \mathbf{x}^{k+1} \leftarrow \mathbf{x}^k$		Deaktivieren aktiver Beschränkung i^k
end		
else		Minimum noch nicht gefunden ($\mathbf{s}^k \neq \mathbf{0}$)
α^k & $i^k \leftarrow (4.81)$		Schrittweitenbestimmung
if $\alpha^k < 1$ then		
$\mathcal{A}^{k+1} \leftarrow \mathcal{A}^k \cup \{i^k\}$		Aktivieren neuer Beschränkung i^k
else		
$\mathcal{A}^{k+1} \leftarrow \mathcal{A}^k$		
end		
$\mathbf{x}^{k+1} \leftarrow \mathbf{x}^k + \alpha^k \mathbf{s}^k$		nächster Iterationspunkt
end		
end		

Tabelle 4.2: Aktive-Restriktionen-Verfahren.

Der zulässige Bereich $\mathcal{X}_{ad}$ und die Höhenlinien der Kostenfunktion sind in Abbildung 4.12 dargestellt. Die Beschränkungen werden im Folgenden mit den Indices 1 bis 5 entsprechend ihrer Reihenfolge gekennzeichnet.

Start: Als Startwert für das Aktive-Beschränkungen-Verfahren wird $\mathbf{x}^0 = [2, 0]^T$ gewählt. Da die Beschränkungen 3 und 5 in $\mathbf{x}^0$ aktiv sind, wird die Arbeitsmenge zu $\mathcal{A}^0 = \{3, 5\}$ gesetzt. Die Lösung des unterlagerten Problems (4.77) führt zu $\mathbf{s}^0 = \mathbf{0}$. Die Auswertung der KKT-Bedingung (4.73a) mit $\mu_i^0 = 0, i = 1, 2, 4$ führt auf die Lagrange-Multiplikatoren $\mu_3 = -2$ und $\mu_5 = -1$ der aktiven Beschränkungen 3 und 5.

Iteration 1: Beschränkung 3 wird aus der Arbeitsmenge $\mathcal{A}^0$ entfernt, da $\mu_3^0 < \mu_5^0 < 0$. Somit ergibt sich $\mathcal{A}^1 = \{5\}$. Die Lösung von (4.77) lautet $\mathbf{s}^1 = [-1, 0]^T$. Die Schrittweite $\alpha^k = 1$ folgt aus (4.81). Somit ist ein "voller" Schritt $\mathbf{x}^2 = \mathbf{x}^1 + \mathbf{s}^1 = [1, 0]^T$ ohne das Auftreten einer weiteren aktiven Beschränkung möglich, so dass $\mathcal{A}^2 = \mathcal{A}^1$ gesetzt wird, siehe Abbildung 4.12.

Iteration 2: Die Lösung von (4.77) ergibt $\mathbf{s}^2 = \mathbf{0}$. Die Auswertung der KKT-Bedingung (4.73a) liefert $\mu_5^2 = -5$ für die einzige aktive Beschränkung in $\mathcal{A}^2 = \{5\}$. Gemäß dem Algorithmus in Tabelle 4.2 wird 5 aus $\mathcal{A}^2$ entfernt, was zur leeren Menge $\mathcal{A}^3 = \{\}$ führt.

Iteration 3: Die Lösung des jetzt unbeschränkten Problems (4.77) führt auf $\mathbf{s}^3 = [0, 2.5]^T$ mit der Schrittweite $\alpha^3 = 0.6$ gemäß (4.81). Somit ergibt sich der neue Iterationspunkt $\mathbf{x}^4 = [1, 1.5]^T$. Da die (jetzt aktive) Beschränkung 1 einen vollen Schritt blockierte, wird $\mathcal{A}^4 = \{1\}$ gesetzt.

Iteration 4: Jetzt ergibt sich $\mathbf{s}^4 = [0.4, 0.2]^T$ mit $\alpha^4 = 1$. Da keine neue Beschränkung aktiviert wird, bleibt die Arbeitsmenge $\mathcal{A}^5 = \mathcal{A}^4 = \{1\}$ unverändert und es ergibt sich $\mathbf{x}^5 = [1.4, 1.7]^T$, siehe Abbildung 4.12.

Iteration 5: Im letzten Schritt liefert (4.77) $\mathbf{s}^5 = \mathbf{0}$ mit dem Lagrange-Multiplikator $\mu_1^5 = 0.8 > 0$ aus (4.73a). Somit stellt $\mathbf{x}^5 = \mathbf{x}^*$ die optimale Lösung dar und der Algorithmus terminiert.




Abbildung 4.12: Iterationen des Aktive-Beschränkungen-Verfahrens in Beispiel 4.6.

4.4.4 Weitere numerische Verfahren

Das Aktive-Restriktionen-Verfahren ist gut geeignet für Probleme kleiner bis mittlerer Dimension, kann aber eine langsame Konvergenz bei hoch-dimensionalen QPs aufweisen, da die Arbeitsmenge $\mathcal{A}^k$ nur jeweils um ein Element reduziert oder erweitert wird. Alternativ sind *Projizierte-Gradienten-Verfahren* für große Probleme gut geeignet, da sie eine schnelle Änderung der Arbeitsmenge $\mathcal{A}^k$ erlauben.

Eine weitere Verfahrensklasse zur Lösung von quadratischen Problemen sind Interior-Point-Verfahren, wie sie bereits in der Linearen Programmierung vorgestellt wurden (Abschnitt 4.3.4). Durch die Einführung von *Schlupfvariablen* können die Ungleichungsbeschränkungen (4.72c) dabei wieder auf die Standardform (4.44b)-(4.44c) gebracht werden.

Weitere Informationen zu Projizierte-Gradienten-Verfahren und Interior-Point-Methoden im Rahmen der Quadratischen Optimierung finden sich in den Büchern am Ende des Kapitels.

Aufgabe 4.10 Verifizieren Sie die Lösung des quadratischen Problems in Beispiel 4.6 mit Hilfe der MATLAB-Funktion `quadprog` aus der Optimization Toolbox (siehe auch Abbildung 4.13).

```
% Matlab solution of a quadratic example problem
% -----
opt = optimoptions('quadprog','Display','iter','Algorithm','interior-point-convex');

G = [2,0; 0,2]; % cost function: 0.5*x'*G*x + c'*x
c = [-2;-5];
C = [-1,2; 1,2; 1,-2; -1,0; 0,-1]; % constraints: C*x <= d
d = [ 2; 6; 2; 0; 0];

x0 = [2.0;0.0]; % initial guess

[x,f] = quadprog(G,c,C,d,[],[],[],[],[],opt); % solution with quadprog
fprintf('\nComputed solution: [%g, %g] mit f(x) = %g\n',x,f);
```

Abbildung 4.13: MATLAB-Code zu Aufgabe 4.10 (quadprog).

4.5 Nichtlineare Optimierung

Nach den betrachteten Sonderfällen der linearen und quadratischen Optimierung soll nun auf Lösungsstrategien für allgemein nichtlineare Probleme (4.1) eingegangen werden, die hier der Vollständigkeit halber wiederholt werden:

$$\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) \quad (4.82a)$$

$$\text{u.B.v. } g_i(\mathbf{x}) = 0, \quad i = 1, \dots, p \quad (4.82b)$$

$$h_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, q. \quad (4.82c)$$

4.5.1 Sequentielle quadratische Programmierung

Eine effiziente Methode zur Lösung nichtlinearer Probleme ist die *sequentielle quadratische Programmierung*, die eine Folge von linear-quadratischen Approximationen des beschränkten Problems (4.82) löst. Dieses Verfahren greift somit auf Methoden aus der quadratischen Programmierung zurück.

Veranschaulichung und allgemeiner Algorithmus

Zur Veranschaulichung der Funktionsweise von SQP-Verfahren wird zunächst das gleichungsbeschränkte Problem

$$\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) \quad (4.83a)$$

$$\text{u.B.v. } \mathbf{g}(\mathbf{x}) = \mathbf{0} \quad (4.83b)$$

mit $\mathbf{g} = [g_1, \dots, g_p]^T$ betrachtet. Die Funktionen $f(\mathbf{x})$ und $\mathbf{g}(\mathbf{x})$ seien stetig differenzierbar. Die Idee von SQP-Verfahren besteht darin, das nichtlineare Problem (4.83) am aktuellen Iterationspunkt $\mathbf{x}^k$ durch ein quadratisches Problem zu approximieren und dessen Lösung zur Berechnung des nächsten Punktes $\mathbf{x}^{k+1}$ zu verwenden.

Die Herleitung des zu lösenden quadratischen Problems lässt sich am einfachsten erklären, wenn man die Optimalitätsbedingungen für (4.83) betrachtet. Mit der Lagrange-Funktion $L(\mathbf{x}, \boldsymbol{\lambda}) =$

$f(\mathbf{x}) + \boldsymbol{\lambda}^\top \mathbf{g}(\mathbf{x})$ reduzieren sich die KKT-Bedingungen (4.29) auf das Gleichungssystem

$$\mathbf{F}(\mathbf{x}, \boldsymbol{\lambda}) = \begin{bmatrix} \nabla f(\mathbf{x}) + \mathbf{A}(\mathbf{x})^\top \boldsymbol{\lambda} \\ \mathbf{g}(\mathbf{x}) \end{bmatrix} = \mathbf{0} \quad \text{mit} \quad \mathbf{A}(\mathbf{x}) = [\nabla g_1(\mathbf{x}), \dots, \nabla g_p(\mathbf{x})]^\top \quad (4.84)$$

der Ordnung $n + p$ für die $n + p$ Unbekannten $(\mathbf{x}, \boldsymbol{\lambda})$. Wenn zur numerischen Lösung des Gleichungssystems das ungedämpfte Newton-Verfahren verwendet wird (Schrittweite $\alpha = 1$), so ergibt sich ähnlich zu (4.67) die Iterationsvorschrift

$$\begin{bmatrix} \mathbf{x}^{k+1} \\ \boldsymbol{\lambda}^{k+1} \end{bmatrix} = \begin{bmatrix} \mathbf{x}^k \\ \boldsymbol{\lambda}^k \end{bmatrix} + \mathbf{s}^k \quad \text{mit} \quad \mathbf{s}^k = \begin{bmatrix} \Delta \mathbf{x}^k \\ \Delta \boldsymbol{\lambda}^k \end{bmatrix} \quad (4.85)$$

und die Newton-Richtung $\mathbf{s}^k$ als Lösung von

$$\underbrace{\begin{bmatrix} \nabla_{xx}^2 L(\mathbf{x}^k, \boldsymbol{\lambda}^k) & \mathbf{A}(\mathbf{x}^k)^\top \\ \mathbf{A}(\mathbf{x}^k) & \mathbf{0} \end{bmatrix}}_{\nabla \mathbf{F}(\mathbf{x}^k, \boldsymbol{\lambda}^k)} \underbrace{\begin{bmatrix} \Delta \mathbf{x}^k \\ \Delta \boldsymbol{\lambda}^k \end{bmatrix}}_{-\mathbf{F}(\mathbf{x}^k, \boldsymbol{\lambda}^k)} = \underbrace{\begin{bmatrix} -\nabla f(\mathbf{x}^k) - \mathbf{A}(\mathbf{x}^k)^\top \boldsymbol{\lambda}^k \\ -\mathbf{g}(\mathbf{x}^k) \end{bmatrix}}_{-\mathbf{F}(\mathbf{x}^k, \boldsymbol{\lambda}^k)}. \quad (4.86)$$

Die Matrix $\nabla \mathbf{F}(\mathbf{x}^k, \boldsymbol{\lambda}^k)$ stellt dabei die Jacobi-Matrix von $\mathbf{F}(\mathbf{x}^k, \boldsymbol{\lambda}^k)$ bzgl. $(\mathbf{x}, \boldsymbol{\lambda})$ dar.

Eine alternative Sichtweise auf die Newton-Iterationsvorschrift (4.85), (4.86) ergibt sich, wenn man das quadratische Problem

$$\min_{\mathbf{s} \in \mathbb{R}^n} \quad f(\mathbf{x}^k) + \nabla f(\mathbf{x}^k)^\top \mathbf{s} + \frac{1}{2} \mathbf{s}^\top \nabla_{xx}^2 L(\mathbf{x}^k, \boldsymbol{\lambda}^k) \mathbf{s} \quad (4.87a)$$

$$\text{u.B.v.} \quad \mathbf{A}(\mathbf{x}^k) \mathbf{s} + \mathbf{g}(\mathbf{x}^k) = \mathbf{0} \quad (4.87b)$$

mit den Optimalitätsbedingungen

$$\nabla_{xx}^2 L(\mathbf{x}^k, \boldsymbol{\lambda}^k) \mathbf{s}^k + \nabla f(\mathbf{x}^k) + \mathbf{A}(\mathbf{x}^k)^\top \boldsymbol{\lambda}_s^k = \mathbf{0} \quad (4.88a)$$

$$\mathbf{A}(\mathbf{x}^k) \mathbf{s} + \mathbf{g}(\mathbf{x}^k) = \mathbf{0} \quad (4.88b)$$

für die Lösung $(\mathbf{s}^k, \boldsymbol{\lambda}_s^k)$ betrachtet. Wenn man nun den Term $\mathbf{A}(\mathbf{x}^k)^\top \boldsymbol{\lambda}^k$ auf beiden Seiten der ersten Gleichung in (4.86) addiert, erhält man mit $\boldsymbol{\lambda}^{k+1} = \boldsymbol{\lambda}^k + \Delta \boldsymbol{\lambda}^k$

$$\begin{bmatrix} \nabla_{xx}^2 L(\mathbf{x}^k, \boldsymbol{\lambda}^k) & \mathbf{A}(\mathbf{x}^k)^\top \\ \mathbf{A}(\mathbf{x}^k) & \mathbf{0} \end{bmatrix} \begin{bmatrix} \Delta \mathbf{x}^k \\ \boldsymbol{\lambda}^{k+1} \end{bmatrix} = \begin{bmatrix} -\nabla f(\mathbf{x}^k) \\ -\mathbf{g}(\mathbf{x}^k) \end{bmatrix}. \quad (4.89)$$

Man erkennt direkt, dass (4.89) und die Optimalitätsbedingungen (4.88) für das quadratische Problem (4.87) für $\Delta \mathbf{x}^k = \mathbf{s}^k$ und $\boldsymbol{\lambda}^{k+1} = \boldsymbol{\lambda}_s^k$ identisch sind. Die Iterationsvariablen $(\mathbf{x}^{k+1}, \boldsymbol{\lambda}^{k+1})$ können somit entweder als Lösung der Newton-Iteration (4.85), (4.86) oder als Lösung des quadratischen Problems (4.87) mit $\mathbf{x}^{k+1} = \mathbf{x}^k + \mathbf{s}^k$ und den Multiplikatoren $\boldsymbol{\lambda}^{k+1} = \boldsymbol{\lambda}_s^k$ bestimmt werden.

Diese Sichtweise kann direkt auf ungleichungsbeschränkte Optimierungsprobleme erweitert werden, da die Gleichungsbeschränkungen (4.87b) des quadratischen Problems eine Linearisierung von $\mathbf{g}(\mathbf{x})$ am Punkt $\mathbf{x}^k$ darstellt. Im Fall des allgemeinen nichtlinearen Problems (4.82) betrachten SQP-Verfahren in jedem Schritt k das quadratische Problem

$$\min_{\mathbf{s} \in \mathbb{R}^n} \quad \frac{1}{2} \mathbf{s}^\top \nabla_{xx}^2 L(\mathbf{x}^k, \boldsymbol{\lambda}^k, \boldsymbol{\mu}^k) \mathbf{s} + \nabla f(\mathbf{x}^k)^\top \mathbf{s} \quad (4.90a)$$

$$\text{u.B.v.} \quad \nabla g_i(\mathbf{x}^k)^\top \mathbf{s} + g_i(\mathbf{x}^k) = 0, \quad i = 1, \dots, p \quad (4.90b)$$

$$\nabla h_i(\mathbf{x}^k)^\top \mathbf{s} + h_i(\mathbf{x}^k) \leq 0, \quad i = 1, \dots, q, \quad (4.90c)$$

Initialization:

$k \leftarrow 0$	Iterationszähler
$\mathbf{x}^0$	Startpunkt
$\mathbf{H}^0$	Startapproximation der Hesse-Matrix (pos. def.)

repeat

$\mathbf{s}^k \leftarrow$ Lösung von (4.90)	
$\alpha^k \leftarrow$ z.B. Armijo-Bed. (3.21)	Wahl von Schrittweite α^k für Abstieg in Straffkt. $P(\mathbf{x}^k + \alpha^k \mathbf{s}^k, \sigma) < P(\mathbf{x}^k, \sigma)$, z.B. mit (4.91)
$\mathbf{x}^{k+1} \leftarrow \mathbf{x}^k + \alpha^k \mathbf{s}^k$	nächster Iterationspunkt
$k \leftarrow k + 1$	

until $\|\nabla_{\mathbf{x}} L(\mathbf{x}^k, \boldsymbol{\lambda}^k, \boldsymbol{\mu}^k)\| \leq \varepsilon$ oder anderes Abbruchkriterium

Tabelle 4.3: Struktur von SQP-Verfahren.

wobei der Anteil $f(\mathbf{x}^k)$ in der Kostenfunktion vernachlässigt werden kann, da er unabhängig von $\mathbf{s}$ ist. Zur Lösung von (4.90) stehen die in Abschnitt 4.4 beschriebenen Verfahren zur Verfügung. Die Hesse-Matrix $\nabla_{\mathbf{xx}}^2 L(\mathbf{x}^k, \boldsymbol{\lambda}^k, \boldsymbol{\mu}^k)$ der Lagrange-Funktion kann entweder direkt bestimmt werden, d.h. analytisch oder durch numerisches bzw. automatisches Differenzieren, oder durch eine Quasi-Newton-Approximation, siehe z.B. [14].

Der neue Iterationspunkt ergibt sich zu $\mathbf{x}^{k+1} = \mathbf{x}^k + \alpha^k \mathbf{s}^k$, wobei $\mathbf{s}^k$ die Lösung von (4.90) darstellt. Die Schrittweite α^k muss geeignet gewählt werden, damit der neue Punkt $\mathbf{x}^{k+1}$ einen hinreichenden Abstieg in der Kostenfunktion $f(\mathbf{x}^{k+1}) < f(\mathbf{x}^k)$ bewirkt, andererseits aber auch die Ungleichungsbeschränkungen (4.82c) eingehalten werden. Dieser Punkt wird in Abschnitt 4.5.1 näher untersucht. Der grundsätzliche Algorithmus eines SQP-Verfahrens ist in Tabelle 4.3 dargestellt.

Praktische Verfahren zur Lösung von (4.90) können prinzipiell in folgende Klassen unterteilt werden:

- *EQP-Verfahren* (Englisch: *equality-constrained QP*) wählen in jedem Iterationspunkt $\mathbf{x}^k$ eine Arbeitsmenge an aktiven Beschränkungen und reduzieren (4.90) auf ein gleichungsbeschränktes Problem, wobei alle Beschränkungen, die sich nicht in der Arbeitsmenge befinden, verworfen werden. Die Arbeitsmenge wird in jedem neuen Schritt aktualisiert. Dieses Verfahren hat den Vorteil, dass die Lösung gleichungsbeschränkter quadratischer Probleme für hoch-dimensionale Probleme weniger Rechenaufwand benötigt als die Lösung des allgemeinen Problems (4.90).
- *IQP-Verfahren* (Englisch: *inequality-constrained QP*) verwenden die Menge der aktiven Ungleichungsbeschränkungen von (4.90) als Schätzung der aktiven Beschränkungenmenge $\mathcal{A}(\mathbf{x}^*)$ an der optimalen Lösung $\mathbf{x}^*$. Falls diese Menge $\mathcal{A}(\mathbf{x}^*)$ korrekt bestimmt werden kann, verhält sich das SQP-Verfahren wie ein Newton-Verfahren für gleichungsbeschränkte Probleme und konvergiert schnell zum optimalen Punkt $\mathbf{x}^*$. Dieses Verfahren hat sich als sehr erfolgreich in der Praxis erwiesen. Der Nachteil ist, dass die Lösung von (4.90) bei großen Problemen sehr rechenaufwändig werden kann. Andererseits können in der Nähe des Optimums Informationen aus den vorhergehenden Iterationen verwendet werden (*Warmstart-Strategie*), um eine gute Schätzung für die Lösung in der momentanen Iteration zu erhalten.

Wahl der Schrittweite

Wie bereits erwähnt wurde, ist es nicht ausreichend, die Schrittweite α^k so zu wählen, dass der Abstieg in der Kostenfunktion $f(\mathbf{x}^k + \alpha^k \mathbf{s}^k) < f(\mathbf{x}^k)$ hinreichend groß ist, da auch das Einhalten der Beschränkungen $g_i(\mathbf{x}) = 0$ und $h_i(\mathbf{x}) \leq 0$ berücksichtigt werden muss. Im Allgemeinen wird dazu eine *Straffunktion* angesetzt, die beide Aspekte berücksichtigt. Ein Beispiel dafür ist die sogenannte *l_1 -Straffunktion*

$$P(\mathbf{x}, \sigma) = f(\mathbf{x}) + \sigma \left[\sum_{i=1}^p |g_i(\mathbf{x})| + \sum_{i=1}^q \max\{0, h_i(\mathbf{x})\} \right], \quad (4.91)$$

die die Eigenschaft besitzt, dass jede Lösung $\mathbf{x}^*$ des nichtlinearen Problems (4.82) ebenfalls ein minimierender Punkt von P ist, unter der Voraussetzung, dass $(\mathbf{x}^*, \boldsymbol{\lambda}^*, \boldsymbol{\mu}^*)$ die hinreichenden Optimalitätsbedingungen (4.37) erfüllt und der Strafparameter σ die Ungleichungen $\sigma > |\lambda_i^*|$, $i = 1, \dots, p$ und $\sigma > |\mu_i^*|$, $i = 1, \dots, q$ erfüllt. Man spricht in diesem Zusammenhang von einer *exakten Straffunktion*.

Die Schrittweite α^k kann nun mit einem der in Abschnitt 3.3.1 vorgestellten Liniensuchverfahren geeignet bestimmt werden (z.B. mittels der Armijo-Bedingung (3.21)), um einen hinreichenden Abstieg in der Straffunktion $P(\mathbf{x}^k + \alpha^k \mathbf{s}^k, \sigma) < P(\mathbf{x}^k, \sigma)$ zu erreichen.

Beispiel 4.7 (Optimale Auslegung von Reglerparametern) Als Beispiel soll die Optimierung von Reglerparametern für ein totzeitbehaftetes zeitdiskretes Streckenmodell

$$x(k) = ax(k-1) + bu(k-10) \quad (4.92)$$

mit den Streckenparametern $a = b = 0.5$ betrachtet werden [15]. Das Regelgesetz sei gegeben durch

$$u(k) = c_1 u(k-1) + c_2 e(k) + c_3 e(k-1), \quad (4.93)$$

wobei $e(k) = 1 - x(k)$ den Regelfehler auf einen Einheitssprung darstellt. Die Reglerparameter sollen so eingestellt werden, dass die (zeitdiskrete) betragslineare Regelfläche

$$f(\mathbf{c}) = \sum_{k=1}^N |e(k)| \quad (4.94)$$

bzw. die zeitgewichtete betragslineare Regelfläche

$$f(\mathbf{c}) = \sum_{k=1}^N \frac{k}{N} |e(k)| \quad (4.95)$$

minimiert wird, bei der zeitlich spätere Abweichungen stärker ins Gewicht fallen. Darüber hinaus soll das Überschwingen von $x(k)$ begrenzt werden.

Die Optimization Toolbox von MATLAB stellt zur Lösung von nichtlinearen Optimierungsproblemen die Funktion `fmincon` zur Verfügung. Das SQP-Verfahren kann mit Hilfe der Option `optimset('Algorithm','active-set')` bzw. `optimset('Algorithm','sqp')` ausgewählt werden.

Der MATLAB-Code zur Bestimmung der optimalen Reglerparameter mittels `fmincon` ist in Abbildung 4.14 zusammengefasst.⁷ Dabei wird die Begrenzung des Überschwingens als nichtlineare Beschränkung implementiert. Als Startwert für die Reglerparameter wurde $\mathbf{c}^0 = [1, 0.5, -0.5]^T$ gewählt.

Die optimierten Sprungantworten für die Fälle (4.94) und (4.95) mit jeweils 10% und 0% Überschwingen und die dazugehörigen Reglerparameter sind in den Abbildungen 4.15, 4.16 und in Tabelle 4.4 dargestellt.

In allen Fällen liefert die Optimierung den Wert $c_1 = 1$ zurück. Der Regler (4.93) besitzt somit integrierendes Verhalten. Des Weiteren ist in Abbildung 4.16 zu erkennen, dass die zeitliche Gewichtung in der Kostenfunktion (4.95) eine Möglichkeit darstellt, um das Schwingungsverhalten nach Erreichen des Sollwertes zu dämpfen.

```

function controllerparameters(caseQ)
% -----
global x cold
switch caseQ
    case 1, p.costQ=1; p.ov=0.1; % control surface, max. overshoot 10%
    case 2, p.costQ=1; p.ov=0; % control surface, max. overshoot 0%
    case 3, p.costQ=2; p.ov=0.1; % time-weighted control surface, max. overshoot 10%
    case 4, p.costQ=2; p.ov=0; % time-weighted control surface, max. overshoot 0%
end

p.N = 70; % number of steps
p.a = 0.5; p.b = 0.5; % system parameters
c0 = [1;0.5;-0.5]; % initial guess

opt = optimoptions('fmincon','Algorithm','sqp', ... % SQP method for fmincon
'Display','iter','MaxFunEvals',500);

[c,f] = fmincon(@costfct,c0,[],[],[],[],[],[],@nlconstr,opt,p);
fprintf('\nOptimal parameters c=[%2.3g,%2.3g,%2.3g] with f(c)=%2.3g\n',c,f);

x = stepresponse(c,p); % optimized step response

figure(1); clf % plotting
h(1) = stairs(ones(1,p.N),'r--'); hold on
h(2) = stairs(x,'k');
h(3) = stairs(1-x,'m'); xlabel('Time steps');
axis([0, p.N, -0.1, 1.1+p.ov]);
legend(h,'Reference','State x','Error e')

function x = stepresponse(c,p)
% -----
z = tf('z'); % z-transformation:
G0 = (c(2)+c(3)*z^(-1))/(1-c(1)*z^(-1)) * p.b/(z^10-p.a*z^9); % Gcontrol * Gsystem
x = step( G0/(1+G0), p.N-1 ); % step response

function f = costfct(c,p)
% -----
global x cold
x = stepresponse(c,p); % step response
if p.costQ==1, f = sum( abs(1-x) ); % cost function
else f = 1/p.N*sum( [1:p.N]*abs(1-x) ); end
cold = c;

function [C,Ceq] = nlconstr(c,p)
% -----
global x cold
if any(c~=cold), x=stepresponse(c,p); end % if new c-values
C = max(x-(1+p.ov)); Ceq = []; % nonlin. inequ. constr.

```

Abbildung 4.14: MATLAB-Code zur Bestimmung der optimalen Reglerparameter (fmincon).

⁷ Der geschlossene Regelkreis (4.92), (4.93) ist als z-Übertragungsfunktion implementiert. Die Sprungantwort wird mit Hilfe der Funktion step berechnet.




Abbildung 4.15: Sprungantwort des optimierten Regelkreises mit Kostenfunktion (4.94) (Überschwingen 10%: - -, 0%: -).




Abbildung 4.16: Sprungantwort des optimierten Regelkreises mit Kostenfunktion (4.95) (Überschwingen 10%: - -, 0%: -).

Kostenfkt.	max. Überschw.	c_1^*	c_2^*	c_3^*	$f(\mathbf{c}^*)$
(4.94)	10%	1.000	0.439	-0.369	14.6
(4.94)	0%	1.000	0.439	-0.372	14.8
(4.95)	10%	1.000	0.367	-0.297	1.93
(4.95)	0%	1.000	0.400	-0.333	2.06

Tabelle 4.4: Optimale Reglerparameter für den Regelkreis (4.92)-(4.93).

4.5.2 Weitere numerische Verfahren

Ein grundsätzlich anderes Vorgehen als bei SQP-Verfahren besteht darin, das ursprüngliche Problem (4.82) durch ein oder mehrere unbeschränkte Probleme zu ersetzen, die sukzessive numerisch gelöst werden. Im Folgenden wird nur kurz auf diese Verfahren eingegangen. Für weitere Informationen sei auf die am Ende des Kapitels angegebenen Bücher verwiesen.

Methode der äußeren Straffunktionen

Im einfachsten Fall kann das ursprüngliche beschränkte Problem (4.82) durch ein neues unbeschränktes Problem ersetzt werden, indem die Beschränkungen (4.82b) und (4.82c) als Strafterme zur Kostenfunktion addiert werden:

$$\min_{\mathbf{x} \in \mathbb{R}^n} P(\mathbf{x}, \tau) = f(\mathbf{x}) + \frac{1}{\tau} \left[\sum_{i=1}^p \phi(g_i(\mathbf{x})) + \sum_{i=1}^q \psi(h_i(\mathbf{x})) \right]. \quad (4.96)$$

Die Funktionen ϕ und ψ stellen *äußere Straffunktionen* dar, die Beschränkungen von außen bestrafen und somit ein Verletzen der Beschränkungsgrenzen erlauben.

Die Straffunktion ϕ für die Gleichungsbeschränkungen $g_i(\mathbf{x}) = 0$ wird gewöhnlich als Potenzfunktion $\phi(g_i(\mathbf{x})) = |g_i(\mathbf{x})|^r$ mit $r \geq 1$ angesetzt, während ψ typischerweise wie folgt definiert ist

$$\psi(h_i(\mathbf{x})) = (\max\{0, h_i(\mathbf{x})\})^r, \quad r \geq 1. \quad (4.97)$$




Abbildung 4.17: Veranschaulichung von äußeren und inneren Straffunktionen $\psi(h(\mathbf{x}))$ für eine Ungleichungsbeschränkung $h(\mathbf{x}) \leq 0$.

Abbildung 4.17a verdeutlicht das Verhalten von ψ und den Einfluss des Strafparameters τ .

Die Lösung $\mathbf{x}(\tau)$ des neuen unbeschränkten Problems (4.96) wird in der Regel von der optimalen Lösung $\mathbf{x}^*$ des Originalproblems (4.82) abweichen, da der Strafterm in (4.96) die ursprüngliche Kostenfunktion (4.82a) verfälscht.

In der Praxis wird daher das Problem (4.96) sukzessive für eine abnehmende Sequenz $\{\tau^k\}$ von Strafparametern gelöst, was einer zunehmenden Bestrafung der Beschränkungsverletzung entspricht (Abbildung 4.17a). Unter gewissen Bedingungen kann gezeigt werden, dass sich für eine Sequenz $\{\tau^k\}$ mit $\lim_{k \rightarrow \infty} \tau^k = 0$ die optimale Lösung im Limit ergibt, d.h.

$$\lim_{k \rightarrow \infty} \mathbf{x}(\tau^k) = \mathbf{x}^*. \quad (4.98)$$

Ein bekannter Nachteil des Verfahrens ist allerdings, dass das Problem (4.96) für $\tau \rightarrow 0$ zunehmend schlecht konditioniert wird, was eine genaue Approximation der optimalen Lösung $\mathbf{x}^*$ in der Praxis schwierig macht.

Methode der inneren Straffunktionen (Barrieremethode)

Innere Straffunktionen oder *Barrierefunktionen* bestrafen die Annäherung an die Beschränkungsgrenze und gehen gegen Unendlich, wenn die Grenze $h_i(\mathbf{x}) = 0$ berührt wird, wie in den Abbildungen 4.17b und 4.8 zu erkennen ist. Beispiele von Barrierefunktionen sind

$$\psi(h_i(\mathbf{x})) = \frac{-1}{h_i(\mathbf{x})} \quad \text{oder} \quad \psi(h_i(\mathbf{x})) = -\ln(-h_i(\mathbf{x})). \quad (4.99)$$

Da Barrierefunktionen nur im Inneren des zulässigen Bereiches definiert sind, können nur Ungleichungsbeschränkungen (4.82) berücksichtigt werden:

$$\min_{\mathbf{x} \in \mathbb{R}^n} P(\mathbf{x}, \tau) = f(\mathbf{x}) + \tau \sum_{i=1}^q \psi(h_i(\mathbf{x})). \quad (4.100)$$

Durch sukzessive Reduktion des Strafparameters τ reduziert sich die Bestrafung des zulässigen Bereiches für $h_i(\mathbf{x}) < 0$, während $\psi \rightarrow \infty$ bei Berührung der Beschränkungsgrenze $h_i(\mathbf{x}) \rightarrow 0$

erhalten bleibt (Abbildung 4.17b). Wie im Fall der äußeren Straffunktionen kann (unter gewissen Umständen) gezeigt werden, dass für eine abnehmende Sequenz $\{\tau^k\}$ mit $\lim_{k \rightarrow \infty} \tau^k = 0$ die optimale Lösung $\mathbf{x}^*$ im Limit (4.98) erreicht wird.

Bei Barrieremethoden stellt sich insbesondere das Problem, eine zulässige Startlösung $\mathbf{x}^0$ zu bestimmen, die innerhalb der Schranken $h_i(\mathbf{x}) \leq 0$ liegt.

Interior-Point-Verfahren

Interior-Point-Verfahren sind bereits im Zusammenhang mit der linearen Programmierung in Abschnitt 4.3.4 vorgestellt worden. Ihre Erweiterung auf nichtlineare Probleme soll deshalb nur kurz angerissen werden. Interior-Point-Verfahren basieren auf der Idee, die strikte Komplementaritätsbedingung (4.29e) durch einen Parameter $\tau > 0$ zu modifizieren, d.h. $\mu_i^* h_i(\mathbf{x}^*) + \tau = 0$, um die numerische Lösung der KKT-Bedingungen (4.29) zu erleichtern. Wie bereits in Abschnitt 4.3.4 gezeigt wurde, besteht ein Zusammenhang zwischen Interior-Point-Verfahren und der logarithmischen Barrierefunktion in (4.99). Allerdings sind Interior-Point-Verfahren numerisch besser konditioniert und gehören zu den leistungsfähigsten Verfahren der nichtlinearen Optimierung. Für weitergehende Informationen sei insbesondere auf den sehr guten Übersichtsaufsatz [9] und die Bücher [17, 14] verwiesen.

4.6 Lagrange-Dualität

In den vorherigen Abschnitten wurden beschränkte Optimierungsprobleme hauptsächlich anhand der Lösung der Optimalitätsbedingungen (KKT-Bedingungen) untersucht und algorithmisch der Minimumspunkt $\mathbf{x}^*$ gesucht. Bei der Dualitätstheorie wird statt dessen ein alternatives Optimierungsproblem betrachtet, das zum ursprünglichen Optimierungsproblem *dual* ist. Dieses duale Problem zeichnet sich durch interessante Eigenschaften aus, weswegen das duale Problem in manchen Fällen einfacher zu lösen ist als das Originalproblem.

In diesem Abschnitt wird zunächst auf die duale Formulierung eingegangen und anschließend ein bekanntes numerisches Verfahren zur Lösung des dualen Problems, die erweiterte Lagrange-Methode, vorgestellt.

4.6.1 Duale Formulierung

Als Basis wird in weiterer Folge das nichtlineare Optimierungsproblem

$$\min_{\mathbf{x} \in \mathcal{X}} f(\mathbf{x}) \quad (4.101a)$$

$$\text{u.B.v. } \mathbf{g}(\mathbf{x}) = \mathbf{0} \quad (4.101b)$$

$$\mathbf{h}(\mathbf{x}) \leq \mathbf{0} \quad (4.101c)$$

betrachtet, wobei im Vergleich zu (4.82) die Beschränkungsfunktionen in $\mathbf{g} = [g_1, \dots, g_p]^\top$ und $\mathbf{h} = [h_1, \dots, h_q]^\top$ der Kompaktheit wegen vektoriell zusammengefasst sind. Zudem berücksichtigt die Formulierung (4.101) einen zusätzlichen Definitionsbereich $\mathcal{X} \subseteq \mathbb{R}^n$ für die Optimierungsvariablen $\mathbf{x}$.

Gemäß Definition 4.2 lautet die Lagrange-Funktion für das Problem (4.101)

$$L(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\mu}) = f(\mathbf{x}) + \boldsymbol{\lambda}^\top \mathbf{g}(\mathbf{x}) + \boldsymbol{\mu}^\top \mathbf{h}(\mathbf{x}) \quad (4.102)$$

mit den Lagrange-Multiplikatoren $\boldsymbol{\lambda} \in \mathbb{R}^p$ und $\boldsymbol{\mu} \in \mathbb{R}^q$. Die sogenannte *duale Funktion* ist nun als das Infimum⁸ der Lagrange-Funktion bzgl. $\mathbf{x}$ definiert.

Definition 4.4 (Duale Funktion) Die Lagrange-duale Funktion (kurz: duale Funktion) ist definiert durch

$$\theta(\boldsymbol{\lambda}, \boldsymbol{\mu}) = \inf_{\mathbf{x} \in \mathcal{X}} L(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\mu}). \quad (4.103)$$

Problemabhängig kann es sein, dass die duale Funktion $\theta(\boldsymbol{\lambda}, \boldsymbol{\mu})$ den Wert $-\infty$ annimmt, was bspw. der Fall ist, wenn L linear in $\mathbf{x}$ und $\mathcal{X} = \mathbb{R}^n$ ist (siehe Beispiel 4.8). Aus diesem Grund wird der Bereich definiert, auf dem θ endlich ist, d.h.

$$D = \{(\boldsymbol{\lambda}, \boldsymbol{\mu}) \in \mathbb{R}^{p \times q} \mid \theta(\boldsymbol{\lambda}, \boldsymbol{\mu}) > -\infty\}. \quad (4.104)$$

Die duale Funktion besitzt interessante strukturelle Eigenschaften auf D , und zwar unabhängig von den Konvexitätseigenschaften der Kostenfunktion $f(\mathbf{x})$ und der Beschränkungsfunktionen $\mathbf{g}(\mathbf{x})$ und $\mathbf{h}(\mathbf{x})$ des Originalproblems (4.82), wie der folgende Satz zeigt.

Satz 4.5 Die Menge D ist konvex und die duale Funktion θ ist konkav auf D .

Beweis: Für jedes $\mathbf{x}$, $(\boldsymbol{\lambda}, \boldsymbol{\mu})$, $(\boldsymbol{\lambda}', \boldsymbol{\mu}')$ und $\alpha \in [0, 1]$ gilt

$$L(\mathbf{x}, \alpha\boldsymbol{\lambda} + (1 - \alpha)\boldsymbol{\lambda}', \alpha\boldsymbol{\mu} + (1 - \alpha)\boldsymbol{\mu}') = \alpha L(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\mu}) + (1 - \alpha)L(\mathbf{x}, \boldsymbol{\lambda}', \boldsymbol{\mu}')$$

Betrachtet man das Infimum der Lagrange-Funktion, so gilt

$$\begin{aligned} \inf_{\mathbf{x} \in \mathbb{R}^n} L(\mathbf{x}, \alpha\boldsymbol{\lambda} + (1 - \alpha)\boldsymbol{\lambda}', \alpha\boldsymbol{\mu} + (1 - \alpha)\boldsymbol{\mu}') &= \inf_{\mathbf{x} \in \mathbb{R}^n} (\alpha L(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\mu}) + (1 - \alpha)L(\mathbf{x}, \boldsymbol{\lambda}', \boldsymbol{\mu}')) \\ &\geq \alpha \inf_{\mathbf{x} \in \mathbb{R}^n} L(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\mu}) + (1 - \alpha) \inf_{\mathbf{x} \in \mathbb{R}^n} L(\mathbf{x}, \boldsymbol{\lambda}', \boldsymbol{\mu}') \end{aligned}$$

bzw.

$$\theta(\alpha\boldsymbol{\lambda} + (1 - \alpha)\boldsymbol{\lambda}', \alpha\boldsymbol{\mu} + (1 - \alpha)\boldsymbol{\mu}') \geq \alpha\theta(\boldsymbol{\lambda}, \boldsymbol{\mu}) + (1 - \alpha)\theta(\boldsymbol{\lambda}', \boldsymbol{\mu}'),$$

was die Konkavität der dualen Funktion θ beweist. Wenn $(\boldsymbol{\lambda}, \boldsymbol{\mu})$, $(\boldsymbol{\lambda}', \boldsymbol{\mu}')$ zu D gehören, so gilt ebenfalls $\alpha\boldsymbol{\lambda} + (1 - \alpha)\boldsymbol{\lambda}' \in D$, da $\theta(\alpha\boldsymbol{\lambda} + (1 - \alpha)\boldsymbol{\lambda}', \alpha\boldsymbol{\mu} + (1 - \alpha)\boldsymbol{\mu}') > -\infty$, was zeigt, dass D konvex ist. ■

Definition 4.5 (Duales Problem) Das zu (4.101) Lagrange-duale Problem (kurz: duales Problem) ist definiert durch

$$\max_{\boldsymbol{\lambda}, \boldsymbol{\mu}} \quad \theta(\boldsymbol{\lambda}, \boldsymbol{\mu}) \quad (4.105a)$$

$$\text{u.B.v.} \quad \boldsymbol{\mu} \geq \mathbf{0}. \quad (4.105b)$$

⁸ Das Infimum einer nichtleeren Menge $\mathcal{X} \subset \mathbb{R}$, kurz $\inf \mathcal{X}$, bezeichnet die größte untere Schranke von $\mathcal{X}$. Es existiert also eine Zahl ξ so, dass $x \geq \xi$ für alle $x \in \mathcal{X}$ gilt und weiters für alle $\xi' > \xi$ ein $x \in \mathcal{X}$ so existiert, dass $x < \xi'$. Das Infimum von $\mathcal{X}$ muss nicht notwendigerweise in der Menge enthalten sein, siehe z.B. $\inf \mathcal{X} = 0$ mit $\mathcal{X} = (0, 1)$ und $0 \notin \mathcal{X}$. Angewandt auf eine Funktion $f: \mathcal{U} \rightarrow \mathcal{V}$ gilt $\inf_{u \in \mathcal{U}} f(u) = \inf \mathcal{V}$. Die Definition des Supremums $\sup \mathcal{X}$ als kleinste obere Schranke einer Menge $\mathcal{X}$ erfolgt analog.

Im Sinne der Dualitätstheorie wird das ursprüngliche Optimierungsproblem (4.101) als *primales Problem* bezeichnet. Bei den Variablen spricht man von den *primale Variablen* $\mathbf{x}$ und den *dualen Variablen* $(\boldsymbol{\lambda}, \boldsymbol{\mu})$.

Das duale Problem ist stets konvex, selbst wenn das primale Optimierungsproblem (4.101) nicht konvex sein sollte. Neben der Konvexität von (4.105) ist von Vorteil, dass die duale Formulierung im Gegensatz zum primalen Problem (4.82) nur lineare Ungleichungsbeschränkungen besitzt. In manchen Fällen kann es daher sinnvoll sein, dass duale Problem (4.105) anstelle des primalen zu lösen. Ein Algorithmus, der auf der dualen Formulierung basiert, ist der erweiterte Lagrange-Algorithmus, der in Abschnitt 4.6.2 vorgestellt wird.

Wie bereits erwähnt, kann bei der dualen Formulierung der Fall auftreten, dass die duale Funktion $\theta(\boldsymbol{\lambda}, \boldsymbol{\mu})$ den Wert $-\infty$ annimmt. In vielen Fällen kann die Menge D in (4.104) allerdings explizit bestimmt und in die duale Formulierung (4.105) eingearbeitet werden, wie das folgende Beispiel zeigt.

Beispiel 4.8 (Duale Standardform linearer Optimierungsprobleme) Betrachtet wird ein lineares Problem in Standardform (siehe auch Abschnitt 4.3)

$$\min_{\mathbf{x} \in \mathbb{R}^n} \quad \mathbf{c}^T \mathbf{x} \quad (4.106a)$$

$$\text{u.B.v.} \quad \mathbf{A}\mathbf{x} = \mathbf{b}, \quad \mathbf{x} \geq \mathbf{0} \quad (4.106b)$$

mit der Lagrange-Funktion

$$L(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\mu}) = \mathbf{c}^T \mathbf{x} + \boldsymbol{\lambda}^T (\mathbf{A}\mathbf{x} - \mathbf{b}) + \boldsymbol{\mu}^T (-\mathbf{x}) = (\mathbf{A}^T \boldsymbol{\lambda} - \boldsymbol{\mu} + \mathbf{c})^T \mathbf{x} - \boldsymbol{\lambda}^T \mathbf{b}.$$

Das duale Problem (4.105) lautet dann

$$\max_{\boldsymbol{\lambda}, \boldsymbol{\mu}} \quad \theta(\boldsymbol{\lambda}, \boldsymbol{\mu}) = \begin{cases} -\boldsymbol{\lambda}^T \mathbf{b} & \text{falls } \mathbf{A}^T \boldsymbol{\lambda} - \boldsymbol{\mu} + \mathbf{c} = \mathbf{0} \\ -\infty & \text{sonst,} \end{cases} \quad (4.107a)$$

$$\text{u.B.v.} \quad \boldsymbol{\mu} \geq \mathbf{0}. \quad (4.107b)$$

Die duale Funktion $\theta(\boldsymbol{\lambda}, \boldsymbol{\mu})$ ergibt sich nach der Definition (4.103) und ist offensichtlich nur für $\mathbf{A}^T \boldsymbol{\lambda} - \boldsymbol{\mu} + \mathbf{c} = \mathbf{0}$ endlich. Diese Bedingung kann in der Formulierung des dualen Problems (4.107) mitberücksichtigt werden,

$$\max_{\boldsymbol{\lambda}} \quad -\boldsymbol{\lambda}^T \mathbf{b} \quad (4.108a)$$

$$\text{u.B.v.} \quad \mathbf{A}^T \boldsymbol{\lambda} + \mathbf{c} \geq \mathbf{0}. \quad (4.108b)$$

wobei sich die Ungleichungsbeschränkung (4.108b) durch Zusammenfassen von $\mathbf{A}^T \boldsymbol{\lambda} - \boldsymbol{\mu} + \mathbf{c} = \mathbf{0}$ und $\boldsymbol{\mu} \geq \mathbf{0}$ ergibt. Die Formulierung (4.108) wird häufig auch als Lagrange-duale Standardform oder kurz duale Standardform in der linearen Optimierung bezeichnet.

Aufgabe 4.11 Betrachtet wird das lineare Problem (4.106), allerdings mit dem Unterschied, dass die Ungleichungsbeschränkung $\mathbf{x} \geq \mathbf{0}$ in den Definitionsbereich $\mathbf{x} \in \mathcal{X}$ mit $\mathcal{X} = \{\mathbf{x} \in \mathbb{R}^n \mid \mathbf{x} \geq \mathbf{0}\}$ integriert wird. Bestimmen Sie die duale Funktion (4.103) und zeigen Sie, dass das resultierende duale Problem identisch zu (4.108) ist.

Zumindest für den Fall ohne Gleichungsbeschränkungen (4.101b) und unter Annahme von Konvexität stellt der folgende Satz einen Zusammenhang zwischen den Optimalitätsbedingungen des primalen Problems und der Lösung des dualen Problems her.

Satz 4.6 ([14]) *Das primale Optimierungsproblem (4.101a), (4.101c) besitze eine Lösung $\mathbf{x}^*$ und die Funktionen f und h_i , $i = 1, \dots, q$ seien konvex auf $\mathbb{R}^n$ und differenzierbar am Punkt $\mathbf{x}^*$. Dann ist jedes Multiplikatorpaar $(\boldsymbol{\lambda}^*, \boldsymbol{\mu}^*)$, das am Punkt $\mathbf{x}^*$ die KKT-Bedingungen (4.29) erfüllt, eine Lösung des dualen Problems.*

Falls für die Lösung eines Optimierungsproblems die duale Formulierung verwendet werden soll, stellt sich insbesondere die Kehrfrage von Satz 4.6, nämlich wann gesichert ist, dass die Lösung von (4.105) auch eine optimale Lösung von (4.82) ist. Dies steht in engem Zusammenhang mit der Eigenschaft der *schwachen* und der *starken Dualität*.

Satz 4.7 (Schwache Dualität) *Für jeden zulässigen primalen und dualen Punkt, d.h. $\mathbf{x} \in \mathcal{X}_{ad} = \{\mathbf{x} \in \mathcal{X} \mid \mathbf{g}(\mathbf{x}) = \mathbf{0}, \mathbf{h}(\mathbf{x}) \leq \mathbf{0}\}$ und $(\boldsymbol{\lambda}, \boldsymbol{\mu})$ mit $\boldsymbol{\mu} \geq \mathbf{0}$, gilt $\theta(\boldsymbol{\lambda}, \boldsymbol{\mu}) \leq f(\mathbf{x})$.*

Die schwache Dualität besagt insbesondere, dass das Maximum $\theta^* = \max_{\boldsymbol{\lambda}, \boldsymbol{\mu} \geq \mathbf{0}} \theta(\boldsymbol{\lambda}, \boldsymbol{\mu})$ der dualen Funktion stets eine untere Grenze für den optimalen Kostenfunktionswert $f^* = f(\mathbf{x}^*)$ des primalen Optimierungsproblems (4.82) darstellt, d.h.

$$\theta^* \leq f^*.$$

Die Differenz $f^* - \theta^*$ zwischen beiden Werten wird als *Dualitätslücke* bezeichnet. Wenn keine Dualitätslücke existiert, also

$$\theta^* = f^*$$

gilt, so spricht man von *starker Dualität*. Falls $\mathbf{x}^*$ und $(\boldsymbol{\lambda}^*, \boldsymbol{\mu}^*)$ eine primal-dual optimale Lösung ist und starke Dualität vorliegt, so erfüllt die Lagrange-Funktion die *Sattelpunktbedingung*

$$L(\mathbf{x}^*, \boldsymbol{\lambda}, \boldsymbol{\mu}) \leq L(\mathbf{x}^*, \boldsymbol{\lambda}^*, \boldsymbol{\mu}^*) \leq L(\mathbf{x}, \boldsymbol{\lambda}^*, \boldsymbol{\mu}^*) \quad \forall \mathbf{x} \in \mathcal{X}, \boldsymbol{\lambda}, \boldsymbol{\mu} \geq \mathbf{0}. \quad (4.109)$$

Eine optimale Lösung minimiert also die Lagrange-Funktion bzgl. den primalen Variablen und maximiert sie bzgl. den dualen Variablen.

Der Umkehrschluss gilt ebenfalls: wenn $(\mathbf{x}^*, \boldsymbol{\lambda}^*, \boldsymbol{\mu}^*)$ die Sattelpunktbedingung (4.109) erfüllt, so ist $\mathbf{x}^*$ primal optimal, $(\boldsymbol{\lambda}^*, \boldsymbol{\mu}^*)$ ist dual optimal und die Dualitätslücke ist null.

Satz 4.8 (Sattelpunkt) *Ein primal-dualer Punkt $(\mathbf{x}^*, \boldsymbol{\lambda}^*, \boldsymbol{\mu}^*)$ mit $\boldsymbol{\mu}^* \geq \mathbf{0}$ ist genau dann optimal, wenn die Sattelpunktbedingung (4.109) für alle $\mathbf{x} \in \mathcal{X}$ und $(\boldsymbol{\lambda}, \boldsymbol{\mu}) \in \mathbb{R}^{p \times q}$ mit $\boldsymbol{\mu} \geq \mathbf{0}$ erfüllt ist.*

Beispiel 4.9 *Betrachtet wird das Optimierungsproblem*

$$\min_{\mathbf{x} \in \mathbb{R}} \quad f(\mathbf{x}) = 2x - \frac{1}{2}x^2 - \frac{2}{3}x^3 + \frac{1}{4}x^4 \quad (4.110a)$$

$$\text{u.B.v.} \quad h(\mathbf{x}) = 4x^2 - 1 \leq 0 \quad (4.110b)$$




Abbildung 4.18: Verlauf der Funktionen $f(x)$, $h(x)$ und $L(x, \mu)$ für diskrete Werte von $\mu \in [0, 3]$ sowie Darstellung der dualen Funktion $\theta(\mu)$ als untere Schranke der optimalen Kosten f^* (Beispiel 4.9).




Abbildung 4.19: Grafische Validierung der Sattelpunktbedingung (4.109) für Beispiel 4.9.

mit der Lagrange-Funktion $L(x, \mu) = 2x - \frac{1}{2}x^2 - \frac{2}{3}x^3 + \frac{1}{4}x^4 + \mu(4x^2 - 1)$. Abbildung 4.18 stellt linkerhand $f(x)$ und $h(x)$ sowie die zulässige Menge $\mathcal{X}_{ad} = \{x \in \mathbb{R} \mid -\frac{1}{2} \leq x \leq \frac{1}{2}\}$ grau hinterlegt dar. Zusätzlich ist $L(\cdot, \mu)$ für verschiedene Werte von $\mu \in [0, 3]$ sowie die entsprechenden Minima, die dem Verlauf der dualen Funktion $\theta(\mu)$ entsprechen, dargestellt. Man erkennt, dass $\theta(\mu)$ im zulässigen Bereich $\mathcal{X}_{ad}$ gemäß Satz 4.7 unterhalb der Kostenfunktion $f(x)$ verläuft.

Die rechte Hälfte von Abbildung 4.18 stellt die duale Funktion $\theta(\mu)$ über μ sowie den optimalen Wert f^* der Kostenfunktion als Lösung von (4.110) dar. Da das Maximum $\theta^* = \max_{\mu \geq 0} \theta(\mu)$ mit f^* übereinstimmt, existiert keine Dualitätslücke und starke Dualität liegt vor. Zusätzlich ist in Abbildung 4.19 die Lagrange-Funktion $L(x, \lambda)$ dargestellt. Man erkennt anhand der roten Kurven, dass die Sattelpunktbedingung (4.109) am primal-dual optimalen Punkt (x^*, μ^*) erfüllt ist.

Der Nachweis von starker Dualität basiert i.a. auf Konvexitätsannahmen, auch wenn Beispiel 4.9 zeigt, dass starke Dualität auch bei nicht-konvexen Problemen vorliegen kann. Es sei daran erinnert, dass ein nichtlineares Optimierungsproblem mit linearen Gleichungsbeschrän-

kungen

$$\min_{\mathbf{x} \in \mathcal{X}} f(\mathbf{x}) \quad (4.111a)$$

$$\text{u.B.v. } \mathbf{Ax} = \mathbf{b} \quad (4.111b)$$

$$\mathbf{h}(\mathbf{x}) \leq \mathbf{0} \quad (4.111c)$$

konvex ist, wenn die Funktionen f und h_i , $i = 1, \dots, q$ konvex sind (siehe Satz 2.5) und zusätzlich $\mathcal{X}$ konvex ist. Zusätzlich wird zur Gewährleistung von starker Dualität häufig die Beschränkungsqualifikation von Slater

$$\exists \mathbf{x} \in \text{relint}(\mathcal{X}) : \mathbf{Ax} = \mathbf{b}, \quad h_i(\mathbf{x}) < 0, \quad i = 1, \dots, q \quad (4.112)$$

benötigt, die besagt, dass mindestens ein innerer Punkt $\mathbf{x}$ des primalen Problems existieren muss.⁹ Es gilt nun folgender Satz.

Satz 4.9 (Starke Dualität) *Das primale Optimierungsproblem (4.111) sei konvex für $\mathbf{x} \in \mathbb{R}^n$ und zulässig, das Minimum $f^* = f(\mathbf{x}^*)$ sei endlich und die Beschränkungsqualifikation (4.112) sei erfüllt. Dann gilt:*

- Es existiert keine Dualitätslücke, d.h. $\theta^* = f^*$.
- Es existiert mindestens ein Paar dualer Variablen mit $\theta(\boldsymbol{\lambda}^*, \boldsymbol{\mu}^*) = \theta^*$.
- Die Sattelpunktbedingung (4.109) ist erfüllt.
- Wenn $\mathbf{x}^*$ eine globale primale Lösung ist, so ist $(\boldsymbol{\lambda}^*, \boldsymbol{\mu}^*)$ eine globale Lösung des dualen Problems (4.105).

Aus den Annahmen in Satz 4.9 folgt nicht automatisch die Eindeutigkeit der primalen Lösung $\mathbf{x}^*$. Dies kann zusätzlich durch die Annahme strikter Konvexität der Lagrange-Funktion $L(\cdot, \boldsymbol{\lambda}^*, \boldsymbol{\mu}^*)$ gewährleistet werden [14]. Weiters sei angemerkt, dass Konvexität alleine nicht ausreichend ist, um starke Dualität zu gewährleisten. Das folgende Beispiel verdeutlicht dies.

Beispiel 4.10 (Konvexes Problem mit Dualitätslücke [3]) Betrachtet wird das Problem

$$\min_{\mathbf{x} \in \mathcal{X}} e^{-\sqrt{x_1 x_2}} \quad (4.113a)$$

$$\text{u.B.v. } x_1 = 0, \quad (4.113b)$$

wobei die Kostenfunktion $f(\mathbf{x}) = e^{-\sqrt{x_1 x_2}}$ auf dem Bereich $\mathcal{X} = \{\mathbf{x} \in \mathbb{R}^2 \mid \mathbf{x} \geq \mathbf{0}\}$ definiert und konvex ist. Das Minimum liegt bei $f^* = f(\mathbf{x}^*) = 1$ mit $x_1^* = 0$ und $x_2^* \geq 0$. Mit der Lagrange-Funktion $L(\mathbf{x}, \lambda) = e^{-\sqrt{x_1 x_2}} + \lambda x_1$ ergibt sich die duale Funktion

$$\theta(\lambda) = \inf_{\mathbf{x} \in \mathcal{X}} (e^{-\sqrt{x_1 x_2}} + \lambda x_1) = \begin{cases} 0 & \text{falls } \lambda \geq 0. \\ -\infty & \text{sonst} \end{cases} \quad (4.114)$$

Im ersten Fall ($\lambda \geq 0$) gilt $x_1 \rightarrow 0$ und $x_1 x_2 \rightarrow \infty$. Dies wird klar, wenn man $\mathbf{x} = [1/\xi, \xi^2]^T$ und

$$\lim_{\xi \rightarrow \infty} L(\mathbf{x}, \lambda \geq 0) = \lim_{\xi \rightarrow \infty} e^{-\sqrt{\xi}} + \frac{\lambda}{\xi} = 0$$

⁹ Falls $\mathcal{X}$ mindestens einen inneren Punkt besitzt, so gilt $\text{relint}(\mathcal{X}) = \text{int}(\mathcal{X})$.

betrachtet. Somit gilt $\theta^* = \max_{\lambda} \theta(\lambda) = 0$. Wegen $f^* - \theta^* = 1 > 0$ existiert eine Dualitätslücke. Im Hinblick auf Satz 4.9 sind zwei Voraussetzungen verletzt: die Beschränkungsqualifikation (4.112) ist nicht erfüllt und $f(\mathbf{x})$ ist nur auf $\mathcal{X}$ konvex, nicht aber auf $\mathbb{R}^n$.

Aufgabe 4.12 Untersuchen Sie die folgenden Optimierungsprobleme auf starke Dualität:

$$\begin{array}{ll} \min_{\mathbf{x} \in \mathbb{R}} & x^4 \\ \text{u.B.v.} & x^2 \geq 1 \end{array} \qquad \begin{array}{ll} \min_{\mathbf{x} \in \mathbb{R}} & x^2 \\ \text{u.B.v.} & x^4 \geq 1. \end{array}$$

Unter der Annahme, dass starke Dualität vorliegt, kann die duale Formulierung zur Lösung des ursprünglichen Optimierungsproblems (4.101) bzw. (4.111) verwendet werden. Formal gesehen gliedert sich die Bestimmung der optimalen primalen Lösung $\mathbf{x}^*$ dabei in zwei Schritte. Zunächst wird $(\boldsymbol{\lambda}^*, \boldsymbol{\mu}^*)$ durch Lösung des dualen Problems (4.105) bestimmt. Unter Ausnutzung der Sattelpunktbedingung (4.109) folgt dann die Bestimmung von $\mathbf{x}^*$ als das minimierende Argument von (4.103). Bei der erweiterten Lagrange-Methode werden diese formalen Maximierungs-Minimierungsschritte in einem sequentiellen Vorgehen kombiniert.

4.6.2 Erweiterte Lagrange-Methode

Die erweiterte Lagrange-Methode ist auf gleichungsbeschränkte nichtlineare Optimierungsprobleme der Form

$$\min_{\mathbf{x} \in \mathcal{X}} f(\mathbf{x}) \tag{4.115a}$$

$$\text{u.B.v. } \mathbf{g}(\mathbf{x}) = \mathbf{0} \tag{4.115b}$$

mit den Beschränkungsfunktionen $\mathbf{g} = [g_1 \dots g_p]^\top$ anwendbar. Die Erweiterung auf Ungleichungsbeschränkungen wird in Abschnitt 4.6.3 erläutert.

Die *erweiterte Lagrange-Funktion* ist definiert durch

$$L_c(\mathbf{x}, \boldsymbol{\lambda}) = f(\mathbf{x}) + \boldsymbol{\lambda}^\top \mathbf{g}(\mathbf{x}) + \frac{c}{2} \|\mathbf{g}(\mathbf{x})\|^2 \tag{4.116}$$

mit den Lagrange-Multiplikatoren $\boldsymbol{\lambda}^\top \in \mathbb{R}^p$ und einem zusätzlichen euklidischen Strafterm mit Parameter $c \geq 0$, der Abweichungen von der Beschränkung $\mathbf{g}(\mathbf{x}) = \mathbf{0}$ bestraft. Das duale Problem basierend auf der erweiterten Lagrange-Funktion (4.116) lautet

$$\max_{\boldsymbol{\lambda}} \inf_{\mathbf{x} \in \mathcal{X}} L_c(\mathbf{x}, \boldsymbol{\lambda}). \tag{4.117}$$

Wenn starke Dualität vorliegt und $(\mathbf{x}^*, \boldsymbol{\lambda}^*)$ eine primal-duale Lösung ist, so erfüllt die erweiterte Lagrange-Funktion die Sattelpunktbedingung

$$L_c(\mathbf{x}^*, \boldsymbol{\lambda}) \leq L_c(\mathbf{x}^*, \boldsymbol{\lambda}^*) \leq L_c(\mathbf{x}, \boldsymbol{\lambda}^*) \quad \forall \mathbf{x}, \boldsymbol{\lambda}. \tag{4.118}$$

Im Sinne der erweiterten Lagrange-Methode ist insbesondere der Umkehrschluss relevant: wenn (4.118) erfüllt ist, dann ist $(\mathbf{x}^*, \boldsymbol{\lambda}^*)$ eine primal-duale Lösung und es existiert keine Dualitätslücke.

Initialization:

$k_{\max}$	max. Anzahl an Iterationen
λ^1	dualer Startpunkt
$c^1 > 0$	Startwert Strafparameter
$\varepsilon_g > 0$	Toleranz für Abbruchkriterium
for $k = 1, \dots, k_{\max}$ do	
$\mathbf{x}^k = \arg \min_{\mathbf{x} \in \mathcal{X}} L_{c^k}(\mathbf{x}, \lambda^k)$	Minimierungsschritt (approximativ)
if $\ \mathbf{g}^k\ \leq \varepsilon_g$ or $k = k_{\max}$ then	Konvergenztest mit $\mathbf{g}^k = \mathbf{g}(\mathbf{x}^k)$
return $\mathbf{x}^k$	
end	
$\lambda^{k+1} = \lambda^k + c^k \mathbf{g}^k$	Update der dualen Variablen (steilster Aufstieg)
if $k > 1$ then	
$c^{k+1} = \psi_c(c^k, \ \mathbf{g}^k\ , \ \mathbf{g}^{k-1}\)$	Update der Strafparameter
end	
end	

Tabelle 4.5: Struktur des erweiterten Lagrange-Algorithmus.

Die zusätzliche quadratische Bestrafung der Beschränkungen in der Lagrange-Funktion (4.116) bringt numerische Vorteile mit sich und wirkt sich zudem positiv auf die Dualität des Problems aus. So kann (unter gewissen Voraussetzungen) gezeigt werden, dass für hinreichend große Strafparameter $c > 0$ starke Dualität auch für nicht-konvexe Problemstellungen erreicht werden kann [16]. Für die Verwendung eines erweiterten Lagrange-Algorithmus ist der folgende Satz [14] wichtig, der besagt, dass der Strafterm nicht unnötig groß gewählt werden muss.

Satz 4.10 Sei $\mathbf{x}^*$ eine lokale Lösung von (4.115), für die die Beschränkungsqualifikation (4.26) sowie die KKT-Bedingungen (4.29) und die hinreichenden Optimalitätsbedingungen (4.37) für $\lambda = \lambda^*$ erfüllt sind. Dann existiert eine untere Schranke $\bar{c} > 0$ so, dass $L_c(\mathbf{x}, \lambda^*)$ für alle $c \geq \bar{c}$ ein striktes lokales Minimum an der Stelle $\mathbf{x} = \mathbf{x}^*$ besitzt.

Der erweiterte Lagrange-Algorithmus basiert auf der Idee, $(\mathbf{x}^*, \lambda^*)$ durch iteratives Annähern an den Sattelpunkt (4.118) zu berechnen. Tabelle 4.5 stellt den Grundalgorithmus dar. Wenn $\mathbf{x}$ unbeschränkt ist, d.h. $\mathcal{X} = \mathbb{R}^n$, so können numerische Verfahren der unbeschränkten Optimierung zur Lösung verwendet werden, siehe Kapitel 3. Im Falle von Intervallbeschränkungen der Form $\mathcal{X} = [\mathbf{x}^-, \mathbf{x}^+]$ können diese über Projektion auf den jeweiligen Rand berücksichtigt werden. Das Minimierungsproblem wird in der Regel approximativ gelöst, bspw. durch Verwendung eines Konvergenzkriteriums der Form

$$\|\nabla_{\mathbf{x}} L_{c^k}(\mathbf{x}^k, \lambda^k)\| \leq \varepsilon_L^k, \quad (4.119)$$

wobei $\varepsilon_L^k > 0$ über die Iterationen reduziert wird, oder durch Überprüfung des Fortschritts anhand von $\|\mathbf{x}^k - \mathbf{x}^{k-1}\| \leq \varepsilon_x \|\mathbf{x}^{k-1}\|$ mit $\varepsilon_x < 1$.

Die Aktualisierung der dualen Variablen λ in Tabelle 4.5 erfolgt in Richtung des steilsten Aufstiegs. Dies ist ersichtlich, wenn man den Gradienten der erweiterten Lagrange-Funktion (4.116) $\nabla_{\lambda} L_c = \mathbf{g}(\mathbf{x}^k)$ betrachtet. Die Wahl der Schrittweite kann allerdings nicht per Liniensuche

erfolgen, da L_c linear in λ ist und somit kein Maximumspunkt im Endlichen existiert. Allerdings lässt sich die Wahl des Strafparameters c als Schrittweite auf andere Weise erklären. Wenn man die Stationaritätsbedingung für die (zumindest näherungsweise) Lösung $\mathbf{x}^k$ des Minimierungsproblems

$$\nabla_{\mathbf{x}} L_{c^k}(\mathbf{x}^k, \boldsymbol{\lambda}^k) = \nabla f(\mathbf{x}^k) + \sum_{i=1}^p (\lambda_i^k + c^k g_i(\mathbf{x}^k)) \nabla g_i(\mathbf{x}^k) = \mathbf{0} \quad (4.120)$$

mit der optimalen Lösung von (4.115)

$$\nabla_{\mathbf{x}} L(\mathbf{x}^*, \boldsymbol{\lambda}^*) = \nabla f(\mathbf{x}^*) + \sum_{i=1}^p \lambda_i^* \nabla g_i(\mathbf{x}^*) = \mathbf{0} \quad (4.121)$$

vergleicht, erkennt man, dass die Aktualisierungsvorschrift $\boldsymbol{\lambda}^{k+1} = \boldsymbol{\lambda}^k + c^k \mathbf{g}(\mathbf{x}^k)$ in Tabelle 4.5 so interpretiert werden kann, dass $\boldsymbol{\lambda}^{k+1}$ möglichst nah an $\boldsymbol{\lambda}^*$ gebracht werden soll.

Eine andere Veranschaulichung für die Wahl von c als Schrittweite ergibt sich, wenn man das *proximale Maximierungsproblem*

$$\boldsymbol{\lambda}^{k+1} = \arg \max_{\boldsymbol{\lambda}} \left(L_{c^k}(\mathbf{x}^k, \boldsymbol{\lambda}) - \frac{1}{2c^k} \|\boldsymbol{\lambda} - \boldsymbol{\lambda}^k\|^2 \right) \quad (4.122)$$

betrachtet, das bei der Maximierung von L_c zusätzlich die Abweichung vom vorherigen Iterationspunkt bestraft. Die Lösung dieses strikt konvexen Problems führt ebenfalls auf die Aktualisierungsvorschrift in Tabelle 4.5.

Bei der Aktualisierung des Strafparameters ist es naheliegend, c^k zu erhöhen, wenn bei der Reduktion des Beschränkungsfehlers $\|\mathbf{g}^k\| = \|\mathbf{g}(\mathbf{x}^k)\|$ nicht genug Fortschritt erzielt wird. Eine einfache Aktualisierungsvorschrift ist daher

$$c^{k+1} = \psi_c(c^k, \|\mathbf{g}^k\|, \|\mathbf{g}^{k-1}\|) = \begin{cases} \beta c^k & \text{falls } \|\mathbf{g}^k\| > \gamma \|\mathbf{g}^{k-1}\| \\ c^k & \text{sonst} \end{cases} \quad (4.123)$$

mit $\gamma < 1$ und $\beta > 1$. Empfohlene Werte [3] hierfür sind $\gamma = 0.25$ und $\beta \in [5, 10]$. Wie bereits erwähnt, wird der Minimierungsschritt $\min_{\mathbf{x} \in \mathcal{X}} L_{c^k}(\mathbf{x}, \boldsymbol{\lambda}^k)$ in Tabelle 4.5 in der Regel approximativ durchgeführt. In diesem Fall hat sich ein adaptives Anpassen des Strafparameters c^k in beide Richtungen, also auch ein temporäres Absenken von $c^{k+1} < c^k$, als vorteilhaft erwiesen, siehe bspw. LANCELOT [5] oder die MPC-Toolbox GRAMPC [6]. Ein Absenken von c^k ist dann sinnvoll, wenn die Beschränkungen bereits das Konvergenzkriterium $\|\mathbf{g}^k\| \leq \varepsilon_g$ erfüllen, aber die Minimierung von $L_{c^k}(\mathbf{x}, \boldsymbol{\lambda}^k)$ noch ungenügend ist, also bspw. das Kriterium (4.119) noch nicht erfüllt ist.

Der folgende Satz [3, 14] zeigt auf, dass der erweiterte Lagrange-Algorithmus zumindest lokal um eine optimale Lösung $(\mathbf{x}^*, \boldsymbol{\lambda}^*)$ und für hinreichend große Strafparameter lineare Konvergenz besitzt.

Satz 4.11 (Konvergenz des erweiterten Lagrange-Algorithmus) Die Annahmen von Satz 4.10 seien am Punkt $(\mathbf{x}^*, \boldsymbol{\lambda}^*)$ erfüllt und $\bar{c} > 0$ sei entsprechend Satz 4.10 gewählt.

Dann existieren Konstanten $\delta_c, \delta_x, C > 0$ so, dass für alle λ^k und c^k mit $\|\lambda^k - \lambda^*\| \leq \delta_c \bar{c}$ und $c^k \geq \bar{c}$ das Problem

$$\begin{aligned} \min_{x \in \mathcal{X}} \quad & L_{c^k}(x, \lambda^k) \\ \text{u.B.v.} \quad & \|x - x^*\| \leq \delta_x \end{aligned}$$

eine eindeutige Lösung x^k besitzt. Für x^k und $\lambda^{k+1} = \lambda^k + c^k g(x^k)$ gilt zudem

$$\|x^k - x^*\| \leq C \|\lambda^k - \lambda^*\| / c^k, \quad \|\lambda^{k+1} - \lambda^*\| \leq C \|\lambda^k - \lambda^*\| / c^k. \quad (4.124)$$

Aufgabe 4.13 ([3]) Untersuchen Sie für die beiden Beispiele

$$\begin{aligned} \min_{x \in \mathbb{R}^2} \quad & \frac{1}{2}(x_1^2 + x_2^2) & \min_{x \in \mathbb{R}^2} \quad & \frac{1}{2}(-x_1^2 + x_2^2) \\ \text{u.B.v.} \quad & x_1 = 1 & \text{u.B.v.} \quad & x_1 = 1 \end{aligned}$$

das Lösungsverhalten des erweiterten Lagrange-Algorithmus und bestimmen Sie die untere Schranke $\bar{c} > 0$ für den Strafparameter $c^k \geq \bar{c}$ für die numerische Konvergenz des Algorithmus.

4.6.3 Handhabung von Ungleichungsbeschränkungen

Die erweiterte Lagrange-Methode wurde im vorherigen Abschnitt für gleichungsbeschränkte Probleme der Form (4.115) beschrieben. Sollen zusätzliche Ungleichungsbeschränkungen

$$h(x) \leq 0 \quad (4.125)$$

mit $h = [h_1, \dots, h_q]^T$ berücksichtigt werden, so müssen diese in einem ersten Schritt durch das Einführen von Schlupfvariablen $s \geq 0$ zu den Gleichungsbeschränkungen (4.115b) hinzugefügt werden

$$\hat{g}(x, s) = \begin{bmatrix} g(x) \\ h(x) + s \end{bmatrix} = 0. \quad (4.126)$$

Die erweiterte Lagrange-Funktion lautet dann

$$L_c(x, s, \lambda) = f(x) + \lambda^T \hat{g}(x, s) + \frac{c}{2} \|\hat{g}(x, s)\|^2 \quad (4.127)$$

mit den Lagrange-Multiplikatoren $\lambda^T = [\lambda_g^T, \lambda_h^T] \in \mathbb{R}^{p+q}$ und dem Strafparameter $c > 0$. Das entsprechende duale Problem (4.117) ist definiert durch

$$\max_{\lambda} \inf_{x \in \mathcal{X}, s \geq 0} L_c(x, s, \lambda). \quad (4.128)$$

Die innere Minimierung bzgl. $s \geq 0$ reduziert sich auf das strikt konvexe Problem ($c > 0$)

$$\min_{s \geq 0} \left(\lambda_h^T (h(x) + s) + \frac{c}{2} \|h(x) + s\|^2 \right). \quad (4.129)$$

Die Lösung erhält man über die Stationaritätsbedingung und Projektion auf die zulässige Menge $s \geq 0$, d.h.

$$s = \max \{0, -\lambda_h / c - h(x)\}, \quad (4.130)$$

wobei die vektorwertige **max**-Funktion elementweise zu verstehen ist. Einsetzen von (4.130) in (4.126) führt auf die neue Form der Gleichungsbeschränkungen

$$\bar{\mathbf{g}}_c(\mathbf{x}, \boldsymbol{\lambda}) = \begin{bmatrix} \mathbf{g}(\mathbf{x}) \\ \max\{\mathbf{h}(\mathbf{x}), -\boldsymbol{\lambda}_h/c\} \end{bmatrix} = \mathbf{0} \quad (4.131)$$

und die entsprechende erweiterte Lagrange-Funktion

$$\bar{L}_c(\mathbf{x}, \boldsymbol{\lambda}) = f(\mathbf{x}) + \boldsymbol{\lambda}^T \bar{\mathbf{g}}_c(\mathbf{x}, \boldsymbol{\lambda}) + \frac{c}{2} \|\bar{\mathbf{g}}_c(\mathbf{x}, \boldsymbol{\lambda})\|^2 \quad (4.132)$$

für das duale Problem

$$\max_{\boldsymbol{\lambda}} \inf_{\mathbf{x} \in \mathcal{X}} \bar{L}_c(\mathbf{x}, \boldsymbol{\lambda}). \quad (4.133)$$

Die Berücksichtigung von Ungleichungsbeschränkungen im erweiterten Lagrange-Algorithmus erfolgt also dadurch, dass $\mathbf{g}$ und L_c in Tabelle 4.5 durch (4.131) und (4.132) ersetzt und die Dimension von $\boldsymbol{\lambda}$ entsprechend angepasst wird. Bei der Umformulierung der Gleichungsbeschränkungen (4.131) ist zu beachten, dass diese nun von den Multiplikatoren $\boldsymbol{\lambda}$ und dem Strafparameter c abhängen.

4.6.4 Anmerkungen

Der Vorteil der erweiterten Lagrange-Methode besteht in der Tatsache, dass das innere Minimierungsproblem

$$\inf_{\mathbf{x} \in \mathcal{X}} L_c(\mathbf{x}, \boldsymbol{\lambda})$$

in der Regel einfacher zu lösen ist als das ursprüngliche, beschränkte Optimierungsproblem, da es bis auf die zulässige Menge $\mathbf{x} \in \mathcal{X}$ unbeschränkt ist. In jüngerer Zeit wurde die duale Formulierung im Zusammenhang mit Varianten des Gradientenverfahrens, insbesondere beschleunigten Gradientenverfahren [13], populär. Ein Überblick über verschiedene primal-duale Lösungsverfahren ist in [11] dargestellt.

Die verhältnismäßig einfache Struktur der erweiterten Lagrange-Methode bietet zudem Vorteile bei Implementierungen auf eingebetteten Systemen bzw. leistungsschwacher Hardware, wie bspw. Steuergeräten im Automotive-Bereich oder speicherprogrammierbaren Steuerungen (SPS) in Automatisierungssystemen. Bei eingebetteten Systemen sind insbesondere Algorithmen vonnöten, die eine schnelle Berechnung einzelner Iterationen ermöglichen (unter Inkaufnahme von Suboptimalität) bei gleichzeitiger numerischer Robustheit bei begrenzter Rechengenauigkeit [7, 8].

Die Dualitätstheorie findet auch im Zusammenhang mit verteilten Optimierungsverfahren und vernetzten Systemen Anwendung, da sie ermöglicht, zentrale Optimierungsprobleme zu entkoppeln und verteilt zu lösen. Ein populäres Verfahren ist *ADMM* (*Alternating Direction Method of Multipliers*) [10, 4], das für die Lösung von Optimierungsproblemen der Form

$$\min_{\mathbf{x}, \mathbf{y}} f_1(\mathbf{x}) + f_2(\mathbf{y}) \quad (4.134a)$$

$$\text{u.B.v. } \underbrace{\mathbf{Ax} + \mathbf{By} - \mathbf{b}}_{\mathbf{g}(\mathbf{x}, \mathbf{y})} = \mathbf{0} \quad (4.134b)$$

mit den Optimierungsvariablen $(\mathbf{x}, \mathbf{y}) \in \mathbb{R}^{n_1 \times n_2}$, den Kostenfunktionen $f_1(\mathbf{x})$ und $f_2(\mathbf{y})$ und der Kopplungsbedingung (4.134b) geeignet ist. Mit der erweiterten Lagrange-Funktion $L_c(\mathbf{x}, \mathbf{y}, \boldsymbol{\lambda}) = f_1(\mathbf{x}) + f_2(\mathbf{y}) + \boldsymbol{\lambda}^\top \mathbf{g}(\mathbf{x}, \mathbf{y}) + \frac{c}{2} \|\mathbf{g}(\mathbf{x}, \mathbf{y})\|^2$ lautet die ADMM-Iterationsvorschrift

$$\mathbf{x}^{k+1} = \arg \min_{\mathbf{x}} L_{c^k}(\mathbf{x}, \mathbf{y}^k, \boldsymbol{\lambda}^k) \quad (4.135a)$$

$$\mathbf{y}^{k+1} = \arg \min_{\mathbf{y}} L_{c^k}(\mathbf{x}^{k+1}, \mathbf{y}, \boldsymbol{\lambda}^k) \quad (4.135b)$$

$$\boldsymbol{\lambda}^{k+1} = \boldsymbol{\lambda}^k + c^k \mathbf{g}^{k+1} \quad (4.135c)$$

$$c^{k+1} = \psi_c(c^k, \|\mathbf{g}^k\|, \|\mathbf{g}^{k+1}\|) \quad (4.135d)$$

mit $\mathbf{g}^k = \mathbf{g}(\mathbf{x}^k, \mathbf{y}^k)$. Die sequenzielle Lösung der Minimierungsprobleme für $\mathbf{x}$ und $\mathbf{y}$ („Alternating Direction“) erlaubt die Dekomposition des Gesamtproblems. Dieser Ansatz wird beispielsweise in der verteilten modellprädiktiven Regelung vernetzter Systeme oder auch in der Bildverarbeitung und Nachrichtentechnik eingesetzt, um großskalige Optimierungsprobleme effizient verteilt zu lösen.

4.7 Software-Übersicht

Im Folgenden ist eine Auswahl an Software zur Lösung von statischen Optimierungsproblemen zusammengestellt.

Lineare Optimierung

- linprog: MATLAB Optimization Toolbox (kostenpflichtig)
- CPLEX (kostenpflichtig)
<http://www.ilog.com/products/cplex>
- GLPK: “GNU Linear Programming Kit” (frei zugänglich)
<http://www.gnu.org/software/glpk>
- lp_solve: Mixed-Integer Lineare Optimierung (frei zugänglich)
<http://lpsolve.sourceforge.net>
- CVXGEN (kostenfreie Lizenz für akademische Benutzung)
<https://cvxgen.com>

Quadratische Optimierung

- quadprog: MATLAB Optimization Toolbox (kostenpflichtig)
- qpOASES (frei zugänglich)
<http://github.com/coin-or/qpOASES>
- OOQP (frei zugänglich)
<http://pages.cs.wisc.edu/~swright/ooqp>
- CPLEX (kostenpflichtig)
<http://www.ilog.com/products/cplex>
- LOQO (kostenpflichtig)
<http://vanderbei.princeton.edu/loqomenu.html>

- CVXGEN (kostenfreie Lizenz für akademische Benutzung)
<https://www.cvxgen.com>

Nichtlineare Optimierung

- fmincon: MATLAB Optimization Toolbox (kostenpflichtig)
- IPOPT (frei zugänglich)
<https://github.com/coin-or/Ipopt>
- SNOPT (kostenpflichtig, aber Studentenversion frei zugänglich)
<http://ccom.ucsd.edu/~optimizers>
- LOQO (kostenpflichtig)
<http://vanderbei.princeton.edu>
- MINOS (kostenpflichtig)
http://www.sbsi-sol-optimize.com/asp/sol_product_minos.htm

Modellierungssprachen & Automatische Code-Generierung

Die meisten der oben angegebenen Optimierer unterstützen eine Anbindung an MATLAB oder an eine der Modellierungssprachen AMPL (z.B. LOQO, GLPK, IPOPT) oder GAMS (z.B. MINOS). Diese Sprachen bieten eine symbolorientierte Syntax zum Formulieren von Optimierungsproblemen. Von zunehmender Bedeutung ist ebenso eine automatische Code-Generierung, wie sie beispielsweise von CasADi angeboten wird.

- AMPL: "A Mathematical Programming Language"
<http://www.ampl.com>
- GAMS: "General Algebraic Modeling System"
<http://www.gams.com>
- CasADi: Code-Generierung unter Verwendung von automatischem Differenzieren
<https://web.casadi.org>

4.8 Literatur

- [1] G. Allaire. *Numerical Analysis and Optimization*. Oxford: Oxford University Press, 2007.
- [2] J.A.E. Andersson, J. Gillis, G. Horn, J.B. Rawlings und M. Diehl. "CasADi – A software framework for nonlinear optimization and optimal control". In: *Mathematical Programming Computation* (2018). Online verfügbar.
- [3] D.P. Bertsekas. *Nonlinear Programming*. Belmont. Athena Scientific, 1999.
- [4] S. Boyd, N. Parikh, E. Chu, B. Peleato und J. Eckstein. "Distributed optimization and statistical learning via the alternating direction method of multipliers". In: *Foundations and Trends in Machine Learning* 3.1 (2011), S. 1–122.
- [5] A. R. Conn, G.I.M. Gould und P. L. Toint. *LANCELOT: A Fortran Package for Large-Scale Nonlinear Optimization (Release A)*. Berlin, Germany: Springer-Verlag, 1992.

- [6] T. Englert, A. Völz, F. Mesmer, S. Rhein und K. Graichen. "A software framework for embedded nonlinear model predictive control using a gradient-based augmented Lagrangian approach (GRAMPC)". In: *Optimization and Engineering* 20.3 (2019), S. 769–809. DOI: 10.1007/s11081-018-9417-2.
- [7] H.J. Ferreau, S. Almér, R. Verschueren, M. Diehl, D. Frick, A. Domahidi, J.L. Jerez, G. Stathopoulos und C. Jones. "Embedded optimization methods for industrial automatic control". In: *Proc. 20th IFAC World Congress*. 2017, S. 13736–13751.
- [8] R. Findeisen, K. Graichen und M. Mönnigmann. "Eingebettete Optimierung in der Regelungstechnik – Grundlagen und Herausforderungen". In: *at – Automatisierungstechnik* 66.11 (2018), S. 877–902.
- [9] A. Forsgren, P.E. Gill und M.H. Wright. "Interior methods for nonlinear optimization". In: *SIAM Review* 44.4 (2002), S. 525–597.
- [10] M. Fortin und R. Glowinski, Hrsg. *Augmented Lagrangian Methods: Applications to the Solution of Boundary-Value Problems*. Amsterdam: North-Holland, 1983.
- [11] D. Kouzoupis, H.J. Ferreau, H. Peyrl und M. Diehl. "First-order methods in embedded nonlinear model predictive control". In: *Proc. 2015 European Control Conference (ECC)*. 2015, S. 2617–2622.
- [12] J. Mattingley und S. Boyd. "CVXGEN: A code generator for embedded convex optimization". In: *Optimization and Engineering* 13.1 (2012), S. 1–27.
- [13] Y. Nesterov. "Introductory lectures on convex optimization: A basic course". In: *Applied Optimization*. Hrsg. von P.M. Pardalos und D.W. Hearn. Bd. 87. Applied Optimization. Norwell, MA, USA: Kluwer Academic Publishers, 2004.
- [14] J. Nocedal und S.J. Wright. *Numerical Optimization*. New York: Springer, 2006.
- [15] M. Papageorgiou. *Optimierung*. München: Oldenbourg, 1991.
- [16] R.T. Rockafellar. "Augmented Lagrange multiplier functions and duality in nonconvex programming". In: *SIAM Journal on Control* 12.2 (1974), S. 268–285.
- [17] S.J. Wright. *Primal-Dual Interior-Point Methods*. Society for Industrial und Applied Mathematics (SIAM), 1997.

5 Dynamische Optimierung

In den bisherigen Kapiteln ging es um die Minimierung einer Funktion bzgl. eines Parametervektors $\mathbf{x}$ im Euklidischen Raum $\mathbb{R}^n$. Im Folgenden sollen nun dynamische Optimierungsprobleme betrachtet werden, bei denen eine Funktion einer unabhängigen Variablen (in der Regel eine Zeitfunktion) gesucht wird, die ein *Kostenfunktional* minimiert. Die häufigste Anwendung findet man bei dynamischen Systemen, für die eine optimale Eingangstrajektorie $\mathbf{u}^*(t)$ gesucht wird. Man spricht in diesem Zusammenhang auch von einem *Optimalsteuerungsproblem*.

5.1 Allgemeine Aufgabenstellung

Eine recht allgemeine Struktur von Optimalsteuerungsproblemen lautet

$$\min_{\mathbf{u}(\cdot)} \quad J(\mathbf{u}) = V(\mathbf{x}(t_f), t_f) + \int_{t_0}^{t_f} l(\mathbf{x}(t), \mathbf{u}(t), t) dt \quad (5.1a)$$

$$\text{u.B.v.} \quad \dot{\mathbf{x}} = \mathbf{f}(\mathbf{x}, \mathbf{u}, t), \quad \mathbf{x}(t_0) = \mathbf{x}_0 \quad (5.1b)$$

$$\mathbf{g}(\mathbf{x}(t_f), t_f) = \mathbf{0} \quad (5.1c)$$

$$\mathbf{h}(\mathbf{x}(t), \mathbf{u}(t), t) \leq \mathbf{0} \quad \forall t \in [t_0, t_f]. \quad (5.1d)$$

Sowohl die Endbedingungen (5.1c), die Art des Kostenfunktionals (5.1a), die Beschränkungen (5.1d) als auch die Endzeit t_f haben Einfluss auf die Charakteristik des Optimierungsproblems. Im Folgenden wird angenommen, dass alle auftretenden Funktionen stetig differenzierbar in ihren Argumenten sind.

Endbedingungen (5.1c)

Die Gleichungen (5.1b)-(5.1c) für sich genommen stellen ein *Steuerungsproblem* dar, da für ein (im Allgemeinen) nichtlineares System mit Zustand $\mathbf{x} \in \mathbb{R}^n$ und Eingang $\mathbf{u} \in \mathbb{R}^m$ eine Steuertrajektorie $\mathbf{u}(t)$, $t \in [t_0, t_f]$ gesucht wird, die das System vom Anfangszustand $\mathbf{x}(t_0) = \mathbf{x}_0$ zu einer gewünschten Endfunktion (5.1c) zur Endzeit t_f überführt. Die allgemeine Form (5.1c) von Endbedingungen kommt in der Praxis eher selten vor.¹ Wesentlich häufiger sind partielle Endbedingungen der Form

$$x_i(t_f) = x_{f,i}, \quad i \in \mathcal{I}_f. \quad (5.2)$$

Die Menge $\mathcal{I}_f$ umfasst die Indizes der bei t_f fixierten Zustände x_i . Wenn der vollständige Endzustand vorgegeben ist, d.h. $\mathbf{x}(t_f) = \mathbf{x}_f$, so gilt $\mathcal{I}_f = \{1, \dots, n\}$. Der andere Grenzfall liegt vor, wenn $\mathcal{I}_f = \{\}$ ist. Man spricht in diesem Fall von einem *freien Endzustand*.

¹ Ein Beispiel einer nichtlinearen Endbedingung ist die Optimierung der Flugbahn einer Trägerrakete, die einen Satelliten auf eine geostationären Umlaufbahn um die Erde bringen soll.

Im Folgenden werden vorrangig die partiellen Endbedingungen (5.2) betrachtet. Auf die allgemeinen Endbedingungen (5.1c) wird in Abschnitt 5.3.6 eingegangen.

Kostenfunktional (5.1a)

Aus den in der Regel unendlich vielen Steuerfunktionen $\mathbf{u}(t)$, die das System (5.1b) mit gegebenen Anfangsbedingungen zu (5.1c) bzw. (5.2) überführen, wird eine *optimale Steuerung* $\mathbf{u}^*(t)$ gesucht, die das Kostenfunktional (5.1a) minimiert. Bei der allgemeinen Form (5.1a) wird zwischen der *Endzustandsbewertung* bzw. dem *Mayer-Term* $V(\mathbf{x}(t_f), t_f)$ und dem *Integralanteil* $I(\mathbf{x}, \mathbf{u}, t)$ unterschieden. Generell kann das Kostenfunktional somit folgende Formen aufweisen

$$J(\mathbf{u}) = \begin{cases} V(\mathbf{x}(t_f), t_f) + \int_{t_0}^{t_f} I(\mathbf{x}(t), \mathbf{u}(t), t) dt & \text{Bolza-Form} \\ \int_{t_0}^{t_f} I(\mathbf{x}(t), \mathbf{u}(t), t) dt & \text{Lagrange-Form} \\ V(\mathbf{x}(t_f), t_f) & \text{Mayer-Form} \end{cases} \quad (5.3)$$

Die Bolza- und Lagrange-Darstellungen können stets in die Mayer-Form gebracht werden, indem der Integralanteil als neuer Zustand

$$\dot{x}_{n+1} = I(\mathbf{x}, \mathbf{u}, t), \quad x_{n+1}(t_0) = 0 \quad (5.4)$$

eingeführt und $x_{n+1}(t_f)$ zu $V(\mathbf{x}(t_f), t_f)$ hinzugefügt wird. Die wichtigsten Beispiele für ein Integralkriterium sind

$J(\mathbf{u}) = \frac{1}{2} \int_{t_0}^{t_f} \mathbf{x}^T(t) \mathbf{Q} \mathbf{x}(t) dt$	quadratische Zustandsgewichtung ($\mathbf{Q}$ symmetrisch & $\mathbf{Q} > \mathbf{0}$)
$J(\mathbf{u}) = \frac{1}{2} \int_{t_0}^{t_f} \mathbf{u}^T(t) \mathbf{R} \mathbf{u}(t) dt$	energieoptimales Kriterium ($\mathbf{R}$ symmetrisch & $\mathbf{R} > \mathbf{0}$)
$J(\mathbf{u}) = \frac{1}{2} \int_{t_0}^{t_f} \mathbf{x}^T(t) \mathbf{Q} \mathbf{x}(t) + \mathbf{u}^T(t) \mathbf{R} \mathbf{u}(t) dt$	allgemeines quadratisches Kriterium ($\mathbf{Q}, \mathbf{R}$ symmetrisch & $\mathbf{Q} \geq \mathbf{0}, \mathbf{R} > \mathbf{0}$)
$J(\mathbf{u}) = \int_{t_0}^{t_f} 1 dt = t_f - t_0$	zeitoptimales Kriterium
$J(\mathbf{u}) = \int_{t_0}^{t_f} 1 + \mathbf{u}^T(t) \mathbf{R} \mathbf{u}(t) dt$	Kombination Zeit-/Energieoptimalität

Im Zusammenhang mit quadratischen Termen der Form $\mathbf{u}^T \mathbf{R} \mathbf{u}$ wird gewöhnlich der Begriff *Energieoptimalität* verwendet, da der zu minimierende Ausdruck häufig im Zusammenhang mit der Energie eines elektrischen Signals steht.

Beispiel 5.1 In Kapitel 1 wurden unterschiedliche Kostenfunktionale betrachtet. Im Falle der Goddard-Rakete (Beispiel 1.4) stellt $V(\mathbf{x}(t_f), t_f) = -h(t_f)$ die Maximierung der Flughöhe dar, während im Konsumenten-Beispiel 1.5 $V(\mathbf{x}(t_f), t_f) = -K^\kappa(t_f)$ das Vererbungskapital des Konsumenten berücksichtigt. Die Kombination aus zeit- und energieoptimalen Anteilen im Integralkriterium wurde beim inversen Pendel in Beispiel 1.3 betrachtet.

Endzeit t_f

Die Endzeit (oder Optimierungshorizont) t_f kann entweder vorgegeben oder frei sein. Falls die Endzeit frei ist, muss t_f als Teil der Lösung des Optimierungsproblems (5.1) bestimmt werden.

Die Endzeit t_f spielt in diesem Zusammenhang eine wichtige Rolle und entscheidet oft, ob ein Problem lösbar ist oder nicht.

Beschränkungen (5.1d)

Beschränkungen sind in vielen praktischen Problemen vorhanden. Die nichtlineare Form (5.1d) ist eine sehr allgemeine Schreibweise, die in den meisten Fällen auf Beschränkungen der Eingänge $\mathbf{u}$

$$\mathbf{u}(t) \in U \subseteq \mathbb{R}^m \quad \forall t \in [t_0, t_f] \quad (5.5)$$

und/oder der Zustände

$$\mathbf{x}(t) \in X \subseteq \mathbb{R}^n \quad \forall t \in [t_0, t_f] \quad (5.6)$$

reduziert werden kann. Der in der Praxis am häufigsten auftretende Fall sind Eingangsbeschränkungen, wie z.B. Spannungsbegrenzungen oder Maximalkräfte eines Aktors.

Der Inhalt dieses Kapitels beschränkt sich größtenteils auf die Betrachtung der Eingangsbeschränkungen (5.5). Die strenge mathematische Berücksichtigung von Zustandsbeschränkungen (5.6) bzw. von allgemeinen Beschränkungen (5.1d) ist erheblich schwieriger als der eingangsbeschränkte Fall und wird in Abschnitt 5.5.5 lediglich angedeutet.

5.2 Variationsrechnung

Die Betrachtung von dynamischen Optimierungsproblemen ist naturgemäß komplexer als bei statischen Problemen, bei denen die Optimierungsvariablen von endlicher Anzahl im $\mathbb{R}^n$ sind. Eine elegante Methodik, mit der dynamische Optimierungsprobleme angegangen werden können, ist die *Variationsrechnung*, die Ende des 17. und Anfang des 18. Jahrhunderts entwickelt wurde. Die bekanntesten Namen, die mit der Variationsrechnung in Verbindung gebracht werden, sind *Bernoulli*, *Euler* und *Lagrange*.

Um eine Einführung in die Variationsrechnung zu geben, werden zunächst allgemeine Funktionale betrachtet, bevor die Ergebnisse auf unbeschränkte Optimalsteuerungsprobleme erweitert werden (Abschnitt 5.3).

5.2.1 Grundlagen

Bei der bisher betrachteten statischen oder endlich-dimensionalen Optimierung wurde eine Funktion $f(\mathbf{x})$, ggf. mit Nebenbedingungen, minimiert. Die Optimierungsvariablen $\mathbf{x}$ waren dabei Elemente des Euklidischen Raums $\mathbb{R}^n$. Im Gegensatz dazu wird bei der dynamischen Optimierung die Minimierung eines *Funktional*s

$$J(\mathbf{x}^*) = \min_{\mathbf{x} \in \mathcal{X}} J(\mathbf{x}) \quad (5.7)$$

mit $J : \mathcal{X} \rightarrow \mathbb{R}$ betrachtet, bei dem $\mathbf{x}$ Elemente eines *Funktionenraums* $\mathcal{X}$ sind. Ein Beispiel ist die Minimierung des Funktional

$$J(\mathbf{x}) = \int_{t_0}^{t_f} \phi(\mathbf{x}(t), \dot{\mathbf{x}}(t), t) dt, \quad (5.8)$$

bei dem die optimale Funktion $\mathbf{x}^*(t)$, $t \in [t_0, t_f]$ gesucht wird, die $J(\mathbf{x})$ minimiert. Das spezielle Funktional (5.8) wird auch als *Lagrange-Problem der Variationsrechnung* bezeichnet und wird in Abschnitt 5.2.2 noch näher untersucht.

Im Sinne der dynamischen Optimierung wird $\mathbf{x}(t)$ auch als *Trajektorie* bezeichnet. Mit der Menge $\mathcal{X}_{ad}$ wird die entsprechende zulässige Menge bezeichnet. Werden beispielsweise für das Funktional (5.7) die Nebenbedingungen

$$\mathbf{x}(t_0) = \mathbf{x}_0, \quad \mathbf{x}(t_f) = \mathbf{x}_f \quad (5.9)$$

definiert, so ist die zulässige Menge wie folgt gegeben

$$\mathcal{X}_{ad} = \{\mathbf{x} \in \mathcal{X} \mid \mathbf{x}(t_0) = \mathbf{x}_0, \mathbf{x}(t_f) = \mathbf{x}_f\}. \quad (5.10)$$

Für ein globales Minimum eines Funktional $J(\mathbf{x})$ an einer Stelle $\mathbf{x}^*$ gilt nun

$$J(\mathbf{x}^*) \leq J(\mathbf{x}) \quad \forall \mathbf{x} \in \mathcal{X}_{ad}. \quad (5.11)$$

Für die Definition eines *lokalen* Minimums ist hingegen die Verwendung einer geeigneten Norm $\|\cdot\|$ von $\mathcal{X}$ bzw. $\mathcal{X}_{ad}$ notwendig:

$$\exists \alpha > 0 : \quad J(\mathbf{x}^*) \leq J(\mathbf{x}) \quad \forall \mathbf{x} \in \{\mathbf{x} \in \mathcal{X}_{ad} \mid \|\mathbf{x} - \mathbf{x}^*\| \leq \alpha\}. \quad (5.12)$$

In der Variationsrechnung wird als Funktionsraum häufig die Klasse der stetig (stückweise) differenzierbaren Funktionen betrachtet, die allgemein wie folgt definiert ist:

- $\mathcal{C}^k[t_0, t_f]$: Klasse der auf $[t_0, t_f]$ k -mal stetig differenzierbaren Funktionen
- $\bar{\mathcal{C}}^k[t_0, t_f]$: Klasse der auf $[t_0, t_f]$ k -mal stückweise stetig differenzierbaren Funktionen
- $\mathcal{C}_n^k[t_0, t_f]$: Klasse der Funktionen $\mathbf{x} = [x_1, \dots, x_n]^T$ mit $x_i \in \mathcal{C}^k[t_0, t_f]$, $i = 1, \dots, n$
- $\bar{\mathcal{C}}_n^k[t_0, t_f]$: Klasse der Funktionen $\mathbf{x} = [x_1, \dots, x_n]^T$ mit $x_i \in \bar{\mathcal{C}}^k[t_0, t_f]$, $i = 1, \dots, n$.

Eine geeignete zugehörige Norm $\|\cdot\|$ ist die Supremumsnorm

$$\|\mathbf{x}\|_\infty = \|\mathbf{x}(\cdot)\|_\infty = \max_{t \in [t_0, t_f]} \|\mathbf{x}(t)\| \quad \text{bzw.} \quad \|\mathbf{x}\|_\infty = \|\mathbf{x}(\cdot)\|_\infty = \max_{t \in [t_0, t_f]} \|\mathbf{x}(t)\|, \quad (5.13)$$

wobei $\|\mathbf{x}(t)\|$ eine geeignete Norm im $\mathbb{R}^n$ darstellt.

Die Erweiterung des Begriffs des Gradienten aus dem Endlich-Dimensionalen ist die Gâteaux-Ableitung, die auch als erste Variation des Funktional $J(\mathbf{x})$ bezeichnet wird:

Definition 5.1 (Erste Variation bzw. Gâteaux-Ableitung) Die erste Variation bzw. Gâteaux-Ableitung des Funktional $J : \mathcal{X} \rightarrow \mathbb{R}$ am Punkt $\mathbf{x} \in \mathcal{X}$ in Richtung von $\mathbf{y} \in \mathcal{X}$ ist definiert durch

$$\delta J(\mathbf{x}; \mathbf{y}) = \lim_{\varepsilon \rightarrow 0} \frac{J(\mathbf{x} + \varepsilon \mathbf{y}) - J(\mathbf{x})}{\varepsilon} = \left. \frac{dJ(\mathbf{x} + \varepsilon \mathbf{y})}{d\varepsilon} \right|_{\varepsilon=0}. \quad (5.14)$$

Falls $\delta J(\mathbf{x}; \mathbf{y})$ für alle $\mathbf{y} \in \mathcal{X}$ existiert, so heißt J Gâteaux-differenzierbar am Punkt $\mathbf{x} \in \mathcal{X}$.

Beispiel 5.2 Betrachtet wird das Funktional $J(x) = \int_{t_0}^{t_f} x(t)^2 + x(t) dt$ mit $x \in \mathcal{C}^1[t_0, t_f]$. Für jede Richtung $y \in \mathcal{C}^1[t_0, t_f]$ gilt

$$\begin{aligned} \delta J(x; y) &= \lim_{\varepsilon \rightarrow 0} \frac{J(x + \varepsilon y) - J(x)}{\varepsilon} \\ &= \lim_{\varepsilon \rightarrow 0} \left[\frac{1}{\varepsilon} \int_{t_0}^{t_f} (x(t) + \varepsilon y(t))^2 + x(t) + \varepsilon y(t) - x(t)^2 - x(t) dt \right] \\ &= \lim_{\varepsilon \rightarrow 0} \left[\int_{t_0}^{t_f} 2x(t)y(t) + y(t) + \varepsilon y(t)^2 dt \right] \\ &= \int_{t_0}^{t_f} 2x(t)y(t) + y(t) dt. \end{aligned} \quad (5.15)$$

Auf das gleiche Ergebnis kommt man durch direktes Differenzieren nach ε

$$\begin{aligned} \delta J(x; y) &= \left. \frac{dJ(x + \varepsilon y)}{d\varepsilon} \right|_{\varepsilon=0} \\ &= \int_{t_0}^{t_f} \left. \frac{d}{d\varepsilon} [(x(t) + \varepsilon y(t))^2 + x(t) + \varepsilon y(t)] \right|_{\varepsilon=0} dt \\ &= \int_{t_0}^{t_f} 2(x(t) + \varepsilon y(t))y(t) + y(t) dt \Big|_{\varepsilon=0} \\ &= \int_{t_0}^{t_f} 2x(t)y(t) + y(t) dt. \end{aligned} \quad (5.16)$$

Das Funktional J ist also an allen Punkten $y \in \mathcal{C}^1[t_0, t_f]$ Gâteaux-differenzierbar.

Gemäß der Definition (5.14) müssen für die Existenz der Gâteaux-Ableitung $\delta J(\mathbf{x}; \mathbf{y})$ die Funktionale $J(\mathbf{x})$ und $J(\mathbf{x} + \varepsilon \mathbf{y})$ für alle hinreichend kleinen ε definiert sein und zudem die Ableitung von $J(\mathbf{x} + \varepsilon \mathbf{y})$ nach ε existieren. Das folgende Beispiel verdeutlicht diesen Umstand.

Beispiel 5.3 (Nicht-Existenz der Gâteaux-Ableitung [5]) Das Funktional $J(x) = \int_0^1 |x(t)| dt$ ist für alle $x \in \mathcal{C}^1[0, 1]$ definiert und endlich. Für $x(t) = 0$ und $y(t) = t$ erhält man

$$\frac{J(x + \varepsilon y) - J(x)}{\varepsilon} = \frac{1}{\varepsilon} \int_0^1 |\varepsilon t| dt = \text{sign}(\varepsilon) \int_0^1 t dt = \begin{cases} \frac{1}{2} & \text{für } \varepsilon > 0 \\ -\frac{1}{2} & \text{für } \varepsilon < 0. \end{cases} \quad (5.17)$$

Der Grenzwert für $\varepsilon \rightarrow 0$ ist also nicht eindeutig und somit existiert die Gâteaux-Ableitung am Punkt $x(t) = 0$ in Richtung $y(t) = t$ nicht.

Wenn für ein Funktional $J(\mathbf{x})$ an einem Punkt $\mathbf{x} \in \mathcal{X}$ die Gâteaux-Ableitung existiert und $\delta J(\mathbf{x}; \mathbf{y}) < 0$ gilt, so ist $\mathbf{y} \in \mathcal{X}$ eine Abstiegsrichtung, d.h.

$$J(\mathbf{x} + \alpha \mathbf{y}) < J(\mathbf{x})$$

für hinreichend kleine Schrittweite $\alpha > 0$. Die Bedingung $\delta J(\mathbf{x}; \mathbf{y}) < 0$ stellt somit eine Verallgemeinerung der Abstiegsbedingung (3.18) in der statischen Optimierung dar. Hinsichtlich eines Minimums des Funktionals $J(\mathbf{x}^*)$ an einem Punkt $\mathbf{x}^*$ darf also keine Richtung $\mathbf{y}$ mit




Abbildung 5.1: Veranschaulichung der $\mathcal{X}_{ad}$ -zulässigen Richtung $\delta x(t)$ am Punkt $x^* \in \mathcal{X}_{ad}$.

$\delta J(x^*; y) < 0$ existieren. Dies führt zunächst auf den Begriff der $\mathcal{X}_{ad}$ -zulässigen Richtungen, bevor die notwendige Optimalitätsbedingung 1. Ordnung angegeben werden kann.

Definition 5.2 ($\mathcal{X}_{ad}$ -zulässige Richtung) Das Funktional $J : \mathcal{X} \rightarrow \mathbb{R}$ besitze die zulässige Menge $\mathcal{X}_{ad} \subseteq \mathcal{X}$. Eine Richtung $y \in \mathcal{X}$, $y \neq 0$ heißt $\mathcal{X}_{ad}$ -zulässig an einem Punkt $x \in \mathcal{X}$, wenn $\delta J(x; y)$ existiert und $x + \varepsilon y \in \mathcal{X}_{ad}$ für hinreichend kleine Werte von $\varepsilon \in \mathbb{R}$.

Satz 5.1 (Notwendige Optimalitätsbedingung 1. Ordnung) Das Funktional $J : \mathcal{X} \rightarrow \mathbb{R}$ besitze ein Minimum an der Stelle $x^* \in \mathcal{X}_{ad} \subseteq \mathcal{X}$. Dann gilt

$$\delta J(x^*; \delta x) = 0 \quad (5.18)$$

für alle $\mathcal{X}_{ad}$ -zulässigen Richtungen $\delta x \in \mathcal{X}$ am Punkt x^* .

Der Begriff der $\mathcal{X}_{ad}$ -zulässigen Richtungen δx ist relevant im Zusammenhang mit Nebenbedingungen, die in der zulässigen Menge $\mathcal{X}_{ad}$ berücksichtigt werden. Sind beispielsweise die Randbedingungen (5.9) bzw. die zulässige Menge (5.10) gegeben, so müssen $\mathcal{X}_{ad}$ -zulässige Richtungen $\delta x(t)$ die homogenen Randbedingungen $\delta x(t_0) = 0$ und $\delta x(t_f) = 0$ erfüllen, damit für $x^* \in \mathcal{X}_{ad}$ ebenfalls $x = x^* + \varepsilon \delta x \in \mathcal{X}_{ad}$ gilt. Abbildung 5.1 verdeutlicht diesen Zusammenhang. Satz 5.1 sagt nun aus, dass keine $\mathcal{X}_{ad}$ -zulässige Richtung $\delta x(t)$ existieren darf, die zu einer Reduktion des Funktionals $J(x)$ führen kann.

Um die Optimalitätsbedingung (5.18) für ein gegebenes Funktional $J(x)$ auswerten zu können, ist das sogenannte *Fundamentallema der Variationsrechnung* relevant, dessen Beweis z.B. in [2] nachgelesen werden kann. Dies stellt auch die Grundlage zur Herleitung der sogenannten *Euler-Lagrange-Gleichung* im nächsten Abschnitt dar.

Satz 5.2 (Fundamentallema der Variationsrechnung) Gegeben sei eine stetige Funktion $h \in C_n^0[t_0, t_f]$. Falls für alle stetigen Funktionen $\delta x \in C_n^0[t_0, t_f]$ die Bedingung

$$\int_{t_0}^{t_f} h(t)^T \delta x(t) dt = 0 \quad (5.19)$$

gilt, so gilt $h(t) = 0$ für alle $t \in [t_0, t_f]$.

5.2.2 Euler-Lagrange-Gleichung

Betrachtet wird in weiterer Folge das Lagrange-Problem der Variationsrechnung (5.8) mit den Randbedingungen (5.9), das hier der Vollständigkeit halber wiederholt wird:

$$J(\mathbf{x}) = \int_{t_0}^{t_f} \phi(\mathbf{x}(t), \dot{\mathbf{x}}(t), t) dt \quad (5.20a)$$

mit

$$\mathbf{x} \in \mathcal{X}_{ad} = \{\mathbf{x} \in \mathcal{X} \mid \mathbf{x}(t_0) = \mathbf{x}_0, \mathbf{x}(t_f) = \mathbf{x}_f\}. \quad (5.20b)$$

Die Endzeit t_f sei fest. Es wird angenommen, dass eine optimale Lösung $\mathbf{x}^* \in \mathcal{X}_{ad} \subset \mathcal{X} = \mathcal{C}_n^1[t_0, t_f]$ existiert, die das Funktional (5.20a) minimiert. Das Verschwinden der Gâteaux-Ableitung bzw. der ersten Variation gemäß (5.18) ist dafür eine notwendige Voraussetzung, wobei alle $\mathcal{X}_{ad}$ -zulässigen Variationen $\delta \mathbf{x} \in \mathcal{C}_n^1[t_0, t_f]$ die homogenen Randbedingungen

$$\delta \mathbf{x}(t_0) = \mathbf{0}, \quad \delta \mathbf{x}(t_f) = \mathbf{0} \quad (5.21)$$

erfüllen müssen. Die Gâteaux-Ableitung von J am optimalen Punkt $\mathbf{x}^*$ in Richtung von $\delta \mathbf{x}$ berechnet sich dann zu

$$\begin{aligned} \delta J(\mathbf{x}^*; \delta \mathbf{x}) &= \left. \frac{dJ(\mathbf{x}^* + \varepsilon \delta \mathbf{x})}{d\varepsilon} \right|_{\varepsilon=0} \\ &= \int_{t_0}^{t_f} \left. \frac{d}{d\varepsilon} \phi(\mathbf{x}^*(t) + \varepsilon \delta \mathbf{x}(t), \dot{\mathbf{x}}^*(t) + \varepsilon \delta \dot{\mathbf{x}}(t), t) \right|_{\varepsilon=0} dt \\ &= \int_{t_0}^{t_f} \phi_{\mathbf{x}}(\mathbf{x}^*(t), \dot{\mathbf{x}}^*(t))^T \delta \mathbf{x}(t) + \phi_{\dot{\mathbf{x}}}(\mathbf{x}^*(t), \dot{\mathbf{x}}^*(t))^T \delta \dot{\mathbf{x}}(t) dt, \end{aligned} \quad (5.22)$$

wobei $\phi_{\mathbf{x}}$ und $\phi_{\dot{\mathbf{x}}}$ die partiellen Ableitungsfunktionen von ϕ darstellen, d.h. $\phi_{\mathbf{x}} = (\frac{\partial \phi}{\partial \mathbf{x}})^T$ und $\phi_{\dot{\mathbf{x}}} = (\frac{\partial \phi}{\partial \dot{\mathbf{x}}})^T$. Da die Funktion ϕ stetig differenzierbar ist und $\delta \mathbf{x} \in \mathcal{C}_n^1[t_0, t_f]$, ist der Integrand von (5.22) stetig und somit $J(\mathbf{x})$ an allen Punkten $\mathbf{x} \in \mathcal{X} = \mathcal{C}_n^1[t_0, t_f]$ Gâteaux-differenzierbar.

Im nächsten Schritt wird der zweite Term in (5.22) partiell integriert² (unter Vernachlässigung der Zeitargumente)

$$\int_{t_0}^{t_f} \phi_{\dot{\mathbf{x}}}(\mathbf{x}^*, \dot{\mathbf{x}}^*, t)^T \delta \dot{\mathbf{x}} dt = [\phi_{\dot{\mathbf{x}}}(\mathbf{x}^*, \dot{\mathbf{x}}^*, t)^T \delta \mathbf{x}]_{t_0}^{t_f} - \int_{t_0}^{t_f} \frac{d}{dt} \phi_{\dot{\mathbf{x}}}(\mathbf{x}^*, \dot{\mathbf{x}}^*, t)^T \delta \mathbf{x} dt. \quad (5.23)$$

Da nur $\mathcal{X}_{ad}$ -zulässige Variationen mit $\delta \mathbf{x}(t_0) = \delta \mathbf{x}(t_f) = \mathbf{0}$ betrachtet werden, verschwinden die Randterme in (5.23) und die Gâteaux-Ableitung (5.22) vereinfacht sich zu

$$\delta J(\mathbf{x}^*; \delta \mathbf{x}) = \int_{t_0}^{t_f} \left[\phi_{\mathbf{x}}(\mathbf{x}^*, \dot{\mathbf{x}}^*, t) - \frac{d}{dt} \phi_{\dot{\mathbf{x}}}(\mathbf{x}^*, \dot{\mathbf{x}}^*, t) \right]^T \delta \mathbf{x} dt \quad (5.24)$$

in Abhängigkeit von $\delta \mathbf{x}(t)$. Für eine optimale Trajektorie $\mathbf{x}^*(t)$ muss gemäß Satz 5.1 $\delta J(\mathbf{x}^*; \delta \mathbf{x})$ für alle $\mathcal{X}_{ad}$ -zulässige Variationen $\delta \mathbf{x}(t)$ verschwinden. Somit folgt unmittelbar aus dem Fundamentallemma der Variationsrechnung (Satz 5.2)

$$\boxed{\phi_{\mathbf{x}}(\mathbf{x}^*(t), \dot{\mathbf{x}}^*(t), t) - \frac{d}{dt} \phi_{\dot{\mathbf{x}}}(\mathbf{x}^*(t), \dot{\mathbf{x}}^*(t), t) = \mathbf{0}.} \quad (5.25)$$

² Zur Erinnerung: $\int \mathbf{u}^T \dot{\mathbf{v}} dt = \mathbf{u}^T \mathbf{v} - \int \dot{\mathbf{u}}^T \mathbf{v} dt$

Die Differenzialgleichung (5.25) wird als *Euler-Lagrange-Gleichung* bezeichnet und stellt eine *notwendige Bedingung* für eine optimale Funktion $\mathbf{x}^*(t)$ dar, die das Funktional (5.20a) unter Berücksichtigung der Randbedingungen in (5.20b) minimiert.

Über die *zweite Variation* von J

$$\delta^2 J = \frac{d^2 J(\mathbf{x}^* + \varepsilon \delta \mathbf{x})}{d\varepsilon^2} \Big|_{\varepsilon=0} \geq 0 \quad (5.26)$$

kann gezeigt werden, dass die Hesse-Matrix

$$\phi_{\dot{\mathbf{x}}\dot{\mathbf{x}}}(\mathbf{x}^*(t), \dot{\mathbf{x}}^*(t), t) \text{ positiv semi-definit} \quad \forall t \in [t_0, t_f] \quad (5.27)$$

sein muss. Diese Bedingung ist als *Legendre-Bedingung* bekannt und stellt eine notwendige Bedingung 2. Ordnung für eine optimale Lösung $\mathbf{x}^*(t)$, $t \in [t_0, t_f]$ zusätzlich zur Euler-Lagrange-Gleichung (5.25) dar. Die Herleitung von (5.27) erfolgt analog zum Vorgehen bei der Gâteaux-Ableitung bzw. ersten Variation (5.14) mittels partieller Integration und wird an dieser Stelle nicht weiter vertieft.

Sonderfälle der Euler-Lagrange-Gleichung (5.25) liegen vor, wenn

- ϕ nicht explizit von $\mathbf{x}$ abhängt, d.h. $\phi = \phi(\dot{\mathbf{x}}, t)$. In diesem Fall liefert eine erste Integration von (5.25)

$$\phi_{\dot{\mathbf{x}}}(\dot{\mathbf{x}}^*(t), t) = \text{konst.} \quad (5.28)$$

- ϕ nicht explizit von t abhängt, d.h. $\phi = \phi(\mathbf{x}, \dot{\mathbf{x}})$. In diesem Fall kann gezeigt werden [3], dass sich die Euler-Lagrange-Gleichung (5.25) wie folgt vereinfacht:

$$\phi(\mathbf{x}^*(t), \dot{\mathbf{x}}^*(t)) - \dot{\mathbf{x}}^*(t)^T \phi_{\dot{\mathbf{x}}}(\mathbf{x}^*(t), \dot{\mathbf{x}}^*(t)) = \text{konst.} \quad (5.29)$$

Aufgabe 5.1 Bestimmen Sie den minimalen Abstand zwischen zwei Punkten A und B in der (x, y) -Ebene. Stellen Sie dazu das zu minimierende Kostenfunktional in Abhängigkeit der Bogenlänge s auf und verwenden Sie die Relation

$$ds = \sqrt{dx^2 + dy^2} = \sqrt{1 + y'(x)^2} dx. \quad (5.30)$$

5.2.3 Beispiel: Galileos hängende Kette

Galileo formulierte im Jahr 1638 die Frage, welche Form eine an beiden Enden aufgehängte Kette im Schwerfeld der Erde besitzt. Galileo nahm dabei fälschlicherweise an, dass die Kette eine Parabel beschreiben würde. Das Problem wurde um 1690 von *Jakob und Johannes Bernoulli* und von *Leibnitz* mit Hilfe der Variationsrechnung gelöst.

Betrachtet wird eine Kette der Länge L , deren Enden in den Punkten A und B aufgehängt sind, siehe Abbildung 5.2. Aus dem Hamilton-Prinzip in der Technischen Mechanik folgt, dass die potentielle Energie der Kette im statischen Gleichgewicht minimal sein muss. Mit Hilfe der Bogenlänge s und der Relation (5.30) ergibt sich die potentielle Energie zu

$$V = \rho g \int_0^L y ds = \rho g \int_{x_A}^{x_B} y \sqrt{1 + y'(x)^2} dx, \quad (5.31)$$




Abbildung 5.2: Galileos Problem: Bestimmung der Form $y(x)$ einer hängenden Kette.

wobei g die Erdbeschleunigung und ρ die Masse pro Seillänge darstellt. Im Hinblick auf die Minimierung der potentiellen Energie V kann der konstante Faktor ρg vernachlässigt werden, womit sich das Kostenfunktional und die Randbedingungen

$$J(y) = \int_{x_A}^{x_B} y \sqrt{1 + y'(x)^2} dx, \quad y(x_A) = y_A, \quad y(x_B) = y_B \quad (5.32)$$

ergeben. Da in $\phi(y, y') = y \sqrt{1 + y'(x)^2}$ die Ortsvariable x nicht explizit auftritt, ergibt sich für die Euler-Lagrange-Gleichung (5.25) der Spezialfall (5.29), d.h. (ohne Argumente)

$$\begin{aligned} \phi(y, y') - y' \phi_{y'}(y, y') &= y \sqrt{1 + y'^2} - \frac{y y'^2}{\sqrt{1 + y'^2}} \\ &= \frac{y}{\sqrt{1 + y'^2}} = c_1 = \text{konst.} \end{aligned} \quad (5.33)$$

Unter der Annahme $c_1 \neq 0$ kann die letzte Gleichung in die Form

$$y' = \sqrt{\frac{y^2}{c_1^2} - 1} \quad (5.34)$$

gebracht werden. Unter Berücksichtigung von $y' = \frac{dy}{dx}$ wird x zunächst mittels Integration als Funktion von y ausgedrückt

$$x = \int \frac{1}{\sqrt{y^2/c_1^2 - 1}} dy = c_1 \ln \left(\frac{y + \sqrt{y^2 - c_1^2}}{c_1} \right) + c_2,$$

wobei c_2 eine Integrationskonstante darstellt. Durch Umformung und Quadrierung,

$$\left(c_1 e^{(x-c_2)/c_1} - y \right)^2 = y^2 - c_1^2,$$

kann y in folgender Form geschrieben werden:

$$y = \frac{1}{2} c_1 \frac{e^{2(x-c_2)/c_1} + 1}{e^{(x-c_2)/c_1}} = \frac{1}{2} c_1 \left(e^{(x-c_2)/c_1} + e^{-(x-c_2)/c_1} \right).$$

Mit $\cosh b = \frac{1}{2}(e^b + e^{-b})$ ergibt sich also die Kettenlinie (Englisch: *catenary*)

$$y(x) = c_1 \cosh \left(\frac{x - c_2}{c_1} \right). \quad (5.35)$$

Gegebenenfalls kann noch eine dritte Konstante c_3 zu (5.35) addiert werden, um die Kettenlinie für eine in den Punkten A und B aufgehängte Kette durch (numerische) Lösung der Gleichungen

$$y(x_A) = y_A, \quad y(x_B) = y_B, \quad \int_{x_A}^{x_B} \sqrt{1 + y'(x)^2} \, dx = L \quad (5.36)$$

in Abhängigkeit der Kettenlänge L zu berechnen. Abbildung 5.3 zeigt die Kettenlinie $y(x)$ mit der Länge $L = 1.5$ für verschiedene Aufhängepunkte im Vergleich zu der von Galileo vermuteten Parabel.




Abbildung 5.3: Hängende Kette der Länge $L = 1.5$ für verschiedene Aufhängepunkte.

5.3 Unbeschränkte Optimalsteuerungsprobleme

Im Folgenden wird die Variationsrechnung auf unbeschränkte Optimalsteuerungsprobleme

$$\min_{\mathbf{u}(\cdot)} \quad J(\mathbf{u}) = V(\mathbf{x}(t_f), t_f) + \int_{t_0}^{t_f} l(\mathbf{x}(t), \mathbf{u}(t), t) \, dt \quad (5.37a)$$

$$\text{u.B.v.} \quad \dot{\mathbf{x}} = \mathbf{f}(\mathbf{x}, \mathbf{u}, t), \quad \mathbf{x}(t_0) = \mathbf{x}_0 \quad (5.37b)$$

$$\mathbf{x}_i(t_f) = \mathbf{x}_{f,i}, \quad i \in \mathcal{I}_f \quad (5.37c)$$

angewendet, um notwendige Bedingungen für eine optimale Lösung herzuleiten.

5.3.1 Anwendung der Variationsrechnung

Der bisher betrachtete Fall der Variationsrechnung wird zunächst sukzessive erweitert, um die Systemgleichungen (5.37b) und die partiellen Endbedingungen (5.37c) zu berücksichtigen. Die Endzeit t_f sei zunächst fest, d.h. $V = V(\mathbf{x}(t_f))$.

Die Systemgleichungen (5.37b) können als (dynamische) Gleichungsbeschränkungen betrachtet werden, die (ähnlich dem Vorgehen bei beschränkten statischen Optimierungsproblemen) anhand von Lagrange-Multiplikatoren im Kostenfunktional berücksichtigt werden

$$\bar{J}(\mathbf{u}, \mathbf{x}) = V(\mathbf{x}(t_f), t_f) + \int_{t_0}^{t_f} l(\mathbf{x}(t), \mathbf{u}(t), t) + \boldsymbol{\lambda}^\top (\mathbf{f}(\mathbf{x}, \mathbf{u}, t) - \dot{\mathbf{x}}) dt. \quad (5.38)$$

Die Optimierungsgrößen sind nun durch $\mathbf{u} \in \mathcal{U} = \mathcal{C}_m^0[t_0, t_f]$ und $\mathbf{x} \in \mathcal{X} = \mathcal{C}_n^1[t_0, t_f]$ gegeben. In der zulässigen Menge $\mathcal{X}_{ad}$ werden dabei die Randbedingungen von (5.37) berücksichtigt, d.h.

$$\mathcal{X}_{ad} = \{\mathbf{x} \in \mathcal{X} \mid \mathbf{x}(t_0) = \mathbf{x}_0, x_i(t_f) = x_{f,i}, i \in \mathcal{I}_f\}. \quad (5.39)$$

Im Gegensatz zum endlich-dimensionalen Fall stellt $\boldsymbol{\lambda}(t)$, $t \in [t_0, t_f]$ nun eine Zeitfunktion dar.

Die Gâteaux-Ableitung von $\bar{J}$ an einem (angenommen) optimalen Punkt $\mathbf{u}^* \in \mathcal{U}$ und $\mathbf{x}^* \in \mathcal{X}_{ad}$ in Richtung von $\delta \mathbf{u}$ und $\delta \mathbf{x}$ lautet (ohne Zeitargumente)

$$\begin{aligned} \delta \bar{J}(\mathbf{u}^*, \mathbf{x}^*; \delta \mathbf{u}, \delta \mathbf{x}) &= \left. \frac{d\bar{J}(\mathbf{u}^* + \varepsilon \delta \mathbf{u}, \mathbf{x}^* + \varepsilon \delta \mathbf{x})}{d\varepsilon} \right|_{\varepsilon=0} \\ &= V_{\mathbf{x}}(\mathbf{x}^*(t_f), t_f)^\top \delta \mathbf{x}(t_f) + \int_{t_0}^{t_f} [l_{\mathbf{x}}(\mathbf{x}^*, \mathbf{u}^*, t) + \mathbf{f}_{\mathbf{x}}(\mathbf{x}^*, \mathbf{u}^*, t)^\top \boldsymbol{\lambda}]^\top \delta \mathbf{x} \\ &\quad + [l_{\mathbf{u}}(\mathbf{x}^*, \mathbf{u}^*, t) + \mathbf{f}_{\mathbf{u}}(\mathbf{x}^*, \mathbf{u}^*, t)^\top \boldsymbol{\lambda}]^\top \delta \mathbf{u} - \boldsymbol{\lambda}^\top \delta \dot{\mathbf{x}} dt. \end{aligned} \quad (5.40)$$

Mit partieller Integration des hinteren Integralterms erhält man

$$\begin{aligned} \delta \bar{J}(\mathbf{u}^*, \mathbf{x}^*; \delta \mathbf{u}, \delta \mathbf{x}) &= V_{\mathbf{x}}(\mathbf{x}^*(t_f), t_f)^\top \delta \mathbf{x}(t_f) - [\boldsymbol{\lambda}^\top \delta \mathbf{x}]_{t_0}^{t_f} \\ &+ \int_{t_0}^{t_f} [l_{\mathbf{x}}(\mathbf{x}^*, \mathbf{u}^*, t) + \mathbf{f}_{\mathbf{x}}(\mathbf{x}^*, \mathbf{u}^*, t)^\top \boldsymbol{\lambda} + \dot{\boldsymbol{\lambda}}]^\top \delta \mathbf{x} + [l_{\mathbf{u}}(\mathbf{x}^*, \mathbf{u}^*, t) + \mathbf{f}_{\mathbf{u}}(\mathbf{x}^*, \mathbf{u}^*, t)^\top \boldsymbol{\lambda}]^\top \delta \mathbf{u} dt. \end{aligned}$$

Zusätzlich kann der Restterm vereinfacht werden

$$[\boldsymbol{\lambda}^\top \delta \mathbf{x}]_{t_0}^{t_f} = \boldsymbol{\lambda}(t_f)^\top \delta \mathbf{x}(t_f) - \boldsymbol{\lambda}(t_0)^\top \delta \mathbf{x}(t_0) = \boldsymbol{\lambda}(t_f)^\top \delta \mathbf{x}(t_f),$$

da für $\mathcal{X}_{ad}$ -zulässige Richtungen $\delta \mathbf{x}(t_0) = \mathbf{0}$ gelten muss.

Als notwendige Optimalitätsbedingung muss gelten $\delta \bar{J}(\mathbf{u}^*, \mathbf{x}^*; \delta \mathbf{u}, \delta \mathbf{x}) = 0$. Mit dem Fundamentallema der Variationsrechnung folgt, dass die folgenden Gleichungen gelten müssen

$$\dot{\boldsymbol{\lambda}}^* = -l_{\mathbf{x}}(\mathbf{x}^*, \mathbf{u}^*, t) - \mathbf{f}_{\mathbf{x}}(\mathbf{x}^*, \mathbf{u}^*, t)^\top \boldsymbol{\lambda}^*, \quad t \in (t_0, t_f) \quad (5.41a)$$

$$\mathbf{0} = l_{\mathbf{u}}(\mathbf{x}^*, \mathbf{u}^*, t) + \mathbf{f}_{\mathbf{u}}(\mathbf{x}^*, \mathbf{u}^*, t)^\top \boldsymbol{\lambda}^*, \quad t \in (t_0, t_f) \quad (5.41b)$$

$$0 = (V_{\mathbf{x}}(\mathbf{x}^*(t_f)) - \boldsymbol{\lambda}^*(t_f))^\top \delta \mathbf{x}(t_f) = \sum_{i=1}^n (V_{x_i}(\mathbf{x}^*(t_f)) - \lambda_i^*(t_f)) \delta x_i(t_f). \quad (5.41c)$$

Das heißt, es muss ein zu $\mathbf{x}^*(t)$, $\mathbf{u}^*(t)$ gehörender Lagrange-Multiplikator $\boldsymbol{\lambda}^*(t)$, $t \in [t_0, t_f]$ existieren, der die Differenzialgleichung (5.41a), die algebraische Zwangsbedingung (5.41b) und die Endbedingung (5.41c) für alle $\mathcal{X}_{ad}$ -zulässigen Endvariationen $\delta \mathbf{x}(t_f)$ erfüllt.

Da partielle Endbedingungen (5.37c) gegeben sind, wird die Bedingung (5.41c) ebenfalls komponentenweise betrachtet. Für die Zustände x_i , $i \in \mathcal{I}_f$, die am Endzeitpunkt $t = t_f$ fixiert sind, siehe (5.37c), muss eine zulässige Variation $\delta x_i(t_f) = 0$ erfüllen, während für alle freien Endzustände $x_i(t_f)$, $i \notin \mathcal{I}_f$ die Endvariation beliebig sein kann. Es muss also gelten

$$\lambda_i^*(t_f) = V_{x_i}(\mathbf{x}^*(t_f)), \quad i \notin \mathcal{I}_f, \quad (5.42)$$

damit (5.41c) für alle zulässigen Endvariationen erfüllt ist.




Abbildung 5.4: Totale Variation $\Delta \mathbf{x}_f = \delta \mathbf{x}(t_f^*) + \dot{\mathbf{x}}^*(t_f^*) \delta t_f$ des Endzustandes für $\mathbf{x} \in \mathbb{R}$.

Berücksichtigung einer freien Endzeit

Falls die Endzeit t_f des Optimierungsproblems (5.1) frei ist, muss zusätzlich die Variation um die optimale Endzeit t_f^* betrachtet werden. Die Gâteaux-Ableitung am (angenommen) optimalen Punkt $(\mathbf{u}^*, \mathbf{x}^*, t_f^*)$ in Richtung von $(\delta \mathbf{u}, \delta \mathbf{x}, \delta t_f)$ ist eine Erweiterung von (5.40) und lautet (ohne Zeitargumente)

$$\begin{aligned}
 \delta \bar{J}(\mathbf{u}^*, \mathbf{x}^*, t_f^*; \delta \mathbf{u}, \delta \mathbf{x}, \delta t_f) &= \left. \frac{d \bar{J}(\mathbf{u}^* + \varepsilon \delta \mathbf{u}, \mathbf{x}^* + \varepsilon \delta \mathbf{x}, t_f^* + \varepsilon \delta t_f)}{d\varepsilon} \right|_{\varepsilon=0} \\
 &= \Delta \mathbf{x}_f \\
 &= V_{\mathbf{x}}(\mathbf{x}^*(t_f^*), t_f^*)^T (\delta \mathbf{x}(t_f^*) + \dot{\mathbf{x}}^*(t_f^*) \delta t_f) + V_t(\mathbf{x}^*(t_f^*), t_f^*) \delta t_f \\
 &\quad + (l(\mathbf{x}^*, \mathbf{u}^*, t) + \boldsymbol{\lambda}^T (\mathbf{f}(\mathbf{x}^*, \mathbf{u}^*, t) - \dot{\mathbf{x}}))_{t=t_f^*} \delta t_f \\
 &\quad + \int_{t_0}^{t_f^*} [l_{\mathbf{x}}(\mathbf{x}^*, \mathbf{u}^*, t) + \mathbf{f}_{\mathbf{x}}(\mathbf{x}^*, \mathbf{u}^*, t)^T \boldsymbol{\lambda}]^T \delta \mathbf{x} \\
 &\quad + [l_{\mathbf{u}}(\mathbf{x}^*, \mathbf{u}^*, t) + \mathbf{f}_{\mathbf{u}}(\mathbf{x}^*, \mathbf{u}^*, t)^T \boldsymbol{\lambda}]^T \delta \mathbf{u} - \boldsymbol{\lambda}^T \delta \dot{\mathbf{x}} dt. \quad (5.43)
 \end{aligned}$$

Die *totale Variation* $\Delta \mathbf{x}_f$ berücksichtigt den zusätzlichen Einfluss der Zeitvariation δt_f auf die Änderung des Endzustandes, siehe Abbildung 5.4. Die Variation des Integralwertes bei einer kleinen Variation δt_f der Endzeit wird durch den Term $(l(\mathbf{x}^*, \mathbf{u}^*, t) + \boldsymbol{\lambda}^T (\mathbf{f}(\mathbf{x}^*, \mathbf{u}^*, t) - \dot{\mathbf{x}}))_{t=t_f^*} \delta t_f$ in (5.43) berücksichtigt. Partielle Integration von (5.43) mit $\boldsymbol{\lambda}(t_0)^T \delta \mathbf{x}(t_0) = 0$ liefert

$$\begin{aligned}
 \delta \bar{J}(\mathbf{u}^*, \mathbf{x}^*, t_f^*; \delta \mathbf{u}, \delta \mathbf{x}, \delta t_f) &= V_{\mathbf{x}}(\mathbf{x}^*(t_f^*), t_f^*)^T \Delta \mathbf{x}_f - \boldsymbol{\lambda}(t_f^*)^T (\delta \mathbf{x}(t_f^*) + \dot{\mathbf{x}}^*(t_f^*) \delta t_f) \\
 &\quad + (V_t(\mathbf{x}^*, t) + l(\mathbf{x}^*, \mathbf{u}^*, t) + \boldsymbol{\lambda}^T \mathbf{f}(\mathbf{x}^*, \mathbf{u}^*, t))_{t=t_f^*} \delta t_f \\
 &\quad + \int_{t_0}^{t_f^*} [l_{\mathbf{x}}(\mathbf{x}^*, \mathbf{u}^*, t) + \mathbf{f}_{\mathbf{x}}(\mathbf{x}^*, \mathbf{u}^*, t)^T \boldsymbol{\lambda} + \dot{\boldsymbol{\lambda}}]^T \delta \mathbf{x} \\
 &\quad + [l_{\mathbf{u}}(\mathbf{x}^*, \mathbf{u}^*, t) + \mathbf{f}_{\mathbf{u}}(\mathbf{x}^*, \mathbf{u}^*, t)^T \boldsymbol{\lambda}]^T \delta \mathbf{u} dt.
 \end{aligned}$$

Falls $\mathbf{x}^*(t)$, $\mathbf{u}^*(t)$ mit der Endzeit t_f^* eine optimale Lösung darstellt, muss $\delta \bar{J} = 0$ sein für alle zulässigen Variationen $\delta \mathbf{x}(t)$, $\delta \mathbf{u}(t)$ und δt_f . Es muss also gelten

$$\dot{\boldsymbol{\lambda}}^* = -l_{\mathbf{x}}(\mathbf{x}^*, \mathbf{u}^*, t) - \mathbf{f}_{\mathbf{x}}(\mathbf{x}^*, \mathbf{u}^*, t)^T \boldsymbol{\lambda}^*, \quad t \in (t_0, t_f) \quad (5.44a)$$

$$\mathbf{0} = l_{\mathbf{u}}(\mathbf{x}^*, \mathbf{u}^*, t) + \mathbf{f}_{\mathbf{u}}(\mathbf{x}^*, \mathbf{u}^*, t)^T \boldsymbol{\lambda}^*, \quad t \in (t_0, t_f) \quad (5.44b)$$

$$0 = (V_{\mathbf{x}}(\mathbf{x}^*(t_f^*), t_f^*) - \boldsymbol{\lambda}^*(t_f))^T \Delta \mathbf{x}_f \quad (5.44c)$$

$$0 = \left(V_t(\mathbf{x}^*, t) + l(\mathbf{x}^*, \mathbf{u}^*, t) + \boldsymbol{\lambda}^T \mathbf{f}(\mathbf{x}^*, \mathbf{u}^*, t) \right)_{t=t_f^*} \quad (5.44d)$$

Analog zum vorherigen Abschnitt ist (5.44c) für die Endbedingungen (5.42) erfüllt. Zusätzlich kommt aufgrund der freien Endzeit t_f die Endbedingung (5.44d) hinzu.

5.3.2 Optimalitätsbedingungen

Die im letzten Abschnitt hergeleiteten Beziehungen stellen notwendige Bedingungen dar, die eine optimale Lösung $\mathbf{x}^*(t)$, $\mathbf{u}^*(t)$ des Optimalsteuerungsproblems (5.37) erfüllen muss. Mit Hilfe der sogenannten *Hamilton-Funktion* können diese Beziehungen in einer kompakteren Weise geschrieben werden.

Definition 5.3 (Hamilton-Funktion) Die Hamilton-Funktion für das Optimalsteuerungsproblem (5.37) ist

$$H(\mathbf{x}, \mathbf{u}, \boldsymbol{\lambda}, t) = l(\mathbf{x}, \mathbf{u}, t) + \boldsymbol{\lambda}^T \mathbf{f}(\mathbf{x}, \mathbf{u}, t) \quad (5.45)$$

mit den Lagrange-Multiplikatoren $\boldsymbol{\lambda}(t) \in \mathbb{R}^n$.

Die notwendigen Optimalitätsbedingungen 1. Ordnung für das Optimalsteuerungsproblem (5.37) lassen sich nun aus dem bisher Gesagten wie folgt zusammenfassen:

Satz 5.3 (Notwendige Optimalitätsbedingungen 1. Ordnung) Gegeben sei das Optimalsteuerungsproblem (5.37). Die Funktionen l und $\mathbf{f}$ seien stetig in $(\mathbf{x}, \mathbf{u}, t)$ und stetig differenzierbar in $(\mathbf{x}, \mathbf{u})$. Sei $\mathbf{u}^* \in C_m^0[t_0, t_f]$ eine (lokal) optimale Lösung von (5.37) mit zugehöriger Zustandstrajektorie $\mathbf{x}^* \in C_n^1[t_0, t_f]$. Dann existieren Zeitfunktionen $\boldsymbol{\lambda}^* \in C_n^1[t_0, t_f]$ mit $\boldsymbol{\lambda}^* = [\lambda_1^*, \dots, \lambda_n^*]^T$ so, dass Folgendes gilt:

a) $(\mathbf{u}^*, \mathbf{x}^*, \boldsymbol{\lambda}^*)$ erfüllen die Bedingungen

$$\dot{\mathbf{x}}^* = H_{\mathbf{x}}(\mathbf{x}^*, \mathbf{u}^*, \boldsymbol{\lambda}^*, t) = \mathbf{f}(\mathbf{x}^*, \mathbf{u}^*, t) \quad (5.46a)$$

$$\dot{\boldsymbol{\lambda}}^* = -H_{\mathbf{x}}(\mathbf{x}^*, \mathbf{u}^*, \boldsymbol{\lambda}^*, t) = -l_{\mathbf{x}}(\mathbf{x}^*, \mathbf{u}^*, t) - \mathbf{f}_{\mathbf{x}}(\mathbf{x}^*, \mathbf{u}^*, t)^T \boldsymbol{\lambda}^* \quad (5.46b)$$

$$\mathbf{0} = H_{\mathbf{u}}(\mathbf{x}^*, \mathbf{u}^*, \boldsymbol{\lambda}^*, t) = l_{\mathbf{u}}(\mathbf{x}^*, \mathbf{u}^*, t) + \mathbf{f}_{\mathbf{u}}(\mathbf{x}^*, \mathbf{u}^*, t)^T \boldsymbol{\lambda}^* \quad (5.46c)$$

für $t \in [t_0, t_f]$ mit den Zustandsrandbedingungen

$$\mathbf{x}^*(t_0) = \mathbf{x}_0 \quad (5.47a)$$

$$x_i^*(t_f) = x_{f,i}, \quad i \in \mathcal{I}_f \quad (5.47b)$$

und der Transversalitätsbedingung

$$\lambda_i^*(t_f) = V_{x_i}(\mathbf{x}(t_f), t_f), \quad i \notin \mathcal{I}_f. \quad (5.47c)$$

b) Ist die Endzeit t_f frei und sei t_f^* die (lokal) optimale Endzeit, so ist (5.46) für $t \in [t_0, t_f^*]$ und (5.47) für $t_f = t_f^*$ erfüllt und es gilt die Transversalitätsbedingung für die Hamilton-Funktion

$$H(\mathbf{x}^*(t_f^*), \mathbf{u}^*(t_f^*), \boldsymbol{\lambda}^*(t_f^*), t_f^*) = -V_t(\mathbf{x}^*(t_f^*), t_f^*). \quad (5.48)$$

Die Differenzialgleichungen (5.46a), (5.46b) werden als *kanonische Gleichungen* oder *Hamilton-Gleichungen* bezeichnet, während (5.46b) für sich genommen das *adjungierte System* mit dem *adjungierten Zustand* $\boldsymbol{\lambda}$ darstellt.

Die Optimalitätsbedingungen definieren eine *Zwei-Punkt-Randwertaufgabe* (RWA) für die optimalen Zustände $\mathbf{x}^*(t)$, $\boldsymbol{\lambda}^*(t)$ und die optimale Steuerung $\mathbf{u}^*(t)$. Falls t_f fest ist, umfasst die RWA (5.46), (5.47) $2n$ Gleichungen mit $2n$ Randbedingungen. Falls t_f frei ist, kommt zusätzlich die Transversalitätsbedingung (5.48) hinzu, um die optimale Endzeit t_f^* bestimmen zu können. Die Endbedingungen in (5.47) beinhalten insbesondere die folgenden Sonderfälle:

- **Fester Endzustand** $\mathbf{x}(t_f) = \mathbf{x}_f$, d.h. $\mathcal{I}_f = \{1, \dots, n\}$: Der komplette Zustand $\mathbf{x}$ ist am Anfang und Ende des Zeitintervalls $[t_0, t_f]$ fixiert, während der adjungierte Endzustand $\boldsymbol{\lambda}(t_f)$ frei ist.
- **Freier Endzustand** $\mathbf{x}(t_f)$, d.h. $\mathcal{I}_f = \{\}$: In diesem Fall ist der komplette adjungierte Endzustand (5.47c) fixiert, d.h. $\boldsymbol{\lambda}(t_f) = V_x(\mathbf{x}(t_f), t_f)$, und die Randbedingungen teilen sich in Anfangs- und Endbedingungen für $\mathbf{x}(t_0)$ und $\boldsymbol{\lambda}(t_f)$ auf.
- **Freie Endzeit** t_f mit Mayer-Term $V = 0$ oder $V = V(\mathbf{x}(t_f))$: In diesem Fall ist die Transversalitätsbedingung (5.48) homogen, d.h. $H|_{t=t_f^*} = 0$.

Zusätzlich kann die Legendre-Bedingung (5.27) für das Optimalsteuerungsproblem (5.1) wie folgt angegeben werden

$$H_{uu}(\mathbf{x}^*(t), \mathbf{u}^*(t), \boldsymbol{\lambda}^*(t), t) \text{ positiv semi-definit} \quad \forall t \in [t_0, t_f], \quad (5.49)$$

die eine notwendige Optimalitätsbedingung 2. Ordnung für eine optimale Lösung $\mathbf{x}^*(t)$, $\mathbf{u}^*(t)$ darstellt. Die Funktion H_{uu} stellt dabei die zweite partielle Ableitung bzw. Hesse-Matrix $\frac{\partial^2 H}{\partial \mathbf{u}^2}$ der Hamilton-Funktion dar.

Eine besondere Eigenschaft der Hamilton-Funktion (5.45) ist ihr Verhalten entlang einer optimalen Lösung:

$$\begin{aligned} \frac{d}{dt} H(\mathbf{x}^*(t), \mathbf{u}^*(t), \boldsymbol{\lambda}^*(t), t) &= H_t^* + \overbrace{(H_x^*)^\top \dot{\mathbf{x}}^*}^{(H_x^*)^\top \mathbf{f}^*} + \overbrace{(H_u^*)^\top \dot{\mathbf{u}}^*}^0 + \overbrace{(H_\lambda^*)^\top \dot{\boldsymbol{\lambda}}^*}^{-(\mathbf{f}^*)^\top H_x^*} \\ &= H_t(\mathbf{x}^*(t), \mathbf{u}^*(t), \boldsymbol{\lambda}^*(t), t), \end{aligned} \quad (5.50)$$

wobei $()^*$ als Kurzform zur Evaluierung der Funktionen entlang der optimalen Trajektorien verwendet wird. Für zeitinvariante Probleme (5.37), bei denen weder die Kostenfunktion J noch die Systemfunktion $\mathbf{f}$ explizit von t abhängen, ist die Hamilton-Funktion H entlang einer optimalen Trajektorie also konstant!




Abbildung 5.5: Optimale Trajektorien in Aufgabe 5.2.

Aufgabe 5.2 (Feste Endzeit & Endbedingung) Betrachtet wird das Problem

$$\begin{aligned} \min_{u(\cdot)} \quad & \int_0^1 \frac{1}{2} u^2 + \frac{a}{2} x^2 dt, \quad a > 0 \\ \text{u.B.v.} \quad & \dot{x} = u, \quad x(0) = 1, \quad x(1) = 0. \end{aligned}$$

Zeigen Sie, dass die Lösung

$$x^*(t) = \frac{1}{1 - e^{2\sqrt{a}}} \left(e^{\sqrt{a}t} - e^{\sqrt{a}(2-t)} \right), \quad u^*(t) = \frac{\sqrt{a}}{1 - e^{2\sqrt{a}}} \left(e^{\sqrt{a}t} + e^{\sqrt{a}(2-t)} \right) \quad (5.51)$$

lautet und interpretieren Sie die Ergebnisse in Abbildung 5.5, die für verschiedene Parameterwerte a dargestellt sind.

Aufgabe 5.3 (Feste Endzeit & partielle Endbedingung) Betrachtet wird

$$\begin{aligned} \min_{u(\cdot)} \quad & \frac{a}{2} x_2(1)^2 + \int_0^1 \frac{1}{2} u^2 dt, \quad a \geq 0 \\ \text{u.B.v.} \quad & \dot{x}_1 = x_2, \quad x_1(0) = 1, \quad x_1(1) = 0 \\ & \dot{x}_2 = u, \quad x_2(0) = 0 \end{aligned}$$

Zeigen Sie, dass sich für den (freien) Endzustand $x_2^*(1) = -6/(4 + a)$ in Abhängigkeit des Parameters $a \geq 0$ ergibt und dass die optimale Lösung

$$x_1^*(t) = \frac{2(1+a)}{4+a} t^3 - \frac{3(2+a)}{a+4} t^2 + 1, \quad u^*(t) = \frac{12(1+a)}{4+a} t - \frac{6(2+a)}{a+4} \quad (5.52)$$

lautet. Interpretieren Sie die Ergebnisse in Abbildung 5.6.

5.3.3 Beispiel zur Betrachtung einer freien Endzeit

Betrachtet wird ein Partikel der Masse m in der (x, y) -Ebene, auf das eine konstante Kraft $F = ma$ wirkt. Die Stellgröße u des Problems ist der Winkel zwischen der Schubrichtung und der x -Achse, siehe Abbildung 5.7. Ziel ist es, das Partikel in minimaler Zeit t_f mit $t_0 = 0$ zu




Abbildung 5.6: Optimale Trajektorien in Aufgabe 5.3.

einem Zielpunkt (x_f, y_f) zu steuern. Unter der Annahme, dass außer dem Schub keine weiteren Kräfte auftreten, kann das Optimalsteuerungsproblem wie folgt formuliert werden

$$\min_{u(\cdot)} t_f \quad (5.53a)$$

$$\text{u.B.v. } \dot{x} = v, \quad x(0) = x_0, \quad x(t_f) = x_f \quad (5.53b)$$

$$\dot{v} = a \cos(u), \quad v(0) = v_0 \quad (5.53c)$$

$$\dot{y} = w, \quad y(0) = y_0, \quad y(t_f) = y_f \quad (5.53d)$$

$$\dot{w} = a \sin(u), \quad w(0) = w_0. \quad (5.53e)$$

Der Endzustand ist nur für die Position (x, y) vorgegeben und nicht für die Geschwindigkeiten, so dass sich in Analogie zu den partiellen Endbedingungen (5.37c) die Menge $\mathcal{I}_f = \{x, y\}$ ergibt. Die Hamilton-Funktion (5.45) für das Problem ist

$$H(\mathbf{x}, u, \boldsymbol{\lambda}) = \lambda_x v + \lambda_v a \cos(u) + \lambda_y w + \lambda_w a \sin(u) \quad (5.54)$$

mit $\mathbf{x} = [x, v, y, w]^T$ und den adjungierten Zuständen $\boldsymbol{\lambda} = [\lambda_x, \lambda_v, \lambda_y, \lambda_w]^T$. Das adjungierte System (5.46b) mit den Endbedingungen (5.47c) lautet

$$\dot{\lambda}_x = -\frac{\partial H}{\partial x} = 0 \quad (5.55a)$$

$$\dot{\lambda}_v = -\frac{\partial H}{\partial v} = -\lambda_x, \quad \lambda_v(t_f) = 0 \quad (5.55b)$$

$$\dot{\lambda}_y = -\frac{\partial H}{\partial y} = 0 \quad (5.55c)$$

$$\dot{\lambda}_w = -\frac{\partial H}{\partial w} = -\lambda_y, \quad \lambda_w(t_f) = 0, \quad (5.55d)$$

woraus direkt

$$\lambda_x = \text{konst.}, \quad \lambda_v = \lambda_x(t_f - t), \quad \lambda_y = \text{konst.}, \quad \lambda_w = \lambda_y(t_f - t) \quad (5.56)$$

folgt. Des Weiteren muss (5.46c) gelten, d.h.

$$\frac{\partial H}{\partial u} = -\lambda_v a \sin(u) + \lambda_w a \cos(u) = 0,$$




Abbildung 5.7: Bewegung eines Partikels der Masse m in der (x, y) -Ebene.

womit sich u wie folgt berechnen lässt

$$\begin{aligned} \tan(u) &= \frac{\lambda_w}{\lambda_v} \stackrel{(5.56)}{=} \frac{\lambda_y(t_f - t)}{\lambda_x(t_f - t)} = \frac{\lambda_y}{\lambda_x} = \text{konst.} \\ \Rightarrow u &= \arctan\left(\frac{\lambda_y}{\lambda_x}\right) \quad \text{falls} \quad -\frac{\pi}{2} < u < \frac{\pi}{2}. \end{aligned} \quad (5.57)$$

Die optimale Steuerung ist also auf dem gesamten Zeitintervall $[t_0 = 0, t_f]$ konstant und die Zustände $x(t)$ und $y(t)$ können durch zweifache Integration der Differenzialgleichungen (5.53c), (5.53e) und Einsetzen der Anfangsbedingungen bestimmt werden³

$$x(t) = g_x(\lambda_x, \lambda_y, t) = x_0 + v_0 t + \frac{1}{2} a \cos(u) t^2, \quad \cos(u) \stackrel{(5.57)}{=} \frac{1}{\sqrt{1 + \lambda_y^2 / \lambda_x^2}} \quad (5.58a)$$

$$v(t) = g_v(\lambda_x, \lambda_y, t) = v_0 + a \cos(u) t \quad (5.58b)$$

$$y(t) = g_y(\lambda_x, \lambda_y, t) = y_0 + w_0 t + \frac{1}{2} a \sin(u) t^2, \quad \sin(u) \stackrel{(5.57)}{=} \frac{\lambda_y}{\lambda_x \sqrt{1 + \lambda_y^2 / \lambda_x^2}} \quad (5.58c)$$

$$w(t) = g_w(\lambda_x, \lambda_y, t) = w_0 + a \sin(u) t. \quad (5.58d)$$

Da die Endzeit t_f frei ist, muss zusätzlich die Transversalitätsbedingung (5.48) gelten, wobei sich die Hamilton-Funktion (5.54) aufgrund der Endbedingungen $\lambda_v(t_f) = \lambda_w(t_f) = 0$ entsprechend vereinfacht

$$H(\mathbf{x}, u, \boldsymbol{\lambda})|_{t=t_f} = -1 \quad \Rightarrow \quad \lambda_x g_v(\lambda_x, \lambda_y, t_f) + \lambda_y g_w(\lambda_x, \lambda_y, t_f) = -1. \quad (5.59)$$

Die gewünschten Endbedingungen $x(t_f) = x_f$, $y(t_f) = y_f$ und die Endzeit t_f müssen aus den Gleichungen (5.58a), (5.58c), (5.59) berechnet werden, die ein Gleichungssystem für die drei verbleibenden Unbekannten $(\lambda_x, \lambda_y, t_f)$ darstellen

$$\begin{bmatrix} g_x(\lambda_x, \lambda_y, t_f) \\ g_y(\lambda_x, \lambda_y, t_f) \\ \lambda_x g_v(\lambda_x, \lambda_y, t_f) + \lambda_y g_w(\lambda_x, \lambda_y, t_f) \end{bmatrix} - \begin{bmatrix} x_f \\ y_f \\ -1 \end{bmatrix} = \mathbf{0} \quad (5.60)$$

welches auf numerischem Wege gelöst werden kann.

Eine geeignete MATLAB-Funktion zur Lösung von nichtlinearen Gleichungen ist `fsolve` aus der Optimization Toolbox. Die Funktion `fsolve` verwendet standardmäßig die Methode der

³ Trigonometrische Beziehungen: $\sin(\arctan(b)) = b / \sqrt{1 + b^2}$, $\cos(\arctan(b)) = 1 / \sqrt{1 + b^2}$.

Vertrauensbereiche (siehe Abschnitt 3.4.1), um ein Gleichungssystem in Residuenform $\mathbf{F}(\mathbf{x}) = \mathbf{0}$ als Minimierungsproblem in $\mathbf{x}$ zu lösen.

Als Beispiel ist in Abbildung 5.8 der MATLAB-Code dargestellt, wie `fsolve` zur Lösung von (5.60) verwendet werden kann. Der gewünschte Endpunkt (x_f, y_f) wird beim Aufruf der Funktion `particle(xf,yf)` übergeben, wobei angenommen wird, dass das Partikel am Punkt $(x_0, y_0) = (0, 0)$ mit der Geschwindigkeit $(v_0, w_0) = (0, 1)$ in vertikale Richtung startet. Abbildung 5.9 stellt die optimalen Bahnen $x^*(t)$, $y^*(t)$ des Partikels in der (x, y) -Ebene für verschiedene Endpunkte (x_f, y_f) dar. Die Pfeile zeigen die (konstante) Richtung $u = \arctan(\lambda_y/\lambda_x)$ der angreifenden Kraft ma an.

```
function [t,x,y,p] = particle(xf,yf)
% -----
% (xf,yf): desired target point
% (t,x,y): trajectory of the particle
% p:      parameter structure

p.a = 1;                                % parameters
p.x0=0; p.v0=0; p.y0=0; p.w0=1;         % initial conditions
p.xf=xf; p.yf=yf;                       % terminal conditions

opt = optimset('Display','iter');        % options
X0 = [-1,0,1];                          % initial guess for fsolve
Xopt = fsolve(@eqns,X0,opt,p);           % numerical solution with fsolve
p.lx=Xopt(1); p.ly=Xopt(2); p.tf=Xopt(3); % solution

t = linspace(0,p.tf,100);               % trajectories
x = xfct(p.lx,p.ly,t,p);
y = yfct(p.lx,p.ly,t,p);
% -----
function res = eqns(X,p)                  % equations in residual form
lx=X(1); ly=X(2); tf=X(3);
res = [ xfct(lx,ly,tf,p) - p.xf;
        yfct(lx,ly,tf,p) - p.yf;
        lx*vfct(lx,ly,tf,p) + ly*wfct(lx,ly,tf,p) + 1 ];
% -----
function x = xfct(lx,ly,t,p)              % functions for x and v
cosu = 1/sqrt(1+(ly/lx)^2);
x = p.x0 + p.v0*t + p.a/2*cosu*t.^2;      % 't.^2' = component-wise evaluation
function v = vfct(lx,ly,t,p)
cosu = 1/sqrt(1+(ly/lx)^2);
v = p.v0 + p.a*cosu*t;
% -----
function y = yfct(lx,ly,t,p)              % functions for y and w
sinu = ly/(lx*sqrt(1+(ly/lx)^2));
y = p.y0 + p.w0*t + p.a/2*sinu*t.^2;      % 't.^2' = component-wise evaluation
function w = wfct(lx,ly,t,p)
sinu = ly/(lx*sqrt(1+(ly/lx)^2));
w = p.w0 + p.a*sinu*t;
```

Abbildung 5.8: MATLAB-Code für das Partikel-Problem unter Verwendung von `fsolve`.

5.3.4 Allgemeine Vorgehensweise und singulärer Fall

Die vorherigen Beispiele illustrierten, wie die Optimalitätsbedingungen (5.46a)-(5.48) bei einfachen Problemen weitgehend analytisch gelöst werden können. Eine generelle Vorgehensweise zur Berechnung einer optimalen Steuerung mittels der Optimalitätsbedingungen gliedert sich in die folgenden Schritte:




Abbildung 5.9: Zeitoptimale Steuerung eines Partikels zu verschiedenen Endpunkten.

1. Aufstellen der Hamilton-Funktion $H(\mathbf{x}, \mathbf{u}, \boldsymbol{\lambda}, t) = l(\mathbf{x}, \mathbf{u}, t) + \boldsymbol{\lambda}^\top \mathbf{f}(\mathbf{x}, \mathbf{u}, t)$
2. Berechnung von $\mathbf{u}$ aus (5.46c), so dass sich $\mathbf{u}$ als Funktion von $(\mathbf{x}, \boldsymbol{\lambda}, t)$ ergibt:

$$\boldsymbol{u} = \boldsymbol{\psi}(\boldsymbol{x}, \boldsymbol{\lambda}, t). \quad (5.61)$$

3. Einsetzen der Funktion (5.61) in die kanonischen Gleichungen (5.46a)-(5.46b) führt auf das Randwertproblem

$$\dot{\mathbf{x}} = \mathbf{f}(\mathbf{x}, \boldsymbol{\psi}(\mathbf{x}, \boldsymbol{\lambda}, t), t), \quad \dot{\boldsymbol{\lambda}} = -H_{\mathbf{x}}(\mathbf{x}, \boldsymbol{\psi}(\mathbf{x}, \boldsymbol{\lambda}, t), \boldsymbol{\lambda}, t), \quad \text{RBen} \quad (5.47)$$

mit $H_x = \frac{\partial H}{\partial x}$, das nun unabhängig von der Stellgröße $\mathbf{u}$ ist. Falls die Endzeit t_f frei ist, kommt noch die Endbedingung (5.48) hinzu.

4. Die Lösung des Randwertproblems liefert $\mathbf{x}^*(t)$, $\boldsymbol{\lambda}^*(t)$, $t \in [t_0, t_f]$, womit sich die Steuertrajektorie $\mathbf{u}^*(t)$ aus (5.61) ergibt. In den meisten Fällen muss das Randwertproblem numerisch gelöst werden (siehe Abschnitt 5.6).

Es sei angemerkt, dass die Lösung der kanonischen Gleichungen nicht automatisch die Optimalität der resultierenden Trajektorien $\mathbf{x}^*(t)$, $\mathbf{u}^*(t)$ impliziert, da es sich lediglich um notwendige Bedingungen handelt. Aus der Sicht des Anwenders wird aber häufig angenommen, dass eine (eindeutige) optimale Lösung für ein gegebenes Problem existiert, und somit die Auswertung der notwendigen Optimalitätsbedingungen ausreichend ist.

Falls $\mathbf{u}$ in der Systemfunktion $\mathbf{f}(\mathbf{x}, \mathbf{u})$ oder im Integralanteil $I(\mathbf{x}, \mathbf{u}, t)$ des Kostenfunktional (5.37a) nichtlinear eingeht, muss die Funktion (5.61) in der Regel numerisch bestimmt werden. In vielen praktischen Fällen kann dies aber umgangen werden:

Beispiel 5.4 (Eingangsaffine Systeme & energieoptimaler Kostenanteil) Das Aufstellen der Funktion (5.61) ist besonders einfach für eingangsaffine Systeme

$$\dot{\mathbf{x}} = \mathbf{f}(\mathbf{x}, \mathbf{u}) = \mathbf{f}_0(\mathbf{x}) + \sum_{i=1}^m \mathbf{f}_i(\mathbf{x}) u_i \quad (5.62)$$

mit energieoptimalen Anteil im Kostenfunktional

$$J(\mathbf{u}) = V(\mathbf{x}(t_f), t_f) + \int_{t_0}^{t_f} l_0(\mathbf{x}) + \frac{1}{2} \sum_{i=1}^m r_i u_i^2 dt, \quad r_i > 0. \quad (5.63)$$

In diesem Fall berechnet sich u_i explizit aus der Bedingung $\frac{\partial H}{\partial u_i} = r_i u_i + \boldsymbol{\lambda}^\top \mathbf{f}_i(\mathbf{x}) = 0$:

$$u_i = \psi_i(\mathbf{x}, \boldsymbol{\lambda}) = -\frac{1}{r_i} \boldsymbol{\lambda}^\top \mathbf{f}_i(\mathbf{x}), \quad i = 1, \dots, m.$$

Problematisch ist der Fall, wenn ein oder mehrere Elemente u_i von $\mathbf{u}$ nicht aus der Stationaritätsbedingung (5.46c) berechnet werden können. Dies lässt sich am einfachsten am Beispiel des eingangsaffinen Systems (5.62) mit skalarer Stellgröße u ($m = 1$) erklären. Falls im Kostenfunktional (5.37a) der Integralanteil I unabhängig von u ist, d.h. $I = I(\mathbf{x}, t)$, lautet die Hamilton-Funktion und die erste Ableitung nach u

$$H(\mathbf{x}, u, \boldsymbol{\lambda}, t) = I(\mathbf{x}, t) + \boldsymbol{\lambda}^\top [\mathbf{f}_0(\mathbf{x}) + \mathbf{f}_1(\mathbf{x})u], \quad H_u(\mathbf{x}, \boldsymbol{\lambda}) = \boldsymbol{\lambda}^\top \mathbf{f}_1(\mathbf{x}) = 0$$

mit $H_u = \frac{\partial H}{\partial u}$. Man spricht in diesem Fall von einem *singulären Problem*, da u_i nicht aus der Beziehung $H_u = 0$ bestimmt werden kann. Trotzdem muss die Stationaritätsbedingung $H_u(\mathbf{x}^*(t), \boldsymbol{\lambda}^*(t)) = 0$ für eine optimale Lösung nach wie vor gelten, auch wenn sie keine Informationen über die optimale Steuerung liefert. Folglich müssen die Zeitableitungen $\frac{d^i}{dt^i} H_u(\cdot)$ ebenfalls verschwinden. Von besonderem Interesse ist dabei die erste Zeitableitung, bei der u explizit erscheint, d.h.

$$\frac{d^r}{dt^r} H_u(\mathbf{x}^*(t), \boldsymbol{\lambda}^*(t)) = 0 \quad \text{mit} \quad \frac{\partial}{\partial u} \left(\frac{d^r}{dt^r} H_u(\cdot) \right) \neq 0.$$

Die Variable r stellt den *Grad der Singularität* dar. Die Gleichung $\frac{d^r}{dt^r} H_u(\cdot) = 0$ kann nun verwendet werden, um $u^*(t)$ zu berechnen.

Es ist offensichtlich, dass die Behandlung von singulären Problemen recht komplex und vor allem problemspezifisch ist. In der Praxis wird dieser Fall häufig umgangen, indem ein *Regularisierungsterm* $\sum_{i=1}^m r_i u_i^2$, siehe (5.63), mit hinreichend kleinen Gewichtungen $r_i > 0$ zur Kostenfunktion hinzugefügt wird. Damit ist sicher gestellt, dass u_i in den einzelnen Stationaritätsbedingungen $H_{u_i} = 0$ nicht verschwindet.

5.3.5 Interpretation der adjungierten Variablen

Im Falle der statischen Optimierung wurde in Abschnitt 4.2.4 gezeigt, dass die Lagrange-Multiplikatoren λ_i und μ_i ein Maß für die Sensitivität der Kostenfunktion f am Optimum bezogen auf kleine Änderungen der jeweiligen Beschränkungen darstellen.

Eine ähnliche Interpretation lässt sich bei Optimalsteuerungsproblemen für die adjungierten Variablen $\boldsymbol{\lambda}^*(t)$ herleiten. Um dies zu betrachten, wird das folgende Optimierungsproblem ohne Endbedingungen, ohne Endgewichtung und mit fester Endzeit t_f betrachtet:

$$\min_{\mathbf{u}(\cdot)} \int_{t_0}^{t_f} l(\mathbf{x}, \mathbf{u}, t) dt \quad (5.64a)$$

$$\text{u.B.v.} \quad \dot{\mathbf{x}} = \mathbf{f}(\mathbf{x}, \mathbf{u}, t), \quad \mathbf{x}(t_0) = \mathbf{x}_0. \quad (5.64b)$$

Die optimale Lösung sei $\mathbf{x}^*(t)$, $\mathbf{u}^*(t)$ und stetig auf $[t_0, t_f]$. Des Weiteren wird angenommen, dass die Funktionen $\mathbf{f}$ und l stetig differenzierbar sind.

Im Folgenden werden kleine Abweichungen $\boldsymbol{\varepsilon}$ von den Anfangsbedingungen $\mathbf{x}(t_0) = \mathbf{x}_0 + \boldsymbol{\varepsilon}$ betrachtet, für die die zugehörigen optimalen Trajektorien mit $\mathbf{x}^\varepsilon(t)$ und $\mathbf{u}^\varepsilon(t)$ bezeichnet werden. Es ist direkt ersichtlich, dass

$$\mathbf{x}^*(t) = \mathbf{x}^0(t), \quad \mathbf{u}^*(t) = \mathbf{u}^0(t), \quad t \in [t_0, t_f] \quad (5.65)$$

gilt. Da die Systemgleichungen (5.64b) für die optimale Lösung $\mathbf{x}^\varepsilon(t)$, $\mathbf{u}^\varepsilon(t)$ erfüllt sind, d.h.

$$\dot{\mathbf{x}}^\varepsilon(t) = \mathbf{f}(\mathbf{x}^\varepsilon(t), \mathbf{u}^\varepsilon(t), t), \quad \mathbf{x}^\varepsilon(t_0) = \mathbf{x}_0 + \boldsymbol{\varepsilon}, \quad (5.66)$$

können sie mit Hilfe von adjungierten Variablen zur Kostenfunktion in (5.64a) addiert werden

$$\begin{aligned} V(\mathbf{x}^\varepsilon(t_0), t_0) &= \int_{t_0}^{t_f} l(\mathbf{x}^\varepsilon(t), \mathbf{u}^\varepsilon(t), t) dt \\ &= \int_{t_0}^{t_f} l(\mathbf{x}^\varepsilon(t), \mathbf{u}^\varepsilon(t), t) + \boldsymbol{\lambda}^*(t)^\top [\mathbf{f}(\mathbf{x}^\varepsilon(t), \mathbf{u}^\varepsilon(t), t) - \dot{\mathbf{x}}^\varepsilon(t)] dt. \end{aligned}$$

Dabei stellen $\boldsymbol{\lambda}^*(t)$ die zur nominellen optimalen Lösung $\mathbf{x}^*(t)$, $\mathbf{u}^*(t)$ gehörenden adjungierten Zustände dar. Unter der Annahme, dass $\mathbf{x}^\varepsilon(t)$ und $\mathbf{u}^\varepsilon(t)$ bzgl. $\boldsymbol{\varepsilon}$ stetig differenzierbar sind, folgt mittels partieller Integration und anschließendem Differenzieren nach $\boldsymbol{\varepsilon}$ (ohne Argumente)

$$\begin{aligned} \frac{d}{d\boldsymbol{\varepsilon}} V(\mathbf{x}^\varepsilon(t_0), t_0) &= -[(\mathbf{x}_\varepsilon^\varepsilon)^\top \boldsymbol{\lambda}^*]_{t_0}^{t_f} + \int_{t_0}^{t_f} (\mathbf{x}_\varepsilon^\varepsilon)^\top [l_x(\mathbf{x}^\varepsilon, \mathbf{u}^\varepsilon, t) + \mathbf{f}_x(\mathbf{x}^\varepsilon, \mathbf{u}^\varepsilon, t)^\top \boldsymbol{\lambda}^* + \dot{\boldsymbol{\lambda}}^*] \\ &\quad + (\tilde{\mathbf{u}}_\varepsilon^\varepsilon)^\top [l_u(\mathbf{x}^\varepsilon, \mathbf{u}^\varepsilon, t) + \mathbf{f}_u(\mathbf{x}^\varepsilon, \mathbf{u}^\varepsilon, t)^\top \boldsymbol{\lambda}^*] dt. \end{aligned}$$

Die Sensitivitäten $\mathbf{x}_\varepsilon^\varepsilon(t) = \frac{d}{d\boldsymbol{\varepsilon}} \mathbf{x}^\varepsilon(t)$ und $\mathbf{u}_\varepsilon^\varepsilon(t) = \frac{d}{d\boldsymbol{\varepsilon}} \mathbf{u}^\varepsilon(t)$ stellen Matrizen dar. Somit ist die obige Gleichung eine Vektorgleichung, in der das Integral elementweise zu verstehen ist.

Für $\boldsymbol{\varepsilon} = \mathbf{0}$ ergibt sich die nominelle optimale Lösung (5.65), womit die vorherige Gleichung wie folgt geschrieben werden kann:

$$\begin{aligned} \frac{d}{d\boldsymbol{\varepsilon}} V(\mathbf{x}^\varepsilon(t_0), t_0) \Big|_{\boldsymbol{\varepsilon}=\mathbf{0}} &= -\mathbf{x}_\varepsilon^0(t_f)^\top \boldsymbol{\lambda}^*(t_f) + \mathbf{x}_\varepsilon^0(t_0)^\top \boldsymbol{\lambda}^*(t_0) \\ &+ \int_{t_0}^{t_f} \mathbf{x}_\varepsilon^0(t)^\top [l_x(\mathbf{x}^*, \mathbf{u}^*, t) + \mathbf{f}_x(\mathbf{x}^*, \mathbf{u}^*, t)^\top \boldsymbol{\lambda}^* + \dot{\boldsymbol{\lambda}}^*] + \mathbf{u}_\varepsilon^0(t)^\top [l_u(\mathbf{x}^*, \mathbf{u}^*, t) + \mathbf{f}_u(\mathbf{x}^*, \mathbf{u}^*, t)^\top \boldsymbol{\lambda}^*] dt. \end{aligned}$$

Da das Tripel $(\mathbf{x}^*, \mathbf{u}^*, \boldsymbol{\lambda}^*)$ aber die notwendigen Optimalitätsbedingungen (5.46b)-(5.46c) erfüllt und $\boldsymbol{\lambda}^*(t_f) = \mathbf{0}$ ist, vereinfacht sich diese Gleichung zu

$$\frac{d}{d\boldsymbol{\varepsilon}} V(\mathbf{x}^\varepsilon(t_0), t_0) \Big|_{\boldsymbol{\varepsilon}=\mathbf{0}} = \mathbf{x}_\varepsilon^0(t_0)^\top \boldsymbol{\lambda}^*(t_0) \quad \Rightarrow \quad V_x(\mathbf{x}_0, t_0) = \boldsymbol{\lambda}^*(t_0) \quad (5.67)$$

mit $V_x = \frac{\partial V}{\partial \mathbf{x}}$. In der letzten Beziehung wurde ausgenutzt, dass an der Stelle $t = t_0$ die Sensitivität $\mathbf{x}_\varepsilon^\varepsilon(t_0)$ genau die Einheitsmatrix $\mathbf{I}$ der Ordnung n ist, wie aus (5.66) leicht ersichtlich ist.

Aus (5.67) erkennt man, dass die adjungierten Variablen $\boldsymbol{\lambda}^*(t_0)$ zur Anfangszeit $t = t_0$ ein Maß für die Sensitivität des Kostenfunktionalen bezüglich Änderungen in den Anfangsbedingungen

$\mathbf{x}_0$ darstellen. Dieser Zusammenhang ist in den Abbildungen 5.5, 5.6 der Aufgaben 5.2 und 5.3 gut erkennbar.

Der bisher gefundene Zusammenhang für die Startzeit $t = t_0$ kann leicht auf das Gesamtintervall $[t_0, t_f]$ erweitert werden, indem das *Optimalitätsprinzip* zu Hilfe gezogen wird.

Satz 5.4 (Optimalitätsprinzip) Falls $\mathbf{u}^*(t)$, $t \in [t_0, t_f]$ eine optimale Steuerung des Problems (5.64) mit der zugehörigen Zustandstrajektorie $\mathbf{x}^*(t)$ ist, so ist $\mathbf{u}^*(t)$, $t \in [t_1, t_f]$ für jedes Restintervall $t_1 \in [t_0, t_f]$ die optimale Steuerung für das Problem

$$\min_{\mathbf{u}(\cdot)} \int_{t_1}^{t_f} l(\mathbf{x}, \mathbf{u}, t) dt \quad (5.68a)$$

$$\text{u.B.v. } \dot{\mathbf{x}} = \mathbf{f}(\mathbf{x}, \mathbf{u}, t), \quad \mathbf{x}(t_1) = \mathbf{x}^*(t_1). \quad (5.68b)$$

Aufgrund des Optimalitätsprinzips kann die Herleitung der Beziehung (5.67) auf das “abgeschnittene” Problem (5.68) übertragen werden, d.h. $V_x(\mathbf{x}^*(t_1), t_1) = \boldsymbol{\lambda}^*(t_1)$. Da aber t_1 auf dem Intervall $[t_0, t_f]$ frei gewählt werden kann, gilt folglich

$$V_x(\mathbf{x}^*(t), t) = \boldsymbol{\lambda}^*(t), \quad t \in [t_0, t_f]. \quad (5.69)$$

Die adjungierten Zustände $\boldsymbol{\lambda}^*(t)$ sind also ein Maß dafür, wie stark sich das Kostenfunktional bei einer kleinen Störung des Zustandes $\mathbf{x}^*(t)$ zur Zeit t ändern würde, wenn die Steuerung auf dem Restintervall $[t, t_f]$ optimal wäre.

5.3.6 Erweiterung auf allgemeine Randbedingungen

Der bisher betrachtete Fall partieller Endbedingungen ist die in der Praxis am häufigsten vorkommende Form von Endbedingungen und spiegelt die Dualität zwischen den Endbedingungen (5.47b) und (5.47c) für die Systemzustände $\mathbf{x}$ und die adjungierten Zustände $\boldsymbol{\lambda}$ wider.

Die Herleitung der Optimalitätsbedingungen (Abschnitt 5.3.2) über die Variationsrechnung erlaubt ebenfalls die Berücksichtigung von allgemeinen Endbedingungen

$$\mathbf{g}(\mathbf{x}(t_f), t_f) = \mathbf{0}, \quad \mathbf{g} : \mathbb{R}^n \times \mathbb{R}_+ \rightarrow \mathbb{R}^r. \quad (5.70)$$

Analog zum Vorgehen in Abschnitt 5.3.1 werden die Endbedingungen (5.70) über zusätzliche Lagrange-Multiplikatoren $\boldsymbol{\nu} \in \mathbb{R}^r$ zu dem erweiterten Kostenfunktional (5.38) hinzugefügt

$$\bar{J} = V(\mathbf{x}(t_f)) + \boldsymbol{\nu}^T \mathbf{g}(\mathbf{x}(t_f), t_f) + \int_{t_0}^{t_f} l(\mathbf{x}(t), \mathbf{u}(t), t) + \boldsymbol{\lambda}^T (\mathbf{f}(\mathbf{x}, \mathbf{u}, t) - \dot{\mathbf{x}}) dt. \quad (5.71)$$

Durch Anwendung der Variationsrechnung lässt sich zeigen, dass sich die Transversalitätsbedingung (5.47c) für eine optimale Lösung durch den zusätzlichen Term $\boldsymbol{\nu}^T \mathbf{g}(\mathbf{x}(t_f), t_f)$ entsprechend erweitert:

$$\boldsymbol{\lambda}^*(t_f) = V_x(\mathbf{x}^*(t_f), t_f) + \mathbf{g}_x(\mathbf{x}^*(t_f), t_f)^T \boldsymbol{\nu}^*. \quad (5.72)$$

Ist die Endzeit t_f frei, so wird die Transversalitätsbedingung (5.48) für die Hamilton-Funktion entsprechend modifiziert:

$$H(\mathbf{x}^*(t_f^*), \mathbf{u}^*(t_f^*), \boldsymbol{\lambda}^*(t_f^*), t_f^*) = -V_t(\mathbf{x}^*(t_f^*), t_f^*) - \mathbf{g}_t(\mathbf{x}^*(t_f^*), t_f^*)^T \boldsymbol{\nu}^* \quad (5.73)$$

Im Falle einer festen Endzeit umfasst das Randwertproblem der Optimalitätsbedingungen die $2n$ Differenzialgleichungen (5.46a), (5.46b), $2n + r$ Randbedingungen (5.47a), (5.72) und die m algebraischen Gleichungen (5.46c) für die $2n$ Zustände $\mathbf{x}^*(t)$, $\boldsymbol{\lambda}^*(t)$ und die r (konstanten) Multiplikatoren $\boldsymbol{\nu}^*$. Falls die Endzeit frei ist, kommt noch die Transversalitätsbedingung (5.73) zur Bestimmung von t_f^* hinzu.

5.4 Optimierung linearer Systeme mit quadratischem Kostenfunktional

Ein großes Anwendungsfeld der Optimalsteuerungstheorie sind lineare Systeme mit quadratischem Kostenfunktional

$$\min_{\mathbf{u}(\cdot)} J(\mathbf{u}) = \frac{1}{2} \mathbf{x}(t_f)^T \mathbf{S} \mathbf{x}(t_f) + \frac{1}{2} \int_{t_0}^{t_f} \mathbf{x}(t)^T \mathbf{Q} \mathbf{x}(t) + \mathbf{u}(t)^T \mathbf{R} \mathbf{u}(t) dt \quad (5.74a)$$

$$\text{u.B.v. } \dot{\mathbf{x}} = \mathbf{A}\mathbf{x} + \mathbf{B}\mathbf{u}, \quad \mathbf{x}(t_0) = \mathbf{x}_0. \quad (5.74b)$$

Der Endzustand $\mathbf{x}(t_f)$ sei frei und die Gewichtungsmatrizen $\mathbf{S}$, $\mathbf{Q}$ seien positiv semi-definit und $\mathbf{R}$ positiv definit. Es wird der Einfachheit halber zunächst angenommen, dass die Systemmatrizen $\mathbf{A}$ und $\mathbf{B}$ sowie die Gewichtungsmatrizen $\mathbf{Q}$, $\mathbf{R}$, $\mathbf{S}$ zeitinvariant sind. Allerdings sind die Betrachtungen in diesem Abschnitt direkt auf den zeitvarianten Fall übertragbar.

Das Optimalsteuerungsproblem (5.74) kann wie folgt interpretiert werden: Bringe das System (5.74b) im Zeitintervall $[t_0, t_f]$ ausgehend von $\mathbf{x}(t_0) = \mathbf{x}_0$ möglichst nahe an den Ursprung $\mathbf{x}(t_f) \approx \mathbf{0}$ unter Verwendung von "akzeptablen" Steuer- und Zustandstrajektorien $\mathbf{u}(t)$ und $\mathbf{x}(t)$. Die Gewichtungsmatrizen $\mathbf{Q}$, $\mathbf{R}$ und $\mathbf{S}$ bestimmen dabei das Zustands- und Eingangsverhalten des Systems (siehe Aufgaben 5.2 und 5.3).

5.4.1 Riccati-Differenzialgleichung

Im Folgenden sollen die im vorherigen Kapitel hergeleiteten Optimalitätsbedingungen auf das linear-quadratische Problem angewendet werden. Mit der Hamilton-Funktion

$$H(\mathbf{x}, \mathbf{u}, \boldsymbol{\lambda}, t) = \frac{1}{2} (\mathbf{x}^T \mathbf{Q} \mathbf{x} + \mathbf{u}^T \mathbf{R} \mathbf{u}) + \boldsymbol{\lambda}^T (\mathbf{A}\mathbf{x} + \mathbf{B}\mathbf{u})$$

lauten die Optimalitätsbedingungen (5.46a)-(5.47c)

$$\dot{\mathbf{x}} = H_{\mathbf{x}} = \mathbf{A}\mathbf{x} + \mathbf{B}\mathbf{u}, \quad \mathbf{x}(t_0) = \mathbf{x}_0 \quad (5.75a)$$

$$\dot{\boldsymbol{\lambda}} = -H_{\boldsymbol{\lambda}} = -\mathbf{Q}\mathbf{x} - \mathbf{A}^T \boldsymbol{\lambda}, \quad \boldsymbol{\lambda}(t_f) = \mathbf{S}\mathbf{x}(t_f) \quad (5.75b)$$

$$\mathbf{0} = H_{\mathbf{u}} = \mathbf{R}\mathbf{u} + \mathbf{B}^T \boldsymbol{\lambda}. \quad (5.75c)$$

Aus (5.75c) folgt die optimale Steuerung

$$\mathbf{u}^*(t) = -\mathbf{R}^{-1} \mathbf{B}^T \boldsymbol{\lambda}^*(t), \quad (5.76)$$

womit sich die Differenzialgleichungen (5.75a), (5.75b) wie folgt schreiben lassen

$$\begin{bmatrix} \dot{\mathbf{x}}^* \\ \dot{\boldsymbol{\lambda}}^* \end{bmatrix} = \begin{bmatrix} \mathbf{A} & -\mathbf{B}\mathbf{R}^{-1}\mathbf{B}^T \\ -\mathbf{Q} & -\mathbf{A}^T \end{bmatrix} \begin{bmatrix} \mathbf{x}^* \\ \boldsymbol{\lambda}^* \end{bmatrix}, \quad \begin{matrix} \mathbf{x}^*(t_0) = \mathbf{x}_0 \\ \boldsymbol{\lambda}^*(t_f) = \mathbf{S}\mathbf{x}^*(t_f) \end{matrix}. \quad (5.77)$$

Es handelt sich also um eine Zwei-Punkt-Randwertaufgabe, die nicht ohne Weiteres per Integration gelöst werden kann. Es kann allerdings mit Hilfe der zu (5.77) gehörenden Transitionsmatrix gezeigt werden, dass $\mathbf{x}^*(t)$ und $\boldsymbol{\lambda}^*(t)$ über eine zeitvariante Matrix $\mathbf{P}(t)$ mit der Endbedingung $\mathbf{P}(t_f) = \mathbf{S}$ verkoppelt sind, d.h.

$$\boldsymbol{\lambda}^*(t) = \mathbf{P}(t)\mathbf{x}^*(t), \quad t \in [t_0, t_f]. \quad (5.78)$$

Durch Differenzieren dieser Beziehung, $\dot{\boldsymbol{\lambda}}^* = \dot{\mathbf{P}}\mathbf{x}^* + \mathbf{P}\dot{\mathbf{x}}^*$, und Einsetzen in die Differenzialgleichungen (5.77) ergibt sich

$$\left[\dot{\mathbf{P}} + \mathbf{P}\mathbf{A} + \mathbf{A}^T\mathbf{P} - \mathbf{P}\mathbf{B}\mathbf{R}^{-1}\mathbf{B}^T\mathbf{P} + \mathbf{Q} \right] \mathbf{x}^*(t) = \mathbf{0}.$$

Damit diese Beziehung erfüllt ist, ist es nicht nur *hinreichend*, dass der Klammerinhalt verschwindet, sondern auch *notwendig*, da die Gleichung für *alle* möglichen Anfangswerte $\mathbf{x}_0$ und damit für alle möglichen optimalen Trajektorien $\mathbf{x}^*(t)$ gelten muss.

Somit erhält man für $\mathbf{P}(t)$ die sogenannte *Matrix-Riccati-Differenzialgleichung*

$$\dot{\mathbf{P}} = -\mathbf{P}\mathbf{A} - \mathbf{A}^T\mathbf{P} + \mathbf{P}\mathbf{B}\mathbf{R}^{-1}\mathbf{B}^T\mathbf{P} - \mathbf{Q}, \quad \mathbf{P}(t_f) = \mathbf{S}. \quad (5.79)$$

Charakteristisch ist, dass die Riccati-Gleichung *nichtlinear* ist, da $\mathbf{P}(t)$ im vorletzten Term quadratisch auftritt. Einsetzen von (5.78) in (5.76) ergibt dann

$$\mathbf{u}^*(t) = -\mathbf{R}^{-1}\mathbf{B}^T\mathbf{P}(t)\mathbf{x}^*(t). \quad (5.80)$$

Einige Anmerkungen zur Riccati-Differenzialgleichung sind im Folgenden zusammengetragen:

- Bei der Lösung von (5.79) geht man aufgrund der nicht vorhandenen Anfangsbedingung zweckmäßigerweise von $t = t_f$ aus und integriert *rückwärts* in der Zeit bis $t = t_0$.
- $\mathbf{P}(t)$ ist positiv semi-definit und symmetrisch. Somit ist die Riccati-Dgl. der Ordnung n^2 aufgrund der Symmetrie nur $n(n+1)/2$ (untereinander verkoppelten) Differenzialgleichungen äquivalent.
- Im Falle von zeitvarianten Systemmatrizen $\mathbf{A}(t)$, $\mathbf{B}(t)$ und/oder Gewichtungsmatrizen $\mathbf{Q}(t)$, $\mathbf{R}(t)$ ändert sich nichts an der Herleitung.

Durch Bestimmung von $\mathbf{P}(t)$ können die optimalen Trajektorien $\mathbf{x}^*(t)$ und $\boldsymbol{\lambda}^*(t)$ aus (5.77) und (5.78) durch Vorwärtsintegration mit der Anfangsbedingung $\boldsymbol{\lambda}^*(t_0) = \mathbf{P}(t_0)\mathbf{x}^*(t_0)$ gewonnen werden. Anschließend ergibt sich die optimale Steuerung $\mathbf{u}^*(t)$ aus (5.76). Von besonderem Interesse ist die Riccati-Dgl. aber vor allem im Rahmen der *optimalen Regelung*, da $\mathbf{P}(t)$ direkt im optimalen Regelgesetz

$$\mathbf{u}(t) = -\mathbf{K}(t)\mathbf{x}(t) \quad \text{mit} \quad \mathbf{K}(t) = \mathbf{R}^{-1}\mathbf{B}^T\mathbf{P}(t) \quad (5.81)$$

und den rückgeführten Zuständen $\mathbf{x}(t)$ verwendet werden kann. Die Matrix $\mathbf{K}(t)$ stellt dabei die zeitvariante *Rückführmatrix* dar.

5.4.2 Beispiel: Zwei-Freiheitsgrade-Regelung zum Aufschwingen des Einfachpendels

Ein Anwendungsgebiet für die Riccati-Differenzialgleichung ist die sogenannte *Zwei-Freiheitsgrade-Regelungsstruktur* (2FHG), die in der Praxis häufig zum Entwurf von Folgeregelungen

eingesetzt wird, siehe Abbildung 5.10. Die Idee der 2FHG-Struktur ist die Entkopplung von Führungs- und Störungsverhalten, indem eine Steuertrajektorie $\mathbf{u}_S(t)$ auf das System geschaltet wird, die das System im nominellen Fall exakt auf einer gewünschten Zustandstrajektorie $\mathbf{x}_S(t)$ führt. Die Regelung stabilisiert das System entlang von $\mathbf{x}_S(t)$ und ist für die Ausregelung von Modellfehlern und Störungen zuständig.




Abbildung 5.10: Regelungsstruktur mit zwei Freiheitsgraden.

Beim 2FHG-Entwurf kann das betrachtete System $\dot{\mathbf{x}} = \mathbf{f}(\mathbf{x}, \mathbf{u})$ um die Referenztrajektorie linearisiert werden, was zu einem linearen zeitvarianten System

$$\Delta \dot{\mathbf{x}} = \mathbf{A}(t)\Delta \mathbf{x} + \mathbf{B}(t)\Delta \mathbf{u} \quad \text{mit} \quad \mathbf{A}(t) = \left. \frac{\partial \mathbf{f}}{\partial \mathbf{x}} \right|_{\mathbf{x}_S(t), \mathbf{u}_S(t)}, \quad \mathbf{B}(t) = \left. \frac{\partial \mathbf{f}}{\partial \mathbf{u}} \right|_{\mathbf{x}_S(t), \mathbf{u}_S(t)} \quad (5.82)$$

mit $\Delta \mathbf{x} = \mathbf{x} - \mathbf{x}_S$ und $\Delta \mathbf{u} = \mathbf{u} - \mathbf{u}_S$ führt, das für den Reglerentwurf herangezogen werden kann. Die Riccati-Differenzialgleichung kann an dieser Stelle verwendet werden, um ein optimales Rückführgesetz der Form (5.81) zu berechnen.

Im Folgenden soll dieses Vorgehen und die Lösung der Riccati-Dgl. (5.79) am Beispiel des in Abbildung 5.11 dargestellten Einfachpendels demonstriert werden. Ein einfaches nichtlineares Modell für die Wagenposition y und den Pendelwinkel ϕ ist ⁴

$$\ddot{y} = u, \quad \ddot{\phi} = \frac{3}{2l} [g \sin(\phi) - \cos(\phi)u] \quad (5.83)$$

mit der Erdbeschleunigung g und der Pendellänge l . Als Eingang u dient die Beschleunigung des Wagens $\ddot{y}$.

Die betrachtete Folgeregelungsaufgabe ist das Aufschwingen des Pendels aus der unteren in die obere (invertierte) Ruhelage, d.h.

$$\left. \begin{array}{l} y(0) = 0, \quad \dot{y}(0) = 0 \\ \phi(0) = -\pi, \quad \dot{\phi}(0) = 0 \end{array} \right\} \Rightarrow \left\{ \begin{array}{l} y(t_f) = 0, \quad \dot{y}(t_f) = 0 \\ \phi(t_f) = 0, \quad \dot{\phi}(t_f) = 0. \end{array} \right. \quad (5.84)$$

Eine mögliche Steuertrajektorie zum Aufschwingen eines Pendels mit der Länge $l = 1$ m in der Zeit $t_f = 2$ s ist

$$u_S(t) = \sum_{i=1}^5 c_i t^i, \quad t \in [0, t_f = 2 \text{ s}] \quad (5.85)$$

⁴ Dieses Modell kann über den Lagrange-Formalismus unter Vernachlässigung von Reibung hergeleitet werden, wobei für das Pendel das Trägheitsmoment eines Stabes $J = \frac{1}{12}ml^2$ mit der Pendelmasse m angesetzt wurde. Da sich m aus den Gleichungen kürzt, ist die Pendeldynamik (5.83) unabhängig von der Masse des Pendels.




Abbildung 5.11: Aufbau des Pendels.




Abbildung 5.12: Momentaufnahmen des Aufschwingens.

mit dem Koeffizientenvektor $\mathbf{c} = [-135.128, 625.696, -888.598, 497.538, -96.3861]^T$ (ohne Einheiten). Diese Steuerung wurde mit Hilfe der in [8] entwickelten Methodik numerisch berechnet, auf die an dieser Stelle aber nicht näher eingegangen werden soll. Abbildung 5.12 veranschaulicht die Aufschwingbewegung des Pendels. Die zugehörigen Zustandstrajektorien $\mathbf{x}_s(t)$ mit

$$\mathbf{x} = [y, \dot{y}, \phi, \dot{\phi}]^T$$

können durch Integration der Bewegungsgleichungen (5.83) bestimmt werden und sind in Abbildung 5.13 dargestellt (rote Kurven).

Um zusätzlich zu der Steuerung (5.85) eine optimale Regelung zu entwerfen, wird das nichtlineare Modell (5.83) um die Solltrajektorien $\mathbf{x}_s(t)$ und $\mathbf{u}_s(t)$ linearisiert, was zu dem linearen zeitvarianten Modell (5.82)

$$\Delta \dot{\mathbf{x}} = \underbrace{\begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & \frac{3}{2l}[g \cos \phi_s(t) + \sin \phi_s(t)u_s(t)] & 0 \end{bmatrix}}_{=\mathbf{A}(t)} \Delta \mathbf{x} + \underbrace{\begin{bmatrix} 0 \\ 1 \\ 0 \\ -\frac{3}{2l} \cos \phi_s(t) \end{bmatrix}}_{=\mathbf{b}(t)} \Delta u \quad (5.86)$$

mit $\mathbf{x}(t) = \mathbf{x}_s + \Delta \mathbf{x}(t)$ und $u(t) = u_s(t) + \Delta u(t)$ führt. Zur Auslegung des Riccati-Reglers wird das zu minimierende Kostenfunktional (5.74a)

$$J(\Delta u) = \frac{1}{2} \Delta \mathbf{x}(t_f)^T \mathbf{S} \Delta \mathbf{x}(t_f)^T + \frac{1}{2} \int_0^{t_f} \Delta \mathbf{x}(t)^T \mathbf{Q} \Delta \mathbf{x}(t) + R \Delta u(t)^2 dt, \quad t_f = 2s \quad (5.87)$$

mit den Diagonalmatrizen $\mathbf{S} = \mathbf{Q} = \text{diag}(1, 1, 1, 1)$ und $R = 0.01$ angesetzt. Der Eingang wird also im Vergleich zu den Zuständen eher gering bestraft, was einer schnellen Reglerauslegung entspricht.

Die Lösung der Riccati-Dgl. (5.79) muss numerisch erfolgen, um die Matrix $\mathbf{P}(t)$ auf dem Zeitintervall $t \in [0, t_f]$ zu erhalten. Das optimale Rückführgesetz für das Aufschwingen des Pendels ergibt sich nach (5.81) zu

$$\Delta u(t) = -\mathbf{k}(t)^T \Delta \mathbf{x}(t) = \frac{1}{R} \mathbf{b}(t)^T \mathbf{P}(t) [\mathbf{x}_s(t) - \mathbf{x}(t)]. \quad (5.88)$$

Dabei wird der Einfachheit halber angenommen, dass der komplette Zustand $\mathbf{x} = [y, \dot{y}, \phi, \dot{\phi}]^T$ als Messinformation zur Verfügung steht. Wie aus Abbildung 5.10 ersichtlich ist, ergibt sich

die gesamte Stellgröße u als Kombination von Steuerung und Regelung

$$u(t) = u_S(t) + \Delta u(t). \quad (5.89)$$

Die simulierten Trajektorien für das Aufschwingen in Abbildung 5.13 stellen den offenen Kreis (Simulation mit reiner Steuerung) und den geschlossenen Kreis (Steuerung und Regelung) dar. Gut erkennbar ist, dass das Pendel bei reiner Steuerung umfällt, während es im geschlossenen Kreis trotz der Anfangsstörung auf die Solltrajektorie $x_S(t)$ gezwungen wird, was zu einer Korrektur der Steuerung $u_S(t)$ durch das Regelgesetz (5.88) führt.

Interessant ist ebenfalls, dass die Reglerverstärkungen $k(t)$ in Abbildung 5.13 das Vorzeichen wechseln, was dadurch zu erklären ist, dass das Pendel von der stabilen unteren Ruhelage in die instabile obere Ruhelage überführt wird. Die Vorzeichenumkehr ist dabei ein Indikator dafür, dass das lineare zeitvariable System während dem Aufschwingen punktuell die Steuerbarkeit verliert. Bei der experimentellen Realisierung müsste deswegen überlegt werden, die Regelung in kritischen Zeitbereichen auszublenden und mit der Steuerung $u_S(t)$ zu durchfahren.

Abbildung 5.14 zeigt den MATLAB-Code zur Lösung der Riccati-Dgl. (5.79), zur Berechnung des Rückführgesetzes (5.88) und zur Simulation des Aufschwingens mit einer Störung in den Anfangsbedingungen (5.84). Der Einfachheit halber wird die Riccati-Dgl. (5.79) für alle Elemente der Matrix $P(t)$ numerisch integriert, obwohl diese (wie bereits erwähnt wurde) symmetrisch ist.




Abbildung 5.13: Simulationsergebnisse für das Aufschwingen des Einfachpendels.

```

function vec = pendulum
% -----
g = 9.81; l = 1;                                     % parameters
p.a1 = 3*g/(2*l); p.a2 = 3/(2*l); p.n=4; p.steps = 200;

p.tf = 2;                                             % reference trajectories
vec.t = linspace(0,p.tf,p.steps);                    % -----
c = [-135.128, 625.696, -888.598, 497.538, -96.3861]; % feedforward trajectory
vec.uref = c(1)*vec.t+c(2)*vec.t.^2+c(3)*vec.t.^3+c(4)*vec.t.^4+c(5)*vec.t.^5;
[tsim,xsim] = ode45(@pendulum_sim,vec.t,[0;0;-pi;0],[],vec,p, 0); % num. int. for state traj.
vec.xref = xsim';

p.Q = diag([1,1,1,1]); p.R = 0.01; p.S = diag([1,1,1,1]); % weighting matrices
S = reshape(p.S,p.n^2,1); % matrix -> vector
[tsim,Psim] = ode45(@riccati_ode,vec.t(end:-1:1),S,[],vec,p); % Riccati: backward integration
vec.P = Psim(end:-1:1,:)''; % -----

for i=1:length(vec.t), % time-varying feedback gain
    [A,B] = matrices(vec.t(i),vec,p); % -----
    P = reshape(vec.P(:,i),p.n,p.n);
    vec.k(:,i) = inv(p.R)*B'*P;
end

% simulation with initial error
X0 = [0;0;-pi+10*pi/180;2]; % -----
[tsim,x_ol] = ode45(@pendulum_sim,vec.t,X0,[],vec,p, 0); % open-loop
[tsim,x_cl] = ode45(@pendulum_sim,vec.t,X0,[],vec,p, 1); % closed-loop
vec.x_ol = x_ol'; vec.x_cl = x_cl';

for i=1:p.steps, % computation of feedback part
    vec.du(i) = vec.k(:,i)'*(vec.xref(:,i)-vec.x_cl(:,i));
end

function F = pendulum_sim(t,x,vec,p,control)
% -----
y=x(1:2); phi=x(3:4);
uref = interp1(vec.t,vec.uref,t); % feedforward control
if control==0, % simulation open-loop
    u = uref;
else % simulation closed-loop
    xref = interp1(vec.t,vec.xref',t)';
    k = interp1(vec.t,vec.k',t);
    u = uref + k*(xref-x);
end
F = [ y(2); u; phi(2); p.a1*sin(phi(1))-p.a2*cos(phi(1))*u ]; % nonlin. pendulum model

function Pp = riccati_ode(t,Pvec,vec,p)
% -----
[A,B] = matrices(t,vec,p); % time-varying matrices A and B
P = reshape(Pvec,p.n,p.n); % vector -> matrix
Pp = -P*A - A'*P + P*B*inv(p.R)*B'*P - p.Q; % Riccati diff. eqn.
Pp = reshape(Pp,p.n^2,1); % matrix -> vector

function [A,B] = matrices(t,vec,p)
% -----
phiref = interp1(vec.t,vec.xref(3:4,:),'',t)'; % current reference values
uref = interp1(vec.t,vec.uref,t);
A = [0,1,0,0; 0,0,0,0; 0,0,0,1; % time-varying matrices A and B
      0,0,p.a1*cos(phiref(1))+p.a2*sin(phiref(1))*uref,0];
B = [0; 1; 0; -p.a2*cos(phiref(1))];

```

Abbildung 5.14: MATLAB-Code zur Berechnung der optimalen Rückführung (5.88) und zur Simulation des Aufschwingens des Pendels.

5.4.3 Algebraische Riccati-Gleichung (Sonderfall $t_f \rightarrow \infty$)

Die Berechnung der optimalen Rückführung (5.81) wird besonders einfach, wenn ein unendliches Zeitintervall $[t_0, \infty)$ betrachtet wird. In diesem Fall macht die Endgewichtung $\mathbf{x}(t_f)^T \mathbf{S} \mathbf{x}(t_f)$ keinen Sinn, da ohnehin $\lim_{t \rightarrow \infty} \mathbf{x}(t) = \mathbf{0}$ gelten muss, damit das Integral im Kostenfunktional (5.74a) existiert. Es wird also im Folgenden

$$\mathbf{S} = \mathbf{0}$$

gesetzt. Des Weiteren wird angenommen, dass

- die Matrizen $\mathbf{A}$, $\mathbf{B}$, $\mathbf{Q}$ und $\mathbf{R}$ in (5.74) zeitinvariant sind,
- $\mathbf{Q}$ positiv semi-definit und $\mathbf{R}$ positiv definit ist,
- das System (5.74b) vollständig steuerbar ist,
- das Paar $[\mathbf{A}, \mathbf{C}]$ beobachtbar ist, wobei die Matrix $\mathbf{C}$ aus der Zerlegung $\mathbf{C}^T \mathbf{C} = \mathbf{Q}$ (z.B. mittels der Cholesky-Zerlegung) resultiert.⁵

Unter diesen Annahmen kann gezeigt werden, dass die Lösung der Riccati-Dgl. (5.79) in Rückwärtszeit gegen eine stationäre positiv definite Matrix $\bar{\mathbf{P}}$ konvergiert, siehe z.B. [11, 12]. Dabei ist $\bar{\mathbf{P}}$ unabhängig von dem Randwert $\mathbf{P}(t_f)$ bei dem die Rückwärtsintegration gestartet wird, solange $\mathbf{P}(t_f)$ positiv semi-definit ist. Somit kann zur näherungsweisen Bestimmung von $\bar{\mathbf{P}}$ die Riccati-Dgl. (5.79) ausgehend von einem beliebigen positiv semi-definiten Endpunkt $\mathbf{P}(t_f)$, z.B. $\mathbf{P}(t_f) = \mathbf{0}$, rückwärts integriert werden, bis die zeitliche Änderung $\dot{\mathbf{P}}(t)$ unterhalb eines Toleranzkriteriums liegt.

Eine elegantere Möglichkeit zur Bestimmung von $\bar{\mathbf{P}}$ ist die Lösung der sogenannten *algebraischen Riccati-Gleichung*

$$\bar{\mathbf{P}}\mathbf{A} + \mathbf{A}^T \bar{\mathbf{P}} - \bar{\mathbf{P}}\mathbf{B}\mathbf{R}^{-1}\mathbf{B}^T \bar{\mathbf{P}} + \mathbf{Q} = \mathbf{0}, \quad (5.90)$$

die sich direkt aus (5.79) mit $\dot{\mathbf{P}}(t) = \mathbf{0}$ ergibt. Da die Gleichung nichtlinear ist, können mehrere Lösungen existieren. Es kann aber unter den obigen Annahmen gezeigt werden, dass nur *eine positiv definite* Lösung $\bar{\mathbf{P}}$ existiert. Zur Berechnung von $\bar{\mathbf{P}}$ aus der algebraischen Riccati-Gleichung (5.90) können verschiedene Verfahren verwendet werden (z.B. das Verfahren nach Kalman und Englar), auf die an dieser Stelle nicht eingegangen werden soll.

Mit Hilfe des Optimalitätsprinzips in Satz 5.4 kann gezeigt werden, dass das nun zeitinvariante Rückführgesetz (5.81)

$$\mathbf{u}(t) = -\bar{\mathbf{K}}\mathbf{x}(t) \quad \text{mit} \quad \bar{\mathbf{K}} = \mathbf{R}^{-1}\mathbf{B}^T \bar{\mathbf{P}}$$

tatsächlich die optimale Lösung des Problems (5.74) auf dem unendlichen Intervall $[t_0, \infty)$ liefert. Die Ergebnisse sind im folgenden Satz zusammengefasst.

Satz 5.5 (LQ-Regler für lineare zeitinvariante Systeme) Gegeben sei das steuerbare lineare zeitinvariante System

$$\dot{\mathbf{x}} = \mathbf{A}\mathbf{x} + \mathbf{B}\mathbf{u}, \quad \mathbf{x}(t_0) = \mathbf{x}_0$$

⁵ Eine anschauliche Erklärung der letzten beiden Annahmen kann in [12] nachgelesen werden.

mit dem zu minimierenden Kostenfunktional

$$J(\mathbf{u}) = \frac{1}{2} \int_{t_0}^{\infty} \mathbf{x}(t)^{\top} \mathbf{Q} \mathbf{x}(t) + \mathbf{u}(t)^{\top} \mathbf{R} \mathbf{u}(t) dt, \quad (5.91)$$

wobei $\mathbf{Q}$ positiv semi-definit und $\mathbf{R}$ positiv definit sind und das Paar $[\mathbf{A}, \mathbf{C}]$ mit $\mathbf{Q} = \mathbf{C}^{\top} \mathbf{C}$ beobachtbar ist. Dann ergibt sich das Minimum von (5.91) durch das optimale Rückführgesetz

$$\mathbf{u}(t) = -\bar{\mathbf{K}} \mathbf{x}(t) \quad \text{mit} \quad \bar{\mathbf{K}} = \mathbf{R}^{-1} \mathbf{B}^{\top} \bar{\mathbf{P}}, \quad (5.92)$$

wobei $\bar{\mathbf{P}}$ die eindeutige positiv definite Lösung der algebraischen Riccati-Gleichung (5.90) ist. Des Weiteren besitzen sämtliche Eigenwerte der Matrix $(\mathbf{A} - \mathbf{B} \mathbf{R}^{-1} \mathbf{B}^{\top} \bar{\mathbf{P}})$ negative Realteile, so dass der geschlossene Kreis

$$\dot{\mathbf{x}} = [\mathbf{A} - \mathbf{B} \mathbf{R}^{-1} \mathbf{B}^{\top} \bar{\mathbf{P}}] \mathbf{x}, \quad \mathbf{x}(t_0) = \mathbf{x}_0$$

asymptotisch stabil ist.

Der optimale Zustandsregler (5.92) wird häufig auch als *Riccati-Regler* oder *LQ-Regler* ("linear-quadratischer Regler") bezeichnet und wird in der Praxis häufig eingesetzt. Im Gegensatz zum Polvorgabe-Verfahren können die Eigenwerte des geschlossenen Kreises nicht direkt vorgegeben werden. Dafür besitzen die Einträge in den Gewichtungsmatrizen $\mathbf{Q}$ und $\mathbf{R}$ (zumindest in der Diagonalen) eine anschauliche Bedeutung für das Verhalten des geschlossenen Kreises. Unter MATLAB kann die optimale Rückführmatrix $\mathbf{K} = \mathbf{R}^{-1} \mathbf{B}^{\top} \bar{\mathbf{P}}$ mit Hilfe der Befehle `lqr` bzw. `lqrd` oder `dlqr` berechnet werden.

5.5 Optimalsteuerungsprobleme mit Eingangsbeschränkungen

Bei den bisherigen Betrachtungen mittels der Variationsrechnung wurde vorausgesetzt, dass das Optimalsteuerungsproblem (5.37) unbeschränkt ist. Im Folgenden sollen Beschränkungen der Steuergrößen

$$\mathbf{u}(t) \in U \subseteq \mathbb{R}^m \quad \forall t \in [t_0, t_f] \quad (5.93)$$

betrachtet werden, wobei U eine Untermenge des $\mathbb{R}^m$ darstellt und zu jedem Zeitpunkt t eingehalten werden soll. Eingangsbeschränkungen kommen in der Praxis am häufigsten vor und lassen sich mittels *Pontryagin's Maximumprinzip* berücksichtigen. Zustandsbeschränkungen sind im Rahmen der dynamischen Optimierung wesentlich schwieriger zu handhaben und sollen an dieser Stelle nicht weiter vertieft werden.

5.5.1 Pontryagin's Maximumprinzip

Das Maximumprinzip wurde 1956 von *L.S. Pontryagin* als Hypothese formuliert und in den folgenden Jahren von ihm und seinen Mitarbeitern *Boltjanski*, *Gamkrelidse* und *Mischenko* für zunehmend allgemeinere Systemklassen bewiesen.⁶




Abbildung 5.15: Randminima im beschränkten Fall $u \in U = [u^-, u^+]$.

Pontryagin's Maximumprinzip stützt sich auf die Hamilton-Funktion und die kanonischen Gleichungen (5.46). Allerdings verliert die Bedingung $H_u = 0$ ihre Gültigkeit als notwendige Optimalitätsbedingung. Dieser Umstand ist in Abbildung 5.15 illustriert, wo für den Fall einer skalaren Eingangsgröße u die Hamilton-Funktion $H(\mathbf{x}^*, u, \boldsymbol{\lambda}^*, t)$ für feste (optimale) $\mathbf{x}^*(t)$, $\boldsymbol{\lambda}^*(t)$ zu einer festen Zeit t über u aufgetragen ist. Im unbeschränkten Fall a) stellen (5.46c) und (5.49), also $H_u = 0$ und H_{uu} positiv semi-definit, notwendige Bedingungen für ein *Minimum* der Hamilton-Funktion H zu jedem Zeitpunkt t dar. Falls u dagegen auf einem Intervall $U = [u^-, u^+]$ beschränkt ist, kann das Minimum auf dem Rand u^- oder u^+ liegen, wo nicht notwendigerweise $H_u = 0$ gilt, wie die Fälle b) und c) in Abbildung 5.15 zeigen.

Es ist also naheliegend, dass das Verschwinden der partiellen Ableitung von H nach u durch

$$H(\mathbf{x}^*, \mathbf{u}^*, \boldsymbol{\lambda}^*, t) = \min_{u \in U} H(\mathbf{x}^*, u, \boldsymbol{\lambda}^*, t)$$

zu ersetzen ist. Diese Bedingung stellt die Basis von Pontryagin's Maximumprinzip dar, das im Folgenden für zeitinvariante Systeme (d.h. l und $\mathbf{f}$ in (5.94) hängen nicht explizit von der Zeit t ab) angegeben wird.

Satz 5.6 (Maximumprinzip für zeitinvariante Systeme) Gegeben sei das Optimalsteuerungsproblem

$$\min_{\mathbf{u}(\cdot)} J(\mathbf{u}) = \int_{t_0}^{t_f} l(\mathbf{x}(t), \mathbf{u}(t)) dt \quad (5.94a)$$

$$\text{u.B.v. } \dot{\mathbf{x}} = \mathbf{f}(\mathbf{x}, \mathbf{u}) \quad (5.94b)$$

$$\mathbf{x}(t_0) = \mathbf{x}_0, \quad \mathbf{x}(t_f) = \mathbf{x}_f \quad (5.94c)$$

$$\mathbf{u}(t) \in U, \quad \forall t \in [t_0, t_f] \quad (5.94d)$$

mit freier Endzeit t_f . Die Funktionen l und $\mathbf{f}$ seien stetig in $(\mathbf{x}, \mathbf{u})$ und stetig differenzierbar in $\mathbf{x}$. Falls das Problem (5.94) eine optimale Lösung $\mathbf{x}^*(t)$, $\mathbf{u}^*(t)$, $t \in [t_0, t_f]$ besitzt, dann

⁶ Das Maximumprinzip wurde ursprünglich für *Maximierungsprobleme* definiert, woher auch der Name stammt. Somit müsste es im hier betrachteten Fall korrekterweise *Minimumprinzip* heißen, wie es auch in der Literatur gelegentlich vorkommt. Angesichts seiner Bedeutung in der dynamischen Optimierung und der Verbindung mit dem Namen Pontryagin soll es im Folgenden weiterhin als *Maximumprinzip* bezeichnet werden.

existiert eine nicht-negative Konstante $\lambda_0 \geq 0$ und n nicht-verschwindende (stückweise stetig differenzierbare) Zeitfunktionen $\boldsymbol{\lambda}^* \in \mathcal{C}_n^1[t_0, t_f^*]$ mit $\boldsymbol{\lambda}^* = [\lambda_1^*, \dots, \lambda_n^*]^\top$, so dass Folgendes gilt:

a) $\mathbf{x}^*(t)$ und $\boldsymbol{\lambda}^*(t)$, $t \in [t_0, t_f^*]$ erfüllen die kanonischen Gleichungen

$$\dot{\mathbf{x}}^* = \mathbf{f}(\mathbf{x}^*, \mathbf{u}^*), \quad \dot{\boldsymbol{\lambda}}^* = -H_{\mathbf{x}}(\mathbf{x}^*, \mathbf{u}^*, \boldsymbol{\lambda}^*) \quad (5.95)$$

und die Randbedingungen (5.94c) mit der Hamilton-Funktion

$$H(\mathbf{x}, \mathbf{u}, \boldsymbol{\lambda}, \lambda_0) = \lambda_0 l(\mathbf{x}, \mathbf{u}) + \boldsymbol{\lambda}^\top \mathbf{f}(\mathbf{x}, \mathbf{u}). \quad (5.96)$$

b) $H(\mathbf{x}^*(t), \mathbf{u}, \boldsymbol{\lambda}^*(t), \lambda_0^*)$ als Funktion von $\mathbf{u}$ besitzt ein absolutes Minimum an der Stelle $\mathbf{u}(t) = \mathbf{u}^*(t) \in U$ für alle $t \in [t_0, t_f^*]$:

$$H(\mathbf{x}^*(t), \mathbf{u}^*, \boldsymbol{\lambda}^*(t), \lambda_0^*) = \min_{\mathbf{u} \in U} H(\mathbf{x}^*(t), \mathbf{u}, \boldsymbol{\lambda}^*(t), \lambda_0^*) \quad \forall t \in [t_0, t_f^*]. \quad (5.97)$$

c) $H(\mathbf{x}^*(t), \mathbf{u}^*(t), \boldsymbol{\lambda}^*(t), \lambda_0^*)$ ist konstant für alle $t \in [t_0, t_f^*]$. Bei einer freien Endzeit t_f^* gilt außerdem die Transversalitätsbedingung

$$H(\mathbf{x}^*(t_f^*), \mathbf{u}^*(t_f^*), \boldsymbol{\lambda}^*(t_f^*), \lambda_0^*) = 0. \quad (5.98)$$

Das Maximumprinzip kann auf Probleme mit partiellen oder allgemeinen Endbedingungen erweitert werden, indem die Randbedingungen für die kanonischen Gleichungen in (5.95) analog zum unbeschränkten Fall durch (5.47b), (5.47c) bzw. durch (5.70), (5.72) ersetzt werden.

Im zeitvarianten Fall, d.h. $l = l(\mathbf{x}, \mathbf{u}, t)$ und $\mathbf{f} = \mathbf{f}(\mathbf{x}, \mathbf{u}, t)$ ändert sich c) in Satz 5.6 dahingehend, dass H nicht mehr konstant ist, sondern die Differenzialgleichung (5.50) erfüllen muss, d.h.

$$\frac{d}{dt} H = \lambda_0^* l_t(\mathbf{x}^*(t), \mathbf{u}^*(t), t) + \boldsymbol{\lambda}^*(t)^\top \mathbf{f}_t(\mathbf{x}^*(t), \mathbf{u}^*(t), t) \quad \forall t \in [t_0, t_f^*]$$

mit $l_t = \frac{\partial l}{\partial t}$ und $\mathbf{f}_t = \frac{\partial \mathbf{f}}{\partial t}$. Der zusätzliche Parameter λ_0 in der Hamilton-Funktion (5.96) berücksichtigt sogenannte *abnormale* Fälle von Optimalsteuerungsproblemen, für die $\lambda_0^* = 0$ gilt. Dieser Fall liegt z.B. vor, wenn die optimale Lösung unabhängig von der integrierten Kostenfunktion l in (5.94a) ist. Abnormale Probleme sind *nicht sinnvoll gestellt*, da ihre Lösung den Wert des zu minimierenden Kostenfunktional nicht beeinflusst.

Für sinnvoll gestellte Probleme gilt $\lambda_0^* > 0$. Es ist dabei gebräuchlich, $\lambda_0^* = 1$ zu setzen, womit sich die gleiche Hamilton-Funktion wie im unbeschränkten Fall ergibt.

Beispiel 5.5 (Abnormaler Fall) Gegeben sei das Problem

$$\begin{aligned} \min_{u(\cdot)} \quad & \int_0^1 l(x, u) dt \\ \text{u.B.v.} \quad & \dot{x} = u, \quad x(0) = 0, \quad x(1) = 1 \\ & u(t) \in [0, 1]. \end{aligned}$$

Es existiert nur eine Steuerung $u^*(t) = 1$, die den Zustand $x^*(t) = t$ von $x^*(0) = 0$ nach $x^*(1) = 1$ überführt. Somit ist die optimale Lösung unabhängig von der Wahl der Kostenfunktion $I(x, u)$ und es liegt ein abnormaler Fall vor.

5.5.2 Allgemeine Vorgehensweise

Die Anwendung des Maximumprinzips orientiert sich zum großen Teil am Vorgehen im unbeschränkten Fall (Abschnitt 5.3.4).⁷

1. Aufstellen der Hamilton-Funktion mit $\lambda_0 = 1$: $H(\mathbf{x}, \mathbf{u}, \boldsymbol{\lambda}) = I(\mathbf{x}, \mathbf{u}) + \boldsymbol{\lambda}^\top \mathbf{f}(\mathbf{x}, \mathbf{u})$.
2. Lösung des Minimierungsproblems $\mathbf{u}^* = \arg \min_{\mathbf{u} \in U} H(\mathbf{x}, \mathbf{u}, \boldsymbol{\lambda})$ für jede mögliche Kombination $(\mathbf{x}, \boldsymbol{\lambda})$. Somit ergibt sich eine Funktion

$$\mathbf{u} = \boldsymbol{\psi}(\mathbf{x}, \boldsymbol{\lambda}) \quad (5.99)$$

in Abhängigkeit von $(\mathbf{x}, \boldsymbol{\lambda})$. Das Aufstellen dieser Funktion zur punktweisen Minimierung von H wird im Abschnitt 5.5.3 näher erläutert.

3. Einsetzen der Funktion (5.99) in die kanonischen Gleichungen (5.95) führt auf das Randwertproblem

$$\dot{\mathbf{x}} = \mathbf{f}(\mathbf{x}, \boldsymbol{\psi}(\mathbf{x}, \boldsymbol{\lambda})), \quad \dot{\boldsymbol{\lambda}} = -H_{\mathbf{x}}(\mathbf{x}, \boldsymbol{\psi}(\mathbf{x}, \boldsymbol{\lambda}), \boldsymbol{\lambda}), \quad \text{RBen} \quad (5.94c).$$

Im Falle von partiellen oder nichtlinearen Randbedingungen werden $\mathbf{x}(t_0) = \mathbf{x}_0$ und $\mathbf{x}(t_f) = \mathbf{x}_f$ in (5.94c) entsprechend durch (5.47b), (5.47c) bzw. (5.70), (5.72) ersetzt. Falls die Endzeit frei ist, kommt noch die Endbedingung (5.98) hinzu.

4. Die (numerische) Lösung des Randwertproblems liefert $\mathbf{x}^*(t)$, $\boldsymbol{\lambda}^*(t)$, womit sich die Steuertrajektorie $\mathbf{u}^*(t)$ aus (5.99) ergibt.

Analog zum unbeschränkten Fall in Abschnitt 5.3.4 sei erwähnt, dass das Maximumprinzip lediglich notwendige Bedingungen für eine optimale Lösung darstellt. Für bestimmte Aufgabenklassen kann das Maximumprinzip als hinreichend betrachtet werden, z.B. für die zeitoptimale Steuerung von zeitinvarianten linearen Systemen.

5.5.3 Minimierung der Hamilton-Funktion

Die Lösung des Minimierungsproblems (5.97) wird im Folgenden für einige praktisch relevante Fälle angegeben. Dabei wird davon ausgegangen, dass das bisher allgemein nichtlineare System (5.94b) in eingangsaffiner Form

$$\dot{\mathbf{x}} = \mathbf{f}(\mathbf{x}, \mathbf{u}) = \mathbf{f}_0(\mathbf{x}) + \sum_{i=1}^m \mathbf{f}_i(\mathbf{x}) u_i \quad (5.100)$$

vorliegt. Des Weiteren wird der gebräuchliche Fall betrachtet, dass alle Komponenten u_i des Eingangs $\mathbf{u} = [u_1, \dots, u_m]^\top$ beidseitig beschränkt sind, d.h.

$$\mathbf{u} \in U = [\mathbf{u}^-, \mathbf{u}^+] \quad \text{bzw.} \quad u_i \in [u_i^-, u_i^+], \quad i = 1, \dots, m. \quad (5.101)$$

⁷ In Analogie zu Satz 5.6 wird der zeitinvariante Fall betrachtet, was aber keine Einschränkung darstellt.




Abbildung 5.16: Veranschaulichung von (5.103) im verbrauchsoptimalen Fall.

Kostenfunktional mit verbrauchsoptimalem Anteil

Falls Verbrauchsoptimalität gewünscht wird, kann das Kostenfunktional in (5.94a) in der Form

$$J(\mathbf{u}) = \int_{t_0}^{t_f} l_0(\mathbf{x}) + \sum_{i=1}^m r_i |u_i| dt, \quad r_i > 0 \quad (5.102)$$

angesetzt werden. Mit $l_0(\mathbf{x}) = 0$ stellt die Minimierung der *Stellfläche* bzw. des *Verbrauchs* $\sum_{i=1}^m r_i |u_i|$ das Optimierungsziel dar. Für $l_0(\mathbf{x}) \neq 0$ kann der verbrauchsoptimale Anteil über die Koeffizienten $r_i > 0$ gewichtet werden.

Die Hamilton-Funktion lautet

$$H(\mathbf{x}, \mathbf{u}, \boldsymbol{\lambda}) = l_0(\mathbf{x}) + \sum_{i=1}^m r_i |u_i| + \boldsymbol{\lambda}^T \left(\mathbf{f}_0(\mathbf{x}) + \sum_{i=1}^m \mathbf{f}_i(\mathbf{x}) u_i \right)$$

Da der Anteil $l_0(\mathbf{x}) + \boldsymbol{\lambda}^T \mathbf{f}_0(\mathbf{x})$ unabhängig von $\mathbf{u}$ ist, kann er im Minimierungsproblem $\min_{\mathbf{u} \in U} H$ vernachlässigt werden.⁸ Zudem treten die Elemente u_i des Eingangs $\mathbf{u} = [u_1, \dots, u_m]^T$ linear in H auf, so dass die Minimierung von H für u_i separat betrachtet werden kann

$$\min_{u_i \in [u_i^-, u_i^+]} H_i(u_i) = r_i |u_i| + q_i(\mathbf{x}, \boldsymbol{\lambda}) u_i \quad \text{mit} \quad q_i(\mathbf{x}, \boldsymbol{\lambda}) = \boldsymbol{\lambda}^T \mathbf{f}_i(\mathbf{x}). \quad (5.103)$$

Der Vorfaktor $q_i(\mathbf{x}, \boldsymbol{\lambda})$ spielt die maßgebliche Rolle in diesem Problem. Abbildung 5.16 illustriert die unterschiedlichen Fälle a)-d), mit denen die optimale Steuerfunktion (5.99) komponentenweise durch die Fallunterscheidung

$$u_i = \psi_i(\mathbf{x}, \boldsymbol{\lambda}) = \begin{cases} u_i^- & \text{falls } q_i(\mathbf{x}, \boldsymbol{\lambda}) \geq r_i \\ 0 & \text{falls } q_i(\mathbf{x}, \boldsymbol{\lambda}) \in (-r_i, r_i), \\ u_i^+ & \text{falls } q_i(\mathbf{x}, \boldsymbol{\lambda}) \leq -r_i \end{cases} \quad i = 1, \dots, m \quad (5.104)$$

⁸ Es sei an dieser Stelle noch einmal betont, dass die Minimierung von $H(\mathbf{x}, \mathbf{u}, \boldsymbol{\lambda})$ als Funktion von $\mathbf{u}$ für feste Größen $\mathbf{x}, \boldsymbol{\lambda}$ (genauer: für die *optimalen* $\mathbf{x}^*(t), \boldsymbol{\lambda}^*(t)$ zu jedem Zeitpunkt t) zu verstehen ist, wie es im Maximumprinzip (Satz 5.6) formuliert ist.

bestimmt ist. Die Steuerung ist also *stückweise stetig*. An den Schaltpunkten $q_i(\mathbf{x}, \boldsymbol{\lambda}) = \pm r_i$ ist u_i nicht eindeutig definiert, was allerdings in der Praxis unproblematisch ist, da die Umschaltungen zu diskreten Zeitpunkten auftreten.

Kostenfunktional mit energieoptimalem Anteil

Falls Energieoptimalität berücksichtigt werden soll, lautet das Kostenfunktional (5.94a)

$$J(\mathbf{u}) = \int_{t_0}^{t_f} l_0(\mathbf{x}) + \frac{1}{2} \sum_{i=1}^m r_i u_i^2 dt, \quad r_i > 0. \quad (5.105)$$

Analog zum vorherigen Fall kann die Minimierung der Hamilton-Funktion elementweise betrachtet werden

$$\min_{u_i \in [u_i^-, u_i^+]} H_i(u_i) = \frac{1}{2} r_i u_i^2 + q_i(\mathbf{x}, \boldsymbol{\lambda}) u_i \quad \text{mit} \quad q_i(\mathbf{x}, \boldsymbol{\lambda}) = \boldsymbol{\lambda}^\top \mathbf{f}_i(\mathbf{x}). \quad (5.106)$$

Durch den quadratischen Term mit $r_i > 0$ hat die Funktion $H_i(u_i)$ stets ein unbeschränktes Minimum an der Stelle

$$u_i^0 = -\frac{1}{r_i} q_i(\mathbf{x}, \boldsymbol{\lambda}).$$

Dies folgt aus der Forderung $\frac{dH_i}{du_i} = r_i u_i + q_i(\mathbf{x}, \boldsymbol{\lambda}) = 0$. Falls u_i^0 innerhalb des zulässigen Intervalls $[u_i^-, u_i^+]$ liegt, ist die optimale Lösung von (5.106) durch $u_i^* = u_i^0$ gegeben. Falls u_i^0 außerhalb von $[u_i^-, u_i^+]$ liegt, so befindet sich das Minimum von $H_i(u_i)$ stets auf der entsprechenden Beschränkung u_i^- oder u_i^+ , da $H_i(u_i)$, $u_i \in [u_i^-, u_i^+]$ für $u_i^0 < u_i^-$ (bzw. $u_i^0 > u_i^+$) streng monoton steigend (fallend) ist, siehe Abbildung 5.17. Somit ist die optimale Steuerfunktion (5.99) wie folgt definiert

$$u_i = \psi_i(\mathbf{x}, \boldsymbol{\lambda}) = \begin{cases} u_i^- & \text{falls } u_i^0 \leq u_i^- \\ u_i^0 & \text{falls } u_i^0 \in (u_i^-, u_i^+) \\ u_i^+ & \text{falls } u_i^0 \geq u_i^+ \end{cases}, \quad i = 1, \dots, m. \quad (5.107)$$




Abbildung 5.17: Veranschaulichung von (5.106) im energieoptimalen Fall.

Zeitoptimales Kostenfunktional

Für zeitoptimale Probleme ist das Kostenfunktional (5.94a) durch

$$J(\mathbf{u}) = \int_{t_0}^{t_f} 1 dt = t_f - t_0 \quad (5.108)$$

definiert. Mit der Hamilton-Funktion

$$H(\mathbf{x}, \mathbf{u}, \boldsymbol{\lambda}) = 1 + \boldsymbol{\lambda}^\top \left(\mathbf{f}_0(\mathbf{x}) + \sum_{i=1}^m \mathbf{f}_i(\mathbf{x}) u_i \right)$$

kann das Minimierungsproblem (5.97) wieder komponentenweise betrachtet werden

$$\min_{u_i \in [u_i^-, u_i^+]} H_i(u_i) = q_i(\mathbf{x}, \boldsymbol{\lambda}) u_i \quad \text{mit} \quad q_i(\mathbf{x}, \boldsymbol{\lambda}) = \boldsymbol{\lambda}^\top \mathbf{f}_i(\mathbf{x}). \quad (5.109)$$

In Abhängigkeit des Vorzeichens von $q_i(\mathbf{x}, \boldsymbol{\lambda})$ ergibt sich also

$$u_i = \psi_i(\mathbf{x}, \boldsymbol{\lambda}) = \begin{cases} u_i^- & \text{falls } q_i(\mathbf{x}, \boldsymbol{\lambda}) > 0 \\ u_i^+ & \text{falls } q_i(\mathbf{x}, \boldsymbol{\lambda}) < 0 \end{cases}, \quad i = 1, \dots, m. \quad (5.110)$$

Ein kritischer Fall liegt vor, falls $q_i(\mathbf{x}(t), \boldsymbol{\lambda}(t)) = 0$ auf einem nicht verschwindenden Subintervall $I_s \in [t_0, t_f]$ gilt. Die Hamilton-Funktion H ist somit *unabhängig von* u_i , so dass H für jeden beliebigen Wert von u_i trivialerweise minimal ist. Die Minimumsforderung (5.97) ist damit zwar erfüllt, liefert aber keine Informationen über die Wahl von u_i . Dieser *singuläre Fall* wurde bereits in Abschnitt 5.3.4 diskutiert.

In der Praxis wird der singuläre Fall oft durch einen zusätzlichen *Regularisierungsterm*

$$J(\mathbf{u}) = \int_{t_0}^{t_f} 1 + \frac{1}{2} \sum_{i=1}^m r_i u_i^2 dt$$

vermieden, wobei $r_i > 0$ hinreichend klein gewählt wird, um annähernd Zeitoptimalität zu erzielen (siehe auch Beispiel 1.3). Durch den Regularisierungsterm entspricht das Kostenfunktional dem Fall (5.105), so dass $u_i = \psi_i(\mathbf{x}, \boldsymbol{\lambda})$ mit (5.107) berechnet werden kann.

5.5.4 Beispiel: Doppelintegrator

Ein bekanntes Beispiel zur Veranschaulichung des Maximumprinzips ist die zeitminimale Überführung eines doppelt integrierenden Systems in den Ursprung $\mathbf{x}(t_f) = \mathbf{0}$. Das Optimalsteuerungsproblem mit dem Zustand $\mathbf{x} = [x_1, x_2]^\top$ kann wie folgt formuliert werden

$$\min_{u(\cdot)} \int_{t_0=0}^{t_f} 1 dt = t_f \quad (5.111a)$$

$$\text{u.B.v.} \quad \dot{x}_1 = x_2, \quad \dot{x}_2 = u \quad (5.111b)$$

$$\mathbf{x}(0) = \mathbf{x}_0, \quad \mathbf{x}(t_f) = \mathbf{0} \quad (5.111c)$$

$$|u(t)| \leq 1 \quad \forall t \in [0, t_f]. \quad (5.111d)$$

Mit der Hamilton-Funktion $H(\mathbf{x}, u, \boldsymbol{\lambda}) = 1 + \lambda_1 x_2 + \lambda_2 u$ ergeben sich die adjungierten Zustände $\boldsymbol{\lambda} = [\lambda_1, \lambda_2]^\top$ aus (5.95) zu

$$\dot{\lambda}_1 = 0 \quad \Rightarrow \quad \lambda_1(t) = c_1 \quad (5.112a)$$

$$\dot{\lambda}_2 = -\lambda_1 \quad \lambda_2(t) = -c_1 t + c_2, \quad (5.112b)$$

wobei c_1 und c_2 Integrationskonstanten darstellen. Die Minimierungsbedingung (5.97) für die Hamilton-Funktion führt auf die optimale Steuerung

$$u(t) = \begin{cases} +1 & \text{falls } \lambda_2 < 0 \\ -1 & \text{falls } \lambda_2 > 0. \end{cases} \quad (5.113)$$

Der singuläre Fall, d.h. $\lambda_2(t) = 0$ auf einem nicht verschwindenden Subintervall $t \in I_s$, kann nicht auftreten, da dann aufgrund von (5.112b) $\lambda_2(t) = 0$ auf dem Gesamtintervall $[0, t_f]$ gelten müsste. Dies widerspricht aber der Transversalitätsbedingung (5.98) für die freie Endzeit t_f

$$H(\mathbf{x}, u, \boldsymbol{\lambda})|_{t=t_f} = 1 + \lambda_2(t_f) u(t_f) = 0.$$

Der Fall $\lambda_2(t) = 0$ kann also nur zu einem diskreten Zeitpunkt $t = t_s$ auftreten, was einem Umschalten von $u(t)$ zwischen -1 und $+1$ entspricht.⁹ Da $\lambda_2(t)$ in (5.112b) eine Gerade darstellt, gibt es *maximal einen* Umschaltzeitpunkt im Zeitintervall $[t_0, t_f]$, an dem $u(t)$ zwischen -1 und $+1$ wechselt. Somit existieren lediglich vier mögliche Schaltsequenzen $\{+1\}$, $\{-1\}$, $\{+1, -1\}$, $\{-1, +1\}$, die für eine optimale Lösung in Frage kommen. Da u stets auf einem Intervall konstant ist, stellen die Trajektorien in der (x_1, x_2) -Ebene Parabeln dar, wie in der folgenden Aufgabe gezeigt werden soll.

Aufgabe 5.4 Zeigen Sie, dass die Lösung von (5.111b) für $u(t) = \pm 1 = \text{konst.}$ die folgende Parabelgleichung erfüllt

$$x_1 = \frac{x_2^2}{2u} + c, \quad u = \pm 1, \quad c \in \mathbb{R}.$$

Das Optimierungsziel ist das schnellstmögliche Erreichen des Ursprungs $\mathbf{x}(t_f) = \mathbf{0}$ ausgehend von einem beliebigen Anfangspunkt $\mathbf{x}(0) = \mathbf{x}_0$. Der Ursprung ist aber nur über die *Schaltkurve* $x_1 = x_2^2/2$ für $u = 1$ bzw. $x_1 = -x_2^2/2$ für $u = -1$ erreichbar, siehe Abbildung 5.18. Diese beiden Fälle können in der Funktion

$$S(x_2) = -\frac{1}{2}x_2|x_2|.$$

zusammengefasst werden. Angesichts der Tatsache, dass lediglich die Schaltsequenzen $\{+1\}$, $\{-1\}$, $\{+1, -1\}$, $\{-1, +1\}$ für u in Frage kommen, gibt es nur eine Möglichkeit, um $\mathbf{x}(0) = \mathbf{x}_0$ schnellstmöglich zum Ursprung $\mathbf{x}(t_f) = \mathbf{0}$ zu bringen:

- Falls $x_{1,0} = S(x_{2,0})$ gilt, ist keine Umschaltung notwendig, und $\mathbf{x}(t_f) = \mathbf{0}$ wird direkt über die Schaltkurve mit $u(t) = 1$ oder $u(t) = -1$ erreicht, siehe Abbildung 5.18.
- Falls $\mathbf{x}_0$ nicht auf der Schaltkurve liegt, d.h. $x_{1,0} < S(x_{2,0})$ oder $x_{1,0} > S(x_{2,0})$, ist genau eine Umschaltung notwendig, um die Schaltkurve zu erreichen und anschließend zum Ursprung zu laufen, siehe Abbildung 5.19.

Das optimale Steuer- bzw. Regelgesetz lautet also

$$u(t) = \begin{cases} +1 & \text{falls } x_1 < S(x_2) \\ +1 & \text{falls } x_1 = S(x_2) \text{ und } x_1 > 0 \\ -1 & \text{falls } x_1 > S(x_2) \\ -1 & \text{falls } x_1 = S(x_2) \text{ und } x_1 < 0, \end{cases} \quad (5.114)$$

⁹ Es kann gezeigt werden, dass im Falle von steuerbaren linearen (zeitinvarianten) Systemen zeitoptimale Probleme stets nicht-singulär sind, siehe z.B. [12, 7].




Abbildung 5.18: Mögliche Trajektorien des Doppelintegrators in der (x_1, x_2) -Ebene.




Abbildung 5.19: Optimale Umschaltung für verschiedene Anfangswerte x_0 .

mit dessen Hilfe der Schaltzeitpunkt t_s und die minimale Endzeit t_f berechnet werden können. Abbildung 5.20 stellt die zeitoptimalen Trajektorien für den Doppelintegrator für verschiedene Anfangswerte $x_0 = [x_{1,0}, x_{2,0}]^T$ dar.

Aufgabe 5.5 Verifizieren Sie, dass der optimale Umschaltzeitpunkt t_s und die Endzeit t_f fallabhängig wie folgt definiert sind:

$$t_s = \begin{cases} x_{2,0} + \sqrt{\frac{1}{2}x_{2,0}^2 + x_{1,0}} & \text{falls } x_{1,0} > S(x_{2,0}) \\ -x_{2,0} + \sqrt{\frac{1}{2}x_{2,0}^2 - x_{1,0}} & \text{falls } x_{1,0} < S(x_{2,0}) \end{cases} \quad (5.115)$$

$$t_f = \begin{cases} x_{2,0} + \sqrt{2x_{2,0}^2 + 4x_{1,0}} & \text{falls } x_{1,0} > S(x_{2,0}) \\ -x_{2,0} + \sqrt{2x_{2,0}^2 - 4x_{1,0}} & \text{falls } x_{1,0} < S(x_{2,0}) \\ |x_{2,0}| & \text{falls } x_{1,0} = S(x_{2,0}) \end{cases} \quad (5.116)$$

Eine praktische Schreibweise für die fallabhängige Definition des Stellgesetzes (5.114) ist durch

$$u(t) = -\text{sign}\left(x_1 + \frac{1}{2}x_2|x_2|\right), \quad 0 = \text{sign}(0) \quad (5.117)$$

gegeben. In der Signum-Funktion ist der Sonderfall $x_1 = S(x_2)$ in (5.114) nicht berücksichtigt, was bedeutet, dass der Zustand x die Schaltkurve $S(x_2)$ um ein kleines Stück überquert, bevor die Umschaltung erfolgt. Dies stellt allerdings numerisch kein Problem dar, da der Zustand x nach dem Umschalten auf einer Trajektorie hinreichend nahe zur Schaltgeraden $S(x_2)$ verläuft.

Aufgabe 5.6 Implementieren Sie das doppelintegrierende System (5.111b) mit dem optimalen Regelgesetz (5.117) unter MATLAB/SIMULINK und verifizieren Sie die Ergebnisse in Abbildung 5.20 für verschiedene Anfangswerte x_0 . Verwenden Sie t_f gemäß (5.116) als Zeithorizont für die Simulation.




Abbildung 5.20: Zeitoptimale Trajektorien des Doppelintegrators.

5.5.5 Zustandsabhängige Eingangsbeschränkungen

Das Maximumprinzip (siehe Satz 5.6) kann auf eine allgemeinere Klasse von Stellgrößenbeschränkungen

$$\mathbf{h}(\mathbf{x}(t), \mathbf{u}(t)) \leq \mathbf{0} \quad \forall t \in [t_0, t_f] \quad (5.118)$$

mit $\mathbf{h} : \mathbb{R}^n \times \mathbb{R}^m \rightarrow \mathbb{R}^q$ erweitert werden. Da die Beschränkungen (5.118) allgemein vom Zustand $\mathbf{x}$ abhängen, ist die zulässige Menge

$$U(\mathbf{x}) = \{\mathbf{u} \in \mathbb{R}^m : \mathbf{h}(\mathbf{x}, \mathbf{u}) \leq \mathbf{0}\} \quad (5.119)$$

für die Steuergrößen $\mathbf{u}$ ebenfalls zustandsabhängig, d.h. es muss gelten $\mathbf{u}(t) \in U(\mathbf{x}(t)) \quad \forall t \in [t_0, t_f]$. Es wird angenommen, dass alle Elemente von $\mathbf{h} = [h_1, \dots, h_q]^T$ explizit von $\mathbf{u}$ abhängen und dass die Beschränkungsqualifikation¹⁰

$$\text{Rang} \left[\frac{\partial \mathbf{h}}{\partial \mathbf{u}}, \text{diag}(\mathbf{h}) \right] = q \quad (5.120)$$

erfüllt ist. Ähnlich dem Vorgehen bei statischen Optimierungsproblemen (Kapitel 4) werden die Ungleichungsbeschränkungen (5.118) mittels (zeitabhängiger) Lagrange-Multiplikatoren $\boldsymbol{\mu} = [\mu_1, \dots, \mu_q]^T$ zur Hamilton-Funktion (5.96) addiert

$$H(\mathbf{x}, \mathbf{u}, \boldsymbol{\lambda}, \lambda_0, \boldsymbol{\mu}) = \lambda_0 l(\mathbf{x}, \mathbf{u}) + \boldsymbol{\lambda}^T \mathbf{f}(\mathbf{x}, \mathbf{u}) + \boldsymbol{\mu}^T \mathbf{h}(\mathbf{x}, \mathbf{u}). \quad (5.121)$$

Zusätzlich zu den Bedingungen (5.95)–(5.98) des Maximumprinzips, die nun für die modifizierte Hamilton-Funktion (5.121) und die (zustandsabhängige) zulässige Menge (5.119) gelten, kommen noch die Komplementaritäts- und Vorzeichenbedingungen

$$\mu_i^*(t) h_i(\mathbf{x}^*(t), \mathbf{u}^*(t)) = 0, \quad \mu_i^*(t) \geq 0 \quad \forall t \in [t_0, t_f] \quad (5.122)$$

als notwendige Optimalitätsbedingungen hinzu. Die Korrespondenz zu den KKT-Bedingungen (4.29d), (4.29e) im statischen Fall ist dabei offensichtlich.

¹⁰ Die Beschränkungsqualifikation (5.120) besagt, dass die Gradienten aller in einem Punkt $(\mathbf{x}, \mathbf{u})$ aktiven Beschränkungen $h_i(\mathbf{x}, \mathbf{u}) = 0$ linear unabhängig sein müssen.

Im Fall von reinen Zustandsbeschränkungen

$$\mathbf{x}(t) \in X \subseteq \mathbb{R}^n \quad \text{bzw.} \quad \mathbf{h}(\mathbf{x}(t)) \leq 0 \quad \forall t \in [t_0, t_f]$$

mit $\mathbf{h} : \mathbb{R}^n \rightarrow \mathbb{R}^q$ werden die Optimalitätsbedingungen erheblich komplizierter und verlangen eine genaue Betrachtung von *beschränkten und unbeschränkten Bereichen*, d.h. Subintervalle von $[t_0, t_f]$, auf denen die Beschränkungen aktiv oder inaktiv sind. Des Weiteren existieren verschiedene Möglichkeiten, Zustandsbeschränkungen in der Hamilton-Funktion zu berücksichtigen, die zu unterschiedlichen Optimalitätsbedingungen führen. Für mehr Informationen zu diesem Thema sei auf den Übersichtsaufsatz [9] und die Bücher [4, 12] verwiesen.

5.6 Numerische Lösung der Optimalitätsbedingungen (indirekte Methoden)

In der Regel muss ein dynamisches Optimierungsproblems bzw. Optimalsteuerungsproblems numerisch gelöst werden. Verfahren, die auf der Lösung der Optimalitätsbedingungen (5.46)-(5.48) bzw. (5.95)-(5.98) im stellgrößenbeschränkten Fall basieren, werden als *indirekte Methoden* bezeichnet. Bekannte Verfahren sind *Diskretisierungs-, Schieß- und Gradientenverfahren*, die im Folgenden erläutert werden.

5.6.1 Diskretisierungsverfahren

Wie bereits mehrfach erwähnt wurde, stellen die Optimalitätsbedingungen für dynamische Optimierungsprobleme ein Zwei-Punkt-Randwertproblem dar. Insbesondere wenn sich die optimale Steuerung als Funktion $\mathbf{u} = \boldsymbol{\psi}(\mathbf{x}, \boldsymbol{\lambda})$ der Zustände $\mathbf{x}$ und $\boldsymbol{\lambda}$ ausdrücken lässt, können die kanonischen Gleichungen in die von $\mathbf{u}$ unabhängige Form (siehe Abschnitt 5.3.4 und 5.5.2)

$$\left. \begin{aligned} \dot{\mathbf{x}} &= \mathbf{f}(\mathbf{x}, \boldsymbol{\psi}(\mathbf{x}, \boldsymbol{\lambda}), t) \\ \dot{\boldsymbol{\lambda}} &= -H_{\mathbf{x}}(\mathbf{x}, \boldsymbol{\psi}(\mathbf{x}, \boldsymbol{\lambda}), \boldsymbol{\lambda}, t) \end{aligned} \right\} \quad \dot{\bar{\mathbf{x}}} = \mathbf{F}(\bar{\mathbf{x}}, t), \quad \bar{\mathbf{x}} = \begin{bmatrix} \mathbf{x} \\ \boldsymbol{\lambda} \end{bmatrix} \quad (5.123)$$

überführt werden. Im Folgenden werden eine feste (vorgegebene) Endzeit t_f und die folgenden Anfangs- und (partiellen) Endbedingungen

$$\mathbf{x}(t_0) = \mathbf{x}_0, \quad \mathbf{G}(\bar{\mathbf{x}}(t_f)) = \begin{bmatrix} [x_i(t_f) - x_{f,i}]_{i \in \mathcal{I}_f} \\ [\lambda_i(t_f) - V_{x_i}(\mathbf{x}(t_f), t_f)]_{i \notin \mathcal{I}_f} \end{bmatrix} = \mathbf{0} \quad (5.124)$$

mit $\mathbf{G} : \mathbb{R}^{2n} \rightarrow \mathbb{R}^n$ betrachtet, so dass $2n$ Randbedingungen für die $2n$ Differenzialgleichungen zur Verfügung stehen. Die Behandlung von allgemeinen Endbedingungen und einer freien Endzeit t_f wird in Abschnitt 5.6.3 angesprochen.

Eine gebräuchliche Vorgehensweise zur Lösung von Zwei-Punkt-Randwertaufgaben ist die Diskretisierung des Zeitintervalls $[t_0, t_f]$

$$t_0 = t^0 < t^1 < \dots < t^N = t_f,$$

um die Lösung an den $N + 1$ Stützstellen t^k zu approximieren, d.h.

$$\bar{\mathbf{x}}^k \approx \bar{\mathbf{x}}(t^k), \quad k = 0, 1, \dots, N. \quad (5.125)$$




Abbildung 5.21: Veranschaulichung der Trapezregel.

Eine bekannte Diskretisierungsformel ist z.B. die *Trapezregel*

$$\frac{\bar{x}^{k+1} - \bar{x}^k}{t^{k+1} - t^k} = \frac{1}{2} \left[F(\bar{x}^k, t^k) + F(\bar{x}^{k+1}, t^{k+1}) \right], \quad k = 0, 1, \dots, N-1, \quad (5.126a)$$

die in Abbildung 5.21 veranschaulicht ist. Zusätzlich müssen die $2n$ Randbedingungen (5.124)

$$\mathbf{x}^0 = \mathbf{x}_0, \quad \mathbf{G}(\bar{\mathbf{x}}^N) = \mathbf{0} \quad (5.126b)$$

erfüllt sein. Die Bedingungen (5.126) stellen ein nichtlineares Gleichungssystem der Ordnung $2n(N+1)$ für die $2n(N+1)$ zu bestimmenden Variablen (5.125) dar.

Ein verwandtes Verfahren zur Lösung von Zwei-Punkt-Randwertaufgaben ist das *Kollokationsverfahren*, das den Zustand $\bar{\mathbf{x}}(t)$ auf jedem Intervall $[t^k, t^{k+1}]$ durch Basisfunktionen (z.B. Polynome) annähert. Die Übereinstimmung mit den Differenzialgleichungen (5.123) wird an zusätzlichen *Kollokationspunkten* innerhalb der Intervalle $[t^k, t^{k+1}]$ erzwungen und die Stetigkeit an den Intervallgrenzen t^k durch Stetigkeitsbedingungen gefordert. Somit ergibt sich ebenfalls ein nichtlineares Gleichungssystem für die Koeffizienten der Basisfunktionen. Für bestimmte Basisfunktionen und Kollokationspunkte ist das Kollokationsverfahren zu gewissen Diskretisierungsformeln äquivalent.

Einige Merkmale von Diskretisierungsverfahren sind im Folgenden zusammengetragen:

- Aufgrund der simultanen Betrachtung der Differenzialgleichungen (5.123) und Randbedingungen (5.124) sind Diskretisierungsverfahren oft numerisch robuster als das Schießverfahren (Abschnitt 5.6.2).
- Trotzdem spielt die Startschätzung der adjungierten Variablen eine maßgebliche Rolle und entscheidet oft darüber, ob und wie schnell das Verfahren konvergiert.
- Der Implementierungsaufwand ist recht hoch. Die Jacobi-Matrix des Gleichungssystems (5.126) ist *dünn besetzt* und weist eine *Blockstruktur* auf. Diese strukturellen Eigenschaften können durch geeignete numerische Verfahren ausgenutzt werden.
- Die Anzahl der Stützstellen ($N+1$) hat maßgeblichen Einfluß auf die Lösung. Größere Werte von N erhöhen die Genauigkeit, vergrößern aber ebenfalls die Dimension des zu lösenden Gleichungssystems.
- Die Trapezregel besitzt die Verfahrensordnung 2, d.h. die numerische Lösung $\bar{\mathbf{x}}^k \approx \bar{\mathbf{x}}(t^k)$ stimmt bis zum quadratischen Term mit der Taylorreihe der exakten Lösung $\bar{\mathbf{x}}(t)$ an der Stelle $t = t^k$ überein. Alternativ können z.B. Runge-Kutta-Formeln mit höherer Verfahrensordnung verwendet werden.




Abbildung 5.22: Veranschaulichung des Schießverfahrens (Beispiel 5.6).

5.6.2 Schießverfahren

Im Gegensatz zum Diskretisierungsverfahren, das ein großes Gleichungssystem für die Differentialgleichungen (5.123) und die Randbedingungen (5.124) löst, betrachtet das Schießverfahren das Anfangswertproblem

$$\dot{\bar{\mathbf{x}}} = \mathbf{F}(\bar{\mathbf{x}}, t), \quad \bar{\mathbf{x}}(t_0) = \begin{bmatrix} \mathbf{x}_0 \\ \boldsymbol{\lambda}_0 \end{bmatrix} \quad (5.127)$$

mit den (noch unbekannten) Anfangswerten $\boldsymbol{\lambda}_0$ der adjungierten Zustände $\boldsymbol{\lambda}$. Die Lösung von (5.127) kann formal in Abhängigkeit von $\boldsymbol{\lambda}_0$ wie folgt geschrieben werden

$$\bar{\mathbf{x}}(t; \boldsymbol{\lambda}_0) = \begin{bmatrix} \mathbf{x}_0 \\ \boldsymbol{\lambda}_0 \end{bmatrix} + \int_{t_0}^t \mathbf{F}(\bar{\mathbf{x}}(\tau; \boldsymbol{\lambda}_0), \tau) d\tau. \quad (5.128)$$

Um die Endbedingungen in (5.124) zu erfüllen, muss gelten

$$\mathbf{G}(\bar{\mathbf{x}}(t_f; \boldsymbol{\lambda}_0)) = \mathbf{0}, \quad (5.129)$$

was ein nichtlineares Gleichungssystem der Ordnung n für die Anfangsbedingungen $\boldsymbol{\lambda}_0 \in \mathbb{R}^n$ darstellt.

Das Gleichungssystem (5.129) muss im Allgemeinen iterativ gelöst werden, z.B. mit Hilfe des Newton-Verfahrens. Das Anfangswertproblem (5.127) wird dazu unterlagert numerisch integriert, um die Trajektorie (5.128) zu bestimmen. Aufgrund der wiederholten (numerischen) Integration von (5.127) spricht man in diesem Zusammenhang vom *Schießverfahren*.

Beispiel 5.6 Zur Veranschaulichung des Schießverfahrens sei das Randwertproblem

$$\dot{x}_1 = x_2, \quad \dot{x}_2 = f(x_1, x_2), \quad x_1(t_0) = 0, \quad x_1(t_f) = 0$$

gegeben. Wird das Randwertproblem als Anfangswertproblem betrachtet, so hängt die Lösung $x_1(t; x_{2,0})$ vom Startwert $x_2(t_0) = x_{2,0}$ des zweiten Zustandes ab. Der Wert $x_{2,0}$ entspricht der Anfangssteigung der Trajektorie $x_1(t; x_{2,0})$, die so gewählt werden muss, dass die Endbedingung $x_1(t_f; x_{2,0}) = 0$ erfüllt ist, siehe Abbildung 5.22.

Einige Anmerkungen zum Schießverfahren:

- Der Implementierungsaufwand ist aufgrund der sequentiellen Lösung des Anfangswertproblems (5.127) und der Endbedingungen (5.129) relativ gering.
- Gute Startwerte für λ_0 sind wichtig, da das Schießverfahren häufig sehr sensitiv bzgl. dieser Größen ist.
- Die Integration des Anfangswertproblems (5.127) kann numerisch kritisch sein, vor allem wenn das Zeitintervall $[t_0, t_f]$ vergleichsweise groß ist, da die kanonischen Gleichungen in der Regel instabile Moden besitzen.¹¹
- Abhilfe verschaffen *Mehrfachschießverfahren*, die das Intervall $[t_0, t_f]$ in Unterintervalle unterteilen [1, 13].

5.6.3 Berücksichtigung allgemeiner Endbedingungen und freier Endzeit

In den vorherigen Abschnitten wurde zunächst von einer festen Endzeit t_f und partiellen Endbedingungen ausgegangen. Im Falle von allgemeinen Endbedingungen (5.70) wird die Funktion $\mathbf{G}$ in (5.124) durch

$$\mathbf{G}(\bar{\mathbf{x}}(t_f), \boldsymbol{\nu}) = \begin{bmatrix} \mathbf{g}(\mathbf{x}(t_f), t_f) \\ \boldsymbol{\lambda}(t_f) - (V_{\mathbf{x}}(\mathbf{x}(t_f), t_f) + \mathbf{g}_{\mathbf{x}}(\mathbf{x}(t_f), t_f)^T \boldsymbol{\nu}) \end{bmatrix} = \mathbf{0} \quad (5.130)$$

mit $\mathbf{G} : \mathbb{R}^{2n} \times \mathbb{R}^r \rightarrow \mathbb{R}^{n+r}$ ersetzt. Die Lagrange-Multiplikatoren $\boldsymbol{\nu} \in \mathbb{R}^r$ stellen zusätzliche Parameter dar, die den zusätzlichen r Randbedingungen in der Funktion $\mathbf{G}$ Rechnung tragen.

Falls die Endzeit t_f frei ist, kann eine Zeittransformation

$$t = t_0 + \delta\tau \quad \text{mit} \quad \tau \in [0, 1] \quad (5.131)$$

verwendet werden, um die kanonischen Gleichungen auf das normierte Zeitintervall $[0, 1]$ der neuen Zeitkoordinate τ zu transformieren. Der Parameter δ stellt dabei den Zeitstreckfaktor dar, mit dem sich die Endzeit zu $t_f = t_0 + \delta$ (entsprechend $\tau = 1$) ergibt. Mit den neuen Zuständen

$$\tilde{\mathbf{x}}(\tau) := \begin{bmatrix} \mathbf{x}(t_0 + \delta\tau) \\ \boldsymbol{\lambda}(t_0 + \delta\tau) \end{bmatrix}, \quad \tau \in [0, 1]$$

und der Notation $(\cdot)' = \frac{d}{d\tau}(\cdot)$ ergibt sich für die kanonischen Gleichungen (5.123)

$$\tilde{\mathbf{x}}' = \delta \mathbf{F}(\tilde{\mathbf{x}}, t_0 + \delta\tau), \quad \tau \in (0, 1). \quad (5.132)$$

Zusätzlich müssen die Anfangs- und Endbedingungen in (5.124) bzw. (5.130) in die neue Zeitkoordinate $\tau \in [0, 1]$ transformiert und um die Transversalitätsbedingung (5.48) bzw. (5.73) erweitert werden.

Für das Diskretisierungs- bzw. Schießverfahren stellen die zusätzlichen Größen δ und/oder $\boldsymbol{\nu}$ weitere zu bestimmende Variablen dar, wobei die zusätzlichen Gleichungen in den Randbedingungen $\mathbf{G}(\cdot) = \mathbf{0}$ die gleiche Dimension besitzen. Im Folgenden sind die unterschiedlichen Fälle zusammengefasst:

¹¹ Im linearen Fall kann gezeigt werden, dass die Eigenwerte der kanonischen Gleichungen, siehe (5.77), symmetrisch zur imaginären Achse sind.

Endzeit t_f	Endbed.	Zusätzliche Parameter		Anzahl Anfangs-/Endbed.	
		$\delta \in \mathbb{R}$	$\boldsymbol{\nu} \in \mathbb{R}^r$	$\mathbf{x}(t_0) = \mathbf{x}_0$	$\mathbf{G}(\cdot) = \mathbf{0}$
fest	partiell	-	-	n	n
fest	allgemein	-	✓	n	$n + r$
frei	partiell	✓	-	n	$n + 1$
frei	allgemein	✓	✓	n	$n + r + 1$

5.6.4 Gradientenverfahren

Ein weiteres klassisches Verfahren zur Lösung von Optimalsteuerungsproblemen ist das *Gradientenverfahren*, das Ähnlichkeit zum gleichnamigen Verfahren bei statischen Optimierungsproblemen (siehe Abschnitt 3.3.2) aufweist. Die hauptsächliche Anwendung findet das Gradientenverfahren bei dynamischen Optimierungsproblemen mit fester Endzeit und freiem Endzustand

$$\min_{\mathbf{u}(\cdot)} J(\mathbf{u}) = V(\mathbf{x}(t_f), t_f) + \int_{t_0}^{t_f} l(\mathbf{x}(t), \mathbf{u}(t), t) dt \quad (5.133a)$$

$$\text{u.B.v. } \dot{\mathbf{x}} = \mathbf{f}(\mathbf{x}, \mathbf{u}, t), \quad \mathbf{x}(t_0) = \mathbf{x}_0. \quad (5.133b)$$

Zunächst stellt sich die Frage, was der Gradient bzw. die maximale Abstiegsrichtung für das Funktional $J(\mathbf{u})$ ist. Dazu folgender wichtiger Satz:

Satz 5.7 (Gateaux-Ableitung von $J(\mathbf{u})$) Das Funktional $J(\mathbf{u})$ sei Gateaux-differenzierbar am Punkt $\mathbf{u} \in \mathcal{C}_m^0[t_0, t_f]$ und $\mathbf{x}, \boldsymbol{\lambda} \in \mathcal{C}_n^1[t_0, t_f]$ sei die Lösung der kanonischen Gleichungen

$$\dot{\mathbf{x}} = \mathbf{f}(\mathbf{x}, \mathbf{u}, t), \quad \mathbf{x}(t_0) = \mathbf{x}_0 \quad (5.134a)$$

$$\dot{\boldsymbol{\lambda}} = -H_{\mathbf{x}}(\mathbf{x}, \mathbf{u}, \boldsymbol{\lambda}, t), \quad \boldsymbol{\lambda}(t_f) = V_{\mathbf{x}}(\mathbf{x}(t_f)). \quad (5.134b)$$

Dann lautet die Gateaux-Ableitung in Richtung von $\mathbf{v} \in \mathcal{C}_m^0[t_0, t_f]$

$$\delta J(\mathbf{u}; \mathbf{v}) = \int_{t_0}^{t_f} H_{\mathbf{u}}(\mathbf{x}(t), \mathbf{u}(t), \boldsymbol{\lambda}(t), t)^T \mathbf{v}(t) dt. \quad (5.135)$$

Aufgabe 5.7 (optional) Beweisen Sie Satz 5.7, indem Sie die Stelltrajektorie $\mathbf{w}^\varepsilon(t) = \mathbf{u}(t) + \varepsilon \mathbf{v}(t)$, $t \in [t_0, t_f]$ mit zugehöriger Zustandstrajektorie $\mathbf{y}^\varepsilon(t)$ und $\mathbf{x}(t) = \mathbf{y}^0(t)$ für $\varepsilon = 0$ betrachten. Leiten Sie dann $\delta J(\mathbf{u}, \mathbf{v}) = \left. \frac{dJ(\mathbf{w}^\varepsilon)}{d\varepsilon} \right|_{\varepsilon=0}$ her, indem Sie $J(\mathbf{w}^\varepsilon)$ um den (zu Null evaluierenden) Integranden $\boldsymbol{\lambda}(t)^T (\mathbf{f}(\mathbf{y}^\varepsilon(t), \mathbf{w}^\varepsilon(t), t) - \dot{\mathbf{y}}^\varepsilon(t))$ erweitern.

Definiert man den Gradienten über die partielle Ableitung der Hamilton-Funktion nach $\mathbf{u}$, d.h.

$$\mathbf{g}(t) = H_{\mathbf{u}}(\mathbf{x}(t), \mathbf{u}(t), \boldsymbol{\lambda}(t), t), \quad t \in [t_0, t_f], \quad (5.136)$$

so gilt $\delta J(\mathbf{u}, -\mathbf{g}) < 0$ und $-\mathbf{g}$ stellt die steilste Abstiegsrichtung am Punkt $\mathbf{u} \in \mathcal{C}_m^0[t_0, t_f]$ dar. Das Gradientenverfahren nutzt zudem die Entkopplung der Randbedingungen für $\mathbf{x}(t_0)$ und $\boldsymbol{\lambda}(t_f)$ aus, indem es in jedem Iterationsschritt j die kanonischen Gleichungen (5.134) in Abhängigkeit einer Steuertrajektorie $\mathbf{u}^j(t)$, $t \in [t_0, t_f]$ sequentiell in Vorwärts- und Rückwärtszeit

Initialization:

$j \leftarrow 0$	Iterationszähler
ε	Abbruchkriterium
$\mathbf{u}^0(t)$	Startschätzung der Steuertrajektorie
$\mathbf{x}^0(t)$	Integration von (5.134a) in Vorwärtszeit
repeat	
$\boldsymbol{\lambda}^j(t)$	Integration von (5.134b) in Rückwärtszeit
$\mathbf{g}^j(t) \leftarrow (5.136)$	Berechnung des Gradienten
$\alpha^j \leftarrow \arg \min_{\alpha > 0} J(\mathbf{u}^j - \alpha \mathbf{g}^j)$	Linien suche (meist approximative Lösung)
$\mathbf{u}^{j+1}(t) = \mathbf{u}^j(t) - \alpha^j \mathbf{g}^j(t)$	neue Steuertrajektorie mit Schrittweite α^j
$\mathbf{x}^{j+1}(t)$	Integration von (5.134a) in Vorwärtszeit
$j \leftarrow j + 1$	
until $ J(\mathbf{u}^j) - J(\mathbf{u}^{j-1}) \leq \varepsilon$	oder anderes Abbruchkriterium

Tabelle 5.1: Algorithmus des Gradientenverfahrens.

integriert, um die Zustandstrajektorien $\mathbf{x}^j(t)$ und $\boldsymbol{\lambda}^j(t)$ zu bestimmen. Der negative Gradient $-\mathbf{g}^j(t)$ kann dann verwendet werden, um einen Abstieg im Kostenfunktional (5.133a) zu erreichen. Tabelle 5.1 fasst den grundsätzlichen Algorithmus zusammen.

Das unterlagerte Liniensuchproblem wird in der Regel approximativ gelöst, z.B. mit Hilfe einer Armijo-Bedingung (siehe Abschnitt 3.3.1). In manchen Versionen des Gradientenverfahrens wird die Liniensuche durch eine feste Schrittweite α ersetzt, womit sich direkt $\mathbf{u}^{j+1}(t) = \mathbf{u}^j(t) - \alpha \mathbf{g}^j(t)$ ergibt. In diesem Fall muss allerdings α hinreichend klein gewählt werden, was oft zu einer langsameren Konvergenz führt. Ein guter Kompromiss zwischen Genauigkeit und Rechenaufwand kann durch eine explizite oder adaptive Liniensuche erzielt werden. Eine explizite Berechnungsvorschrift für die Schrittweite kann durch die Minimierung der Differenz zwischen zwei Stellgrößen-Updates $\mathbf{u}^{j+1}(t)$ und $\mathbf{u}^j(t)$ hergeleitet werden. Eine Alternative ist die approximative Lösung des Liniensuchproblems auf einem Intervall $[\alpha^-, \alpha^+]$, das über die Gradienteniterationen dynamisch adaptiert wird [6].

Mehr Informationen zum Gradientenverfahren finden sich z.B. in [14, 4, 12]. Einige Anmerkungen sind im Folgenden zusammengetragen:

- Ein Vorteil des Gradientenverfahrens (vor allem bei allgemeinen nichtlinearen Problemen) ist, dass $\mathbf{u}$ nicht explizit aus $H_{\mathbf{u}} = \mathbf{0}$ bzw. $\min_{\mathbf{u} \in U} H$ berechnet werden muss (siehe Abschnitte 5.3.4 und 5.5.2).
- Stellgrößenbeschränkungen $\mathbf{u} \in U$ können durch *Projektion* auf die zulässige Menge U berücksichtigt werden.
- Das Gradientenverfahren ist in der Regel numerisch robuster als das Schießverfahren, da das adjungierte System (5.134b) nicht in die instabile Vorwärtsrichtung integriert wird. Ein weiterer Pluspunkt (auch gegenüber Diskretisierungsverfahren) ist, dass die Startschätzung der adjungierten Variablen entfällt.
- Es tritt meist eine deutliche Reduktion des Kostenfunktionals am Anfang des Verfahrens

auf (für kleine j). Die Konvergenz in der Nähe der optimalen Lösung ist aber recht langsam.

- Alternativ können *Konjugierte-Gradienten-Verfahren* oder *Gradientenverfahren 2. Ordnung* mit besseren Konvergenzeigenschaften verwendet werden.
- Das Gradientenverfahren kann auf partielle/allgemeine Randbedingungen und freie Endzeit erweitert werden, wodurch sich aber die Robustheit und Konvergenzeigenschaften oft deutlich verschlechtern.

5.7 Reduktion auf statische Optimierungsprobleme (direkte Methoden)

Direkte Methoden beruhen auf der Parametrierung der Steuertrajektorie $\mathbf{u}(t)$, $t \in [t_0, t_f]$, um das Optimalsteuerungsproblem auf ein endlich-dimensionales Problem zu reduzieren, das mit den bekannten Methoden der statischen Optimierung gelöst werden kann (siehe Kapitel 3 und 4). Im Folgenden sind einige Vorteile des direkten/indirekten Lösungswegs gegenübergestellt:

Direkte Verfahren:

- Herleitung der kanonischen Gleichungen ist nicht notwendig
- Zustandsbeschränkungen sind leichter zu berücksichtigen
- oft größerer Konvergenzbereich, da keine Startschätzung der adjungierten Zustände benötigt wird

Indirekte Verfahren:

- liefern Einsicht in die Struktur der optimalen Lösung
- hochgenaue Lösung (wichtig z.B. bei der Bahnplanung in der Raumfahrt)
- adjungierte Variablen können für Sensitivitätsanalyse und Reglerentwurf ("*neighbouring extremal control*") verwendet werden

Unterschieden wird bei direkten Verfahren zwischen *Teil-* oder *Volldiskretisierung*, die im Folgenden erläutert werden. Als Basis dafür dient ein allgemeines beschränktes Optimalsteuerungsproblem der Form

$$\min_{\mathbf{u}(\cdot)} \quad J(\mathbf{u}) = V(\mathbf{x}(t_f)) + \int_{t_0}^{t_f} l(\mathbf{x}(t), \mathbf{u}(t), t) dt \quad (5.137a)$$

$$\text{u.B.v.} \quad \dot{\mathbf{x}} = \mathbf{f}(\mathbf{x}, \mathbf{u}, t), \quad \mathbf{x}(t_0) = \mathbf{x}_0 \quad (5.137b)$$

$$\mathbf{g}(\mathbf{x}(t_f)) = \mathbf{0} \quad (5.137c)$$

$$\mathbf{h}(\mathbf{x}(t), \mathbf{u}(t), t) \leq \mathbf{0} \quad \forall t \in [t_0, t_f]. \quad (5.137d)$$

Die Endzeit t_f sei der Einfachheit halber fest. Falls t_f frei ist, kann die Zeittransformation (5.131) verwendet werden, um das Problem wieder auf ein festes Intervall $[0, 1]$ in der neuen Zeitkoordinate τ zu transformieren.




Abbildung 5.23: Stückweise konstante und stückweise lineare Parametrierung der Steuertrajektorie im skalaren Fall ($m = 1$).

5.7.1 Teildiskretisierung

Bei direkten Lösungsverfahren wird zunächst das Zeitintervall $[t_0, t_f]$ diskretisiert

$$t_0 = t^0 < t^1 < \dots < t^N = t_f, \quad (5.138)$$

und die Steuergrößen $\mathbf{u}$ auf den N Subintervallen $[t^k, t^{k+1}]$ parametrisiert. Im einfachsten Fall wird $\mathbf{u}$ auf jedem Subintervall konstant angesetzt, d.h.

$$\mathbf{u}(t) = \boldsymbol{\psi}(t, \hat{\mathbf{u}}) = \mathbf{u}^k, \quad t \in [t^k, t^{k+1}) \quad \text{mit} \quad \hat{\mathbf{u}} = \begin{bmatrix} \mathbf{u}^0 \\ \vdots \\ \mathbf{u}^{N-1} \end{bmatrix} \in \mathbb{R}^{mN}. \quad (5.139)$$

Somit ergibt sich für die Steuertrajektorie $\mathbf{u}(t) = \boldsymbol{\psi}(t, \hat{\mathbf{u}})$ ein stückweise konstantes Profil in Abhängigkeit der mN Parameter $\hat{\mathbf{u}}$. Alternativ können z.B. stückweise lineare Ansätze für $\boldsymbol{\psi}(t, \hat{\mathbf{u}})$ verwendet werden, siehe Abbildung 5.23.

Durch die Parametrierung der Steuertrajektorie $\mathbf{u}(t) = \boldsymbol{\psi}(t, \hat{\mathbf{u}})$ wird das Optimalsteuerungsproblem auf das statische (endlich-dimensionale) Optimierungsproblem

$$\min_{\hat{\mathbf{u}} \in \mathbb{R}^{mN}} \quad \hat{J}(\hat{\mathbf{u}}) = V(\mathbf{x}(t_f)) + \sum_{k=0}^{N-1} \int_{t^k}^{t^{k+1}} l(\mathbf{x}(t), \boldsymbol{\psi}(t, \hat{\mathbf{u}}), t) dt \quad (5.140a)$$

$$\text{u.B.v.} \quad \dot{\mathbf{x}} = \mathbf{f}(\mathbf{x}, \boldsymbol{\psi}(t, \hat{\mathbf{u}}), t), \quad t \in (t^k, t^{k+1}), \quad k = 0, 1, \dots, N-1 \quad (5.140b)$$

$$\mathbf{x}(t^0) = \mathbf{x}_0, \quad \mathbf{x}(t^k) = \mathbf{x}(t^{k-}), \quad k = 0, 1, \dots, N-1 \quad (5.140c)$$

$$\mathbf{g}(\mathbf{x}(t^N)) = \mathbf{0} \quad (5.140d)$$

$$\mathbf{h}(\mathbf{x}(t), \boldsymbol{\psi}(t, \hat{\mathbf{u}}), t) \leq \mathbf{0} \quad \forall t \in [t^k, t^{k+1}], \quad k = 0, 1, \dots, N-1 \quad (5.140e)$$

überführt. Zur Lösung des nichtlinearen Optimierungsproblems (5.140) in Abhängigkeit der Parameter $\hat{\mathbf{u}}$ muss die Differenzialgleichung (5.140b) auf den einzelnen Subintervallen unterlagert numerisch integriert werden. Die Bedingungen (5.140c) gewährleisten dabei die Stetigkeit des Zustandes $\mathbf{x}(t)$ über die Intervallgrenzen t^k hinweg.

Ein Problem in dieser Formulierung ist, dass die Ungleichungsbeschränkungen (5.140e) korrekterweise auf jedem Intervall $[t^k, t^{k+1}]$ und nicht nur an den Stützstellen t^k erfüllt sein sollten.

In der Praxis wird (5.140e) häufig durch punktweise Ungleichungsbeschränkungen

$$\mathbf{h}(\mathbf{x}(t^{k,j}), \boldsymbol{\psi}(t^{k,j}, \hat{\mathbf{u}}), t^{k,j}) \leq \mathbf{0}$$

an einer Anzahl von inneren Punkten $t^{k,j} \in [t^k, t^{k+1}]$ ersetzt. Das Problem (5.140) kann dann mit herkömmlichen Methoden der nichtlinearen Optimierung, z.B. dem SQP-Verfahren, angegangen werden.

Einige Merkmale direkter Verfahren mit Teildiskretisierung sind:

- Falls die Bedingungen (5.140c) als Anfangsbedingungen und nicht als Gleichungsbeschränkungen im Optimierungsverfahren implementiert sind, erfüllt die Zustandstrajektorie $\mathbf{x}(t)$, $t \in [t_0, t_f]$ (im Rahmen des verwendeten Integrationsverfahrens) stets die Differenzialgleichung (5.140b), d.h. auch während der einzelnen Iterationen des Optimierungsverfahrens.
- Die Berechnung der Gradienten der Kostenfunktion und Beschränkungen in (5.140) nach $\hat{\mathbf{u}}$ (z.B. über die Sensitivitätsdgl.) ist im Allgemeinen recht aufwändig.
- Aufgrund der separaten Integration der Systemgleichungen (5.140b) auf den einzelnen Intervallen spricht man bei der Teildiskretisierung oft von einem *direkten sequentiellen Verfahren*.

5.7.2 Volldiskretisierung

Im Gegensatz zur Teildiskretisierung werden bei der Volldiskretisierung neben der Steuertrajektorie ebenfalls die Differenzialgleichungen (5.137b) an den Stützstellen (5.138) diskretisiert. In Analogie zu Abschnitt 5.6.1 kann dies z.B. mit Hilfe der Trapezregel (5.126) erfolgen, während $\mathbf{u}$ stückweise linear angesetzt wird:

$$\frac{\mathbf{x}^{k+1} - \mathbf{x}^k}{t^{k+1} - t^k} = \frac{1}{2} \left[\mathbf{f}(\mathbf{x}^k, \mathbf{u}^k, t^k) + \mathbf{f}(\mathbf{x}^{k+1}, \mathbf{u}^{k+1}, t^{k+1}) \right], \quad k = 0, 1, \dots, N-1.$$

Somit ergibt sich für das Optimalsteuerungsproblem (5.137) das nichtlineare Optimierungsproblem

$$\min_{\hat{\mathbf{x}}, \hat{\mathbf{u}}} \quad \hat{J}(\hat{\mathbf{x}}, \hat{\mathbf{u}}) = V(\mathbf{x}^N) + \sum_{k=0}^{N-1} \frac{t^{k+1} - t^k}{2} \left[l(\mathbf{x}^k, \mathbf{u}^k, t^k) + l(\mathbf{x}^{k+1}, \mathbf{u}^{k+1}, t^{k+1}) \right] \quad (5.141a)$$

$$\text{u.B.v.} \quad \frac{\mathbf{x}^{k+1} - \mathbf{x}^k}{t^{k+1} - t^k} = \frac{1}{2} \left[\mathbf{f}(\mathbf{x}^k, \mathbf{u}^k, t^k) + \mathbf{f}(\mathbf{x}^{k+1}, \mathbf{u}^{k+1}, t^{k+1}) \right], \quad k = 0, 1, \dots, N-1 \quad (5.141b)$$

$$\mathbf{x}^0 = \mathbf{x}_0, \quad \mathbf{g}(\mathbf{x}^N) = \mathbf{0} \quad (5.141c)$$

$$\mathbf{h}(\mathbf{x}^k, \mathbf{u}^k, t^k) \leq \mathbf{0} \quad k = 0, 1, \dots, N. \quad (5.141d)$$

Im Optimierungsproblem werden die diskretisierten Systemgleichungen (5.141b) zusammen mit den Anfangs- und Endbedingungen (5.141c) als Gleichungsbeschränkungen behandelt. Die Optimierungsvariablen umfassen dabei die diskretisierten Eingangs- und Zustandsvariablen

$$\hat{\mathbf{u}} = \begin{bmatrix} \mathbf{u}^0 \\ \vdots \\ \mathbf{u}^N \end{bmatrix} \in \mathbb{R}^{m(N+1)}, \quad \hat{\mathbf{x}} = \begin{bmatrix} \mathbf{x}^0 \\ \vdots \\ \mathbf{x}^N \end{bmatrix} \in \mathbb{R}^{n(N+1)}. \quad (5.142)$$

Die Anzahl der Optimierungsvariablen, $(m + n)(N + 1)$, ist somit zwar deutlich höher als bei der Teildiskretisierung, dafür liegen aber die Differenzialgleichungen (5.137b) bereits als Gleichungsbeschränkungen vor und müssen nicht separat integriert werden.

Einige Merkmale direkter Verfahren mit Volldiskretisierung sind:

- Die Optimierungsvariablen $\hat{\mathbf{x}}$ erfüllen die diskretisierten Systemgleichungen (5.141b) nur bei der optimalen Lösung $\hat{\mathbf{x}}^*$ hinreichend genau.
- Die Berechnung der Gradienten der Kostenfunktion und Beschränkungen in (5.141) nach $(\hat{\mathbf{x}}, \hat{\mathbf{u}})$ ist einfacher als im Falle der Teildiskretisierung. Des Weiteren sind die Matrizen dünn besetzt und weisen eine Blockstruktur auf, die von speziellen numerischen Verfahren ausgenutzt werden kann.
- Im Gegensatz zu (5.140e) liegen die Ungleichungsbeschränkungen (5.141d) ebenfalls direkt in diskretisierter Form vor.
- Die Genauigkeit der volldiskretisierten optimalen Lösung hängt direkt von der Anzahl der Stützstellen $(N + 1)$ ab. Im Gegensatz zur Teildiskretisierung beeinflusst N nicht nur wie fein die Steuerung diskretisiert wird, sondern ebenfalls wie genau $\hat{\mathbf{x}}$ die tatsächliche Lösung der Differenzialgleichungen (5.137b) annähert.
- Aufgrund der Volldiskretisierung des Optimalsteuerungsproblems (5.137) spricht man in diesem Zusammenhang auch von *direkten simultanen Verfahren*.

5.8 Software-Übersicht

Neben der beschriebenen Möglichkeit, ein Optimalsteuerungsproblem eigenhändig zu diskretisieren und als nichtlineares Optimierungsproblem zu lösen, gibt es verschiedene Software-Pakete für dynamische Optimierungsprobleme, die großteils auf direkter Teil- oder Volldiskretisierung basieren und teils externe Solver (bspw. IPOPT oder qpOASES) einbinden. Eine kleine Auswahl an frei erhältlichen und kostenpflichtigen Programmen ist im Folgenden zusammengetragen:

- acados (Open Source-Lizenz)
<https://docs.acados.org>
- CasADi (Open Source-Lizenz)
<https://web.casadi.org>
- GRAMPC (Open Source-Lizenz)
<https://github.com/grampc/grampc>
- HQP (Open Source-Lizenz)
<http://hqp.sourceforge.net>
- ICLOCS2 (frei zugänglich, aber externer Solver benötigt)
<http://www.ee.ic.ac.uk/iclocs>
- TOMLAB/PROPT (kostenpflichtig)
<http://tomdyn.com>

5.9 Literatur

- [1] U.M. Ascher, R.M.M. Mattheij und R.D. Russell. *Numerical solution of boundary value problems of ordinary differential equations*. Prentice Hall, 1988.
- [2] M. Athans und P.L. Falb. *Optimal Control*. New York: McGraw-Hill, 1966.
- [3] B. van Brunt. *The Calculus of Variations*. New York: Springer, 2004.
- [4] A.E. Bryson und Y.-C. Ho. *Applied Optimal Control*. New York: John Wiley & Sons, 1975.
- [5] B. Chachuat. *Nonlinear and Dynamic Optimization: From Theory to Practice*. <https://infoscience.epfl.ch/record/111939>, 2007.
- [6] T. Englert, A. Völz, F. Mesmer, S. Rhein und K. Graichen. “A software framework for embedded nonlinear model predictive control using a gradient-based augmented Lagrangian approach (GRAMPC)”. In: *Optimization and Engineering* 20.3 (2019), S. 769–809. DOI: 10.1007/s11081-018-9417-2.
- [7] O. Föllinger. *Optimale Steuerung und Regelung*. München: Oldenbourg, 1994.
- [8] K. Graichen. *Feedforward Control Design for Finite-Time Transition Problems of Non-linear Systems with Input and Output Constraints*. Dissertation, Universität Stuttgart. <http://dx.doi.org/10.18419/opus-4093>. Aachen: Shaker-Verlag, 2006.
- [9] R.F. Hartl, S.P. Sethi und R.G. Vickson. “A survey of the maximum principles for optimal control problems with state constraints”. In: *SIAM Review* 37 (1995), S. 181–218.
- [10] M.I. Kamien und N.L. Schwartz. *Dynamic Optimization: The Calculus of Variations and Optimal Control in Economics and Management*. 2nd edition. Amsterdam: North-Holland, Amsterdam, 1991.
- [11] H. Kwakernaak und R. Sivan. *Linear Optimal Control Systems*. New York: Wiley-Interscience, 1972.
- [12] M. Papageorgiou, M. Leibold und M. Buss. *Optimierung*. Berlin: Springer, 2012.
- [13] H.J. Pesch. “Optimal and nearly optimal guidance by multiple shooting”. In: *Proc. Intern. Symp. “Mécanique Spatiale”*. Hrsg. von Centre d’Études Spatiales (CNES). Toulouse, 6.-10.11.1989: Cepadues Editions, 1990, S. 761–771.
- [14] E. Polak. “An historical survey of computational methods in optimal control”. In: *SIAM Review* 15 (1973), S. 553–584.

6 Modellprädiktive Regelung (MPC)

Modellprädiktive Regelungsverfahren (Englisch: *MPC – Model Predictive Control*) basieren auf der Lösung eines dynamischen Optimierungsproblems auf einem bewegten Horizont und erweisen sich besonders zur Regelung von nichtlinearen Mehrgrößensystemen und zur Berücksichtigung von Beschränkungen als geeignet. In diesem Kapitel wird eine Einführung in MPC gegeben und verschiedene MPC-Formulierungen vorgestellt. Da MPC im Allgemeinen mit einem hohen numerischen Aufwand verbunden ist, werden zusätzlich Aspekte einer echtzeitfähigen Implementierung am realen System untersucht. Für eine detaillierte Diskussion von MPC sei auf die Literatur [19, 2, 8, 5, 14] verwiesen.

6.1 Grundprinzip der modellprädiktiven Regelung

In diesem Abschnitt wird auf das Grundprinzip von MPC eingegangen, was als Basis für die Untersuchung verschiedener MPC-Formulierungen in Abschnitt 6.2 dient. Im Folgenden wird ein nichtlineares System der Form

$$\dot{\mathbf{x}}(t) = \mathbf{f}(\mathbf{x}(t), \mathbf{u}(t)), \quad \mathbf{x}(0) = \mathbf{x}_0 \quad (6.1)$$

mit dem Zustand $\mathbf{x} \in \mathbb{R}^n$ und dem Eingang $\mathbf{u} \in \mathbb{R}^m$ betrachtet. Zusätzlich wird angenommen, dass die Stell- und Zustandsgrößen für alle Zeiten $t \geq 0$ die Beschränkungen

$$\mathbf{u}(t) \in U, \quad \mathbf{x}(t) \in X, \quad t \geq 0 \quad (6.2)$$

erfüllen sollen. Als Regelungsaufgabe wird die Stabilisierung des Ursprungs

$$\mathbf{0} = \mathbf{f}(\mathbf{0}, \mathbf{0}) \quad (6.3)$$

betrachtet, was allerdings keine Einschränkung darstellt. Jede andere Ruhelage $(\mathbf{x}_R, \mathbf{u}_R)$ mit $\mathbf{0} = \mathbf{f}(\mathbf{x}_R, \mathbf{u}_R)$ lässt sich durch eine einfache Zustands-/Eingangstransformation $\tilde{\mathbf{x}} = \mathbf{x} - \mathbf{x}_R$ und $\tilde{\mathbf{u}} = \mathbf{u} - \mathbf{u}_R$ berücksichtigen.

6.1.1 Dynamische Optimierung auf bewegtem Horizont

Das Ziel eines MPC-Verfahrens ist die Bestimmung eines nichtlinearen Regelgesetzes basierend auf der Lösung eines dynamischen Optimierungsproblems

$$\min_{\bar{\mathbf{u}}(\cdot)} \quad J_T(\mathbf{x}_k, \bar{\mathbf{u}}) = V(\bar{\mathbf{x}}(T)) + \int_0^T l(\bar{\mathbf{x}}(\tau), \bar{\mathbf{u}}(\tau)) d\tau \quad (6.4a)$$

$$\text{u.B.v.} \quad \dot{\bar{\mathbf{x}}}(\tau) = \mathbf{f}(\bar{\mathbf{x}}(\tau), \bar{\mathbf{u}}(\tau)), \quad \bar{\mathbf{x}}(0) = \mathbf{x}_k = \mathbf{x}(t_k) \quad (6.4b)$$

$$\bar{\mathbf{x}}(\tau) \in X, \quad \bar{\mathbf{u}}(\tau) \in U, \quad \tau \in [0, T] \quad (6.4c)$$

$$\bar{\mathbf{x}}(T) \in S. \quad (6.4d)$$

Dabei stellt $\mathbf{x}_k$ den Systemzustand zum Zeitpunkt t_k dar. Die Horizontlänge T bestimmt die Länge des Zeitintervalls, auf dem die Zustandstrajektorie des Systems prädiziert wird. Der Querstrich kennzeichnet interne Größen $\bar{\mathbf{x}}(\tau)$, $\bar{\mathbf{u}}(\tau)$ mit der Prädiktionszeit $\tau \in [0, T]$ im Vergleich zum realen System (6.1) mit der Laufzeit $t \geq 0$. In weiterer Folge seien die folgenden Eigenschaften erfüllt:

Grundlegende Annahmen:

- A.1 Die Systemfunktion $\mathbf{f}$ sei stetig differenzierbar in ihren Argumenten und für jedes $\mathbf{x}_0 \in X$ und jede Steuertrajektorie $\mathbf{u}(t) \in U$, $t \in [0, T]$ existiert eine beschränkte Lösung des Systems (6.1).
- A.2 Die Beschränkungsmengen X und U mit $\mathbf{0} \in X \subseteq \mathbb{R}^n$ und $\mathbf{0} \in U \subseteq \mathbb{R}^m$ sind konvex und U ist zusätzlich kompakt.
- A.3 Der Integralkostenterm $I(\mathbf{x}, \mathbf{u})$ und die (optionale) Endkostengewichtung $V(\mathbf{x})$ im Kostenfunktional (6.4a) seien stetig differenzierbar in ihren Argumenten und positiv definite Funktionen mit $I(\mathbf{0}, \mathbf{0}) = V(\mathbf{0}) = 0$ und den quadratischen Abschätzungen

$$\begin{aligned} m_I(\|\mathbf{x}\|^2 + \|\mathbf{u}\|^2) &\leq I(\mathbf{x}, \mathbf{u}) \leq M_I(\|\mathbf{x}\|^2 + \|\mathbf{u}\|^2) \\ m_V\|\mathbf{x}\|^2 &\leq V(\mathbf{x}) \leq M_V\|\mathbf{x}\|^2 \end{aligned} \quad (6.5)$$

für gewisse Konstanten $m_I, M_I > 0$ und $m_V, M_V > 0$.

Eine häufige Wahl für $I(\mathbf{x}, \mathbf{u})$ und $V(\mathbf{x})$ sind z.B. die quadratischen Funktionen

$$V(\mathbf{x}) = \mathbf{x}^T \mathbf{P} \mathbf{x}, \quad I(\mathbf{x}, \mathbf{u}) = \mathbf{x}^T \mathbf{Q} \mathbf{x} + \mathbf{u}^T \mathbf{R} \mathbf{u} \quad (6.6)$$

mit symmetrischen und positiv definiten Matrizen $\mathbf{P}, \mathbf{Q}, \mathbf{R}$. Neben den Stell- und (möglicherweise) Zustandsbeschränkungen (6.4c) wird bei manchen MPC-Formulierungen eine zusätzliche Endbeschränkung (6.4d) mit $S \subset \mathbb{R}^n$ und $\mathbf{0} \in S$ verwendet (Abschnitt 6.2).

Unter der Voraussetzung, dass das dynamische Optimierungsproblem (6.4) lösbar ist¹, wird die optimale Lösung und das optimale Kostenfunktional gekennzeichnet durch

$$\bar{\mathbf{u}}_T^*(\tau; \mathbf{x}_k), \quad \bar{\mathbf{x}}_T^*(\tau; \mathbf{x}_k), \quad \tau \in [0, T] \quad (6.7)$$

und

$$J_T^*(\mathbf{x}_k) := J_T(\mathbf{x}_k, \bar{\mathbf{u}}_k^*).$$

Um ein stabilisierendes modellprädiktives Regelgesetz zu erhalten, wird häufig davon ausgegangen, dass die optimale Lösung des Optimierungsproblems (6.4) in jedem Zeitschritt t_k (numerisch) exakt bestimmt wird. Auf dem aktuellen Abtastintervall $t \in [t_k, t_k + \Delta t]$ mit der Abtastzeit Δt wird der erste Abschnitt der optimalen Steuertrajektorie $\bar{\mathbf{u}}_T^*(\tau; \mathbf{x}_k)$ als Stellgröße

$$\mathbf{u}(t_k + \tau) = \bar{\mathbf{u}}_T^*(\tau; \mathbf{x}_k) =: \kappa_T(\bar{\mathbf{x}}_T^*(\tau; \mathbf{x}_k); \mathbf{x}_k), \quad \tau \in [0, \Delta t] \quad (6.8)$$

für das System (6.1) verwendet, was als ein *optimales Regelgesetz* mit $\kappa_T(\mathbf{0}; \mathbf{x}_k) = \mathbf{0}$ interpretiert werden kann. Im nächsten Abtastschritt $t_{k+1} = t_k + \Delta t$ mit der Abtastzeit Δt wird das Optimierungsproblem (6.4) mit dem neuen Anfangszustand $\mathbf{x}_{k+1}$ erneut gelöst. Abbildung 6.1 veranschaulicht die Funktionsweise von MPC.

¹ Existenzbeweise für gewisse Klassen dynamischer Optimierungsprobleme (6.4) finden sich z.B. in [17, 1].




Abbildung 6.1: Prinzip der modellprädiktiven Regelung.

Falls keine Modellungenauigkeiten oder Störungen auftreten, ergibt sich der nächste Anfangszustand zu $\mathbf{x}_{k+1} = \mathbf{x}_T^*(\Delta t; \mathbf{x}_k)$. Für die Trajektorien im geschlossenen Kreis ergibt sich somit im nominellen Fall

$$\begin{aligned} \mathbf{x}(t) &= \mathbf{x}(t_k + \tau) = \bar{\mathbf{x}}_T^*(\tau; \mathbf{x}_k), \\ \mathbf{u}(t) &= \mathbf{u}(t_k + \tau) = \bar{\mathbf{u}}_T^*(\tau; \mathbf{x}_k), \quad \tau \in [0, \Delta t), \quad k \in \mathbb{N}_0^+. \end{aligned} \quad (6.9)$$

6.1.2 Zeitkontinuierliche vs. zeitdiskrete MPC-Darstellung

In der Praxis wird die stückweise stetige Stellgröße (6.8) häufig durch eine konstante Stellgröße ersetzt, z.B. indem $\mathbf{u}(t_k + \tau) = \bar{\mathbf{u}}_T^*(0; \mathbf{x}_k) = \text{konst.}$ für $\tau \in [0, \Delta t)$ verwendet wird oder die Steuertrajektorie zur Lösung von (6.4) direkt als stückweise konstante Parametrierung angesetzt wird, siehe Abbildung 6.2 bzw. auch Abschnitt 5.7.1.

Wenn also eine konstante Stellgröße $\mathbf{u}_k$ auf dem Intervall $t \in [t_k, t_k + \Delta t)$ betrachtet wird, so ergibt sich die Zustandstrajektorie $\mathbf{x}(t) = \mathbf{x}(t; \mathbf{x}_k, \mathbf{u}_k)$, weshalb das zeitkontinuierliche System (6.1) auch als ein nichtlineares zeitdiskretes System der Form

$$\mathbf{x}_{k+1} = \mathbf{f}_d(\mathbf{x}_k, \mathbf{u}_k) \quad (6.10)$$

interpretiert werden kann. In der Literatur wird deswegen häufig eine zeitdiskrete Variante des




Abbildung 6.2: MPC mit stückweise konstanter Stellgröße (siehe auch Abbildung 6.1).

Optimierungsproblems (6.4)

$$\min_{\hat{\mathbf{u}}} \quad J_N(\mathbf{x}_k, \hat{\mathbf{u}}) = V(\bar{\mathbf{x}}_N) + \sum_{j=0}^{N-1} l(\bar{\mathbf{x}}_j, \bar{\mathbf{u}}_j) \quad (6.11a)$$

$$\text{u.B.v.} \quad \bar{\mathbf{x}}_{j+1} = \mathbf{f}_d(\bar{\mathbf{x}}_j, \bar{\mathbf{u}}_j), \quad \bar{\mathbf{x}}_0 = \mathbf{x}_k = \mathbf{x}(t_k) \quad (6.11b)$$

$$\bar{\mathbf{x}}_j \in X, \quad \bar{\mathbf{u}}_j \in U, \quad j = 0, 1, \dots, N-1 \quad (6.11c)$$

$$\bar{\mathbf{x}}_N \in S \quad (6.11d)$$

mit N Prädiktionsschritten und der Eingangsparametrierung $\hat{\mathbf{u}} = [\bar{\mathbf{u}}_0, \dots, \bar{\mathbf{u}}_{N-1}]^T$ verwendet. Für diese Formulierung lassen sich Aspekte wie asymptotische Stabilität mathematisch einfacher bzw. mit schwächeren Annahmen untersuchen.

Andererseits ist bekannt, dass für ein allgemeines nichtlineares zeitkontinuierliches System (6.1) die zeitdiskrete Darstellung (6.10) nur *näherungsweise* berechnet werden kann. Des Weiteren sind die systemdynamischen Eigenschaften des Originalsystems (6.1) in der zeitkontinuierlichen MPC-Formulierung besser ersichtlich. Aus diesen Gründen wird in weiterer Folge die zeitkontinuierliche MPC-Formulierung aus Abschnitt 6.1.1 als Basis verwendet.

6.2 MPC-Formulierungen

In der Praxis und aus der Historie heraus existieren verschiedene MPC-Formulierungen basierend auf der allgemeinen Darstellung des Optimierungsproblems (6.4). Die Formulierungen unterscheiden sich dabei häufig in ihrer Bedeutung für die Theorie und Praxis. So sind z.B. Endbeschränkungen der Form (6.4d) nützlich, um Stabilität im geschlossenen Regelkreis zu garantieren. Andererseits ist die Gewährleistung der Existenz einer Lösung bei einer endbeschränkten MPC-Formulierung schwierig und der numerische Aufwand zur Lösung des Optimierungsproblems (6.4) in der Regel deutlich höher als im Falle eines freien Endzustandes. Im Folgenden wird ein Überblick über die verschiedenen MPC-Formulierungen gegeben und die jeweiligen Stabilitätseigenschaften im geschlossenen Kreis untersucht.

6.2.1 Unendlicher Horizont

Wird ein unendlich langer Prädiktionshorizont betrachtet, d.h. $T \rightarrow \infty$, so lässt sich das Optimierungsproblem (6.4) ohne die Endbeschränkungen (6.4d) und ohne die Endkostengewichtung

in (6.4a) formulieren, da die optimale Lösung ohnehin $\lim_{t \rightarrow \infty} \bar{\mathbf{x}}_{\infty}^*(t; \mathbf{x}_k) = \mathbf{0}$ erfüllen muss, damit das Kostenfunktional einen endlichen Wert besitzt. Somit ergibt sich die Formulierung

$$\min_{\bar{\mathbf{u}}(\cdot)} \quad J_{\infty}(\mathbf{x}_k, \bar{\mathbf{u}}) = \int_0^{\infty} l(\bar{\mathbf{x}}(\tau), \bar{\mathbf{u}}(\tau)) d\tau \quad (6.12a)$$

$$\text{u.B.v.} \quad \dot{\bar{\mathbf{x}}}(\tau) = \mathbf{f}(\bar{\mathbf{x}}(\tau), \bar{\mathbf{u}}(\tau)), \quad \bar{\mathbf{x}}(0) = \mathbf{x}_k = \mathbf{x}(t_k) \quad (6.12b)$$

$$\bar{\mathbf{x}}(\tau) \in X, \quad \bar{\mathbf{u}}(\tau) \in U, \quad \tau \in [0, \infty). \quad (6.12c)$$

Es gilt nun folgender Satz:

Satz 6.1 (MPC mit unendlichem Horizont) Die Menge $\Gamma \subseteq X \subseteq \mathbb{R}^n$ aller Anfangsbedingungen $\mathbf{x}_k$, für die (6.12) lösbar ist, sei nichtleer. Dann gilt

$$J_{\infty}^*(\bar{\mathbf{x}}_{\infty}^*(\Delta t; \mathbf{x}_k)) = J_{\infty}^*(\mathbf{x}_k) - \int_0^{\Delta t} l(\bar{\mathbf{x}}_{\infty}^*(\tau; \mathbf{x}_k), \bar{\mathbf{u}}_{\infty}^*(\tau; \mathbf{x}_k)) d\tau \quad \forall \mathbf{x}_k \in \Gamma. \quad (6.13)$$

Des Weiteren ist der Ursprung des geregelten Systems (6.1) asymptotisch stabil im Sinne von $\lim_{t \rightarrow \infty} \|\mathbf{x}(t)\| = 0$ und Γ stellt den Einzugsbereich dar.

Beweis: Die Gleichung (6.13) folgt direkt aus dem Optimalitätsprinzip nach Bellman. Falls (6.12) für $t = t_0$ eine Lösung besitzt ($\mathbf{x}_0 \in \Gamma$), ist aufgrund des unendlichen Horizonts im nominellen Fall gesichert, dass (6.12) auch für den nächsten Punkt $\mathbf{x}_{k+1} = \bar{\mathbf{x}}_{\infty}^*(\Delta t; \mathbf{x}_k)$ lösbar ist, d.h. $\bar{\mathbf{x}}_{\infty}^*(\Delta t; \mathbf{x}_k) \in \Gamma$. Durch Induktion ergibt sich somit für die Trajektorien (6.9) im geschlossenen Kreis

$$J_{\infty}^*(\mathbf{x}(t)) = J_{\infty}^*(\mathbf{x}_0) - \int_0^t l(\mathbf{x}(\tau), \mathbf{u}(\tau)) d\tau \stackrel{(6.5)}{\leq} J_{\infty}^*(\mathbf{x}_0) - \int_0^t m_l \|\mathbf{x}(\tau)\|^2 d\tau. \quad (6.14)$$

Da $J_{\infty}^*(\mathbf{x}_0)$, $\mathbf{x}_0 \in \Gamma$ beschränkt ist und $J_{\infty}^*(\mathbf{x}(t)) \geq 0$ gilt, ist das Integral in (6.14) ebenfalls beschränkt. Mit der grundlegenden Annahme A.1 folgt daraus, dass $\mathbf{x}(t)$ für alle Zeiten beschränkt ist. Dies gilt auch für die Zeitableitung $\dot{\mathbf{x}}(t) = \mathbf{f}(\mathbf{x}(t), \mathbf{u}(t))$ mit $\mathbf{u}(t) \in U$, $t \geq t_0$, da U kompakt und $\mathbf{f}$ stetig differenzierbar ist. Somit ist $\mathbf{x}(t)$ gleichmäßig stetig. An dieser Stelle ist nun das Lemma von Barbalat von Bedeutung:

Lemma 6.1 (Barbalat's Lemma) Sei $\phi : \mathbb{R} \rightarrow \mathbb{R}$ eine gleichmäßig stetige Funktion auf dem Intervall $[0, \infty)$. Wenn das Integral

$$\lim_{t \rightarrow \infty} \int_0^t \phi(\tau) d\tau$$

existiert und endlich ist, so gilt $\lim_{t \rightarrow \infty} \phi(t) = 0$.

Mit $\phi(\tau) = \|\mathbf{x}(\tau)\|^2$ sind die Voraussetzungen von Lemma 6.1 erfüllt und es gilt folglich $\|\mathbf{x}(t)\| \rightarrow 0$ für $t \rightarrow \infty$. ■

Es sei angemerkt, dass die Eigenschaft $\lim_{t \rightarrow \infty} \|\mathbf{x}(t)\| = 0$ nicht automatisch die Stabilität im Sinne von Lyapunov impliziert (siehe z.B. die Vorlesung "Nichtlineare Regelungen"). Diese kann gezeigt werden, wenn zusätzlich die Stetigkeit von J_{∞}^* auf Γ angenommen wird.

Wenn J_∞^* auf Γ sogar stetig differenzierbar ist, die Niveaumengen von J_∞^* kompakt sind und der Grenzübergang $\Delta t \rightarrow 0$ betrachtet wird, so gilt für die Trajektorien (6.9) im geschlossenen Kreis

$$\frac{d}{dt} J_\infty^*(\mathbf{x}(t)) = \frac{\partial J_\infty^*(\mathbf{x}(t))}{\partial \mathbf{x}} \mathbf{f}(\mathbf{x}(t), \mathbf{u}(t)) = -l(\mathbf{x}(t), \mathbf{u}(t)) \stackrel{(6.5)}{\leq} -m_l \|\mathbf{x}(t)\|^2 \leq 0. \quad (6.15)$$

Daraus folgt, dass jede kompakte Untermenge

$$\Gamma_\alpha = \{\mathbf{x} \in \Gamma : J_\infty^*(\mathbf{x}) \leq \alpha\} \quad (6.16)$$

des Einzugsbereichs Γ *positiv invariant* ist. Dies gilt sowohl für den inkrementellen ($\Delta t > 0$) als auch für den infinitesimalen Fall ($\Delta t \rightarrow 0$). Die optimale Kostenfunktion $J_\infty^*(\mathbf{x})$ stellt somit eine *Lyapunov-Funktion* dar, was impliziert, dass der Ursprung im geschlossenen Kreis asymptotisch stabil ist.

6.2.2 Endlicher Horizont und Endbeschränkungen

In der Praxis ist die numerische Lösung des Problems (6.12) auf einem unendlichen Horizont nur näherungsweise möglich und zudem mit einem hohen Rechenaufwand verbunden. Aus der MPC-Historie heraus entstanden deshalb Überlegungen, welche Bedingungen bei einer MPC-Formulierung mit endlichem Horizont $T < \infty$ gelten müssen, damit Stabilität im geschlossenen Kreis garantiert werden kann. Diese Überlegungen führten auf die folgende MPC-Formulierung mit Endbeschränkung:

$$\min_{\bar{\mathbf{u}}(\cdot)} J_T(\mathbf{x}_k, \bar{\mathbf{u}}) = \int_0^T l(\bar{\mathbf{x}}(\tau), \bar{\mathbf{u}}(\tau)) d\tau \quad (6.17a)$$

$$\text{u.B.v. } \dot{\bar{\mathbf{x}}}(\tau) = \mathbf{f}(\bar{\mathbf{x}}(\tau), \bar{\mathbf{u}}(\tau)), \quad \bar{\mathbf{x}}(0) = \mathbf{x}_k = \mathbf{x}(t_k) \quad (6.17b)$$

$$\bar{\mathbf{x}}(\tau) \in X, \quad \bar{\mathbf{u}}(\tau) \in U, \quad \tau \in [0, T] \quad (6.17c)$$

$$\bar{\mathbf{x}}(T) = \mathbf{0}. \quad (6.17d)$$

Es wird also gefordert, dass die optimale Zustandstrajektorie $\bar{\mathbf{x}}_T^*(\tau; \mathbf{x}_k)$ am Ende des Prädiktionshorizonts T den Ursprung exakt erreicht. Unter dieser Nebenbedingung gilt der folgende Satz:

Satz 6.2 (MPC mit Endbeschränkung) Die Menge $\Gamma \subseteq X \subseteq \mathbb{R}^n$ aller Anfangsbedingungen $\mathbf{x}_k$, für die (6.17) lösbar ist, sei nichtleer. Dann gilt

$$J_T^*(\bar{\mathbf{x}}_T^*(\Delta t; \mathbf{x}_k)) \leq J_T^*(\mathbf{x}_k) - \int_0^{\Delta t} l(\bar{\mathbf{x}}_T^*(\tau; \mathbf{x}_k), \bar{\mathbf{u}}_T^*(\tau; \mathbf{x}_k)) d\tau \quad \forall \mathbf{x}_k \in \Gamma. \quad (6.18)$$

Des Weiteren ist der Ursprung des geregelten Systems (6.1) asymptotisch stabil im Sinne von $\lim_{t \rightarrow \infty} \|\mathbf{x}(t)\| = 0$ und Γ stellt den Einzugsbereich dar.

Beweis: Da $\bar{\mathbf{x}}_T^*(T; \mathbf{x}_k) = \mathbf{0}$ für alle $\mathbf{x}_k \in \Gamma$ ist, stellt

$$\hat{\mathbf{x}}(\tau) = \begin{cases} \bar{\mathbf{x}}_T^*(\tau + \Delta t; \mathbf{x}_k) & \tau \in [0, T - \Delta t) \\ \mathbf{0} & \tau \in [T - \Delta t, T] \end{cases}, \quad \hat{\mathbf{u}}(\tau) = \begin{cases} \bar{\mathbf{u}}_T^*(\tau + \Delta t; \mathbf{x}_k) & \tau \in [0, T - \Delta t) \\ \mathbf{0} & \tau \in [T - \Delta t, T] \end{cases}$$

eine zulässige Trajektorie für das endbeschränkte Problem (6.17) im Schritt $k+1$ dar, d.h. für $\mathbf{x}_{k+1} = \bar{\mathbf{x}}_T^*(\Delta t; \mathbf{x}_k)$. Für das Kostenfunktional gilt nun

$$\begin{aligned} J_T^*(\bar{\mathbf{x}}_T^*(\Delta t; \mathbf{x}_k)) &\leq \int_0^T l(\hat{\mathbf{x}}(\tau), \hat{\mathbf{u}}(\tau)) d\tau \\ &= \int_{\Delta t}^T l(\bar{\mathbf{x}}_T^*(\tau; \mathbf{x}_k), \bar{\mathbf{u}}_T^*(\tau; \mathbf{x}_k)) dt + \overbrace{\int_0^{\Delta t} l(\mathbf{0}, \mathbf{0}) dt}^{=0} \\ &= J_T^*(\mathbf{x}_k) - \int_0^{\Delta t} l(\bar{\mathbf{x}}_T^*(\tau; \mathbf{x}_k), \bar{\mathbf{u}}_T^*(\tau; \mathbf{x}_k)) dt \end{aligned}$$

was (6.18) beweist. Der Beweis der Stabilität ($\lim_{t \rightarrow \infty} \|\mathbf{x}(t)\| = 0$) entspricht dem Vorgehen im Beweis von Satz 6.1. ■

Die Verwendung der Endbeschränkung (6.17d) ist mit mehreren Nachteilen verbunden. Einerseits kann die Menge Γ , auf der das Problem (6.17) lösbar ist, sehr klein sein, wenn ein kurzer Prädiktionshorizont T verwendet wird. In der Praxis bedeutet dies insbesondere, dass die Lösbarkeit beim Auftreten von Störungen nicht garantiert werden kann. Andererseits ist die (numerisch) exakte Einhaltung einer Endbeschränkung im Allgemeinen mit einem hohen numerischen Aufwand verbunden.

6.2.3 Endlicher Horizont und Endregion

Eine naheliegende Möglichkeit zum Aufweichen der Endbeschränkung $\bar{\mathbf{x}}(T) = \mathbf{0}$ in (6.17) besteht darin, diese durch eine *Endregion* $S_\beta \subseteq X$ zu ersetzen, die den zu stabilisierenden Ursprung beinhaltet ($\mathbf{0} \in S_\beta$). Somit ergibt sich die folgende MPC-Formulierung mit Endregion

$$\min_{\bar{\mathbf{u}}(\cdot)} \quad J_T(\mathbf{x}_k, \bar{\mathbf{u}}) = V(\bar{\mathbf{x}}(T)) + \int_0^T l(\bar{\mathbf{x}}(\tau), \bar{\mathbf{u}}(\tau)) d\tau \quad (6.19a)$$

$$\text{u.B.v.} \quad \dot{\bar{\mathbf{x}}}(\tau) = \mathbf{f}(\bar{\mathbf{x}}(\tau), \bar{\mathbf{u}}(\tau)), \quad \bar{\mathbf{x}}(0) = \mathbf{x}_k = \mathbf{x}(t_k) \quad (6.19b)$$

$$\bar{\mathbf{x}}(\tau) \in X, \quad \bar{\mathbf{u}}(\tau) \in U, \quad \tau \in [0, T] \quad (6.19c)$$

$$\bar{\mathbf{x}}(T) \in S_\beta. \quad (6.19d)$$

Zur Gewährleistung der asymptotischen Stabilität im Sinne von $\lim_{t \rightarrow \infty} \|\mathbf{x}(t)\| = 0$ ist nun zusätzlich eine Endkostengewichtung im Kostenfunktional (6.19a) notwendig, für die zusätzliche Forderungen gelten, wie im nächsten Satz gezeigt wird.

Satz 6.3 (MPC mit Endregion) Die Menge $\Gamma \subseteq X \subseteq \mathbb{R}^n$ aller Anfangsbedingungen $\mathbf{x}_k$, für die (6.19) lösbar ist, sei nichtleer. Des Weiteren existiere eine kompakte nichtleere Menge $S_\beta = \{\mathbf{x} \in \mathbb{R}^n : V(\mathbf{x}) \leq \beta\} \subseteq \Gamma$ mit $\beta > 0$ und ein (lokales) Regelgesetz $\mathbf{q}(\mathbf{x}) \in U$ für alle $\mathbf{x} \in S_\beta$ so, dass

$$\frac{\partial V}{\partial \mathbf{x}} \mathbf{f}(\mathbf{x}, \mathbf{q}(\mathbf{x})) + l(\mathbf{x}, \mathbf{q}(\mathbf{x})) \leq 0 \quad \forall \mathbf{x} \in S_\beta \quad (6.20)$$

erfüllt ist. Dann gilt

$$J_T^*(\bar{\mathbf{x}}_T^*(\Delta t; \mathbf{x}_k)) \leq J_T^*(\mathbf{x}_k) - \int_0^{\Delta t} l(\bar{\mathbf{x}}_T^*(\tau; \mathbf{x}_k), \bar{\mathbf{u}}_T^*(\tau; \mathbf{x}_k)) d\tau \quad \forall \mathbf{x}_k \in \Gamma. \quad (6.21)$$

Des Weiteren ist der Ursprung des geregelten Systems (6.1) asymptotisch stabil im Sinne von $\lim_{t \rightarrow \infty} \|\mathbf{x}(t)\| = 0$ und Γ stellt den Einzugsbereich dar.

Beweis: Da $\bar{\mathbf{x}}_T^*(T; \mathbf{x}_k) \in S_\beta$ für alle $\mathbf{x}_k \in \Gamma$ ist, wird für den nächsten MPC-Schritt mit Anfangszustand $\mathbf{x}_{k+1} = \bar{\mathbf{x}}_T^*(\Delta t; \mathbf{x}_k)$ zunächst die zusammengesetzte Trajektorie

$$\hat{\mathbf{x}}(\tau) = \begin{cases} \bar{\mathbf{x}}_T^*(\tau + \Delta t; \mathbf{x}_k), & \tau \in [0, T - \Delta t) \\ \bar{\mathbf{x}}^q(\tau - T + \Delta t), & \tau \in [T - \Delta t, T] \end{cases}, \quad \hat{\mathbf{u}}(\tau) = \begin{cases} \bar{\mathbf{u}}_T^*(\tau + \Delta t; \mathbf{x}_k), & \tau \in [0, T - \Delta t) \\ \bar{\mathbf{u}}^q(\tau - T + \Delta t), & \tau \in [T - \Delta t, T] \end{cases}$$

betrachtet, wobei $\bar{\mathbf{x}}^q(\tau)$ mit $\bar{\mathbf{x}}^q(0) = \bar{\mathbf{x}}_T^*(T; \mathbf{x}_k)$ die Trajektorie darstellt, die sich durch Anwendung des lokalen Regelgesetzes $\bar{\mathbf{u}}^q(\tau) = \mathbf{q}(\bar{\mathbf{x}}^q(\tau))$ ergibt. Dabei gilt $\bar{\mathbf{x}}^q(\tau) \in S_\beta$ für alle $\tau \geq 0$, d.h. S_β ist positiv invariant aufgrund der Definition von S_β und der Ungleichung (6.20), die in der Form

$$\frac{d}{d\tau} V(\bar{\mathbf{x}}^q(\tau)) \leq -l(\bar{\mathbf{x}}^q(\tau), \bar{\mathbf{u}}^q(\tau)) \quad (6.22)$$

geschrieben werden kann. Offensichtlich ist die Trajektorie $\hat{\mathbf{x}}(\tau)$, $\hat{\mathbf{u}}(\tau)$, $\tau \in [0, T]$ für das Problem (6.19) im Schritt $k + 1$, (d.h. für $\mathbf{x}_{k+1} = \bar{\mathbf{x}}_T^*(\Delta t; \mathbf{x}_k)$) zulässig, wodurch dessen Lösbarkeit im Schritt $k + 1$ gewährleistet ist. Es gilt nun

$$\begin{aligned} J_T^*(\bar{\mathbf{x}}_T^*(\Delta t; \mathbf{x}_k)) &\leq \int_0^T l(\hat{\mathbf{x}}(\tau), \hat{\mathbf{u}}(\tau)) d\tau + V(\hat{\mathbf{x}}(T)) \\ &= J_T^*(\mathbf{x}_k) - \int_0^{\Delta t} l(\bar{\mathbf{x}}_T^*(\tau; \mathbf{x}_k), \bar{\mathbf{u}}_T^*(\tau; \mathbf{x}_k)) d\tau \\ &\quad + \underbrace{V(\bar{\mathbf{x}}^q(\Delta t)) - V(\bar{\mathbf{x}}^q(0)) + \int_0^{\Delta t} l(\bar{\mathbf{x}}^q(\tau), \bar{\mathbf{u}}^q(\tau)) d\tau}_{\leq 0}. \end{aligned} \quad (6.23)$$

Die Integration der Ungleichung (6.22) zeigt, dass der unterklammerte Ausdruck in (6.23) nicht-positiv ist, was (6.21) beweist. Der Beweis der Stabilität im geschlossenen Kreis im Sinne von $\lim_{t \rightarrow \infty} \|\mathbf{x}(t)\| = 0$ entspricht dem Vorgehen im Beweis von Satz 6.1. ■

Die wichtigste Forderung in Satz 6.3 ist die Existenz des (lokalen) Regelgesetzes $\mathbf{q}(\mathbf{x})$, so dass die Endkostengewichtung $V(\mathbf{x})$ die Ungleichung (6.20) erfüllt. Aus der nichtlinearen Regelungstechnik ist bekannt, dass (6.20) eine *Control-Lyapunov-Ungleichung* darstellt und somit offensichtlich gefordert wird, dass $V(\mathbf{x})$ eine *Control-Lyapunov-Funktion* (CLF) und $\mathbf{q}(\mathbf{x})$ ein CLF-Regelgesetz darstellt.

Aufgabe 6.1 (CLF im linearen unbeschränkten Fall) Betrachtet wird die lineare und unbeschränkte MPC-Formulierung

$$\min_{\bar{\mathbf{u}}(\cdot)} J_T(\mathbf{x}_k, \bar{\mathbf{u}}) = \bar{\mathbf{x}}^T(T) \mathbf{P} \bar{\mathbf{x}}(T) + \int_0^T \bar{\mathbf{x}}^T(\tau) \mathbf{Q} \bar{\mathbf{x}}(\tau) + \bar{\mathbf{u}}^T(\tau) \mathbf{R} \bar{\mathbf{u}}(\tau) d\tau \quad (6.24a)$$

$$\text{u.B.v. } \dot{\bar{\mathbf{x}}}(\tau) = \mathbf{A} \bar{\mathbf{x}}(\tau) + \mathbf{B} \bar{\mathbf{u}}(\tau), \quad \bar{\mathbf{x}}(0) = \mathbf{x}_k = \mathbf{x}(t_k) \quad (6.24b)$$

mit $\mathbf{x} \in \mathbb{R}^n$, $\mathbf{u} \in \mathbb{R}^m$ und den symmetrischen und positiv definiten Matrizen $\mathbf{Q} \in \mathbb{R}^{n \times n}$ und $\mathbf{R} \in \mathbb{R}^{m \times m}$. Das System (6.24b) sei stabilisierbar und die Matrix $\mathbf{P}$ stelle die Lösung der algebraischen Riccati-Gleichung

$$\mathbf{P} \mathbf{A} + \mathbf{A}^T \mathbf{P} - \mathbf{P} \mathbf{B} \mathbf{R}^{-1} \mathbf{B}^T \mathbf{P} + \mathbf{Q} = \mathbf{0} \quad (6.25)$$

dar. Zeigen Sie, dass in diesem Fall die CLF-Ungleichung (6.20) durch das Regelgesetz

$$\mathbf{q}(\mathbf{x}) = -\mathbf{K}\mathbf{x}, \quad \mathbf{K} = \mathbf{R}^{-1}\mathbf{B}^\top \mathbf{P} \quad (6.26)$$

auf $S_\beta = \mathbb{R}^n$ erfüllt ist und somit auf die Betrachtung der Endregion S verzichtet werden kann.

In der linearen MPC-Formulierung (6.24) kann die CLF-Ungleichung (6.20) also auf relativ einfache Weise und vor allem *global* garantiert werden, wodurch auch die Betrachtung der Endregion S_β entfallen kann.

Aufgabe 6.2 (CLF im nichtlinearen unbeschränkten Fall) Betrachtet wird die nicht-lineare MPC-Formulierung

$$\min_{\bar{\mathbf{u}}(\cdot)} \quad J_T(\mathbf{x}_k, \bar{\mathbf{u}}) = \bar{\mathbf{x}}^\top(T) \mathbf{P} \bar{\mathbf{x}}(T) + \int_0^T \gamma \bar{\mathbf{x}}^\top(\tau) \mathbf{Q} \bar{\mathbf{x}}(\tau) + \bar{\mathbf{u}}^\top(\tau) \mathbf{R} \bar{\mathbf{u}}(\tau) d\tau \quad (6.27a)$$

$$\text{u.B.v.} \quad \dot{\bar{\mathbf{x}}}(\tau) = \mathbf{f}(\bar{\mathbf{x}}(\tau), \bar{\mathbf{u}}(\tau)), \quad \bar{\mathbf{x}}(0) = \mathbf{x}_k = \mathbf{x}(t_k) \quad (6.27b)$$

$$\bar{\mathbf{x}}(T) \in S_\beta. \quad (6.27c)$$

mit $\mathbf{x} \in \mathbb{R}^n$, $\mathbf{u} \in \mathbb{R}^m$, den positiv definiten Matrizen $\mathbf{Q} \in \mathbb{R}^{n \times n}$ und $\mathbf{R} \in \mathbb{R}^{m \times m}$ sowie einer Konstanten $\gamma \in (0, 1)$. Die Linearisierung des Systems (6.27b) um den Ursprung sei stabilisierbar und $\mathbf{P}$ stelle die Lösung der entsprechenden algebraischen Riccati-Gleichung (6.25) dar. Zeigen Sie, dass für jedes $\gamma \in (0, 1)$ eine Endregion $S_\beta \ni \mathbf{0}$ existiert, auf der die CLF-Ungleichung (6.20) mit dem lokalen Regelgesetz (6.26) erfüllt ist.

Im nichtlinearen Fall (6.27) wird der zusätzliche Parameter $\gamma \in (0, 1)$ verwendet, um den Integralanteil im Vergleich zur Endkostengewichtung abzuschwächen, damit eine nicht verschwindende Endregion S_β existiert.

In Aufgabe 6.1 und 6.2 wird die Endkostenfunktion $V(\mathbf{x})$ mit Hilfe der Riccati-Gleichung (6.25) bestimmt. In der Literatur existieren weitere Ansätze zur Konstruktion von $V(\mathbf{x})$, damit diese die CLF-Ungleichung (6.20) erfüllt. Ein entsprechender Algorithmus zur Berechnung von $V(\mathbf{x})$ und der Endregion S_β ist z.B. in [4] angegeben.

6.2.4 Endlicher Horizont und Endkostengewichtung

Die Ersetzung der Endbeschränkung $\bar{\mathbf{x}}(T) = \mathbf{0}$ durch die Endregion $\bar{\mathbf{x}}(T) \in S_\beta$ im vorherigen Abschnitt führt bereits zu einer deutlichen Vereinfachung der MPC-Problemstellung. Hinsichtlich einer praktischen Implementierung eines modellprädiktiven Reglers ist es aber von Vorteil, wenn selbst die Endregion $\bar{\mathbf{x}}(T) \in S_\beta$ weggelassen werden kann, um ein dynamisches Optimierungsproblem mit freiem Endzustand zu erhalten:

$$\min_{\bar{\mathbf{u}}(\cdot)} \quad J_T(\mathbf{x}_k, \bar{\mathbf{u}}) = V(\bar{\mathbf{x}}(T)) + \int_0^T l(\bar{\mathbf{x}}(\tau), \bar{\mathbf{u}}(\tau)) d\tau \quad (6.28a)$$

$$\text{u.B.v.} \quad \dot{\bar{\mathbf{x}}}(\tau) = \mathbf{f}(\bar{\mathbf{x}}(\tau), \bar{\mathbf{u}}(\tau)), \quad \bar{\mathbf{x}}(0) = \mathbf{x}_k = \mathbf{x}(t_k) \quad (6.28b)$$

$$\bar{\mathbf{x}}(\tau) \in X, \quad \bar{\mathbf{u}}(\tau) \in U, \quad \tau \in [0, T]. \quad (6.28c)$$

Da in der Problemstellung (6.28) auf die Vorgabe der Endregion S_β verzichtet wurde, stellt sich nun die Frage, unter welchen Bedingungen der Endpunkt einer optimalen prädizierten Trajektorie $\bar{\mathbf{x}}_T^*(T; \mathbf{x}_k)$ die Menge S_β erreichen kann, auf der die CLF-Ungleichung (6.20) erfüllt ist. Der Beweis des folgenden Lemmas orientiert sich am Vorgehen in [18].

Lemma 6.2 (Erreichbarkeit der Endregion) Die Menge $\Gamma \subseteq X \subseteq \mathbb{R}^n$ aller Anfangsbedingungen $\mathbf{x}_k$, für die (6.28) lösbar ist, sei nichtleer und es existiere eine kompakte nichtleere Menge $S_\beta = \{\mathbf{x} \in \mathbb{R}^n : V(\mathbf{x}) \leq \beta\} \subseteq \Gamma$ sowie ein (lokales) Regelgesetz $\mathbf{q}(\mathbf{x}) \in U$ für alle $\mathbf{x} \in S_\beta$ so, dass

$$\frac{\partial V}{\partial \mathbf{x}} \mathbf{f}(\mathbf{x}, \mathbf{q}(\mathbf{x})) + l(\mathbf{x}, \mathbf{q}(\mathbf{x})) \leq 0 \quad \forall \mathbf{x} \in S_\beta. \quad (6.29)$$

erfüllt ist. Des Weiteren betrachte man die kompakte Menge

$$\Gamma_\alpha = \{\mathbf{x} \in \Gamma : J_T^*(\mathbf{x}) \leq \alpha\}, \quad \alpha = \beta \left(1 + \frac{m_l}{M_V} T\right) \quad (6.30)$$

mit den Konstanten $m_l, M_V > 0$ aus (6.5). Dann gilt $\bar{\mathbf{x}}_T^*(T; \mathbf{x}_k) \in S_\beta$ für alle $\mathbf{x}_k \in \Gamma_\alpha$ sowie $S_\beta \subseteq \Gamma_\alpha$.

Für alle $\mathbf{x}_k \in \Gamma_\alpha$ ist das Erreichen der Endregion S_β also automatisch gewährleistet. Der folgende Satz fasst nun die Stabilitätseigenschaften zusammen.

Satz 6.4 (MPC mit Endkostengewichtung) Die Annahmen aus Lemma 6.2 seien erfüllt. Dann gilt

$$J_T^*(\bar{\mathbf{x}}_T^*(\Delta t; \mathbf{x}_k)) \leq J_T^*(\mathbf{x}_k) - \int_0^{\Delta t} l(\bar{\mathbf{x}}_T^*(\tau; \mathbf{x}_k), \bar{\mathbf{u}}_T^*(\tau; \mathbf{x}_k)) d\tau \quad \forall \mathbf{x}_k \in \Gamma_\alpha. \quad (6.31)$$

Des Weiteren ist der Ursprung des geregelten Systems (6.1) asymptotisch stabil im Sinne von $\lim_{t \rightarrow \infty} \|\mathbf{x}(t)\| = 0$ und Γ_α liegt im Einzugsbereich.

Beweis: Für $\mathbf{x}_k \in \Gamma_\alpha$ folgt mit Hilfe von Lemma 6.2 $\bar{\mathbf{x}}_T^*(T; \mathbf{x}_k) \in S_\beta$. Die Herleitung der Ungleichung (6.31) folgt dann dem Beweis von Satz 6.3 ebenso wie die Gewährleistung der Existenz einer Lösung von (6.28) im Schritt $k+1$. Des Weiteren gilt $\bar{\mathbf{x}}_T^*(\Delta t; \mathbf{x}_k) \in \Gamma_\alpha$, so dass (6.31) auch im Schritt $k+1$ und allen weiteren MPC-Schritten gilt. Der Beweis der Stabilität im geschlossenen Kreis ($\lim_{t \rightarrow \infty} \|\mathbf{x}(t)\| = 0$) entspricht wieder dem Vorgehen im Beweis von Satz 6.1. ■

Aus der Definition des Einzugsbereiches in (6.30) ist ersichtlich, dass Γ_α durch die Wahl eines längeren Prädiktionshorizonts T vergrößert werden kann, siehe Abbildung 6.3. Dies ist eine oft beobachtete und intuitiv verständliche Eigenschaft von MPC.

Beispiel 6.1 Betrachtet wird das nichtlineare System [4]

$$\begin{aligned} \dot{x}_1 &= x_2 + (\mu + (1 - \mu)x_1)u, & x_1(0) &= x_{10} \\ \dot{x}_2 &= x_1 + (\mu - 4(1 - \mu)x_2)u, & x_2(0) &= x_{20} \end{aligned} \quad (6.32)$$

mit dem Zustand $\mathbf{x} = [x_1, x_2]^T$ und dem beschränkten Eingang $u \in U = [-2, 2]$. Der Parameter $\mu \in (0, 1)$ wird zu $\mu = 0.5$ gewählt. Der Ursprung ist eine instabile Ruhelage des




Abbildung 6.3: Einzugsbereich für den MPC-Fall mit Endkostengewichtung.

Systems (6.32) und die Linearisierung um den Ursprung ist stabilisierbar. Der Integralanteil im Kostenfunktional (6.28a) wird durch

$$l(\mathbf{x}, u) = 0.5x_1^2 + 0.5x_2^2 + u^2 \quad (6.33)$$

angesetzt. In [4] wurde die Endkostengewichtung

$$V(\mathbf{x}) = \mathbf{x}^T \mathbf{P} \mathbf{x} \quad \text{mit} \quad \mathbf{P} = \begin{bmatrix} 16.5926 & 11.5926 \\ 11.5926 & 16.5926 \end{bmatrix} \quad (6.34)$$

und das lineare Regelgesetz $\mathbf{q}(\mathbf{x}) = [2.118, 2.118]\mathbf{x}$ berechnet, mit dem die CLF-Ungleichung (6.29) auf der Menge $S_\beta = \{\mathbf{x} \in \mathbb{R}^2 : V(\mathbf{x}) \leq \beta = 0.7\}$ erfüllt ist. Abbildung 6.4 (links) zeigt S_β sowie den Einzugsbereich Γ_α für verschieden lange Prädiktionshorizonte T . Für alle Startpunkte $\mathbf{x}_k \in \Gamma_\alpha$ liegt der Endpunkt $\bar{\mathbf{x}}_T^*(T; \mathbf{x}_k)$ in der Endregion S_β . Die einzelnen Mengen Γ_α wurden numerisch ermittelt und stellen somit eine bessere Abschätzung der Einzugsbereiche dar als die in der Regel konservative Definition (6.30). Wie bereits aus Lemma 6.2 bekannt ist, lässt sich anhand der Formen von S_β und Γ_α erkennen, dass $S_\beta \subseteq \Gamma_\alpha$ für alle T gilt und dass der Einzugsbereich Γ_α vergrößert werden kann, wenn der Prädiktionshorizont vergrößert wird. Zusätzlich stellt die rechte Hälfte von Abbildung 6.4 die simulierten Trajektorien im geschlossenen Kreis für den Anfangspunkt $\mathbf{x}_0 = [-0.5, -0.8]^T$ und $T = 1.5$ dar.




Abbildung 6.4: Endregion S_β mit $\beta = 0.7$ und Einzugsbereich Γ_α für verschiedene Horizontlängen T (Beispiel 6.1).

6.2.5 Hinreichend langer Horizont

Auch wenn die vorherige MPC-Formulierung ohne Endbeschränkungen auskommt, so ist für den Nachweis der Stabilität notwendig, dass $V(\mathbf{x})$ die CLF-Ungleichung (6.29) erfüllt. Je nach der Länge des Prädiktionshorizonts T führt dies aber zu einem dominanten Beitrag im Kostenfunktional und "verfälscht" das qualitative Regelverhalten, das über die Gewichtung im Integralterm vorgegeben werden kann (siehe Beispiel 6.1).

Andererseits ist aus Abschnitt 6.2.1 bekannt, dass bei einem unendlich langen Horizont Stabilität auch ohne Endkostenterm gewährleistet ist. Somit liegt die Frage nahe, ob bei einem "hinreichend langen" Horizont die asymptotische Stabilität garantiert werden kann, ohne dass die Endkostengewichtung $V(\mathbf{x})$ und die Erfüllung der CLF-Ungleichung (6.29) benötigt wird. Es wird also die folgende MPC-Formulierung betrachtet:

$$\min_{\bar{\mathbf{u}}(\cdot)} J_T(\mathbf{x}_k, \bar{\mathbf{u}}) = \int_0^T l(\bar{\mathbf{x}}(\tau), \bar{\mathbf{u}}(\tau)) d\tau \quad (6.35a)$$

$$\text{u.B.v. } \dot{\bar{\mathbf{x}}}(\tau) = \mathbf{f}(\bar{\mathbf{x}}(\tau), \bar{\mathbf{u}}(\tau)), \quad \bar{\mathbf{x}}(0) = \mathbf{x}_k = \mathbf{x}(t_k) \quad (6.35b)$$

$$\bar{\mathbf{u}}(\tau) \in U, \quad \tau \in [0, T]. \quad (6.35c)$$

Die Untersuchung dieser MPC-Formulierung ohne Endkostengewichtung und Endbeschränkung ist mathematisch aufwendiger als bei den vorherigen Fällen und verlangt strengere Annahmen. Aus diesem Grund wird auch auf die Betrachtung von Zustandsbeschränkungen $\bar{\mathbf{x}}(\tau) \in X$ verzichtet. Des Weiteren wird die Definition der (lokalen) Lipschitz-Stetigkeit benötigt:

Definition 6.1 (Lokale Lipschitz-Stetigkeit) Eine Funktion f heißt lokal Lipschitz-stetig in $\mathbf{x}$, wenn es um jeden Punkt $\mathbf{x}_0$ eine Umgebung $B_r(\mathbf{x}_0) = \{\mathbf{x} \in \mathbb{R}^n : \|\mathbf{x} - \mathbf{x}_0\| \leq r\}$ mit $r > 0$ und eine Lipschitz-Konstante $L > 0$ gibt, so dass für alle $\mathbf{x}_1, \mathbf{x}_2 \in B_r(\mathbf{x}_0)$ gilt:

$$\|f(\mathbf{x}_1) - f(\mathbf{x}_2)\| \leq L \|\mathbf{x}_1 - \mathbf{x}_2\|. \quad (6.36)$$

Für vektorwertige Funktionen $\mathbf{f}$ erweitert sich (6.36) zu $\|\mathbf{f}(\mathbf{x}_1) - \mathbf{f}(\mathbf{x}_2)\| \leq L \|\mathbf{x}_1 - \mathbf{x}_2\|$. Der folgende Satz zeigt nun, dass unter gewissen Annahmen stets ein hinreichend langer Horizont T gefunden werden kann, so dass das MPC-Schema stabil ist.

Satz 6.5 (MPC mit hinreichend langem Horizont) Das Problem (6.35) sei lösbar für alle $\mathbf{x}_k \in \mathbb{R}^n$ und $T \in [\Delta t, \infty)$. Des Weiteren gelte:

1. Das um den Ursprung linearisierte System (6.1) ist stabilisierbar.
2. $J_T^*(\mathbf{x})$ ist stetig differenzierbar in $\mathbf{x}$ und für alle $T \in [\Delta t, \infty)$.
3. Das optimale Regelgesetz in (6.8) ist lokal Lipschitz-stetig.

Dann existiert für jede kompakte Menge $\Gamma_\alpha = \{\mathbf{x} \in \mathbb{R}^n : J_\infty^*(\mathbf{x}) \leq \alpha\}$ mit $\alpha < \infty$ und für jedes $\delta \in (0, 1)$ ein $T_\delta < \infty$ derart, dass für alle $T \geq T_\delta$ gilt

$$J_T^*(\bar{\mathbf{x}}_T^*(\Delta t; \mathbf{x}_k)) \leq J_T^*(\mathbf{x}_k) - \delta \int_0^{\Delta t} l(\bar{\mathbf{x}}_T^*(\tau; \mathbf{x}_k), \bar{\mathbf{u}}_T^*(\tau; \mathbf{x}_k)) d\tau \quad \forall \mathbf{x}_k \in \Gamma_\alpha. \quad (6.37)$$

Für $T \geq T_\delta$ ist der Ursprung des geregelten Systems (6.1) exponentiell stabil und Γ_α liegt im Einzugsbereich.

Beweis: Aufgrund des Bellmanschen Optimalitätsprinzips lässt sich das optimale Kostenfunktional $J_T^*(\mathbf{x}_k)$ am Punkt $\mathbf{x}_k$ in die zwei Anteile

$$J_T^*(\mathbf{x}_k) = \int_0^{\Delta t} l(\bar{\mathbf{x}}_T^*(\tau; \mathbf{x}_k), \bar{\mathbf{u}}_T^*(\tau; \mathbf{x}_k)) d\tau + J_{T-\Delta t}^*(\bar{\mathbf{x}}_T^*(\Delta t; \mathbf{x}_k)) \quad (6.38)$$

aufspalten. Des Weiteren gilt $J_{T_1}^*(\mathbf{x}_k) \leq J_{T_2}^*(\mathbf{x}_k)$ für alle $T_1 \leq T_2$, was aus der Ungleichung

$$J_{T_1}^*(\mathbf{x}_k) \leq \int_0^{T_1} l(\bar{\mathbf{x}}_{T_2}^*(\tau; \mathbf{x}_k), \bar{\mathbf{u}}_{T_2}^*(\tau; \mathbf{x}_k)) d\tau \leq J_{T_2}^*(\mathbf{x}_k)$$

leicht ersichtlich ist. Durch Negierung der Gleichung (6.38), Addition von $J_T^*(\bar{\mathbf{x}}_T^*(\Delta t; \mathbf{x}_k))$ und Verwendung von $J_T^*(\bar{\mathbf{x}}_T^*(\Delta t; \mathbf{x}_k)) \leq J_\infty^*(\bar{\mathbf{x}}_T^*(\Delta t; \mathbf{x}_k))$ erhält man

$$\begin{aligned} & J_T^*(\bar{\mathbf{x}}_T^*(\Delta t; \mathbf{x}_k)) - J_T^*(\mathbf{x}_k) \\ & \leq J_\infty^*(\bar{\mathbf{x}}_T^*(\Delta t; \mathbf{x}_k)) - J_{T-\Delta t}^*(\bar{\mathbf{x}}_T^*(\Delta t; \mathbf{x}_k)) - \int_0^{\Delta t} l(\bar{\mathbf{x}}_T^*(\tau; \mathbf{x}_k), \bar{\mathbf{u}}_T^*(\tau; \mathbf{x}_k)) d\tau. \end{aligned} \quad (6.39)$$

Zur weiteren Untersuchung wird die Funktion $\psi_T : X_\alpha \rightarrow \mathbb{R}$

$$\psi_T(\mathbf{x}) = \begin{cases} \frac{J_\infty^*(\mathbf{x}) - J_{T-\Delta t}^*(\mathbf{x})}{J_{\Delta t}^*(\mathbf{x})} & \text{falls } \mathbf{x} \neq \mathbf{0} \\ \limsup_{\mathbf{x} \rightarrow \mathbf{0}} \psi_T(\mathbf{x}) & \text{falls } \mathbf{x} = \mathbf{0} \end{cases} \quad (6.40)$$

auf der kompakten Menge

$$X_\alpha \subset \mathbb{R}^n : \quad \bar{\mathbf{x}}_T^*(\tau; \mathbf{x}_k) \in X_\alpha, \quad \tau \in [0, \Delta t] \quad \forall \mathbf{x}_k \in \Gamma_\alpha, \quad T \in [\Delta t, \infty) \quad (6.41)$$

definiert. Für $\mathbf{x} \neq \mathbf{0}$ ist ersichtlich, dass $\psi_T(\mathbf{x})$ stetig und für $T \in [\Delta t, \infty)$ monoton fallend ist. Für den kritischen Punkt $\mathbf{x} = \mathbf{0}$ lässt sich zeigen [15], dass $\psi_T(\mathbf{0})$ beschränkt ist und $\lim_{T \rightarrow \infty} \psi_T(\mathbf{0}) = 0$ gilt. Somit kann festgehalten werden, dass $\psi_T(\mathbf{x})$ für alle $\mathbf{x} \in X_\alpha$ stetig und beschränkt ist und für jedes feste $\mathbf{x} \in X_\alpha$ in T monoton fallend ist, wobei das Limit $\lim_{T \rightarrow \infty} \psi_T(\mathbf{x}) = 0$ gilt. An dieser Stelle ist der *Satz von Dini* von Bedeutung:

Lemma 6.3 (Satz von Dini) Die Folge stetiger Funktionen $f_n : X \rightarrow \mathbb{R}$ strebe auf der kompakten Menge X monoton gegen eine Funktion $f : X \rightarrow \mathbb{R}$. Ist f stetig, so ist die Konvergenz gleichmäßig auf X .²

Mit Satz 6.3 folgt also, dass jede Folge $\psi_{T_n} : \Gamma \rightarrow \mathbb{R}$ mit $\Delta t = T_1 < T_2 < \dots$ gleichmäßig gegen $\lim_{T \rightarrow \infty} \psi_T(\mathbf{x}) = 0$ konvergiert. Die Definition der gleichmäßigen Konvergenz besagt somit, dass für jedes $\varepsilon \in (0, 1)$ ein $\hat{T} < \infty$ so existiert, dass $\psi_T(\mathbf{x}) < \varepsilon$ für alle $\mathbf{x} \in \Gamma_\alpha$ gilt. Aus (6.40) und für den Punkt $\mathbf{x} = \bar{\mathbf{x}}_T^*(\Delta t; \mathbf{x}_k) \in X_\alpha$ (für $\mathbf{x}_k \in \Gamma_\alpha$) folgt damit

$$J_\infty^*(\bar{\mathbf{x}}_T^*(\Delta t; \mathbf{x}_k)) - J_{T-\Delta t}^*(\bar{\mathbf{x}}_T^*(\Delta t; \mathbf{x}_k)) \leq \varepsilon J_{\Delta t}^*(\bar{\mathbf{x}}_T^*(\Delta t; \mathbf{x}_k)). \quad (6.42)$$

Für den weiteren Weg werden einige Abschätzung benötigt. Mit Hilfe des sogenannten *Gronwall-Lemmas* und einer inversen Formulierung davon [10] gelten die Abschätzungen

$$\|\mathbf{x}_k\| e^{-\hat{L}\tau} \leq \|\bar{\mathbf{x}}_T^*(\tau; \mathbf{x}_k)\| \leq \|\mathbf{x}_k\| e^{\hat{L}\tau}, \quad \tau \in [0, T], \quad \hat{L} = L_f(1 + L_\kappa) \quad (6.43)$$

² Die Folge $f_n : X \rightarrow \mathbb{R}$ mit dem Limit $f : X \rightarrow \mathbb{R}$ heißt *gleichmäßig konvergent*, wenn für jedes $\varepsilon > 0$ eine natürliche Zahl N existiert, so dass für alle $n \geq N$ und für alle $\mathbf{x} \in X$ gilt: $|f_n(\mathbf{x}) - f(\mathbf{x})| < \varepsilon$.

wobei $L_f, L_\kappa > 0$ die Lipschitz-Konstanten der Systemfunktion $\mathbf{f}$ und des optimalen Regelgesetzes κ_T sind (L_κ gelte für alle Zeiten $T \in [\Delta t, \infty)$). Mit Hilfe der linksseitigen Abschätzung in (6.43) und einer ähnlichen Argumentation wie in [4] kann gezeigt werden, dass für alle $T \in [\Delta t, \infty)$ Konstanten $m_J, M_J > 0$ existieren, so dass die folgenden quadratischen Abschätzungen für $J_T^*(\mathbf{x}_k)$ gelten:

$$m_J \|\mathbf{x}_k\|^2 \leq J_T^*(\mathbf{x}_k) \leq M_J \|\mathbf{x}_k\|^2, \quad \mathbf{x}_k \in \Gamma_\alpha, \quad T \in [\Delta t, \infty). \quad (6.44)$$

Mit den Ausdrücken (6.43) und (6.44) lässt sich die rechte Seite in (6.42) nun wie folgt abschätzen:

$$\begin{aligned} \varepsilon J_{\Delta t}^*(\bar{\mathbf{x}}_T^*(\Delta t; \mathbf{x}_k)) &\stackrel{(6.44)}{\leq} \varepsilon M_J \|\bar{\mathbf{x}}_T^*(\Delta t; \mathbf{x}_k)\|^2 \\ &\stackrel{(6.43)}{\leq} \varepsilon M_J e^{2\hat{L}\Delta t} \|\mathbf{x}_k\|^2 \\ &\stackrel{(6.44)}{\leq} \varepsilon \frac{M_J}{m_J} e^{2\hat{L}\Delta t} J_{\Delta t}^*(\mathbf{x}_k) \\ &\leq \varepsilon \frac{M_J}{m_J} e^{2\hat{L}\Delta t} \int_0^{\Delta t} l(\bar{\mathbf{x}}_T^*(\tau; \mathbf{x}_k), \bar{\mathbf{u}}_T^*(\tau; \mathbf{x}_k)) d\tau. \end{aligned} \quad (6.45)$$

Somit erkennt man, dass sich (6.39) in der Form (6.37) schreiben lässt, wobei die Konstante δ durch

$$\delta = 1 - \varepsilon \frac{M_J}{m_J} e^{2\hat{L}\Delta t} \quad (6.46)$$

gegeben ist. Da $\varepsilon \in (0, 1)$ frei vorgebar ist, existiert für jedes $\delta \in (0, 1)$ eine Horizontlänge T_δ so, dass (6.37) für $T \geq T_\delta$ gilt.³

Um die asymptotische Stabilität im geschlossenen Kreis zu zeigen, wird das Integral in (6.37) ähnlich wie bisher abgeschätzt:

$$\int_0^{\Delta t} l(\bar{\mathbf{x}}_T^*(\tau; \mathbf{x}_k), \bar{\mathbf{u}}_T^*(\tau; \mathbf{x}_k)) d\tau \geq J_{\Delta t}^*(\mathbf{x}_k) \stackrel{(6.44)}{\geq} m_J \|\mathbf{x}_k\|^2 \stackrel{(6.44)}{\geq} \sigma J_T^*(\mathbf{x}_k) \quad (6.47)$$

mit $\sigma = m_J/M_J \in (0, 1)$. Somit ergibt sich aus (6.37) $J_T^*(\bar{\mathbf{x}}_T^*(\Delta t; \mathbf{x}_k)) \leq (1 - \delta\sigma)J_T^*(\mathbf{x}_k)$ mit $1 - \delta\sigma \in (0, 1)$ bzw. mit Hilfe der Anfangsbedingung $J_T^*(\mathbf{x}_0) \leq \alpha$

$$J_T^*(\mathbf{x}_k) \leq \alpha(1 - \delta\sigma)^k \quad \Rightarrow \quad \|\mathbf{x}_k\| \stackrel{(6.44)}{\leq} \sqrt{\frac{J_T^*(\mathbf{x}_k)}{m_J}} \leq \sqrt{\frac{\alpha}{m_J}} (1 - \delta\sigma)^{k/2}. \quad (6.48)$$

Dies zeigt, dass $\|\mathbf{x}_k\|$ für $k \in \mathbb{N}_0^+$ asymptotisch abnimmt. Um auch die Stabilität im zeitkontinuierlichen Sinne zu untersuchen, reicht es, die obere Abschätzung aus (6.43) zu betrachten:

$$\|\bar{\mathbf{x}}_T^*(\tau; \mathbf{x}_k)\| \stackrel{(6.43)}{\leq} \|\mathbf{x}_k\| e^{\hat{L}\tau} \stackrel{(6.48)}{\leq} \sqrt{\frac{\alpha}{m_J}} e^{\hat{L}\Delta t} (1 - \delta\sigma)^{k/2}, \quad \tau \in [0, \Delta t). \quad (6.49)$$

Damit lässt sich zeigen, dass Konstanten $q_1, q_2 > 0$ so existieren, dass die Trajektorien im geschlossenen Kreis (6.9) durch $\|\mathbf{x}(t)\| \leq q_1 e^{-q_2(t-t_0)}$ beschränkt sind, was exponentielle Stabilität des Ursprungs im geschlossenen Kreis impliziert [16]. ■

³ Lipschitz-Abschätzungen sind in der Regel sehr konservativ, wodurch die explizite Berechnung von δ in (6.46) weniger für den MPC-Entwurf zu gebrauchen ist, sondern eher als Lipschitz-basierte Herleitung einer Beispielfunktion zum Beweis der Existenz von δ zu verstehen ist.




Abbildung 6.5: Höhenlinien des Einzugsbereichs Γ_α (—) und des Reduktionsparameters δ (---) in der (x_1, x_2) -Ebene für den Prädiktionshorizont $T = 1.5$ und $T = 2.5$ (Beispiel 6.2).

Die exponentielle Stabilität, die das Resultat von Satz 6.5 ist, ist eine stärkere Aussage als die bisher betrachtete asymptotische Stabilität im Sinne von $\lim_{t \rightarrow \infty} \|\mathbf{x}(t)\| = 0$. Allerdings basiert der Nachweis der exponentiellen Stabilität auf der Annahme, dass das optimale Regelgesetz in (6.8) lokal Lipschitz-stetig ist. Auf diese Annahme konnte in den bisherigen Sätzen 6.1 bis 6.4 verzichtet werden.

Der Wert von T_δ ist problemspezifisch und in der Regel nur numerisch bzw. simulativ bestimmbar. Nichtsdestotrotz liefert Satz 6.5 das interessante Ergebnis, dass (unter den gegebenen Annahmen) stets eine minimale und endliche Horizontlänge T_δ existiert, so dass für $T \geq T_\delta$ exponentielle Stabilität gewährleistet ist.

Beispiel 6.2 Als Fortsetzung von Beispiel 6.1 wird nun die Endkostengewichtung (6.34) weggelassen, so dass das Kostenfunktional (6.35) lediglich aus dem Integralanteil (6.33) besteht. Somit ergibt sich die MPC-Formulierung

$$\min_{\bar{\mathbf{u}}(\cdot)} J_T(\mathbf{x}_k, \bar{\mathbf{u}}) = \int_0^T 0.5\bar{x}_1^2 + 0.5\bar{x}_2^2 + \bar{u}^2 d\tau \quad (6.50a)$$

$$\text{u.B.v. } \dot{\bar{x}}_1 = \bar{x}_2 + (\mu + (1 - \mu)\bar{x}_1)\bar{u}, \quad \bar{x}_1(0) = \bar{x}_{1,k} = x_1(t_k) \quad (6.50b)$$

$$\dot{\bar{x}}_2 = \bar{x}_1 + (\mu - 4(1 - \mu)\bar{x}_2)\bar{u}, \quad \bar{x}_2(0) = \bar{x}_{2,k} = x_2(t_k) \quad (6.50c)$$

$$\bar{u}(\tau) \in [-2, 2], \quad \tau \in [0, T]. \quad (6.50d)$$

Abbildung 6.5 verdeutlicht den Einfluss der Horizontlänge T auf die MPC-Formulierung (6.50) für die zwei Werte $T = 1.5$ und $T = 2.5$. Die Grenzen der kompakten Untermengen $\Gamma_\alpha = \{\mathbf{x} \in \mathbb{R}^2 : J_\infty^*(\mathbf{x}) \leq \alpha\}$ wurden numerisch approximativ berechnet. Zusätzlich sind in Abbildung 6.5 die Höhenlinien für verschiedene Werte des Faktors δ in (6.37) dargestellt.

Die Höhenlinie $\delta = 0$ stellt die Menge der Punkte $\mathbf{x}_k$ dar, für die im nächsten Schritt keine Abnahme von $J_T^*(\bar{\mathbf{x}}_T^*(\Delta t; \mathbf{x}_k))$ erreicht wird. Für $\delta = 0.25$ bzw. $\delta = -0.5$ ergibt sich jeweils eine Abnahme bzw. eine Zunahme des Kostenfunktionals gemäß (6.37). Die Menge, die durch die Höhenlinie $\delta = 0$ eingeschlossen wird, kann somit als Stabilitätsgrenze für die jeweilige Horizontlänge T betrachtet werden. Aus den δ -Höhenlinien in Abbildung 6.5 für $T = 1.5$ und

$T = 2.5$ ist ersichtlich, dass der Stabilitätsbereich durch einen längeren Prädiktionshorizont T vergrößert werden kann.

Im Sinne von Satz 6.5 lässt sich ebenfalls argumentieren, dass für einen gegebenen Einzugsbereich Γ_α der Horizont T entsprechend groß sein muss, um Stabilität zu erzielen. So ist in Abbildung 6.5 anhand der Höhenlinie $\delta = 0$ erkennbar, dass für den Einzugsbereich $\Gamma_{0.2}$ der Prädiktionshorizont $T = 1.5$ zu kurz ist, während $T = 2.5$ hinreichend ist.

6.3 Echtzeitfähige Implementierung

“All we have to decide is what to do
with the time that is given to us.”

Gandalf the Grey

Die letzten beiden betrachteten MPC-Formulierung mit Endkostengewichtung bzw. mit hinreichend langem Horizont eignen sich besonders gut für eine Implementierung am realen Prozess, da in diesen Formulierungen der numerische Aufwand aufgrund des freien Endzustands in der Regel am niedrigsten ist. Trotzdem ist gerade bei hochdynamischen Systemen mit Abtastzeiten im Millisekundenbereich bzw. bei komplexen hochdimensionalen Problemen eine echtzeitfähige Lösung des unterlagerten dynamischen Optimierungsproblems eine große Herausforderung.

Eine intuitive Möglichkeit zur Verringerung des Rechenaufwandes besteht in der näherungsweisen Lösung des Optimierungsproblems, z.B. durch Verwendung einer festen Anzahl an Iterationen pro Abtastschritt. Im nächsten Abtastschritt kann die Näherungslösung zur Reinitialisierung des Optimierungsverfahrens verwendet werden, um die Abweichung der suboptimalen Trajektorien von der optimalen Lösung sukzessive zu verbessern. Dieses inkrementelle Vorgehen unterscheidet sich somit vom optimalen MPC-Fall, bei dem die (numerisch) optimale Lösung in jedem Abtastschritt berechnet wird.

In der Literatur existieren verschiedene effiziente bzw. suboptimale MPC-Verfahren mit unterschiedlichen Arten von Endbeschränkungen und Anforderungen an das verwendete Optimierungsverfahren, auf die an dieser Stelle aber nicht detailliert eingegangen werden soll. Statt dessen wird im Folgenden eine allgemeine suboptimale Lösungsstrategie untersucht.

6.3.1 Suboptimale Lösungsstrategie

Da es bei einer echtzeitfähigen Implementierung vor allem auf einen niedrigen Rechenaufwand ankommt, wird in weiterer Folge eine MPC-Formulierung mit freiem Endzustand und ohne Zustandsbeschränkungen betrachtet:

$$\min_{\bar{\mathbf{u}}(\cdot)} \quad J_T(\mathbf{x}_k, \bar{\mathbf{u}}) = V(\bar{\mathbf{x}}(T)) + \int_0^T l(\bar{\mathbf{x}}(\tau), \bar{\mathbf{u}}(\tau)) d\tau \quad (6.51a)$$

$$\text{u.B.v.} \quad \dot{\bar{\mathbf{x}}}(\tau) = \mathbf{f}(\bar{\mathbf{x}}(\tau), \bar{\mathbf{u}}(\tau)), \quad \bar{\mathbf{x}}(0) = \mathbf{x}_k = \mathbf{x}(t_k) \quad (6.51b)$$

$$\bar{\mathbf{u}}(\tau) \in U, \quad \tau \in [0, T] \quad (6.51c)$$

Falls keine Endkostengewichtung im Kostenfunktional (6.51a) existiert, gilt $V(\mathbf{x}) = 0$ bzw. $m_V = M_V = 0$ in der quadratischen Abschätzung (6.5).

Im Folgenden wird allgemein von der Existenz eines geeigneten (iterativen) Optimierungsverfahrens ausgegangen, das in jeder Iteration j eine Steuer- und zugehörige Zustandstrajektorie

$$\bar{\mathbf{u}}_T^{(j)}(\tau; \mathbf{x}_k), \quad \bar{\mathbf{x}}_T^{(j)}(\tau; \mathbf{x}_k), \quad \tau \in [0, T] \quad (6.52)$$

berechnet. Für den zugehörigen suboptimalen Wert des Kostenfunktionalen gilt somit

$$J_T^{(j)}(\mathbf{x}_k) := J_T(\mathbf{x}_k, \bar{\mathbf{u}}_T^{(j)}) \geq J_T^*(\mathbf{x}_k).$$

Des Weiteren wird davon ausgegangen, dass das Optimierungsverfahren eine Konvergenzbedingung der Form

$$J_T^{(j+1)}(\mathbf{x}_k) - J_T^*(\mathbf{x}_k) \leq p \left(J_T^{(j)}(\mathbf{x}_k) - J_T^*(\mathbf{x}_k) \right) \quad (6.53)$$

mit $\lim_{j \rightarrow \infty} J_T^{(j)}(\mathbf{x}_k) = J_T^*(\mathbf{x}_k)$ erfüllt. Der Faktor $p \in (0, 1)$ stellt die lineare Konvergenzrate des Optimierungsverfahrens dar.

Im Sinne eines suboptimalen echtzeitfähigen Lösungsansatzes ist es naheliegend, das Optimierungsverfahren nach einer festen Iterationsanzahl

$$j = N$$

abzubrechen und das Anfangsstück der resultierenden suboptimalen Steuertrajektorie $\bar{\mathbf{u}}_T^{(N)}(\tau; \mathbf{x}_k)$ als Stellgröße

$$\mathbf{u}(t_k + \tau) = \bar{\mathbf{u}}_T^{(N)}(\tau; \mathbf{x}_k), \quad \tau \in [0, \Delta t] \quad (6.54)$$

für das System (6.1) zu verwenden. Falls keine Modellungenauigkeiten oder Störungen auftreten, ergibt sich der Anfangszustand für das MPC-Verfahren im nächsten Zeitpunkt t_{k+1} somit zu $\mathbf{x}_{k+1} = \bar{\mathbf{x}}_T^{(N)}(\Delta t; \mathbf{x}_k)$ bzw. insgesamt die Trajektorien im geschlossenen Kreis

$$\begin{aligned} \mathbf{x}(t) &= \mathbf{x}(t_k + \tau) = \bar{\mathbf{x}}_T^{(N)}(\tau; \mathbf{x}_k), \\ \mathbf{u}(t) &= \mathbf{u}(t_k + \tau) = \bar{\mathbf{u}}_T^{(N)}(\tau; \mathbf{x}_k), \quad \tau \in [0, \Delta t], \quad k \in \mathbb{N}_0^+. \end{aligned} \quad (6.55)$$

Im Vergleich zu dem bisher betrachteten optimalen MPC-Fall sind die Trajektorien (6.52) lediglich suboptimal, was sich anhand des *Optimierungsfehlers*

$$\Delta J_T^{(N)}(\mathbf{x}_k) := J_T^{(N)}(\mathbf{x}_k) - J_T^*(\mathbf{x}_k) \geq 0 \quad (6.56)$$

charakterisieren lässt. Das Ziel des suboptimalen MPC-Verfahrens ist es, den Optimierungsfehler $\Delta J_T^{(N)}(\mathbf{x}_k)$ sukzessive zu reduzieren, indem die suboptimale Steuertrajektorie $\bar{\mathbf{u}}_T^{(N)}(\tau; \mathbf{x}_k)$ zur Reinitialisierung des Optimierungsverfahrens im nächsten Schritt verwendet wird:

$$\bar{\mathbf{u}}_T^{(0)}(\tau; \mathbf{x}_{k+1}) := \bar{\mathbf{u}}_T^{(N)}(\tau; \mathbf{x}_k), \quad \tau \in [0, T]. \quad (6.57)$$

Abbildung 6.6 veranschaulicht diesen Zusammenhang.

6.3.2 Stabilität und inkrementelle Verbesserung

Im Folgenden wird zur kompakteren Bezeichnung die Menge

$$\mathcal{U}_{[0, T]} = \{\mathbf{u}(\cdot) \in L_m^\infty[0, T] : \mathbf{u}(t) \in U, t \in [0, T]\} \quad (6.58)$$




Abbildung 6.6: Prinzip der suboptimalen MPC-Implementierung.

aller zulässigen Steuertrajektorien eingeführt.⁴ Dies ist notwendig, da es bei einer suboptimalen MPC-Implementierung nicht mehr ausreichend ist, nur die optimale Steuertrajektorie $\bar{\mathbf{u}}_T^*(\tau; \mathbf{x}_k)$, $\tau \in [0, T]$ von (6.51) zu betrachten, sondern für die einzelnen Iterationen eines Optimierungsalgorithmus allgemein $\bar{\mathbf{u}}_T^{(j)}(\cdot) \in \mathcal{U}_{[0, T]}$ gilt. Aus diesem Grund müssen restriktivere Annahmen getroffen werden als in den bisherigen Untersuchungen. Dies betrifft vor allem die strikte Konvexitätsbedingung

$$\|\mathbf{u} - \mathbf{u}_T^*(\cdot; \mathbf{x}_k)\|_{L_m^2[0, T]}^2 \leq C |J_T(\mathbf{x}_k, \mathbf{u}) - J_T^*(\mathbf{x}_k)| \quad (6.59)$$

für eine Konstante $C > 0$. Für lineare Systeme mit diagonal-quadratischem Kostenfunktional kann gezeigt werden, dass diese Annahme stets erfüllt ist.

Satz 6.6 (Suboptimales MPC) Das Problem (6.51) sei lösbar für alle $\mathbf{x}_k \in \mathbb{R}^n$. Außerdem gelte auf einer kompakten Menge $\Gamma_\alpha = \{\mathbf{x} \in \mathbb{R}^n : J_T^*(\mathbf{x}) \leq \alpha\}$ mit $\alpha < \infty$:

1. Das optimale Regelgesetz in (6.8) ist lokal Lipschitz-stetig.
2. Für jedes $\mathbf{u} \in \mathcal{U}_{[0, T]}$ ist $J_T(\mathbf{x}_k, \mathbf{u})$ zweimal stetig differenzierbar in $\mathbf{x}_k$.
3. Für alle $\mathbf{u} \in \mathcal{U}_{[0, T]}$ und $\mathbf{x}_k \in \Gamma_\alpha$ ist die Konvexitätsbedingung (6.59) erfüllt.
4. Es existiert ein Optimierungsverfahren mit linearer Konvergenzrate $p \in (0, 1)$, so dass (6.53) für alle $\mathbf{x}_k \in \Gamma_\alpha$ erfüllt ist.
5. Es existiert eine Konstante $\delta \in (0, 1]$ so, dass gilt

$$J_T^*(\bar{\mathbf{x}}_T^*(\Delta t; \mathbf{x}_k)) \leq J_T^*(\mathbf{x}_k) - \delta \int_0^{\Delta t} l(\bar{\mathbf{x}}_T^*(\tau; \mathbf{x}_k), \bar{\mathbf{u}}_T^*(\tau; \mathbf{x}_k)) d\tau \quad \forall \mathbf{x}_k \in \Gamma_\alpha. \quad (6.60)$$

Dann existiert eine Mindestiterationsanzahl $\hat{N}$ sowie eine Konstante $\Delta \hat{J} > 0$ so, dass für $N \geq \hat{N}$ und alle Punkte $\mathbf{x}_0 \in \Gamma_\alpha$ mit initialem Optimierungsfehler $\Delta J_T^{(0)}(\mathbf{x}_0) \leq \Delta \hat{J} p^{-N}$ der Ursprung des MPC-geregelten Systems (6.1) exponentiell stabil ist. Des Weiteren nimmt der Optimierungsfehler (6.56) exponentiell ab.

⁴ Unter dem unendlich dimensionalen Vektorraum $L_m^p[0, T]$, $1 \leq p < \infty$ versteht man alle reellwertigen Funktionen $u : [0, T] \rightarrow \mathbb{R}$ im Intervall $[0, T]$ mit der Norm

$$\|u\|_{L^p[0, T]} = \left(\int_0^T |u(t)|^p dt \right)^{1/p} < \infty \quad \text{bzw.} \quad \|\mathbf{u}\|_{L_m^p[0, T]} = \left(\int_0^T \|\mathbf{u}(t)\|_2^p dt \right)^{1/p} < \infty$$

für vektorwertige Funktionen $\mathbf{u} : [0, T] \rightarrow \mathbb{R}^m$. Insbesondere gilt für die Supremumsnorm $\|\mathbf{u}\|_{L_m^p[0, T]} = \sup(\|\mathbf{u}(t)\|_2, t \in [0, T])$. Man beachte, dass im Vektorraum $L_m^p[0, T]$ Funktionen, die fast überall gleich sind (sich also nur auf einer Menge von abzählbaren Punkten unterscheiden), als identisch angesehen werden.

Beweis: Ähnlich dem Vorgehen in [13, 11] kann unter den gegebenen Annahmen gezeigt werden, dass Konstanten $a \in (0, 1]$ und $b, c, d, e > 0$ so existieren, dass $J_T^*(\mathbf{x}_k)$ und $\Delta J_T^{(N)}(\mathbf{x}_k)$ die Abschätzungen

$$\begin{aligned} J_T^*(\mathbf{x}_{k+1}) &\leq (1-a)J_T^*(\mathbf{x}_k) + b\sqrt{J_T^*(\mathbf{x}_k)}\sqrt{\Delta J_T^{(N)}(\mathbf{x}_k)} + c\Delta J_T^{(N)}(\mathbf{x}_k) \\ \Delta J_T^{(N)}(\mathbf{x}_{k+1}) &\leq p^N(1+d)\Delta J_T^{(N)}(\mathbf{x}_k) + p^N e J_T^*(\mathbf{x}_k) \end{aligned} \quad (6.61)$$

erfüllen, wobei $\mathbf{x}_{k+1} = \bar{\mathbf{x}}_T^{(N)}(\Delta t; \mathbf{x}_k)$ den Zustand im nächsten MPC-Schritt darstellt. Durch Induktion lässt sich beweisen, dass für die Anfangsbedingungen

$$J_T^*(\mathbf{x}_0) \leq \alpha, \quad \Delta J_T^{(N)}(\mathbf{x}_0) \leq \Delta \hat{J} = \gamma^2 \alpha \quad \text{mit} \quad \gamma = \frac{-b + \sqrt{b^2 + 2ac}}{2c} \quad (6.62)$$

und eine "hinreichend große" Konvergenzrate

$$p^N \leq \frac{(1 - \frac{a}{2})\gamma^2}{(1+d)\gamma^2 + e} \quad (6.63)$$

die Abschätzungen

$$J_T^*(\mathbf{x}_k) \leq \left(1 - \frac{a}{2}\right)^k \alpha, \quad \Delta J_T^{(N)}(\mathbf{x}_k) \leq \gamma^2 \left(1 - \frac{a}{2}\right)^k \alpha \quad (6.64)$$

gelten. Die obere Schranke für p^N entspricht einer Mindestanzahl $\hat{N}$ an MPC-Iterationen pro Abtastschritt. Ist dies erfüllt, so nehmen sowohl $J_T^*(\mathbf{x}_k)$ als auch $\Delta J_T^{(N)}(\mathbf{x}_k)$ im zeitdiskreten Sinne exponentiell ab. Der Nachweis der exponentiellen Stabilität im geschlossenen Kreis kann nun in einer ähnlichen Weise wie im Beweis von Satz 6.5 bzw. wie in [13] erfolgen. ■

Zur numerischen Lösung von (6.51) können prinzipiell alle in Kapitel 5 (Abschnitte 5.6 und 5.7) behandelten numerischen Verfahren verwendet werden. Allerdings bietet sich aufgrund der endbeschränkungsfreien Formulierung von (6.51) das *Gradientenverfahren* an, dessen Algorithmus bereits in Abschnitt 5.6.4 (Tabelle 5.1) dargestellt wurde. In dem Aufsatz [6] wurde zudem gezeigt, dass das Gradientenverfahren (unter gewissen Konvexitäts- und Regularitätsannahmen) die lineare Konvergenzbedingung (6.53) erfüllt.

Die Stellgrößenbeschränkungen (6.51c) lassen sich beim Gradientenverfahren durch eine einfache Projektion berücksichtigen und die Liniensuche in Tabelle 5.1 kann durch eine adaptive Dreipunktsuche approximiert werden, um eine feste Anzahl an Rechenzeit pro MPC-Schritt einzuhalten [12].

Eine weitere Möglichkeit basierend auf Pontryagin's Maximumprinzip (Abschnitt 5.5.1) besteht darin, die Optimalitätsbedingungen für das Problem (6.51) auf ein *Fixpunktiterationsschema* zu reduzieren, welches schnell und speichereffizient gelöst werden kann. Für weitere Informationen sei auf [11] verwiesen.

6.3.3 Anwendungsbeispiel

Als Beispiel wird ein Verladekran im Labormaßstab [12] verwendet, der in Abbildung 6.7 dargestellt ist. An einem Turm der Höhe h ist ein drehbar gelagerter Ausleger (Winkel ϕ_1) mit einer translatorisch bewegbaren Laufkatze (Position s_1) befestigt. An der Laufkatze ist ein räumlich




Abbildung 6.7: Schematischer Aufbau des Verladekrans mit 5 Freiheitsgraden [12].

drehbar gelagertes Seil (Winkel ϕ_2 und ϕ_3) montiert, dessen Länge mittels einer Winde verändert werden kann. Am Ende des Seils (Position s_2) ist eine Last der Masse m befestigt. Die Erdbeschleunigung mit der Gravitationskonstanten g wirkt in negative z -Richtung.

Die Bewegungsgleichungen des Verladekrans können über den Lagrange-Formalismus hergeleitet werden. Unter der Annahme, dass für die aktuierten Freiheitsgrade ϕ_1 , s_1 und s_2 hinreichend schnelle unterlagerte Regelkreise existieren, lässt sich die Dynamik des Systems durch das Differenzialgleichungssystem

$$\ddot{s}_1 = u_1 \quad (6.65a)$$

$$\ddot{s}_2 = u_2 \quad (6.65b)$$

$$\ddot{\phi}_1 = u_3 \quad (6.65c)$$

$$\begin{aligned} \ddot{\phi}_2 = \frac{1}{s_2 \cos \phi_3} \big(& -2\dot{s}_2\dot{\phi}_1 \cos \phi_2 \sin \phi_3 - 2\dot{s}_2\dot{\phi}_2 \cos \phi_3 - 2\dot{\phi}_1\dot{\phi}_3 s_2 \cos \phi_2 \cos \phi_3 \\ & + 2s_2\dot{\phi}_2\dot{\phi}_3 \sin \phi_3 - s_1\dot{\phi}_1^2 \cos \phi_2 + s_2\dot{\phi}_1^2 \sin \phi_2 \cos \phi_2 \cos \phi_3 \\ & - g \sin \phi_2 + \cos \phi_2 u_1 - s_2 \cos \phi_2 \sin \phi_3 u_3 \big) \end{aligned} \quad (6.65d)$$

$$\begin{aligned} \ddot{\phi}_3 = \frac{1}{s_2} \big(& -2\dot{s}_1\dot{\phi}_1 \cos \phi_3 - 2\dot{s}_2\dot{\phi}_3 + 2\dot{s}_2\dot{\phi}_1 \sin \phi_2 + 2s_2\dot{\phi}_1\dot{\phi}_2 \cos \phi_2 \cos^2 \phi_3 \\ & + s_1\dot{\phi}_1^2 \sin \phi_2 \sin \phi_3 - s_2\dot{\phi}_2^2 \sin \phi_3 \cos \phi_3 + s_2\dot{\phi}_1^2 \cos^2 \phi_2 \sin \phi_3 \cos \phi_3 \\ & - g \cos \phi_2 \sin \phi_3 - \sin \phi_2 \sin \phi_3 u_1 + (s_2 \sin \phi_2 - s_1 \cos \phi_3) u_3 \big) \end{aligned} \quad (6.65e)$$

unabhängig von der Lastmasse m beschreiben. Die Beschleunigungen $\ddot{s}_1$, $\ddot{s}_2$ und $\ddot{\phi}_1$ der aktuierten Achsen stellen dabei die Eingänge u_1 , u_2 und u_3 des Systems dar, die durch die Maximalwerte

$$\begin{aligned} u_1 &\in [u_1^-, u_1^+] = [-2, +2] \text{ m/s}^2 \\ u_2 &\in [u_2^-, u_2^+] = [-2, +2] \text{ m/s}^2 \\ u_3 &\in [u_3^-, u_3^+] = [-2, +2] \text{ rad/s}^2 \end{aligned} \quad (6.66)$$

beschränkt sind. Diese Werte ergeben sich aufgrund der maximalen Motorströme und zusätzlicher Sicherheitsschranken. Mit dem Zustands- und Eingangsvektor

$$\begin{aligned} \mathbf{x} &= [s_1, s_2, \phi_1, \phi_2, \phi_3, \dot{s}_1, \dot{s}_2, \dot{\phi}_1, \dot{\phi}_2, \dot{\phi}_3]^T \\ \mathbf{u} &= [u_1, u_2, u_3]^T \end{aligned}$$

lassen sich die Differenzialgleichungen zweiter Ordnung (6.65) in der allgemeinen nichtlinearen Zustandsdarstellung

$$\dot{\mathbf{x}} = \mathbf{f}(\mathbf{x}, \mathbf{u}), \quad \mathbf{x}(0) = \mathbf{x}_0$$

schreiben. Das nichtlineare Kranmodell umfasst somit $n = 10$ Zustände und $m = 3$ beschränkte Stellgrößen.

Als Testszenario wird ein Arbeitspunktwechsel $\mathbf{x}_0 \rightarrow \mathbf{x}_d$ mit den Werten

$$\mathbf{x}_0 = [0.7 \text{ m}, 0.7 \text{ M}, -60^\circ, 0, 0, 0, 0, 0, 0, 0]^T \quad (6.67a)$$

$$\mathbf{x}_d = [0.2 \text{ m}, 0.25 \text{ m}, 60^\circ, 0, 0, 0, 0, 0, 0, 0]^T \quad (6.67b)$$

betrachtet. Der Übergang beschreibt einen Schwenk des Auslegers um den Winkel ϕ_1 mit gleichzeitiger Änderung der Laufkatzenposition s_1 und der Seillänge s_2 .

Das Kostenfunktional (6.51a) wird in quadratischer Form

$$J_T(\mathbf{x}_k, \bar{\mathbf{u}}) = \Delta \bar{\mathbf{x}}^T(T) \mathbf{P} \Delta \bar{\mathbf{x}}(T) + \int_0^T \Delta \bar{\mathbf{x}}^T(\tau) \mathbf{Q} \Delta \bar{\mathbf{x}}(\tau) + \bar{\mathbf{u}}^T(\tau) \mathbf{R} \bar{\mathbf{u}}(\tau) d\tau \quad (6.68)$$

mit $\Delta \bar{\mathbf{x}} = \bar{\mathbf{x}} - \mathbf{x}_d$ und den Diagonalmatrizen (Vernachlässigung der Einheiten)

$$\mathbf{P} = \text{diag}(10, 10, 10, 10, 10, 1, 1, 1, 1, 1)$$

$$\mathbf{Q} = \text{diag}(1, 1, 1, 1, 1, 0.1, 0.1, 0.1, 1, 1)$$

$$\mathbf{R} = \text{diag}(0.01, 0.01, 0.01)$$

angesetzt. Für den Prädiktionshorizont und die Abtastzeit gilt $T = 1.5 \text{ s}$ und $\Delta t = 2 \text{ ms}$.

Das suboptimale MPC-Verfahren wurde zusammen mit dem projizierten Gradientenverfahren als Cmx-Funktionen in MATLAB implementiert. Die Integrationen der kanonischen Gleichungen (siehe Tabelle 5.1) erfolgen mit Hilfe eines Runge-Kutta-Verfahrens zweiter Ordnung basierend auf einer gleichmäßigen Diskretisierung des Zeitintervalls $[0, T]$ mit 30 Stützstellen.

Abbildung 6.8 zeigt die Simulationsergebnisse für den Positionswechsel (6.67) für verschiedene Werte von N . Als Referenz sind die Simulationsergebnisse des optimalen MPC-Falls dargestellt, d.h. wenn das Problem (6.51) in jedem Abtastschritt (numerisch) exakt gelöst wird. In Abbildung 6.8 ist gut erkennbar, dass bereits eine MPC-Iteration pro Abtastschritt ($N = 1$) zu einem sehr guten Regelverhalten führt. Bei einer Erhöhung der Iterationsanzahl des MPC-Verfahrens ist vor allem bei den Stellgrößenverläufen ein dynamischeres Verhalten und ein gutes Ausnützen der Beschränkungen (6.66) erkennbar. Es ist ebenfalls ersichtlich, dass das suboptimale MPC-Verfahren für größere Werte von N gegen die Referenztrajektorien der optimalen MPC-Implementierung konvergiert.

Abbildung 6.9 stellt die zeitlichen Verläufe des Kostenfunktionals $J_T^{(N)}(\mathbf{x}_k)$ und des Optimierungsfehlers $\Delta J_T^{(N)}(\mathbf{x}_k)$ dar, der in (6.56) eingeführt wurde. Sowohl $J_T^{(N)}(\mathbf{x}_k)$ als auch $\Delta J_T^{(N)}(\mathbf{x}_k)$ klingen exponentiell ab, was die exponentielle Stabilität im geschlossenen Regelkreises und die inkrementelle Verbesserung des suboptimalen MPC-Verfahrens verdeutlicht [13, 12]. Für eine Untersuchung der Rechenzeit (Größenordnung $< 1 \text{ ms}$) und experimentelle Ergebnisse sei auf [12] verwiesen.

Zusätzlich stellt Tabelle 6.1 die Rechenzeiten von GRAMPC sowie die Standardabweichung in Abhängigkeit von N als ein Maß für die Echtzeitfähigkeit dar. Die Ergebnisse wurden auf einem MacBook Pro mit Apple M3 Max CPU erzeugt.




Abbildung 6.8: MPC-Ergebnisse für den Arbeitspunktwechsel (6.67) des Laborkrans [12].




Abbildung 6.9: Zeitlicher Verlauf des Kostenfunktionalen $J_T^{(N)}(\mathbf{x}_k)$ und des Optimierungsfehlers $\Delta J_T^{(N)}(\mathbf{x}_k)$ für das Szenario in Abbildung 6.8 [12].

Gradient steps N	CPU time [ms]	
	avg.	std. dev.
1	0.005	0.0004
2	0.009	0.0006
3	0.012	0.0006
5	0.020	0.0019
10	0.036	0.0018

Tabelle 6.1: Computation times of GRAMPC for the overhead crane.

6.4 Software-Übersicht

Im Laufe der letzten Jahre sind eine Reihe von MPC-Toolboxen veröffentlicht worden, die teils kommerziell, Open Source-lizenziert oder frei zugänglich sind. Die folgende Liste zeigt eine Auswahl an MPC-Toolboxen für lineare und nichtlineare Systeme. Für weitergehende Informationen sei auf den Übersichtsartikel [9] sowie auf die Homepages der entsprechenden Toolboxen verwiesen.

MPC-Toolboxen für lineare Systeme

- CVXGEN (kostenpflichtig, frei für akademische Nutzung)
<https://cvxgen.com/>
- FiOrdOs (Open Source-Lizenz)
<http://fiordos.ethz.ch/>
- Matlab MPC Toolbox (kostenpflichtig)
<https://de.mathworks.com/products/mpc.html>
- μ AO-MPC (frei zugänglich)
<https://github.com/muaompc/muaompc>

MPC-Toolboxen für nichtlineare Systeme

- acados (Open Source-Lizenz)
<https://docs.acados.org>
- C/GMRES (frei zugänglich)
<http://www.ids.sys.i.kyoto-u.ac.jp/~ohtsuka/code/>
- GRAMPC (Open Source-Lizenz)
<https://github.com/grampc/grampc>
- HQP (Open Source-Lizenz)
<http://hqp.sourceforge.net>
- VIATOC (Open Source-Lizenz)
<https://sourceforge.net/projects/viatoc/>

6.5 Literatur

- [1] L.D. Berkovitz. *Optimal Control Theory*. New York: Springer, 1974.
- [2] E. Camacho und C. Alba. *Model Predictive Control*. 2nd. London: Springer, 2004.
- [3] H. Chen. *Stability and Robstness Considerations in Nonlinear Model Predictive Control*. Bd. 674. Düsseldorf: Fortschritt-Berichte VDI Reihe 8, 1997.
- [4] H. Chen und F. Allgöwer. "A quasi-infinite horizon nonlinear model predictive control scheme with guaranteed stability". In: *Automatica* 34.10 (1998), S. 1205–1217.

- [5] M. Diehl, H.J. Ferreau und N. Haverbeke. "Efficient numerical methods for nonlinear MPC and moving horizon estimation". In: *Nonlinear Model Predictive Control - Towards New Challenging Applications*. Hrsg. von L. Magni, D.M. Raimondo und F. Allgöwer. 2009, S. 391–417.
- [6] J.C. Dunn. "On L^2 conditions and the gradient projection method for optimal control problems". In: *SIAM Journal on Control and Optimization* 34.4 (1996), S. 1270–1290.
- [7] T. Englert, A. Völz, F. Mesmer, S. Rhein und K. Graichen. "A software framework for embedded nonlinear model predictive control using a gradient-based augmented Lagrangian approach (GRAMPC)". In: *Optimization and Engineering* 20.3 (2019), S. 769–809. DOI: 10.1007/s11081-018-9417-2.
- [8] R. Findeisen. *Nonlinear Model Predictive Control: A Sampled-Data Feedback Perspective*. Bd. 1087. <http://dx.doi.org/10.18419/opus-4059>. Fortschritt-Berichte VDI Reihe 8, 2006.
- [9] R. Findeisen, K. Graichen und M. Mönnigmann. "Eingebettete Optimierung in der Regelungstechnik – Grundlagen und Herausforderungen". In: *at – Automatisierungstechnik* 66.11 (2018), S. 877–902.
- [10] H.E. Gollwitzer. "A note on a functional inequality". In: *Proc. American Mathematical Society* 23.3 (1969), S. 642–647.
- [11] K. Graichen. "A fixed-point iteration scheme for real-time model predictive control". In: *Automatica* 48.7 (2012), S. 1300–1305.
- [12] K. Graichen, M. Egretzberger und A. Kugi. "Ein suboptimaler Ansatz zur schnellen modellprädiktiven Regelung nichtlinearer Systeme". In: *Automatisierungstechnik* 58 (2010), S. 447–456.
- [13] K. Graichen und A. Kugi. "Stability and incremental improvement of suboptimal MPC without terminal constraints". In: *IEEE Transactions on Automatic Control* 55.11 (2010), S. 2576–2580.
- [14] L. Grüne und J. Pannek. *Nonlinear Model Predictive Control: Theory and Algorithms*. London: Springer, 2011.
- [15] A. Jadbabaie, J. Primbs und J. Hauser. "Unconstrained receding horizon control with no terminal cost". In: *Proc. American Control Conference (ACC)*. Arlington, VA, Juni 2001, S. 3055–3060.
- [16] H.K. Khalil. *Nonlinear Systems*. 2nd. Prentice Hall, 1996.
- [17] E.B. Lee und L. Markus. *Foundations of Optimal Control*. New York: Wiley, 1967.
- [18] D. Limon, T. Alamo, F. Salas und E.F. Camacho. "On the stability of constrained MPC without terminal constraint". In: *IEEE Transaction on Automatic Control* 51.5 (2006), S. 832–836.
- [19] D.Q. Mayne, J.B. Rawlings, C.V. Rao und P.O.M. Scokaert. "Constrained model predictive control: stability and optimality". In: *Automatica* 36.6 (2000), S. 789–814.